



1~100

▼ 1

▼ 中文

案例研究 -

一家公司正在使用 Amazon SageMaker 构建一个基于 Web 的 AI 应用程序。该应用程序将提供以下功能和特性：机器学习实验、训练、中央模型注册表、模型部署以及模型监控。

该应用程序必须确保在机器学习生命周期中安全且隔离地使用训练数据。训练数据存储在 Amazon S3 中。

公司需要使用中央模型注册表来管理应用程序中模型的不同版本。

哪种操作可以以最少的运营开销满足此需求？

A. 为每个模型创建一个单独的 Amazon Elastic Container Registry (Amazon ECR) 存储库。

B. 使用 Amazon Elastic Container Registry (Amazon ECR) 和每个模型版本的唯一标签。

C. 使用 SageMaker Model Registry 和模型组来编目模型。

D. 使用 SageMaker Model Registry 和每个模型版本的唯一标签。

▼ 解答

C

1. 考察的知识点

Amazon SageMaker Model Registry 的功能与使用场景。

如何管理模型版本和模型生命周期。

如何实现安全、隔离的训练数据管理。

如何降低操作复杂性（最小化操作开销）。

2. 选项分析

A.

错误原因：Amazon ECR 主要用于存储容器镜像，而不是专门设计用于管理

机器学习模型的版本和生命周期。为每个模型创建单独的ECR存储库会增加操作复杂性，不符合“最小化操作开销”的要求。

B.

错误原因：虽然可以使用ECR和标签来管理模型版本，但ECR并不是专门为机器学习模型设计的工具。使用ECR管理模型版本需要额外的操作步骤，无法满足“最小化操作开销”的要求。

C.

正确原因：SageMaker Model Registry是专门设计用于管理机器学习模型的工具，支持模型版本控制、模型分组以及生命周期管理。使用Model Registry和模型组可以轻松实现模型的分类和版本管理，同时降低操作复杂性。

D.

错误原因：虽然SageMaker Model Registry支持标签功能，但使用标签管理模型版本可能会增加操作复杂性。相比模型组，标签的管理和查询效率较低，不是最佳实践。

▼ 2

▼ 中文

案例研究 -

一家公司正在使用 Amazon SageMaker 构建一个基于网络的 AI 应用程序。该应用程序将提供以下能力和功能：机器学习实验、训练、中央模型注册表、模型部署和模型监控。

该应用程序必须确保在机器学习生命周期中安全且隔离地使用训练数据。训练数据存储在 Amazon S3 中。

该公司正在尝试连续的训练任务。

公司如何最大限度地减少这些任务的基础设施启动时间？

A.使用 Managed Spot Training。

B.使用 SageMaker managed warm pools。

C.使用 SageMaker Training Compiler。

D.使用 SageMaker distributed data parallelism (SMDDP) library。

▼ 解答

B

1. 考察的知识点

Amazon SageMaker的功能与优化技术，包括如何减少训练任务的启动时间。

理解SageMaker的托管服务，例如Managed Spot Training、Managed Warm Pools等。

熟悉SageMaker Training Compiler和分布式数据并行库的用途。

2. 选项分析

A.

错误。Managed Spot Training主要用于降低训练成本，而不是减少基础设施启动时间。虽然它可以节省费用，但它并不直接解决题目中提到的“最小化基础设施启动时间”的问题。

B.

正确。SageMaker Managed Warm Pools允许用户预热计算资源，从而减少训练任务的启动时间。这是专门设计用于优化连续训练任务的启动时间的功能。

C.

错误。SageMaker Training Compiler主要用于优化模型训练的性能和速度，而不是减少基础设施启动时间。它的作用是加速训练过程，而不是优化资源启动时间。

D.

错误。SMDDP库用于加速分布式训练任务，尤其是处理大规模数据集时的效率提升。它与减少启动时间无关。

▼ 3

▼ 中文

案例研究 -

一家公司正在使用 Amazon SageMaker 构建一个基于网络的 AI 应用程序。该应用程序将提供以下功能和特性：机器学习实验、训练、中央模型注册表、模型部署和模型监控。

该应用程序必须确保在机器学习生命周期中安全且隔离地使用训练数据。训练数据存储在 Amazon S3 中。

公司必须实施基于手动审批的工作流程，以确保只有经过批准的模型才能部署到生产端点。

哪种解决方案可以满足此要求？

- A. 使用 SageMaker Experiments 在模型注册期间促进审批流程。
- B. 在中央模型注册表上使用 SageMaker ML Lineage Tracking。为审批流程创建跟踪实体。
- C. 使用 SageMaker Model Monitor 评估模型性能并管理审批。
- D. 使用 SageMaker Pipelines。当模型版本被注册时，使用 AWS SDK 将审批状态更改为“Approved”。

▼ 解答

D

1. 考察的知识点

Amazon SageMaker的功能，包括SageMaker Pipelines、Model Monitor、Experiments和ML Lineage Tracking。
如何实现模型审批流程和安全的ML生命周期管理。
如何使用AWS SDK进行自动化操作。

2. 选项分析

A. 使用 SageMaker Experiments 在模型注册期间促进审批流程。

错误：SageMaker Experiments主要用于跟踪和组织实验数据，而不是设计审批流程。虽然它可以帮助记录实验结果，但它无法直接实现模型审批的功能。

B. 在中央模型注册表上使用 SageMaker ML Lineage Tracking。为审批流程创建跟踪实体。

错误：SageMaker ML Lineage Tracking用于跟踪模型的来源和依赖关系，但它不是专门设计用于管理审批流程。它无法直接实现手动审批的功能。

C. 使用 SageMaker Model Monitor 评估模型性能并管理审批。

错误：SageMaker Model Monitor的主要功能是监控模型的性能和数据漂移，而不是管理模型的审批状态。它无法实现手动审批流程。

D. 使用 SageMaker Pipelines。当模型版本被注册时，使用 AWS SDK 将审批状态更改为“Approved”。

正确：SageMaker Pipelines支持构建端到端的ML工作流，包括模型注册和审批流程。通过AWS SDK，可以实现手动审批流程并更改模型的状态为“Approved”。此选项完全符合题目要求。

▼ 4

▼ 中文

案例研究 -

一家公司正在使用 Amazon SageMaker 构建一个基于网络的 AI 应用程序。该应用程序将提供以下功能和特点：机器学习实验、训练、中央模型注册表、模型部署和模型监控。

该应用程序必须确保在机器学习生命周期中安全且隔离地使用训练数据。训练数据存储在 Amazon S3 中。

公司需要运行一个按需工作流，以监控从应用程序部署到实时端点的模型的偏差漂移。

哪项操作可以满足此要求？

- A.** 配置应用程序以调用运行 SageMaker Clarify 作业的 AWS Lambda 函数。
- B.** 调用一个 AWS Lambda 函数以拉取 sagemaker-model-monitor-analyzer 内置 SageMaker 镜像。
- C.** 使用 AWS Glue Data Quality 来监控偏差。
- D.** 使用 SageMaker 笔记本比较偏差。

▼ 解答

A

1. 考察的知识点

Amazon SageMaker的功能，包括模型监控和偏差检测。

SageMaker Clarify的用途，用于检测和监控模型的偏差。

AWS Lambda的集成能力，用于触发和运行SageMaker作业。

如何确保数据安全和隔离性。

2. 选项分析

A. 配置应用程序以调用运行 SageMaker Clarify 作业的 AWS Lambda 函数。

正确：SageMaker Clarify是专门设计用于检测和监控模型偏差的工具。通过 AWS Lambda触发Clarify作业，可以实现按需监控偏差漂移。

符合题目要求：按需运行偏差监控工作流，并确保数据安全和隔离。

B. 调用一个 AWS Lambda 函数以拉取 sagemaker-model-monitor-analyzer 内置 SageMaker 镜像。

错误：虽然SageMaker Model Monitor可以用于监控模型性能，但它并不是专门设计用于监控偏差漂移。题目明确要求监控偏差漂移，而不是一般的模型性能。

C. 使用 AWS Glue Data Quality 来监控偏差。

错误：AWS Glue Data Quality 主要用于数据质量检查，而不是模型偏差监控。它不适合用于监控模型的偏差漂移。

D. 使用 SageMaker 笔记本比较偏差。

错误：虽然可以使用 SageMaker 笔记本进行偏差分析，但这不是一个自动化的、按需运行的工作流。题目要求的是一个自动化解决方案，而不是手动分析。

▼ 5

▼ 中文

热点问题 -

一家公司将历史数据存储存储在 Amazon S3 中的 .csv 文件中。只有部分行和列在 .csv 文件中有数据填充。列没有标签。一位机器学习工程师需要准备并存储数据，以便公司可以使用这些数据来训练机器学习模型。

从以下列表中选择并排序正确的步骤以执行此任务。每个步骤应选择一次或不选择。（选择并排序三个步骤。）

- 创建一个 Amazon SageMaker 批量转换作业用于数据清理和特征工程。
- 将处理后的数据存储回 Amazon S3。
- 使用 Amazon Athena 推断架构和可用列。
- 使用 AWS Glue 爬网程序推断架构和可用列。
- 使用 AWS Glue DataBrew 进行数据清理和特征工程。

Step 1:

Select...

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering.
Store the resulting data back in Amazon S3.
Use Amazon Athena to infer the schemas and available columns.
Use AWS Glue crawlers to infer the schemas and available columns.
Use AWS Glue DataBrew for data cleaning and feature engineering.

Step 2:

Select...

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering.
Store the resulting data back in Amazon S3.
Use Amazon Athena to infer the schemas and available columns.
Use AWS Glue crawlers to infer the schemas and available columns.
Use AWS Glue DataBrew for data cleaning and feature engineering.

Step 3:

Select...

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering.
Store the resulting data back in Amazon S3.
Use Amazon Athena to infer the schemas and available columns.
Use AWS Glue crawlers to infer the schemas and available columns.
Use AWS Glue DataBrew for data cleaning and feature engineering.

▼ 解答

Correct Answer:

Step 1:

Select...

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering.
Store the resulting data back in Amazon S3.
Use Amazon Athena to infer the schemas and available columns.
Use AWS Glue crawlers to infer the schemas and available columns.
Use AWS Glue DataBrew for data cleaning and feature engineering.

Step 2:

Select...

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering.
Store the resulting data back in Amazon S3.
Use Amazon Athena to infer the schemas and available columns.
Use AWS Glue crawlers to infer the schemas and available columns.
Use AWS Glue DataBrew for data cleaning and feature engineering.

Step 3:

Select...

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering.
Store the resulting data back in Amazon S3.
Use Amazon Athena to infer the schemas and available columns.
Use AWS Glue crawlers to infer the schemas and available columns.
Use AWS Glue DataBrew for data cleaning and feature engineering.

1. 考察の知识点

- **数据准备与清洗**：如何使用AWS服务进行数据清理和特征工程。
- **数据存储与管理**：如何将处理后的数据存储回Amazon S3。
- **数据架构推断**：如何使用AWS工具推断数据的架构和可用列。

2. 选项分析

Create an Amazon SageMaker batch transform job for data cleaning and feature engineering:错误。Amazon SageMaker的batch transform

主要用于模型推理，而不是数据清理和特征工程。此选项不适合用于数据准备阶段。

Store the resulting data back in Amazon S3:正确。 处理后的数据需要存储回Amazon S3，以便后续使用。

Use Amazon Athena to infer the schemas and available columns:错误。 Amazon Athena主要用于查询数据，而不是推断数据架构。推断数据架构更适合使用AWS Glue Crawlers。

Use AWS Glue crawlers to infer the schemas and available columns:正确。 AWS Glue Crawlers可以自动扫描数据并推断其架构和可用列。

Use AWS Glue DataBrew for data cleaning and feature engineering:正确。 AWS Glue DataBrew是专门设计用于数据清理和特征工程的工具。

▼ 6

▼ 中文

热点 -

一位机器学习工程师需要使用 Amazon SageMaker Feature Store 来创建和管理特征以训练模型。

从以下列表中选择并排列步骤，以在 Feature Store 中创建和使用特征。每个步骤应选择一次。(选择并排列三个步骤。)

- 访问存储以构建训练数据集。
- 创建一个特征组。
- 导入记录。

Step 1:

Access the store to build datasets for training.
 Create a feature group.
 Ingest the records.

Step 2:

Access the store to build datasets for training.
 Create a feature group.
 Ingest the records.

Step 3:

Access the store to build datasets for training.
 Create a feature group.
 Ingest the records.

热点

一位机器学习工程师需要使用 Amazon SageMaker Feature Store 来创建和管理特征以训练模型。

从以下列表中选择并排列步骤，以在 Feature Store 中创建和使用特征。每个步骤应选择一次。（选择并排列三个步骤。）

- 访问存储以构建训练数据集。
- 创建一个特征组。
- 导入记录。

Step 1:

Access the store to build datasets for training.
 Create a feature group.
 Ingest the records.


Step 2:

Access the store to build datasets for training.
 Create a feature group.
 Ingest the records.

Step 3:

Access the store to build datasets for training.
 Create a feature group.
 Ingest the records.

▼ 解答



1. 考察的知识点

本题考察的是Amazon SageMaker Feature Store的使用流程，包括创建特征组、数据记录的摄取以及从特征存储中访问数据以构建训练数据集。

2. 选项分析

Create a feature group: 正确。创建特征组是使用Feature Store的第一步，特征组定义了存储的特征及其元数据。

Ingest the records: 正确。在创建特征组后，需要将数据记录摄取到特征组中，以便存储和管理这些特征。

Access the store to build datasets for training: 正确。在数据摄取完成后，可以从Feature Store中访问数据以构建训练数据集，这是使用特征的最后一步。

▼ 7

▼ 中文

热点问题 -

一家公司希望在 Amazon SageMaker 上托管一个机器学习（ML）模型。一位机器学习工程师正在 AWS CodePipeline 中配置一个持续集成和持续交付

(CI/CD) 管道来部署该模型。当模型的训练数据上传到 Amazon S3 存储桶时，管道必须自动运行。

从以下列表中选择并排列管道的正确步骤。每个步骤应选择一次或不选择。（选择并排列三个步骤。）

- 当新数据上传时，S3 事件通知触发管道。
- S3 生命周期规则通知触发管道，当新数据上传时。
- SageMaker 使用 S3 存储桶中的数据重新训练模型。
- 管道将模型部署到 SageMaker 端点。
- 管道将模型部署到 SageMaker Model Registry。

Step 1: Select...

Select...

An S3 event notification invokes the pipeline when new data is uploaded.
An S3 Lifecycle rule invokes the pipeline when new data is uploaded.
SageMaker retrains the model by using the data in the S3 bucket.
The pipeline deploys the model to a SageMaker endpoint.
The pipeline deploys the model to SageMaker Model Registry.

Step 2: Select...

Select...

An S3 event notification invokes the pipeline when new data is uploaded.
An S3 Lifecycle rule invokes the pipeline when new data is uploaded.
SageMaker retrains the model by using the data in the S3 bucket.
The pipeline deploys the model to a SageMaker endpoint.
The pipeline deploys the model to SageMaker Model Registry.

Step 3: Select...

Select...

An S3 event notification invokes the pipeline when new data is uploaded.
An S3 Lifecycle rule invokes the pipeline when new data is uploaded.
SageMaker retrains the model by using the data in the S3 bucket.
The pipeline deploys the model to a SageMaker endpoint.
The pipeline deploys the model to SageMaker Model Registry.

▼ 解答

Step 1:	Select... Select... An S3 event notification invokes the pipeline when new data is uploaded. An S3 Lifecycle rule invokes the pipeline when new data is uploaded. SageMaker retrains the model by using the data in the S3 bucket. The pipeline deploys the model to a SageMaker endpoint. The pipeline deploys the model to SageMaker Model Registry.
Step 2:	Select... Select... An S3 event notification invokes the pipeline when new data is uploaded. An S3 Lifecycle rule invokes the pipeline when new data is uploaded. SageMaker retrains the model by using the data in the S3 bucket. The pipeline deploys the model to a SageMaker endpoint. The pipeline deploys the model to SageMaker Model Registry.
Step 3:	Select... Select... An S3 event notification invokes the pipeline when new data is uploaded. An S3 Lifecycle rule invokes the pipeline when new data is uploaded. SageMaker retrains the model by using the data in the S3 bucket. The pipeline deploys the model to a SageMaker endpoint. The pipeline deploys the model to SageMaker Model Registry.

1. 考察的知识点

Amazon S3事件通知机制。

Amazon SageMaker模型训练与部署流程。

CI/CD管道的自动化触发与步骤设计。

2. 选项分析

An S3 event notification invokes the pipeline when new data is uploaded.

正确。S3事件通知可以配置为在新数据上传时触发CodePipeline，从而实现自动化流程的启动。

S3 Lifecycle rule invokes the pipeline when new data is uploaded.

错误。S3生命周期规则用于管理对象的存储时间和过期策略，不能直接触发CodePipeline。

SageMaker retrains the model by using the data in the S3 bucket.

正确。模型训练在CI/CD管道中的重要步骤，使用S3中的新数据进行重新训练符合题目要求。

The pipeline deploys the model to a SageMaker endpoint.

正确。将模型部署到SageMaker端点是CI/CD管道的最终步骤之一，用于提供实时推理服务。

The pipeline deploys the model to SageMaker Model Registry.

错误。SageMaker Model Registry用于模型版本管理，但题目要求是部署到端点，而不是注册到模型注册表。

▼ 8

▼ 中文

热点 -

一名机器学习工程师正在使用大型语言模型（LLMs）通过 Amazon Bedrock 构建一个生成式 AI 应用程序。

从以下列表中为每个描述选择正确的生成式 AI 术语。每个术语应被选择一次或完全不选择。（选择三个）

- Embedding
- Retrieval Augmented Generation (RAG)
- Temperature
- Token

Text representation of basic units of data processed by LLMs	Select... Select... Embedding Retrieval Augmented Generation (RAG) Temperature Token
High-dimensional vectors that contain the semantic meaning of text	Select... Select... Embedding Retrieval Augmented Generation (RAG) Temperature Token
Enrichment of information from additional data sources to improve a generated response	Select... Select... Embedding Retrieval Augmented Generation (RAG) Temperature Token

▼ 解答

Correct Answer:

Text representation of basic units of data processed by LLMs	Select... Select... Embedding Retrieval Augmented Generation (RAG) Temperature Token
High-dimensional vectors that contain the semantic meaning of text	Select... Select... Embedding Retrieval Augmented Generation (RAG) Temperature Token
Enrichment of information from additional data sources to improve a generated response	Select... Select... Embedding Retrieval Augmented Generation (RAG) Temperature Token

1.Text representation of basic units of data processed by LLMs

正解：Token

解析：LLM 在處理文字時，並不是直接讀取整句話，而是將文字切分成較小的單位，這些單位就稱為 Token。一個 Token 可以是一個單字、一個音節、甚至是一個標點符號。

關鍵字："basic units of data"（數據的基本單位）。

2.High-dimensional vectors that contain the semantic meaning of text

正解：Embedding

解析：為了讓電腦理解文字之間的「意義」與「關聯」，我們會將文字（Token）轉換成一串數字構成的向量，這就是 Embedding（嵌入）。在一個高維度空間中，語意相近的詞（例如「貓」和「狗」）其向量位置會靠得比較近。

關鍵字："High-dimensional vectors"（高維向量）、"semantic meaning"（語意）。

3.Enrichment of information from additional data sources to improve a generated response

正解：Retrieval Augmented Generation (RAG)

解析：當模型本身的知識不足（例如不知道公司內部文件或最新新聞）時，我們可以讓系統先從外部資料庫「檢索」(Retrieve) 相關資訊，再交給模型進行「生成」(Generate)，這套流程就是 RAG。它有效減少 AI 幻覺並提升準確度。

關鍵字："additional data sources"（額外數據源）、"improve response"（改善回覆）。

補充：為什麼不選 Temperature？

Temperature（溫度）是一個超參數，用來控制模型輸出的「隨機性」或「創造力」。

低溫度（例如 0.2）：輸出更穩定、可預測。

高溫度（例如 0.8）：輸出更多樣、更具創意。

在本題的描述中，並沒有提到關於隨機性或機率分布的控制，因此不選擇此項。

總結答案順序：

Token

Embedding

Retrieval Augmented Generation (RAG)

▼ 9

▼ 中文

热点 -


一位机器学习工程师正在开发一个机器学习模型，用于预测类似大小房屋的价格。该模型将基于多个特征进行预测。机器学习工程师将使用以下特征工程技术来估算房屋价格：

- Feature splitting
- Logarithmic transformation
- One-hot encoding
- Standardized distribution

为以下特征列表选择正确的特征工程技术。每个特征工程技术应选择一次或完全不选择（选择三个）。

City (name)	Select... Select... Feature splitting Logarithmic transformation One-hot encoding Standardized distribution
Type_year (type of home and year the home was built)	Select... Select... Feature splitting Logarithmic transformation One-hot encoding Standardized distribution
Size of the building (square feet or square meters)	Select... Select... Feature splitting Logarithmic transformation One-hot encoding Standardized distribution

▼ 解答



1. 考察的知识点

本题考察的是机器学习中的特征工程技术，包括特征拆分（Feature splitting）、对数变换（Logarithmic transformation）、独热编码（One-hot encoding）、标准化分布（Standardized distribution）。

需要根据特征的类型选择合适的特征工程方法。

2. 选项分析

City (name)

One-hot encoding: 正确。城市名称是类别型数据，适合使用独热编码将其转换为数值型特征。

Type_year (type of home and year the home was built)

Feature splitting: 正确。该特征包含两个信息（房屋类型和建造年份），可以通过特征拆分将其分成两个独立的特征。

Size of the building (square feet or square meters)

Logarithmic transformation: 正确。建筑面积是典型的连续数值型数据，可能存在较大的范围差异，对数变换可以缩小范围并处理偏态分布。

▼ 10

▼ 中文

案例研究 -

一位机器学习工程师正在AWS上开发一个欺诈检测模型，训练数据集包括事务日志、客户档案，以及来自本地MySQL数据库的表。

事务日志和客户档案存储在Amazon S3中。

数据集存在类别分布不平衡问题，这影响了模型算法的学习。此外，许多特征之间存在相互依赖性。算法未能捕获数据中所有期望的潜在模式。

哪个AWS服务或功能可以从各种数据源聚合数据？

- A. Amazon EMR Spark jobs
- B. Amazon Kinesis Data Streams
- C. Amazon DynamoDB
- D. AWS Lake Formation

▼ 解答

D

1. 考察的知识点

数据集整合：如何从多个数据源（如Amazon S3、MySQL数据库等）聚合数据。

AWS服务的功能：了解不同AWS服务（如Amazon EMR、Amazon Kinesis、Amazon DynamoDB、AWS Lake Formation）的用途和适用场景。

2. 选项分析

A. Amazon EMR Spark jobs

分析：Amazon EMR可以运行Spark作业来处理和分析大规模数据集，但它主要用于数据处理和分析，而不是专门设计用于数据源的整合。虽然可以通过编写Spark代码实现数据整合，但这不是最直接的解决方案。

结论：错误。

B. Amazon Kinesis Data Streams

分析：Amazon Kinesis主要用于实时数据流处理，而题目中并未提到需要处理实时数据流。它不适合用于整合静态数据源（如S3和MySQL）。

结论：错误。

C. Amazon DynamoDB

分析：Amazon DynamoDB是一个NoSQL数据库服务，适合存储和查询结构化数据，但它不是一个数据整合工具，无法直接从多个数据源聚合数据。

结论：错误。

D. AWS Lake Formation

分析：AWS Lake Formation专门 designed 用于快速构建数据湖的服务，可以轻松整合来自多个数据源的数据（如S3、数据库等）。它支持数据的集中管理，是题目中最合适的答案。

结论：正确。

▼ 11

▼ 中文

案例研究 -

一位機器學習工程師正在 AWS 上開發一個欺詐偵測模型。訓練數據集包括事件日誌、客戶檔案以及來自本地 MySQL 數據庫的表。

事件日誌和客戶檔案存儲在 Amazon S3 中。

數據集存在多類不同的問題，這影響了模型的學習。此外，許多特徵之間存在相互依賴關係，算法無法輕鬆捕獲數據中的長期潛在模式。

作為某某任務，機器學習工程師必須施加一個解決方案，以自動檢測數據中的異常並可視化結果。

哪種解決方案可以滿足這些需求？

- A. 使用 Amazon Athena 自動檢測異常並可視化結果。
- B. 使用 Amazon Redshift Spectrum 自動檢測異常。使用 Amazon QuickSight 可視化結果。
- C. 使用 Amazon SageMaker Data Wrangler 自動檢測異常並可視化結果。
- D. 使用 AWS Batch 自動檢測異常。使用 Amazon QuickSight 可視化結果。

▼ 解答

C

1. 考察的知識點

數據預處理與特徵工程：如何處理數據中的異常值和不平衡問題。

AWS 服務選擇：熟悉 AWS 服務的功能，例如 Amazon SageMaker Data Wrangler、Amazon Athena、Amazon Redshift Spectrum 等。

可視化工具：如何使用 AWS 服務進行數據可視化，例如 Amazon QuickSight。

1. 選項分析

A. Use Amazon Athena to automatically detect the anomalies and to visualize the result.

錯誤：Amazon Athena 是一個交互式查詢服務，主要用於查詢存儲在 Amazon S3 中的數據。它不具備自動檢測異常的功能，也不支援數據預處理和特徵工程。

B. Use Amazon Redshift Spectrum to automatically detect the anomalies. Use Amazon QuickSight to visualize the result.

錯誤：Amazon Redshift Spectrum 用於直接查詢存儲在 S3 中的數據，但它不具備自動檢測異常的功能。雖然 Amazon QuickSight 可以用於可視化數據，但其不擅長進行複雜的預測分析。

C. Use Amazon SageMaker Data Wrangler to automatically detect the anomalies and to visualize the result.

正確：Amazon SageMaker Data Wrangler 是一個數據處理工具，支援自動檢測異常值、處理數據不平衡問題，並提供內置的可視化功能。這使其成為處理和分析數據的理想選擇。

D. Use AWS Batch to automatically detect the anomalies. Use Amazon QuickSight to visualize the result.

錯誤：AWS Batch 旨在用於批量計算作業，不適合用於自動檢測異常。此外，雖然 Amazon QuickSight 可以用於可視化，但這並不足以滿足數據預處理和異常檢測的需求。

▼ 12

▼ 中文

案例研究 -

一位機器學習工程師正在 AWS 上開發一個欺詐檢測模型。訓練數據集包括事務日誌、客戶檔案以及來自本地 MySQL 數據庫的表。事務日誌和客戶檔案存儲在 Amazon S3 中。

數據集存在類別不平衡問題，這影響了模型算法的學習。此外，許多特徵之間存在相互依賴關係。算法未能捕獲數據集中所有期望的潛在模式。

訓練數據集包括分類數據和數值數據。機器學習工程師必須準備訓練數據集以最大化模型的準確性。

哪種操作能夠以最少的運營開銷滿足此要求？

- A. 使用 AWS Glue 將分類數據轉換為數值數據。
- B. 使用 AWS Glue 將數值數據轉換為分類數據。
- C. 使用 Amazon SageMaker Data Wrangler 將分類數據轉換為數值數據。
- D. 使用 Amazon SageMaker Data Wrangler 將數值數據轉換為分類數據。

▼ 解答

C

1. 考察的知識點

- **數據預處理：** 如何處理分類數據和數值數據以優化模型性能。
- **工具選擇：** AWS 服務（如 AWS Glue 和 Amazon SageMaker Data Wrangler）的功能和適用場景。
- **操作效率：** 選擇最少的操作開銷來完成任務。

2. 選項分析

A. 使用 AWS Glue 將分類數據轉換為數值數據。

- **正確性分析：** AWS Glue 是一種 ETL 工具，適合處理大規模數據轉換任務，但它並不專門針對機器學習數據預處理。
- **錯誤原因：** AWS Glue 的操作複雜性較高，且不具備直接優化機器學習數據的功能，因此不符合「最少操作開銷」的要求。

B. 使用 AWS Glue 將數值數據轉換為分類數據。

- **正確性分析：** 與選項 A 類似，AWS Glue 不適合直接處理機器學習數據預處理任務。
- **錯誤原因：** 將數值數據轉換為分類數據通常不是解決數據不平衡或特徵間依賴問題的最佳方法。

C. 使用 Amazon SageMaker Data Wrangler 將分類數據轉換為數值數據。

- **正確性分析：** Amazon SageMaker Data Wrangler 是專門設計用於機器學習數據預處理的工具，支持輕鬆轉換分類數據為數值數據（如獨熱編碼或標籤）。
- **正確原因：** 此選項直接解決了分類數據處理問題，並且操作開銷較低，符合題目要求。

D. 使用 Amazon SageMaker Data Wrangler 將數值數據轉換為分類數據。

- **正確性分析：** 將數值數據轉換為分類數據通常不適合解決數據不平衡或特徵間依賴問題。
- **錯誤原因：** 此操作不符合題目要求，且不解決模型學習不足的問題。

▼ 13

▼ 中文

案例研究 -

一位機器學習工程師正在 AWS 上開發一個欺詐檢測模型。訓練數據集包括事務日誌、客戶檔案以及來自本地 MySQL 數據庫的表。事務日誌和客戶檔案存儲在 Amazon S3 中。

數據集存在類別不平衡的問題，這影響了模型算法的學習。此外，許多特徵之間存在相互依賴關係。算法未能捕獲數據集中所有期望的潛在模式。

在機器學習工程師訓練模型之前，必須解決數據不平衡的問題。

哪種解決方案能夠以最少的操作努力滿足此要求？

- A. 使用 Amazon Athena 識別導致不平衡的模式，並相應調整數據集。
- B. 使用 Amazon SageMaker Studio Classic 內置算法處理不平衡數據集。
- C. 使用 AWS Glue DataBrew 內置功能對少數類別進行過採樣。
- D. 使用 Amazon SageMaker Data Wrangler 的平衡數據操作對少數類別進行過採樣。

▼ 解答

D



1. 考察的知識點

- **數據預處理：** 解決數據集中的類別不平衡問題。
- **AWS 服務的功能：** 熟悉 Amazon SageMaker Data Wrangler、AWS Glue DataBrew、Amazon Athena 等服務的用途。
- **機器學習模型訓練前的數據準備：** 如何處理數據以提高模型性能。



2. 選項分析

- A. 使用 Amazon Athena 識別導致不平衡的模式，並相應調整數據集。

- **錯誤：** Amazon Athena 主要用於查詢和分析數據，而不是直接處理數據集的不平衡問題。雖然可以用 Athena 識別模式，但調整數據集需要額外的步驟，增加了操作複雜性。

B. 使用 Amazon SageMaker Studio Classic 內置算法處理不平衡數據集。

- **錯誤：** SageMaker Studio Classic 提供了內置算法，但這些算法通常用於模型訓練，而不是專門處理數據不平衡問題。解決數據不平衡問題需要專門的數據預處理工具，而不是直接依賴模型算法。

C. 使用 AWS Glue DataBrew 內置功能對少數類別進行過採樣。

- **錯誤：** AWS Glue DataBrew 是一個數據準備工具，但它的功能更側重於數據清理和轉換，而不是專門處理類別不平衡問題。雖然可以通過自定義操作實現過採樣，但這需要額外的配置，增加了操作複雜性。

D. 使用 Amazon SageMaker Data Wrangler 的平衡數據操作對少數類別進行過採樣。

- **正確：** Amazon SageMaker Data Wrangler 提供了專門的「平衡數據」操作，可以輕鬆實現對少數類別的過採樣。此選項直接解決了問題，並且操作複雜性最低。

▼ 14

▼ 中文

案例研究 -

一位機器學習工程師正在 AWS 上開發一個欺詐檢測模型。訓練數據集包括事務日誌、客戶檔案以及來自本地 MySQL 數據庫的表。事務日誌和客戶檔案存儲在 Amazon S3 中。

數據集存在類別不平衡的問題，這影響了模型算法的學習。此外，許多特徵之間存在相互依賴關係。算法未能捕獲數據集中所有期望的潛在模式。

機器學習工程師需要使用 Amazon SageMaker 內置算法來訓練模型。

機器學習工程師應該使用哪種算法來滿足此需求？

-
- A. LightGBM
 - B. Linear learner
 - C. K-means clustering

D. Neural Topic Model (NTM)

▼ 解答

A



1. 考察的知識點

- **Amazon SageMaker 內置算法**的選擇與應用。
- 如何處理數據集中的**類別不平衡問題**。
- 如何選擇適合處理**特徵間依賴關係**的算法。



2. 選項分析

A. LightGBM

- **正確**：LightGBM 是一種基於梯度提升的算法，適合處理**類別不平衡問題**，並且能夠**捕獲複雜的特徵間依賴關係**。它在處理大規模數據集和高維特徵時表現良好。
- 此選項正確。

B. Linear learner

- **錯誤**：Linear learner 是一種線性算法，適合處理簡單的線性關係。它不擅長捕獲複雜的特徵間依賴關係，因此不適合此場景。
- 此選項錯誤。

C. K-means clustering

- **錯誤**：K-means 是一種無監督學習算法，主要用於聚類任務。此場景是一個**監督學習問題 (欺詐檢測)**，因此 K-means 不適合。
- 此選項錯誤。

D. Neural Topic Model (NTM)

- **錯誤**：NTM 是一種用於主題建模的無監督學習算法，主要用於文本數據的主題提取。此場景與主題建模無關，因此 NTM 不適合。
- 此選項錯誤。

▼ 15

▼ 中文

案例研究 -

一家公司在生產環境中部署了一個 XGBoost 預測模型，用於預測客戶是否可能取消訂閱。該公司使用 Amazon SageMaker Model Monitor 來檢測 F1 分數的偏差。

在對模型質量進行基線分析時，公司記錄了 F1 分數的閾值。在幾個月沒有變化後，模型的 F1 分數顯著下降。

導致 F1 分數下降的原因可能是什麼？

- A. 基礎客戶數據發生了概念漂移，這些數據用於預測。
- B. 模型的複雜性不足以捕捉原始基線數據中的所有模式。
- C. 原始基線數據存在缺失值的數據質量問題。
- D. 在計算基線時，向 Model Monitor 提供了錯誤的真實標籤。

▼ 解答

A



1. 考察的知識點

- Amazon SageMaker Model Monitor 的功能與用途。
- 機器學習模型性能指標 (如 F1 分數) 的變化原因。
- 概念漂移 (Concept Drift) 的定義及影響。



2. 選項分析

A. Concept drift occurred in the underlying customer data that was used for predictions.

- **正確：** 概念漂移是指數據分佈隨時間發生變化，導致模型性能下降。由於模型是基於原始數據訓練的，當數據分佈發生變化時，模型可能無法正確預測，從而導致 F1 分數下降。

B. The model was not sufficiently complex to capture all the patterns in the original baseline data.

- **錯誤：** 如果模型複雜性不足，問題會在**基線分析階段**就顯現，而不是在幾個月後才出現性能下降。因此，這不是導致 F1 分數下降的原因。

C. The original baseline data had a data quality issue of missing values.

- **錯誤：** 如果基線數據存在缺失值問題，問題會在**基線分析階段**就顯現，而不是在幾個月後才導致性能下降。

D. Incorrect ground truth labels were provided to Model Monitor during the calculation of the baseline.

- **錯誤：** 如果基線計算時提供了錯誤的真實標籤，問題會在**基線分析階段**就顯現，而不是在幾個月後才導致性能下降。

▼ 16

▼ 中文

案例研究 -

一家公司有一個數據科學家團隊，他們使用 Amazon SageMaker notebook 實例來測試機器學習模型。當數據科學家需要新的權限時，公司將權限附加到在創建 SageMaker notebook 實例期間創建的每個單獨角色上。

公司需要集中管理團隊的權限。

哪種解決方案可以滿足這一需求？

A. 創建一個具有必要權限的單一 IAM 角色。將該角色附加到團隊使用的每個 notebook 實例上。

B. 創建一個單一 IAM 組。將數據科學家添加到該組中。將該組與團隊使用的每個 notebook 實例關聯。

C. 創建一個單一 IAM 用戶。將 AdministratorAccess AWS 託管 IAM 策略附加到該用戶。配置每個 notebook 實例使用該 IAM 用戶。

D. 創建一個單一 IAM 組。將數據科學家添加到該組中。創建一個 IAM 角色。將 AdministratorAccess AWS 託管 IAM 策略附加到該角色。將該角色與該組關聯。將該組與團隊使用的每個 notebook 實例關聯。

▼ 解答

A



1. 考察的知識點

- IAM 角色與權限管理
- Amazon SageMaker 權限配置

- 權限集中化管理

2. 選項分析

A.

- **正確：**此選項建議創建一個單一的 IAM 角色，並將其附加到每個 SageMaker notebook 實例。這種方法可以**集中化管理權限**，避免為每個用戶單獨創建角色，符合最佳實踐。

B.

- **錯誤：****IAM 組不能直接附加到 SageMaker notebook 實例。** IAM 組用於管理用戶，但無法直接與資源關聯。

C.

- **錯誤：**使用單一 IAM 用戶並附加 AdministratorAccess 策略會導致**權限過度開放**，違反最小權限原則。此外，**IAM 用戶不能直接附加到 SageMaker notebook 實例。**

D.

- **錯誤：**此選項過於複雜且不符合實際操作。**IAM 組無法直接與 IAM 角色或 SageMaker notebook 實例關聯。**

▼ 17

▼ 中文

案例研究 -

一位機器學習工程師需要使用一個機器學習模型來**預測特定位置的公寓價格**。機器學習工程師應該使用哪個指標來評估模型的性能？

-
- A. Accuracy
 - B. Area Under the ROC Curve (AUC)
 - C. F1 score
 - D. Mean absolute error (MAE)

▼ 解答

D

1. 考察的知識點

本題考察的是如何選擇適當的評估指標來衡量機器學習模型的性能，特別是在回歸問題中。

2. 選項分析

A. Accuracy (準確率)

- **錯誤**：Accuracy (準確率) 通常用於**分類問題**，衡量模型預測正確的比例。在**回歸問題**中，Accuracy 並不適用，因此此選項錯誤。

B. Area Under the ROC Curve (AUC)

- **錯誤**：AUC 是用於**評估分類模型**性能的指標，特別是二分類問題中衡量模型區分正負樣本的能力。在**回歸問題**中，AUC 不適用，因此此選項錯誤。

C. F1 score

- **錯誤**：F1 score 是**分類問題**中的指標，用於衡量模型在正負樣本不平衡情況下的性能。它結合了 Precision 和 Recall。在**回歸問題**中，F1 score 不適用，因此此選項錯誤。

D. Mean absolute error (MAE)

- **正確**：MAE 是**回歸問題**中常用的評估指標，衡量**預測值與真實值之間的平均絕對誤差**。它適用於本題中預測房價的場景，因此此選項正確。

▼ 18

▼ 中文

案例研究 -

一位機器學習工程師使用**隨機梯度下降 (SGD)** 訓練了一個神經網絡。該神經網絡在測試集上的表現很差。訓練損失和驗證損失的值保持較高水平，並顯示出一種**振蕩模式**。這些值在幾個周期內下降，然後在幾個周期內上升，之後重複相同的循環。

機器學習工程師應該怎麼做以改進訓練過程？

選項

A. Introduce early stopping.
引入早停。

B. Increase the size of the test set.

增加測試集的大小。

C. Increase the learning rate.

增加學習率。

D. Decrease the learning rate.

降低學習率。

▼ 解答

D



1. 考察的知識點

- 優化算法的調參技巧，特別是學習率對模型訓練的影響。
- 理解訓練損失和驗證損失的行為模式。
- 如何解決模型訓練過程中出現的震蕩問題。



2. 選項分析

A. Introduce early stopping. 引入早停。

- **錯誤**：早停是一種防止過擬合的技術，但題目中並未提到過擬合問題，而是訓練損失和驗證損失出現**震蕩**。這表明問題可能與優化過程有關，而不是過擬合。因此此選項不適合解決當前問題。

B. Increase the size of the test set. 增加測試集的大小。

- **錯誤**：測試集的大小與模型訓練過程無關。增加測試集的大小不會影響訓練損失和驗證損失的震蕩問題，因此此選項錯誤。

C. Increase the learning rate. 增加學習率。

- **錯誤**：增加學習率可能會**加劇震蕩問題**，因為較高的學習率會導致模型在優化過程中跳躍過最優點，進一步加劇損失的波動。因此此選項錯誤。

D. Decrease the learning rate. 降低學習率。

- **正確**：**降低學習率可以減緩優化過程中的震蕩問題**，使模型更穩定地收斂到最優點。這是解決當前問題的正確方法。

▼ 19

▼ 中文

案例研究 -

一位機器學習工程師需要處理數千個現有的 CSV 對象以及上傳的新的 CSV 對象。這些 CSV 對象存儲在一個中央 Amazon S3 存儲桶中，並且具有相同的數量列。其中一列是**交易日期**。機器學習工程師必須根據交易日期查詢數據。

哪種解決方案能夠以**最少的操作開銷**滿足這些需求？

- A. 使用 Amazon Athena 的 CREATE TABLE AS SELECT (CTAS) 語句，根據中央 S3 存儲桶中的數據的交易日期創建一個表。從該表查詢對象。
- B. 為處理後的數據創建一個新的 S3 存儲桶。設置從中央 S3 存儲桶到新 S3 存儲桶的 S3 複製。使用 S3 Object Lambda 根據交易日期查詢對象。
- C. 為處理後的數據創建一個新的 S3 存儲桶。使用 AWS Glue for Apache Spark 創建一個作業，根據交易日期查詢 CSV 對象。配置該作業將結果存儲到新的 S3 存儲桶中。從新的 S3 存儲桶中查詢對象。
- D. 為處理後的數據創建一個新的 S3 存儲桶。使用 Amazon Data Firehose 將數據從中央 S3 存儲桶傳輸到新的 S3 存儲桶。配置 Firehose 運行一個 AWS Lambda 函數，根據交易日期查詢數據。

▼ 解答

A



1. 考察的知識點

- Amazon S3 數據存儲與查詢
- Amazon Athena 的使用
- 數據處理的最佳實踐與操作開銷優化



2. 選項分析

A.

- **分析：**Amazon Athena 是一種**無服務器查詢服務**，能夠直接查詢存儲在 S3 中的數據，支持 SQL 查詢。使用 CTAS 語句可以創建一個表並基於交易日期進行**分區**，操作開銷低且無需額外的數據移動。
- **正確：**此選項最符合題目要求，且**操作開銷最小**。

B.

- **分析：** S3 Object Lambda 允許在訪問 S3 對象時動態修改數據，但並不適合直接用於查詢數據。設置 S3 複製和新存儲桶增加了額外的操作開銷。

- **錯誤：** 此選項不符合題目要求，且操作開銷較高。

C.

- **分析：** AWS Glue 是一種 ETL 服務，適合複雜的數據轉換和處理，但對於簡單查詢任務來說操作開銷較高。創建新存儲桶並存儲結果增加了額外的步驟和成本。

- **錯誤：** 此選項不符合題目要求，且操作開銷較高。

D.

- **分析：** Amazon Kinesis Data Firehose 主要用於實時數據流的傳輸和處理，不適合靜態數據查詢。使用 Lambda 函數進行查詢增加了複雜性和操作開銷。

- **錯誤：** 此選項不符合題目要求，且操作開銷較高。

▼ 20

▼ 中文

案例研究 -

一家公司擁有一個龐大的**非結構化數據集**。該數據集包含多個關鍵屬性的**許多重複記錄**。

在 AWS 上，哪種解決方案可以以**最少的代碼開發**檢測數據集中的重複項？

- A. 使用 Amazon Mechanical Turk 任務檢測重複項。
- B. 使用 Amazon QuickSight ML Insights 構建一個自定義去重模型。
- C. 使用 Amazon SageMaker Data Wrangler 進行預處理並檢測重複項。
- D. 使用 AWS Glue FindMatches 轉換檢測重複項。

▼ 解答

D



1. 考察的知識點

本題考察的是 AWS 服務中**數據處理和去重**的能力，特別是如何使用 AWS 工具檢測數據集中的**重複記錄**。

涉及的服務包括 Amazon Mechanical Turk、Amazon QuickSight ML Insights、Amazon SageMaker Data Wrangler 和 AWS Glue。

2. 選項分析

A.

- **錯誤**：Amazon Mechanical Turk 主要用於**人工任務分發**，適合需要人工參與的複雜任務，但不適合自動化處理大規模數據集的重複檢測。需要大量人工干預，**代碼開發量較少，但效率低且成本高**。

B.

- **錯誤**：Amazon QuickSight 主要用於**數據可視化和商業智能分析**，ML Insights 可以提供一些預測功能，但不適合直接處理大規模數據去重任務。需要額外自定義模型，**開發量較大**。

C.

- **錯誤**：Amazon SageMaker Data Wrangler 主要用於**數據預處理和特徵工程**，雖然可以幫助清理數據，但檢測重複記錄需要額外的邏輯和開發工作。**代碼開發量較大，不是最優解**。

D.

- **正確**：AWS Glue FindMatches 是專門設計用於檢測數據集中的重複記錄的工具，使用機器學習算法**自動化去重過程**。**代碼開發量最少**，直接提供去重功能，是本題的最佳選擇。

▼ 21

▼ 中文

一家公司需要在 Amazon EC2 實例上運行一個**批量數據處理任務**。該任務將在**周末運行**，並需要 **90 分鐘完成**。**處理過程可以接受中斷**。該公司將在未來 **6 個月**的每個周末運行該任務。

哪種 EC2 實例購買選項能夠**最具成本效益**地滿足這些需求？

選項

- A. Spot Instances
- B. Reserved Instances
- C. On-Demand Instances
- D. Dedicated Instances

▼ 解答

A



1. 考察的知識點

- EC2 實例的購買選項及其適用場景。
- 如何選擇**最具成本效益**的實例類型。
- Spot Instances 的特點：低成本、可中斷性。



2. 選項分析

A. Spot Instances (Spot 實例)

- **正確**：Spot Instances 是**最具成本效益**的選項，適用於可以容忍中斷的工作負載。該公司運行的批量處理任務可以接受中斷，並且只需要運行 90 分鐘，因此 Spot Instances 是最佳選擇。

B. Reserved Instances (預留實例)

- **錯誤**：Reserved Instances 適用於**長期穩定**的工作負載，通常需要提前支付費用以獲得折扣。該公司只需要運行**短期的批量任務**（每周 90 分鐘），不適合 Reserved Instances。

C. On-Demand Instances (按需實例)

- **錯誤**：On-Demand Instances 適用於**短期、不可預測**的工作負載，但**成本較高**。雖然可以滿足需求，但不是最具成本效益的選項。

D. Dedicated Instances (專用實例)

- **錯誤**：Dedicated Instances 提供物理隔離的硬件，成本非常高，通常用於滿足合規性或特殊硬件需求。該公司沒有提到需要物理隔離，因此不適合 Dedicated Instances。

▼ 22

▼ 中文

一名機器學習工程師在 `us-east-1` 區域的帳戶 A 中擁有一個 Amazon Comprehend 自定義模型。該機器學習工程師需要將模型複製到同一區域的帳戶 B 中。

哪種解決方案能夠以最少的開發工作滿足此要求？

A. 使用 Amazon S3 製作模型的副本。將副本傳輸到帳戶 B。

B. 創建基於資源的 IAM 策略。使用 Amazon Comprehend ImportModel API 操作將模型複製到帳戶 B。

C. 使用 AWS DataSync 從帳戶 A 複製模型到帳戶 B。

D. 創建帳戶 A 和帳戶 B 之間的 AWS 站點對站點 VPN 連接以傳輸模型。

▼ 解答

B

1. 考察的知识点

Amazon Comprehend的自定义模型管理与跨账户迁移。

使用IAM策略和API操作进行资源共享和迁移。

选择最少开发工作量的解决方案。

选项分析

A.

错误：Amazon Comprehend的自定义模型无法直接通过Amazon S3进行复制和迁移。模型的迁移需要使用专门的API操作，如ImportModel。

B.

正确：Amazon Comprehend支持通过ImportModel API操作将模型从一个账户迁移到另一个账户。使用基于资源的IAM策略可以授予目标账户访问源账户模型的权限。

C.

错误：AWS DataSync主要用于文件和数据的复制，不支持Amazon Comprehend模型的迁移。

D.

错误：VPN连接用于网络通信和数据传输，但无法直接迁移Amazon Comprehend模型。此外，该选项增加了不必要的复杂性。

▼ 中文

一位機器學習工程師正在訓練一個簡單的神經網路模型。該工程師隨著時間的推移在驗證數據集上跟蹤模型的性能。模型的性能在開始時顯著提高，然後在經過特定數量的 epochs 後開始下降。

哪些解決方案可以緩解這個問題？(選擇兩個。)

A. 在模型上啟用 early stopping。

B. 增加層中的 dropout。

C. 增加層的數量。

D. 增加神經元的數量。

E. 調查並減少模型偏差的來源。

▼ 解答

AB

1. 考察的知識點

- 過擬合問題的解決方法。
- 神經網路模型的優化技巧
- 例如 early stopping 和 dropout。

選項分析

A. Enable early stopping on the model.

- **正確。** Early stopping 是一種常見的技術，用於防止模型在訓練過程中過擬合。通過監控驗證集的性能，當性能開始下降時停止訓練，可以有效避免過擬合問題。

B. Increase dropout in the layers.

- **正確。** Dropout 是一種正則化技術，通過隨機丟棄神經元來減少模型的複雜性，從而降低過擬合的風險。增加 dropout 可以幫助緩解模型性能下降的問題。

C. Increase the number of layers.

- **錯誤。** 增加層的數量可能會使模型變得更複雜，從而加劇過擬合問題，而不是解決它。

D. Increase the number of neurons.

- **錯誤**。增加神經元的數量同樣會增加模型的複雜性，可能導致過擬合問題更加嚴重。

E. Investigate and reduce the sources of model bias.

- **錯誤**。雖然減少模型偏差是一個重要的任務，但它與解決過擬合問題無關。題目中描述的問題是模型性能在驗證集上下降，這通常是**過擬合**的表現，而不是**偏差**問題。

▼ 24

▼ 中文

一家公司有一個檢索增強生成（RAG）應用程式，該應用程式使用向量數據庫存儲文檔的嵌入。該公司必須將應用程式遷移到 AWS，並且必須實現一個解決方案來提供文本文件的語義搜索。該公司已經將文本存儲庫遷移到一個 Amazon S3 桶中。哪種解決方案可以滿足這些需求？

A.

使用 AWS Batch 作業處理文件並生成嵌入。使用 AWS Glue 存儲嵌入。使用 SQL 查詢執行語義搜索。

B.

使用自定義 Amazon SageMaker 筆記本運行自定義腳本生成嵌入。使用 SageMaker Feature Store 存儲嵌入。使用 SQL 查詢執行語義搜索。

C.

使用 Amazon Kendra S3 連接器從 S3 桶中提取文檔到 Amazon Kendra，查詢 Amazon Kendra 執行語義搜索。

D.

使用 Amazon Textract 異步作業從 S3 桶中提取文檔。查詢 Amazon Textract 執行語義搜索。

▼ 解答

C

1. 考察的知識點

- 理解 AWS 服務的功能和適用場景，例如 Amazon Kendra、Amazon Textract、SageMaker 等。

- 熟悉如何實現語義搜索和文檔處理的最佳實踐。
- 掌握 AWS 服務之間的集成能力。

2. 選項分析

A.

- **錯誤：** AWS Batch 可以用於處理文件並生成嵌入，但 AWS Glue 主要用於 ETL（提取、轉換、加載）任務，而不是存儲嵌入。
- **錯誤：** SQL 查詢不適合執行語義搜索，因為它無法處理基於向量的相似性搜索。

B.

- **錯誤：** SageMaker Feature Store 主要用於存儲機器學習特徵，而不是專門設計用於存儲嵌入向量。
- **錯誤：** SQL 查詢無法執行語義搜索，無法滿足題目要求。

C.

- **正確：** Amazon Kendra 是一種智能搜索服務，支持語義搜索，並且可以直接從 S3 存儲桶提取文檔。
- **正確：** Amazon Kendra 內置的語義搜索功能，完全滿足題目要求。

D.

- **錯誤：** Amazon Textract 主要用於提取文檔中的結構化數據（例如表格和表單），而不是用於語義搜索。
- **錯誤：** Textract 不支持嵌入向量或語義搜索功能。

▼ 25

▼ 中文

一家公司使用 Amazon Athena 查詢存儲在 Amazon S3 中的數據集。該數據集包含一個目標變量。公司希望預測該變量。公司需要使用該數據集來確定模型是否可以預測目標變量。哪種解決方案可以以最少的開發工作量提供此信息？

A.

使用 Amazon SageMaker Autopilot 創建一個新模型。報告模型的實際性能。

B.

實施自定義腳本以執行數據預處理、多元線性回歸和性能評估。在 Amazon EC2 實例上運行這些腳本。

C.

配置 Amazon Macie 來分析數據集並創建模型。報告模型的實際性能。

D.

從 Amazon Bedrock 中選擇一個模型，使用數據調整模型。報告模型的實際性能。

▼ 解答

A

1. 考察的知識點

Amazon SageMaker Autopilot 的功能和用途。

機器學習模型的自動化構建與性能評估

AWS服務的選擇與適用場景

2. 選項分析

A. Amazon SageMaker Autopilot 可以**自動化地執行數據預處理、特徵工程、模型選擇和超參數優化**，最終生成一個機器學習模型並報告其性能。**最少的開發工作量**：Autopilot 是專門設計用於簡化機器學習流程的工具，用戶只需提供數據集和目標變量即可。

B. 需要手動編寫腳本進行數據預處理、模型訓練和性能評估，這會增加開發工作量，EC2 實例的使用雖然靈活，但**不適合快速驗證目標變量的預測能力**。

C. Amazon Macie 是用於**數據安全和隱私保護**的服務，主要用於識別敏感數據，**而不是用於機器學習模型的構建或性能評估**。

D. Amazon Bedrock 是用於**生成式 AI 模型的服務**，適用於生成文本、圖像等內容，**而不是用於傳統的機器學習任務**。
需要額外的調優工作，開發工作量較大。

▼ 26

▼ 中文

一家公司希望通过考虑每个广告的配色方案来预测广告活动的成功。一个机器学习工程师正在为一个神经网络模型准备数据。数据集包括作为分类数据的颜色信息。

机器学习工程师应该为模型使用哪种特征工程技术？

- A. 对颜色类别应用标签编码。自动为每种颜色分配一个唯一的整数。
- B. 实施填充以确保所有颜色特征向量具有相同的长度。
- C. 对颜色类别执行降维。
- D. 对颜色类别进行独热编码，将配色方案特征转换为一个二进制矩阵。

▼ 解答

D

1. 考察的知识点

本题考察的是机器学习中的特征工程技术，特别是如何处理分类数据（Categorical Data）。

重点在于选择适合神经网络模型的编码方式来处理分类数据。

A.

标签编码（Label Encoding）将每个类别映射为一个唯一的整数。这种方法简单，但对于神经网络来说可能不适合，因为整数编码包含隐含的顺序关系，而颜色类别之间并没有这种顺序关系。

因此，这种方法可能导致模型误解数据的结构，影响预测性能。结论：错误。

B.

填充（Padding）通常用于处理序列数据（如文本或时间序列），以确保输入数据的长度一致。它解决的是序列长度问题，而本题中颜色类别是分类数据，不涉及序列问题。此选项与题意要求无关。

C.

降维（Dimensionality Reduction）通常用于处理高维数值数据，而不是分类数据。颜色类别是离散的分类数据，无法直接应用降维技术。

此选项不适合处理分类数据。结论：错误。

D.

独热编码（One-Hot Encoding）是处理分类数据的常用方法。它将每个类别转换为一个二进制向量，适合神经网络模型，因为它不含隐含的类别之间顺

序关系。这种方法能够有效地表示颜色类别，并且是处理分类数据的最佳实践。

结论：正确。

▼ 27

▼ 中文

一家公司使用混合云环境。一个部署在本地的数据模型使用 Amazon S3 中的数据，为客户提供实时对话引擎。

该模型正在使用敏感数据。一名 ML 工程师需要实施一个解决方案来识别并移除敏感数据。

哪种解决方案可以以最少的运营开销满足这些需求？

A.

将模型部署在 Amazon SageMaker 上。创建一组 AWS Lambda 函数来识别并移除敏感数据。

B.

将模型部署在使用 AWS Fargate 的 Amazon Elastic Container Service (Amazon ECS) 集群上。创建一个 AWS Batch 作业来识别并移除敏感数据。

C.

使用 Amazon Macie 识别敏感数据。创建一组 AWS Lambda 函数来移除敏感数据。

D.

使用 Amazon Comprehend 识别敏感数据。启动 Amazon EC2 实例来移除敏感数据。

▼ 解答

C

1. 考察的知识点

本题主要考察 AWS 服务的选择与组合使用，尤其是针对敏感数据的识别与处理。

涉及的服务包括 Amazon SageMaker、AWS Lambda、Amazon ECS、AWS Fargate、AWS Batch、Amazon Macie、Amazon Comprehend 和 Amazon EC2，重点在于选择能够以最少的操作开销实现敏感数据识别和移除的解决方案。

A.

Amazon SageMaker 是一个托管的机器学习服务，适合模型训练和部署，但本题的重点是敏感数据的识别和移除，而不是模型的部署。

使用 AWS Lambda 函数来识别和移除敏感数据需要额外的开发工作，增加了操作开销。

此选项不符合“最少操作开销”的要求。

结论：错误。

B.

Amazon ECS 和 AWS Fargate 适合容器化应用的部署，但与敏感数据识别和移除无直接关联。

AWS Batch 用于批处理作业调度和运行，需要额外的配置和管理，增加了操作开销。

此选项不符合“最少操作开销”的要求。

结论：错误。

C.

Amazon Macie 是专门设计用于识别和保护敏感数据的服务，能够自动分类和识别敏感数据，特别是处理 Amazon S3 中的数据。

使用 AWS Lambda 函数来移除检测到的敏感数据是一种轻量级的解决方案，符合“最少操作开销”的要求。

结论：正确。

D.

Amazon Comprehend 是一个自然语言处理服务，适合分析文本数据，但不专门用于识别敏感数据。

使用 Amazon EC2 实例来移除敏感数据需要管理服务器和应用程序，增加了操作开销。

此选项不符合“最少操作开销”的要求。

结论：错误。

▼ 28

▼ 中文

一名机器学习工程师需要在 AWS 上创建数据摄取管道和机器学习模型部署管道。所有原始数据存储在 Amazon S3 桶中。

哪种解决方案可以满足这些需求？

A.

使用 Amazon Data Firehose 创建数据摄取管道。使用 Amazon SageMaker Studio Classic 创建模型部署管道。

B.

使用 AWS Glue 创建数据摄取管道。使用 Amazon SageMaker Studio Classic 创建模型部署管道。

C.

使用 Amazon Redshift ML 创建数据摄取管道。使用 Amazon SageMaker Studio Classic 创建模型部署管道。

D.

使用 Amazon Athena 创建数据摄取管道。使用 Amazon SageMaker notebook 创建模型部署管道。

▼ 解答

B

1. 考察的知识点

数据摄取管道的构建：AWS 服务如 AWS Glue、Amazon Kinesis Data Firehose 等的使用。

机器学习模型部署管道的构建：Amazon SageMaker 及其相关工具的使用。

1. 选项分析

A. 使用 Amazon Data Firehose 创建数据摄取管道。使用 Amazon SageMaker Studio Classic 创建模型部署管道。

Amazon Kinesis Data Firehose 主要用于实时数据流的摄取，而题目未提到实时数据需求，且原始数据已存储在 S3 中，因此不适合。

Amazon SageMaker Studio Classic 可以用于模型开发，但不完全适合用于构建完整的模型部署管道。

此选项并未完全符合题目要求。

结论：错误。

B. 使用 AWS Glue 创建数据摄取管道。使用 Amazon SageMaker Studio Classic 创建模型部署管道。

AWS Glue 是一种 ETL 服务，适合从 S3 中提取、转换和加载数据，符合题目中数据摄取管道的需求。

Amazon SageMaker Studio Classic 可以用于模型开发和部署，符合题目中模型部署管道的需求。

此选项最符合题目要求。

结论：正确。

C. 使用 Amazon Redshift ML 创建数据摄取管道。使用 Amazon SageMaker Studio Classic 创建模型部署管道。

Amazon Redshift ML 主要用于在数据仓库中训练和部署模型，而题目中的数据存储存储在 S3 中，Redshift ML 不适合用于数据摄取管道。

Amazon SageMaker Studio Classic 可以用于模型开发，但不完全适合用于构建完整的模型部署管道。

此选项不完全符合题目要求。

结论：错误。

D. 使用 Amazon Athena 创建数据摄取管道。使用 Amazon SageMaker notebook 创建模型部署管道。

Amazon Athena 是一种交互式查询服务，适合分析 S3 中的数据，但不适合作为数据摄取管道的核心工具。

Amazon SageMaker notebook 适合用于实验性开发，但不适合作为用于构建和管理部署管道的主要工具。

此选项不符合题目要求。

结论：错误。

▼ 29

▼ 中文

一家公司拥有数百名数据科学家，正在使用 Amazon SageMaker 创建机器学习模型。这些模型位于 SageMaker Model Registry 的模型组中。

数据科学家分为三类：计算机视觉、自然语言处理（NLP）和语音识别。一名机器学习工程师需要实施一个解决方案，将现有模型组分类组织起来，以提高模型在大型规模上的可发现性。该解决方案不会影响模型的工作及其现有分组的完整性。

哪种解决方案可以满足这些要求？

A.

为这三类创建一个自定义标签。将标签添加到 SageMaker Model Registry

中的模型包。

B.

为每个类别创建一个模型组。将现有模型移至这些类别模型组中。

C.

使用 SageMaker ML Lineage Tracking 自动识别并标记哪些模型组中包含这些模型。

D.

为这三类创建一个 Model Registry 集合。将现有模型组移至这些集合中。

▼ 解答

D

1. 考察的知识点

Amazon SageMaker Model Registry 的功能和使用场景。

如何组织和管理机器学习模型以提高可发现性。

标签、模型组和集合的区别及适用场景。

1. 选项分析

A.

正确性分析：标签可以用于分类和搜索，但它不会改变模型的组织结构，也无法提供层级别的分组功能。

错误原因：此解决方案虽然增强了模型的组织性和可发现性，但标签仅是一种附加属性，无法满足题目要求。

结论：错误。

B.

正确性分析：模型组用于将相关模型组织在一起，适用于根据用途对模型进行分组管理。

错误原因：将现有模型移至新模型组会改变模型的分组结构，违背题目“不会影响现有模型的分组”的要求。

结论：错误。

C.

正确性分析：ML Lineage Tracking 用于追踪模型的来源和依赖关系，但它并不适用于组织模型分组。

错误原因：此选项与题目要求的“组织模型以提高可发现性”无关，且无法满足提高模型可发现性的需求。

结论：错误。

D.

正确性分析：Model Registry 集合允许在不改变现有模型分组的情况下对模型组进行更高级别的分类和组织。

错误原因：此选项最符合题目要求，不影响现有模型组的结构，同时提高了模型的组织性和可发现性。

结论：正确。

▼ 30

▼ 中文

一家公司在新创建的 VPC 的公共子网中运行一个 Amazon SageMaker 域。网络配置正确，机器学习工程师可以访问 SageMaker 域。

最近，公司发现来自某个特定 IP 地址的异常流量访问该域。公司需要阻止来自该特定 IP 地址的流量。

对网络配置进行哪些更新可以满足此要求？

A.

创建一个安全组入站规则以拒绝来自该特定 IP 地址的流量。将安全组分配给该域。

B.

创建一个网络 ACL 入站规则以拒绝来自该特定 IP 地址的流量。将规则分配给该域所在子网的默认网络 ACL。

C.

为该域创建一个 shadow variant，配置 SageMaker Inference Recommender 将来自该特定 IP 地址的流量发送到 shadow endpoint。

D.

创建一个 VPC 路由表以拒绝来自该特定 IP 地址的入站流量。将路由表分配给该域。

▼ 解答

B

1. 考察的知识点

Amazon SageMaker 网络配置与安全性

VPC 网络 ACL 的使用

如何阻止特定 IP 地址的流量

1. 选项分析

A.

错误：安全组不支持显式“拒绝”规则，只能允许或默认拒绝流量。因此无法通过安全组直接阻止特定 IP 地址的流量。

B.

正确：网络 ACL 支持显式“拒绝”规则，可以有效阻止来自特定 IP 地址的流量。将规则应用到子网的默认网络 ACL 是正确的操作。

C.

错误：此选项与问题无关。Shadow variant 和 Inference Recommender 主要用于模型测试和流量分配，而不是用于阻止特定 IP 地址的流量。

D.

错误：VPC 路由表用于定义子网之间的流量路由，不能用于显式阻止特定 IP 地址的流量。

▼ 31

▼ 中文

一家公司正在收集各種語言的音頻、視頻和文本數據。該公司需要使用一個大型語言模型 (LLM) 來總結收集到的西班牙語數據。哪種解決方案能在最短時間內滿足這些需求？

A.

在 Amazon SageMaker 中訓練並部署一個模型，將數據轉換為英文文本。在 SageMaker 中訓練並部署一個 LLM 來總結文本。

B. 使用 Amazon Transcribe 和 Amazon Translate 將數據轉換為英文文本。使用 Amazon Bedrock 和 Jurassic 模型來總結文本。

C. 使用 Amazon Rekognition 和 Amazon Translate 將數據轉換為英文文本。使用 Amazon Bedrock 和 Anthropic Claude 模型來總結文本。

D. 使用 Amazon Comprehend 和 Amazon Translate 將數據轉換為英文文本。使用 Amazon Bedrock 和 Stable Diffusion 模型來總結文本。

▼ 解答

B

A 錯誤: 訓練模型需要大量時間，不符合「最短時間」的要求。

B 正確: Amazon Transcribe 可轉錄音頻，Amazon Translate 可翻譯文本。Amazon Bedrock 提供預訓練模型 (如 Jurassic) 可快速生成總結，符合「最短時間」要求。

C 錯誤: Amazon Rekognition 用於圖像分析，不適合處理音頻。

D 錯誤: Amazon Comprehend 是 NLP 服務，不直接處理音頻轉錄。Stable Diffusion 是生成圖像的模型，不適合文本總結。

▼ 32

▼ 中文

一家金融公司從外部提供商接收大量即時市場數據流。這些數據流每秒包含數千條 JSON 記錄。該公司需要在 AWS 上實施一個可擴展的解決方案，以識別異常數據點。哪種解決方案能夠以最少的運營開銷滿足這些要求？

A. 將即時數據導入 Amazon Kinesis 數據流。使用 Amazon Managed Service for Apache Flink 中的內置 RANDOM_CUT_FOREST 函數處理數據流並檢測數據異常。

B. 將即時數據導入 Amazon Kinesis 數據流。部署一個 Amazon SageMaker 端點用於即時異常檢測。創建一個 AWS Lambda 函數來檢測異常。使用數據流調用該 Lambda 函數。

C. 將即時數據導入運行在 Amazon EC2 實例上的 Apache Kafka。部署一個 Amazon SageMaker 端點用於即時異常檢測。創建一個 AWS Lambda 函數來檢測異常。使用數據流調用該 Lambda 函數。

D. 將即時數據發送到 Amazon Simple Queue Service (Amazon SQS) FIFO 隊列。創建一個 AWS Lambda 函數來消費隊列消息。編寫 Lambda 函數以啟動一個 AWS Glue 提取、轉換和加載 (ETL) 作業，用於批處理和異常檢測。

▼ 解答

A

A 正確: Amazon Kinesis 適合處理高吞吐量即時數據。Amazon Managed Service for Apache Flink 提供內置的 RANDOM_CUT_FOREST 函數，可直接用於異常檢測，無需額外開發，運營開銷最低。

B 錯誤: 使用 SageMaker 端點和 Lambda 函數增加了配置和管理的複雜性。

C 錯誤: 在 EC2 上運行 Kafka 增加了管理負擔。

D 錯誤: SQS 不適合高吞吐量流處理，AWS Glue 是批處理工具，不符合即時性要求。

▼ 33

▼ 中文

一家公司擁有大量客戶在產品發布後的聊天記錄。一位機器學習工程師需要創建一個機器學習模型來分析這些聊天數據。該機器學習工程師需要通過審查客戶對產品的情感來確定產品的成功與否。機器學習工程師應該採取哪種行動以用最少的時間完成評估？

- A. 使用 Amazon Rekognition 分析聊天對話的情感。
- B. 訓練一個 Naive Bayes classifier 來分析聊天對話的情感。
- **C. 使用 Amazon Comprehend 分析聊天對話的情感。**
- D. 使用 random forests 分類聊天對話的情感。

▼ 解答

C

A 錯誤: Amazon Rekognition 用於圖像和視頻分析，不適用於文本。

B & D 錯誤: 訓練自定義模型 (樸素貝葉斯或隨機森林) 需要數據預處理、特徵提取和訓練時間，不符合「最少時間」的要求。

C 正確: Amazon Comprehend 是 NLP 服務，支持直接進行情感分析，無需訓練模型，速度最快。

▼ 34

▼ 中文

一家公司擁有一個會話式 AI 助手，該助手通過 Amazon Bedrock 向 Anthropic Claude 大型語言模型 (LLM) 發送請求。用戶報告說，當他們多次

提出類似問題時，有時會收到不同的答案。一位機器學習工程師需要改進響應，使其**更加一致並減少隨機性**。哪種解決方案可以滿足這些要求？

- A. 增加 temperature 參數和 top_k 參數。
- B. 增加 temperature 參數，減少 top_k 參數。
- C. 減少 temperature 參數。增加 top_k 參數。
- D. 減少 temperature 參數和 top_k 參數。

▼ 解答

D

- **Temperature:** 控制隨機性。值越低，結果越確定；值越高，結果越隨機。
- **Top_k:** 限制候選詞數量。值越低，結果越確定。

A & B 錯誤: 增加 Temperature 會增加隨機性。

C 錯誤: 增加 top_k 會擴大候選詞範圍，可能增加隨機性。

D 正確: 減少 Temperature 和 top_k 都能降低隨機性，提高一致性。

▼ 35

▼ 中文

一家公司正在使用機器學習預測農田中某種特定雜草的存在情況。該公司正在使用 Amazon SageMaker 線性學習器內置算法，並將 `predictor_type` 超參數的值設置為 `multiclass_classifier`。

公司應該怎麼做以**最小化**誤報 (False Positives)？

- A. 將 weight decay 超參數的值設置為零。
- B. 增加訓練週期的數量。
- C. 增加 target_precision 超參數的值。
- D. 將 predictor_type 超參數的值更改為 regressor。

▼ 解答

C

A 錯誤: Weight decay 用於正則化，與減少假陽性無直接關係。

B 錯誤: 增加訓練週期不一定能減少假陽性。

C 正確: `target_precision` 用於優化模型的精確度 (Precision)。提高精確度意味著減少假陽性 (False Positives)。

D 錯誤: 將類型改為回歸 (regressor) 會改變問題類型，不符合分類需求。

▼ 36

▼ 中文

一家公司為其電子商務網站的銷售交易實施了數據攝取管道。該公司使用 Amazon Data Firehose 將數據攝取到 Amazon OpenSearch Service。Firehose 流的緩衝時間間隔設置為 60 秒。OpenSearch 線性模型基於數據生成即時銷售預測，並在 OpenSearch 儀表板中展示數據。該公司需要優化數據攝取管道，以支持即時儀表板的亞秒級延遲。對架構進行哪些更改可以滿足這些需求？

- A. 在 Firehose 流中使用零緩衝，調整 PutRecordBatch 操作中使用的批量大小。
- B. 將 Firehose 流替換為 AWS DataSync 任務。使用增強型扇出消費者配置任務。
- C. 將 Firehose 流的緩衝時間間隔從 60 秒增加到 120 秒。
- D. 將 Firehose 流替換為 Amazon Simple Queue Service (Amazon SQS) 隊列。

▼ 解答

A

A 正確: 將 Firehose 緩衝設置為零可以顯著減少延遲，支援亞秒級需求。

B 錯誤: DataSync 用於數據遷移，非即時流處理。

C 錯誤: 增加緩衝時間會增加延遲。

D 錯誤: SQS 是消息隊列，不適合即時流處理管道的低延遲需求。

▼ 37

▼ 中文

一家公司已經在 Amazon SageMaker 中訓練了一個機器學習模型。該公司需要託管該模型以在生產環境中提供推理服務。該模型必須具有高可用性，並且必須以最低的延遲響應。每個請求的大小將在 1KB 到 3MB 之間。模型將在

一天中接收到不可預測的請求突發。推理服務必須根據需求變化進行比例調整。公司應該如何將模型部署到生產環境以滿足這些要求？

- **A.** 創建一個 SageMaker 即時推理端點。配置自動擴展，將端點配置為呈現現有模型。
- **B.** 將模型部署到一個 Amazon Elastic Container Service (Amazon ECS) 集群上，使用基於 ECS 集群 CPU 的 ECS 定時擴展。
- **C.** 在 Amazon Elastic Kubernetes Service (Amazon EKS) 集群上安裝 SageMaker Operator。在 Amazon EKS 中部署模型。設置水平 Pod 自動擴展以基於內存指標擴展副本。
- **D.** 使用 Spot Instances 和一個 Spot Fleet，並將其置於一個 Application Load Balancer (ALB) 後面以進行推理，使用 ALBRequestCountPerTarget 指標作為自動擴展的指標。

▼ 解答

A

A 正確: SageMaker 即時推理端點專為低延遲、高可用性設計，支持自動擴展以應對突發流量。

B 錯誤: ECS 定時擴展無法應對不可預測的突發流量。

C 錯誤: EKS 複雜度高，且基於內存的擴展可能反應不夠迅速。

D 錯誤: Spot Instances 有中斷風險，不適合生產環境的高可用性需求。

▼ 38

▼ 中文

一位機器學習工程師需要使用 Amazon EMR 集群來批量處理大量數據。任何數據丟失都是不可接受的。哪個實例購買選項可以最具成本效益地滿足這些要求？

- A. 將主節點、核心節點和任務節點運行在 On-Demand Instances 上。
- B. 將主節點、核心節點和任務節點運行在 Spot Instances 上。
- C. 將主節點運行在 On-Demand Instance 上，將核心節點和任務節點運行在 Spot Instances 上。
- D. 將主節點和核心節點運行在 On-Demand Instances 上。將任務節點運行在 Spot Instances 上。**

▼ 解答

D

A 錯誤: 全部使用 On-Demand 成本最高。

B & C 錯誤: 核心節點存儲數據 (HDFS)，若使用 Spot Instances 被中斷會導致數據丟失，不符合需求。

D 正確: 主節點和核心節點使用 On-Demand 確保集群穩定和數據安全；任務節點僅負責計算，不存儲數據，使用 Spot Instances 可降低成本且不影響數據完整性。

▼ 39

▼ 中文

一家公司希望改善其機器學習操作的可持續性。以下哪些操作將減少與公司訓練任務相關的能源使用和計算資源？（選擇兩個。）

- **A.** 使用 Amazon SageMaker Debugger 在檢測到非收斂條件時停止訓練任務。
- **B.** 使用 Amazon SageMaker Ground Truth 進行數據標註。
- **C.** 通過使用 AWS Lambda 函數部署模型。
- **D.** 使用 AWS Trainium 實例進行訓練。
- **E.** 使用 PyTorch 或 TensorFlow 的分佈式訓練選項。

▼ 解答

AD

A 正確: SageMaker Debugger 可及早停止無效訓練，節省資源。

D 正確: AWS Trainium 是專為 ML 訓練設計的晶片，能效比高。

B 錯誤: 數據標註與訓練能源消耗無直接關係。

C 錯誤: 這是部署選項，與訓練無關。

E 錯誤: 分佈式訓練可能增加資源使用總量，不一定減少能耗。

▼ 40

▼ 中文

一家公司計劃創建多個機器學習預測模型。訓練數據存儲在 Amazon S3 中。整個數據集超過 5TB，包含 CSV、JSON、Apache Parquet 和簡單文本文件。數據必須經過幾個連續步驟處理。這些步驟包括複雜的操作，可能需要數小時才能完成運行。一些處理涉及自然語言處理 (NLP) 轉換。整個過程必須自動化。哪種解決方案可以滿足這些需求？

A. 在每個步驟使用 Amazon SageMaker Data Wrangler 處理數據，通過使用 Data Wrangler 作業自動化該過程。

B. 為每個數據處理步驟使用 Amazon SageMaker notebooks，通過使用 Amazon EventBridge 自動化該過程。

C. 在每個步驟使用 AWS Lambda 函數處理數據。通過使用 AWS Step Functions 和 Amazon EventBridge 自動化該過程。

D. 使用 Amazon SageMaker Pipelines 創建數據處理步驟的管道。通過使用 Amazon EventBridge 自動化該管道。

▼ 解答

D

D 正確: SageMaker Pipelines 專為構建、管理和自動化複雜的 ML 工作流設計，支持大規模數據處理和長時間運行的任務 (如 NLP)。EventBridge 可用於觸發自動化。

A 錯誤: Data Wrangler 主要用於交互式數據準備，不適合大規模、長時間運行的複雜 NLP 自動化流程。

B 錯誤: Notebooks 適合實驗，不適合生產級自動化管道。

C 錯誤: Lambda 有運行時間限制 (15分鐘)，不適合處理 5TB 數據和耗時數小時的任務。

▼ 41

▼ 中文

一位機器學習工程師需要使用 AWS CloudFormation 創建一個由 Amazon SageMaker 端點託管的機器學習模型。

機器學習工程師應該在 CloudFormation 模板中聲明哪個資源以滿足此需求？

- **A. AWS::SageMaker::Model**
- B. AWS::SageMaker::Endpoint

- C. AWS::SageMaker::NotebookInstance
- D. AWS::SageMaker::Pipeline

▼ 解答

A

A 正確: `AWS::SageMaker::Model` 資源用於定義一個機器學習模型，這是創建 SageMaker 端點的前提條件。

B 錯誤: `AWS::SageMaker::Endpoint` 用於創建端點，但它依賴於已經定義的模型資源。

C 錯誤: `AWS::SageMaker::NotebookInstance` 用於創建筆記本實例進行開發，而非託管模型。

D 錯誤: `AWS::SageMaker::Pipeline` 用於定義工作流管道。

▼ 42

▼ 中文

一家廣告公司使用 AWS Lake Formation 來管理數據湖。數據湖包含結構化數據和非結構化數據。公司的機器學習工程師被分配到特定的廣告活動。機器學習工程師必須通過 Amazon Athena 與數據交互，並直接瀏覽 Amazon S3 存儲桶中的數據。機器學習工程師必須僅能訪問與其分配的廣告活動相關的資源。哪種解決方案可以以最高的操作效率滿足這些要求？

- A. 在 AWS Glue Data Catalog 上配置 IAM 策略，以根據機器學習工程師的活動限制對 Athena 的訪問。
- B. 將用戶和活動信息存儲在 Amazon DynamoDB 表中。配置 DynamoDB Streams 以調用 AWS Lambda 函數來更新 S3 存儲桶策略。
- **C. 使用 Lake Formation 授權 AWS Glue 訪問 S3 存儲桶。配置 Lake Formation 標籤以將機器學習工程師映射到其活動。**
- D. 配置 S3 存儲桶策略，以根據機器學習工程師的活動限制對 S3 存儲桶的訪問。

▼ 解答

C

C 正確: Lake Formation 專為數據湖權限管理設計，支持基於標籤 (Tag-based) 的訪問控制 (LF-TBAC)。這可以同時管理 Athena 對數據目錄的訪問

以及對底層 S3 數據的訪問，操作效率最高。

A 錯誤: IAM 策略管理複雜度高，且不能直接解決 S3 數據瀏覽的細粒度權限。

B 錯誤: 使用 DynamoDB 和 Lambda 動態更新策略過於複雜且效率低。

D 錯誤: 手動管理每個 S3 存儲桶策略效率低，且無法統一管理 Athena 的訪問。

▼ 43

▼ 中文

一位機器學習工程師需要使用 Amazon SageMaker Canvas 中的數據來訓練一個機器學習模型。數據存儲在 Amazon S3 中，並且結構複雜。機器學習工程師必須使用一種文件格式，以最大限度地減少數據的處理時間。

哪種文件格式可以滿足這些要求？

A. CSV files compressed with Snappy

B. JSON objects in JSONL format

C. JSON files compressed with gzip

D. Apache Parquet files

▼ 解答

D

D 正確: Apache Parquet 是一種列式存儲格式，專為高效處理複雜數據結構而設計。它支持壓縮和優化查詢性能，能夠顯著減少處理時間，非常適合機器學習任務。

A, B, C 錯誤: CSV 和 JSON 對複雜結構的支援有限，且解析速度通常慢於 Parquet，不符合最小化處理時間的要求。

▼ 44

▼ 中文

一位機器學習工程師正在評估多個機器學習模型，並且必須選擇一個模型用於生產環境。模型的假陰性 (False Negative) 預測成本遠高於假陽性 (False Positive) 預測成本。

在選擇模型時，機器學習工程師應該最優先考慮哪個指標結果？

- A. Low precision低精確率
- B. High precision高精確率
- C. Low recall低召回率
- D. High recall高召回率**

▼ 解答

D 正確: 召回率 (Recall) 衡量模型捕獲正類樣本的能力。高召回率意味著模型能找出大部分的正類樣本，從而減少假陰性 (False Negative)。當假陰性成本很高時 (例如漏診疾病)，應優先考慮高召回率。

B 錯誤: 高精確率 (Precision) 意味著減少假陽性，適用於假陽性成本高的場景 (例如垃圾郵件誤判)。

▼ 45

▼ 中文

一家公司使用 Amazon SageMaker 訓練並部署了一個機器學習模型。該公司需要實施一個解決方案來記錄和監控 SageMaker 端點的所有 API 調用事件。該解決方案還必須在 API 調用事件數量超過閾值時提供通知。哪個解決方案可以滿足這些要求？

- A. 使用 SageMaker Debugger 跟蹤推斷並報告指標，創建一個自定義規則，當閾值被突破時提供通知。
- B. 使用 SageMaker Debugger 跟蹤推斷並報告指標，使用 `tensor_variance` 內置規則，當閾值被突破時提供通知。
- **C. 通過使用 AWS CloudTrail 記錄所有端點調用 API 事件。使用 Amazon CloudWatch 儀表板進行監控。設置一個 CloudWatch 警報，當閾值被突破時提供通知。**
- D. 將 Invocations 指標添加到 Amazon CloudWatch 儀表板進行監控。設置一個 CloudWatch 警報，當閾值被突破時提供通知。

▼ 解答

C

C 正確: AWS CloudTrail 可以記錄所有的 API 調用事件 (包括 SageMaker 端點調用)。Amazon CloudWatch 可以監控這些日誌並設置告警通知。

D 錯誤: 雖然 Invocations 指標可以監控數量，但題目要求「記錄所有 API 調用事件」(Record all API call events)，這需要 CloudTrail 的日誌功能，而不

僅僅是 CloudWatch 的計數指標。

A, B 錯誤: SageMaker Debugger 用於訓練過程的調試，而非端點 API 調用的監控。

▼ 46

▼ 中文

一家公司有由 AWS Glue 工作流編排的 AWS Glue 數據處理任務。AWS Glue 任務可以按計劃運行，也可以手動啟動。該公司正在 Amazon SageMaker Pipelines 中開發用於機器學習模型開發的管道。這些管道將在模型開發的數據處理階段使用 AWS Glue 任務的輸出。一名機器學習工程師需要實施一個解決方案，將 AWS Glue 任務與管道集成。哪種解決方案能夠以最少的運營開銷滿足這些需求？

- A. 使用 AWS Step Functions 編排管道和 AWS Glue 任務。
- B. 在 SageMaker Pipelines 中使用處理步驟。配置指向 AWS Glue 任務的 Amazon Resource Names (ARNs) 的輸入。
- **C.** 在 SageMaker Pipelines 中使用 Callback 步驟來啟動 AWS Glue 工作流，並在 AWS Glue 任務運行完成之前暫停管道。
- D. 使用 Amazon EventBridge 按所需順序調用管道和 AWS Glue 任務。

▼ 解答

C

C 正確: SageMaker Pipelines 的 Callback 步驟允許管道暫停並等待外部任務 (如 AWS Glue 工作流) 完成後再繼續。這提供了直接的集成且操作開銷最低。

A 錯誤: 引入 Step Functions 會增加額外的編排層和操作開銷。

B 錯誤: Processing steps 無法直接觸發 Glue 工作流，配置 ARN 作為輸入無效。

D 錯誤: EventBridge 用於觸發，難以管理任務間的依賴和狀態同步。

▼ 47

▼ 中文

一家公司正在使用 Amazon Redshift 數據庫作為其單一數據源。一些數據是敏感的。一位數據科學家需要使用數據庫中的一些敏感數據。一名機器學習工程師必須在不轉換源數據且不在數據庫中存儲匿名數據的情況下，給予數據科學家訪問數據的權限。哪種解決方案能夠以最少的實工作量滿足這些要求？

- **A. 配置動態數據屏蔽策略**，以控制敏感數據在查詢時如何與數據科學家共享。
- **B. 在數據庫之上創建一個帶有屏蔽邏輯的物化視圖**。授予數據科學家必要的讀取權限。
- **C. 將 Amazon Redshift 數據卸載到 Amazon S3**。使用 Amazon Athena 創建帶有屏蔽邏輯的 schema-on-read。與數據科學家共享該視圖。
- **D. 將 Amazon Redshift 數據卸載到 Amazon S3**。創建一個 AWS Glue 作業以匿名化數據。與數據科學家共享該數據集。

▼ 解答

A

- **A 正確:** Amazon Redshift 的動態數據屏蔽 (Dynamic Data Masking) 功能允許在查詢時動態屏蔽敏感數據，無需修改源數據或創建額外副本，實工作量最少。
- **B 錯誤:** 物化視圖需要額外的存儲和維護。
- **C, D 錯誤:** 導出數據到 S3 並使用其他服務 (Athena/Glue) 處理，步驟繁瑣且增加了工作量。

▼ 48

▼ 中文

一位機器學習工程師正在使用訓練任務在 Amazon SageMaker Studio 中微調一個深度學習模型。這位機器學習工程師之前曾使用相同的預訓練模型和類似的數據集。

這位機器學習工程師預計會遇到梯度消失、GPU 未充分利用以及過擬合問題。這位機器學習工程師需要實施一個解決方案，**以檢測這些問題並在問題發生時以預定義的方式做出反應。該解決方案還必須在訓練期間提供全面的實時指標**。哪個解決方案可以以**最少的運營開銷**滿足這些要求？

- **A. 使用 TensorBoard 監控訓練任務**。將發現發布到 Amazon Simple Notification Service (Amazon SNS) 主題。創建一個 AWS Lambda 函

數來消費這些發現並啟動預定義的操作。

- B. 使用 Amazon CloudWatch 默認指標來獲取有關訓練任務的洞察。使用這些指標觸發 AWS Lambda 函數以啟動預定義的操作。
- C. 在 Amazon CloudWatch 中擴展指標以包括每個訓練步驟中的梯度。使用這些指標觸發 AWS Lambda 函數以啟動預定義的操作。
- **D. 使用 SageMaker Debugger 內置規則來監控訓練任務。配置這些規則以啟動預定義的操作。**

▼ 解答

D

D 正確: SageMaker Debugger 提供了內置規則來自動檢測梯度消失、過擬合等問題，並能直接配置觸發預定義的操作 (如停止訓練)，操作開銷最低。

A 錯誤: TensorBoard 需手動集成，且不具備自動觸發操作的原生功能。

B, C 錯誤: CloudWatch 默認指標無法監控深層次的模型問題 (如梯度)，自定義指標需額外開發。

▼ 49

▼ 中文

一家信用卡公司在 Amazon SageMaker 端點上運行了一個欺詐檢測模型。該公司開發了該模型的新版本。公司需要使用實時數據評估新模型的性能，同時不影響生產端用戶。哪種解決方案能夠滿足這些需求？

- A. Set up SageMaker Debugger and create a custom rule.
設置 SageMaker Debugger 並創建一個自定義規則。
- B. Set up blue/green deployments with all-at-once traffic shifting.
設置藍/綠部署並進行一次性流量切換。
- C. Set up blue/green deployments with canary traffic shifting.
設置藍/綠部署並進行金絲雀流量切換。
- **D. Set up shadow testing with a shadow variant of the new model.**
設置影子測試並使用新模型影子變體。

▼ 解答

D

D 正確: 影子測試 (Shadow Testing) 允許新模型接收與生產模型相同的實時流量進行推論，但其結果不會返回給用戶，因此完全不影響生產環境，最適合用於評估性能。

B, C 錯誤: 藍/綠部署和金絲雀部署都會將部分或全部流量切換到新模型，若新模型有問題會影響用戶。

A 錯誤: Debugger 用於調試訓練過程，非推論測試。

▼ 50

▼ 中文

一家公司將關於用戶點擊的時間序列數據存儲在一個 Amazon S3 存儲桶中。原始數據每天由數百萬行用戶活動組成。ML 工程師訪問這些數據以開發他們的 ML 模型。ML 工程師需要使用 Amazon Athena 生成每日報告並分析過去 3 天的點擊趨勢。公司必須保留數據 30 天，然後再歸檔數據。哪種解決方案將為數據檢索提供最高性能？

- A. 將所有時間序列數據保留在 S3 存儲桶中，不進行分區。手動將超過 30 天的數據移動到單獨的 S3 存儲桶。
- B. 創建 AWS Lambda 函數，將時間序列數據複製到單獨的 S3 存儲桶中。應用 S3 生命周期策略，將超過 30 天的數據歸檔到 S3 Glacier Flexible Retrieval。
- **C. 按日期前綴將時間序列數據組織成分區存儲在 S3 存儲桶中。應用 S3 生命周期策略，將超過 30 天的分區數據歸檔到 S3 Glacier Flexible Retrieval。**
- D. 將每天的時間序列數據存儲到單獨的 S3 存儲桶中。使用 S3 生命周期策略，將存儲超過 30 天數據的 S3 存儲桶歸檔到 S3 Glacier Flexible Retrieval。

▼ 解答

C

- **C 正確:** 對於 Athena 查詢，按日期分區 (Partitioning) 是提升性能的最佳實踐，因為它能让 Athena 只掃描相關日期的數據。結合 S3 生命周期策略自動歸檔舊數據，既高效又自動化。
- **A 錯誤:** 不分區會導致 Athena 掃描全量數據，性能低下。
- **D 錯誤:** 每天一個 Bucket 會導致管理複雜，且 Athena 跨 Bucket 查詢不便。

▼ 51

▼ 中文

一家公司在銀行應用程式中部署了一個機器學習模型，該模型能夠即時檢測信用卡欺詐交易。該模型使用了 Amazon SageMaker Asynchronous Inference。消費者報告收到推理結果存在延遲。

一名機器學習工程師需要實施一個解決方案來改善推理性能。該解決方案還必須在模型質量出現偏差時提供通知。

哪種解決方案可以滿足這些要求？

- A. 使用 SageMaker real-time inference 進行推理。使用 SageMaker Model Monitor 提供關於模型質量的通知。
- B. 使用 SageMaker batch transform 進行推理。使用 SageMaker Model Monitor 提供關於模型質量的通知。
- C. 使用 SageMaker Serverless Inference 進行推理。使用 SageMaker Inference Recommender 提供關於模型質量的通知。
- D. 繼續使用 SageMaker Asynchronous Inference 進行推理。使用 SageMaker Inference Recommender 提供關於模型質量的通知。

▼ 解答

A

- **A 正確:** 實時推理（real-time inference）適用於需要低延遲的場景，例如即時檢測信用卡欺詐交易，它比異步推理更快。SageMaker Model Monitor 可以監控模型質量，檢測數據漂移或模型性能下降並發送通知。
- **B 錯誤:** 批量轉換（batch transform）適用於離線處理大批量數據，不適合實時場景，無法解決延遲問題。
- **C 錯誤:** 無伺服器推理（Serverless Inference）在高負載實時場景下可能不如實時推理性能穩定。Inference Recommender 用於推薦配置而非監控質量。
- **D 錯誤:** 異步推理（Asynchronous Inference）適用於高延遲容忍的場景，不適合此案例。

▼ 52

▼ 中文

一位機器學習工程師需要實施一個解決方案來託管訓練好的機器學習模型。一天中的請求率會不一致。

這位機器學習工程師需要一個可擴展的解決方案，在模型未使用時能夠最大限度地降低成本。該解決方案還必須在高峰使用時保持模型響應請求的能力。

哪種解決方案能夠滿足這些要求？

- A. 創建具有固定並發性的 AWS Lambda 函數來託管模型。配置 Lambda 函數以根據模型的請求數量自動擴展。
- B. 將模型部署在使用 AWS Fargate 的 Amazon Elastic Container Service (Amazon ECS) 集群上。設置一個固定數量的任務以在高峰使用時處理請求。
- C. 將模型部署到 Amazon SageMaker 端點。將模型的多個副本部署到端點。創建一個 Application Load Balancer 來在端點的不同模型副本之間路由流量。
- D. 將模型部署到 Amazon SageMaker 端點。創建基於 Amazon CloudWatch 指標的 SageMaker 端點自動擴展策略，以動態調整實例數量。

▼ 解答

D

- **D 正確:** Amazon SageMaker 端點支持自動擴展，可以根據 Amazon CloudWatch 指標動態調整實例數量。這既能應對不一致的請求負載，又能在模型不使用時最小化成本。
- **A 錯誤:** Lambda 執行時間有限制且不支持 GPU，不適合託管需要持續運行的 ML 模型。
- **B 錯誤:** 靜態任務數量無法動態調整資源，會導致資源浪費或高峰期無法滿足需求。
- **C 錯誤:** SageMaker 本身支持自動擴展和流量管理，無需額外的 ALB。

▼ 53

▼ 中文

一家公司使用 Amazon SageMaker Studio 開發一個機器學習模型。該公司擁有一個單一的 SageMaker Studio 域。機器學習工程師需要實現一個解決

方案，當 SageMaker 計算成本達到特定閾值時，能夠自動發送警報。
哪種解決方案可以滿足這些要求？

- A. 通過編輯 SageMaker 域中的 SageMaker 用戶配置文件添加資源標籤。配置 AWS Cost Explorer，當達到閾值時發送警報。
- B. 通過編輯 SageMaker 域中的 SageMaker 用戶配置文件添加資源標籤。配置 AWS Budgets，當達到閾值時發送警報。
- C. 通過編輯每個用戶的 IAM 配置文件添加資源標籤。配置 AWS Cost Explorer，當達到閾值時發送警報。
- D. 通過編輯每個用戶的 IAM 配置文件添加資源標籤。配置 AWS Budgets，當達到閾值時發送警報。

▼ 解答

B

- **B 正確:** 資源標籤可以通過編輯 SageMaker 用戶配置文件添加，AWS Budgets 是專門設計用於設置預算和警報的工具。
- **A 錯誤:** AWS Cost Explorer 本身不支持直接發送警報功能。
- **C, D 錯誤:** 資源標籤應在 SageMaker 用戶配置文件中設置，而非 IAM 配置文件。

▼ 54

▼ 中文

一家公司使用 Amazon SageMaker 進行其機器學習工作負載。公司的機器學習工程師收到一個 50 MB 的 Apache Parquet 數據文件，用於構建欺詐檢測模型。該文件包含幾個相關的列，這些列並不是必須的。

機器學習工程師應該怎麼做才能以最少的工作量刪除文件中不必要的列？

- A. 將文件下載到本地工作站。使用自定義 Python 腳本執行獨熱編碼。
- B. 創建一個 Apache Spark 作業，在 Amazon EMR 上使用自定義處理腳本。
- C. 通過調用 SageMaker Python SDK 創建一個 SageMaker 處理作業。
- D. 在 SageMaker Data Wrangler 中創建一個數據流。配置一個轉換步驟。

▼ 解答

D

- **D 正確:** SageMaker Data Wrangler 提供了一個可視化界面，可以輕鬆處理數據（低代碼），包括刪除不必要的列，符合「最少工作量」的要求。
- **A 錯誤:** 下載到本地處理違背了高效原則。
- **B, C 錯誤:** EMR 和 Processing Job 需要編寫額外代碼和配置，複雜度較高。

▼ 55

▼ 中文

一家公司正在創建一個應用程序，該應用程序將推薦客戶購買的產品。該應用程序將調用 Amazon Q Business 的 API。公司必須確保來自 Amazon Q Business 的響應不包含公司主要競爭對手的名稱。

哪種解決方案可以滿足此要求？

- A. 在 Amazon Q Business 中將競爭對手的名稱配置為一個屏蔽短語。
- B. 配置一個 Amazon Q Business 檢索器以排除競爭對手的名稱。
- C. 為 Amazon Q Business 配置一個 Amazon Kendra 檢索器，以構建排除競爭對手名稱的索引。
- D. 在 Amazon Q Business 中配置文檔屬性提升以降低競爭對手名稱的優先級。

▼ 解答

A

- **A 正確:** Amazon Q Business 支持配置屏蔽短語 (blocked phrases)，可以直接阻止特定的詞或短語出現在響應中。
- **B, C 錯誤:** 這些選項描述的功能在 Amazon Q Business 中不直接適用或過於間接。
- **D 錯誤:** 屬性提升 (Boosting) 只是調整優先級，無法確保完全屏蔽。

▼ 56

▼ 中文

一位機器學習工程師需要使用 Amazon SageMaker 來微調一個用於文本摘要的大型語言模型 (LLM)。該機器學習工程師必須遵循低代碼無代碼 (LCNC) 方

法。哪種解決方案可以滿足這些要求？

- A. 使用 SageMaker Studio 微調一個部署在 Amazon EC2 實例上的 LLM。
- B. 使用 SageMaker Autopilot 微調一個通過自定義 API 端點部署的 LLM。
- C. 使用 SageMaker Autopilot 微調一個部署在 Amazon EC2 實例上的 LLM。
- D. 使用 SageMaker Autopilot 微調一個通過 SageMaker JumpStart 部署的 LLM。

▼ 解答

D

D 正確: SageMaker JumpStart 提供了預訓練模型，可以直接部署和微調。SageMaker Autopilot 與 JumpStart 集成，支持自動化的微調流程，符合 LCNC 要求。

A, B, C 錯誤: 這些選項涉及 EC2 部署或自定義 API，不符合低代碼/無代碼的要求。

▼ 57

▼ 中文

一家公司有一個機器學習模型需要每晚運行一次以預測股票價值。模型的輸入是當天收集的 3 MB 數據。模型生成第二天的預測結果。預測過程運行時間少於 1 分鐘。公司應該如何在 Amazon SageMaker 上部署模型以滿足這些要求？

- A. 使用多模型無伺服器端點。啟用緩存。
- B. 使用異步推理端點。將 InitialInstanceCount 參數設置為 0。
- C. 使用實時端點。配置自動縮放策略，當模型未使用時將模型縮放到 0。
- D. 使用無伺服器推理端點。將 MaxConcurrency 參數設置為 1。

▼ 解答

D

- **D 正確:** 無伺服器推理端點專為間歇性或低頻使用場景設計，按需啟動，避免了持續運行實例的成本。設置 MaxConcurrency 為 1 適合這種單次運行的需求。
- **A 錯誤:** 題目僅涉及單一模型，不需要多模型端點。
- **B 錯誤:** 異步推理適用於處理時間較長或大數據量的請求，此場景運行時間短，不適合。
- **C 錯誤:** 實時端點成本較高，且縮放策略較為複雜。

▼ 58

▼ 中文

一位機器學習工程師使用 Amazon SageMaker 訓練了一個機器學習模型，用於從閉路電視畫面中檢測汽車事故。該機器學習工程師使用 SageMaker Data Wrangler 創建了一個包含事故和非事故圖像的訓練數據集。該模型在訓練和驗證期間表現良好。然而，由於來自不同攝像頭的圖像質量存在差異，該模型在生產環境中的表現不佳。哪種解決方案能在最短時間內提高模型的準確性？

- A. 從所有攝像頭收集更多圖像。使用 Data Wrangler 準備一個新的訓練數據集。
- B. 使用 Data Wrangler 的損壞圖像轉換重新創建訓練數據集。指定脈衝噪聲選項。
- C. 使用 Data Wrangler 的增強圖像對比度轉換重新創建訓練數據集。指定 Gamma 對比選項。
- D. 使用 Data Wrangler 的調整圖像大小轉換重新創建訓練數據集。將所有圖像裁剪為相同大小。

▼ 解答

B

- **B 正確:** 使用「損壞圖像轉換」並添加噪聲可以模擬生產環境中攝像頭圖像質量的變化，增強模型的魯棒性，這是一個快速且有效的解決方案。
- **A 錯誤:** 收集更多數據耗時較長。
- **C 錯誤:** 增強對比度不能解決噪聲或質量變異問題。
- **D 錯誤:** 調整大小與圖像質量變異無關。

▼ 59

▼ 中文

一家公司有一個應用程式，該應用程式使用不同的 API 來生成輸入文本的嵌入。該公司需要實施一個解決方案，每 3 個月自動輪換 API 令牌。哪種解決方案可以滿足此要求？

- A. 將令牌存儲在 AWS Secrets Manager 中。創建一個 AWS Lambda 函數來執行輪換。
- B. 將令牌存儲在 AWS Systems Manager Parameter Store 中。創建一個 AWS Lambda 函數來執行輪換。
- C. 將令牌存儲在 AWS Key Management Service (AWS KMS) 中。使用 AWS 託管密鑰來執行輪換。
- D. 將令牌存儲在 AWS Key Management Service (AWS KMS) 中。使用 AWS 擁有的密鑰來執行輪換。

▼ 解答

A

- **A 正確:** AWS Secrets Manager 專為存儲敏感信息（如 API 令牌）設計，並原生支持自動輪換（可結合 Lambda 函數）。
- **B 錯誤:** Parameter Store 不支持原生的自動輪換功能。
- **C, D 錯誤:** KMS 用於加密密鑰管理，而非直接存儲和輪換 API 令牌。

▼ 60

▼ 中文

名機器學習工程師收到包含缺失值、重複值和極端異常值的數據集。該工程師必須將這些數據集整合到一個單一的數據框中，並為機器學習準備數據。哪種解決方案可以滿足這些要求？

- A. 使用 Amazon SageMaker Data Wrangler 導入數據集並將其整合到一個單一的數據框中。使用清洗和增強功能來準備數據。
- B. 使用 Amazon SageMaker Ground Truth 導入數據集並將其整合到一個單一的數據框中。使用人工參與功能來準備數據。

- C. 手動導入並合併數據集。將數據集整合到一個單一的數據框中。使用 Amazon Q Developer 生成代碼片段以準備數據。
- D. 手動導入並合併數據集。將數據集整合到一個單一的數據框中。使用 Amazon SageMaker data labeling 來準備數據。

▼ 解答

A

- **A 正確:** SageMaker Data Wrangler 專門用於數據預處理，提供導入、整合、清洗（處理缺失值、重複值、異常值）的功能。
- **B, D 錯誤:** Ground Truth 和 Data Labeling 主要用於數據標註，非數據清洗。
- **C 錯誤:** 手動處理效率低且易出錯。

▼ 61

▼ 中文

一家公司擁有歷史數據，顯示客戶是否需要公司員工的長期支持。該公司需要開發一個ML模型來預測新客戶是否需要長期支持。
該公司應使用哪種建模方法來滿足這一需求？

- A. Anomaly detection
異常檢測
- B. Linear regression
線性回歸
- **C. Logistic regression**
邏輯回歸
- D. Semantic segmentation
語義分割

▼ 解答

C

題目分析與解答:

1. 考察的知識點

本題考察的是機器學習模型的選擇，特別是針對分類問題的模型選擇。

需要理解不同模型的用途，例如邏輯回歸用於二分類問題，線性回歸用於回歸問題，異常檢測用於識別異常模式，語義分割用於圖像處理。

2. 選項分析

- **A. Anomaly detection 異常檢測:**
異常檢測通常用於識別數據中的異常模式或異常行為，例如欺詐檢測或設備故障預測。題目要求預測客戶是否需要長期支持，這是一個二分類問題，而不是異常檢測問題。因此此選項錯誤。
- **B. Linear regression 線性回歸:**
線性回歸用於預測連續數值型變量，例如房價或溫度。題目要求預測客戶是否需要長期支持，這是一個分類問題，而不是回歸問題。因此此選項錯誤。
- **C. Logistic regression 邏輯回歸:**
邏輯回歸是一種常用的二分類模型，適用於預測某個事件是否會發生，例如客戶是否需要長期支持。此選項正確。
- **D. Semantic segmentation 語義分割:**
語義分割是一種圖像處理技術，用於將圖像中的每個像素分類為特定類別。題目與圖像處理無關，因此此選項錯誤。

▼ 62

▼ 中文

一位機器學習工程師在 Amazon SageMaker 之外開發了一個二分類模型。該機器學習工程師需要使模型對 SageMaker Canvas 用戶可用，以進行額外的調優。

模型文件存儲在一個 Amazon S3 存儲桶中。機器學習工程師和 Canvas 用戶屬於同一個 SageMaker 域。

為了使機器學習工程師能夠與 Canvas 用戶共享模型，必須滿足哪些要求的組合？（選擇兩個。）

- A. 機器學習工程師和 Canvas 用戶必須位於不同的 SageMaker 域中。
- B. Canvas 用戶必須擁有訪問存儲模型文件的 S3 存儲桶的權限。
- C. 模型必須在 SageMaker Model Registry 中註冊。
- D. 機器學習工程師必須在 AWS Marketplace 上託管模型。
- E. 機器學習工程師必須將模型部署到 SageMaker 端點。

▼ 解答

BC

- 考察的知識點

- Amazon SageMaker Canvas的使用和權限管理。
- 如何共享模型文件並使其可訪問。
- Amazon S3權限設置。
- SageMaker Model Registry的功能和用途。

- 選項分析

- **A. The ML engineer and the Canvas user must be in separate SageMaker domains.**

錯誤：題目明確指出ML工程師和Canvas用戶在同一個SageMaker域中，因此這個選項與題目條件不符。

- **B. The Canvas user must have permissions to access the S3 bucket where the model artifacts are stored.**

正確：Canvas用戶需要訪問存儲模型文件的S3存儲桶權限，否則無法加載模型進行進一步操作。

- **C. The model must be registered in the SageMaker Model Registry.**

正確：SageMaker Model Registry是用於管理和共享模型的工具，註冊模型後可以方便地與其他用戶共享。

- **D. The ML engineer must host the model on AWS Marketplace.**

錯誤：AWS Marketplace是用於發布和銷售模型的市場，與題目要求的共享模型給Canvas用戶無關。

- **E. The ML engineer must deploy the model to a SageMaker endpoint.**

錯誤：雖然部署到SageMaker端點可以使模型可用，但題目並未要求模型必須被部署到端點，且Canvas用戶可以直接使用模型文件或註冊的模型。

▼ 63

▼ 中文

一家公司正在 Amazon SageMaker 上構建一個深度學習模型。該公司使用大量數據作為訓練數據集。公司需要優化模型的超參數，以最小化驗證數據集上的損失函數。

哪種超參數調優策略可以用最少的計算時間實現這一目標？

- A. Hyperband
- B. Grid search
- C. Bayesian optimization
- D. Random search

▼ 解答

A

• 考察的知識點

本題考察的是 Amazon SageMaker 中的超參數調優策略，以及如何選擇最有效的調優方法以減少計算時間。

• 選項分析

◦ **A. Hyperband:**

Hyperband 是一種高效的超參數調優方法，它通過動態分配資源來快速篩選出表現較好的超參數組合。它能夠在最少的計算時間內找到最優解，因此是正確答案。

◦ **B. Grid search:**

網格搜索會嘗試所有可能的超參數組合，計算成本非常高，尤其是在數據量大或超參數空間較大的情況下。因此，這不是最優選擇。

◦ **C. Bayesian optimization:**

貝葉斯優化是一種智能搜索方法，能夠通過概率模型預測最優超參數組合。雖然它比網格搜索和隨機搜索更高效，但在某些情況下計算時間可能仍然較長，尤其是數據量非常大的時候。

◦ **D. Random search:**

隨機搜索通過隨機選擇超參數組合進行訓練，雖然比網格搜索更高效，但它無法保證找到最優解，且計算時間可能仍然較長。

▼ 64

▼ 中文

一家公司計劃在其主要 AWS 帳戶中使用 Amazon Redshift ML。源數據位於次要帳戶的 Amazon S3 存儲桶中。一名機器學習工程師需要在主要帳戶中設置一個機器學習管道，以訪問次要帳戶中的 S3 存儲桶。解決方案必須不需要公共 IPv4 地址。哪種解決方案可以滿足這些要求？

- A. 在主要帳戶中，在未啟用公共訪問的 VPC 中預置一個 Redshift 集群和 Amazon SageMaker Studio。在帳戶之間創建一個 VPC 對等連接。更新 VPC 路由表以移除到 0.0.0.0/0 的路由。
- B. 在主要帳戶中，在未啟用公共訪問的 VPC 中預置一個 Redshift 集群和 Amazon SageMaker Studio。創建一個 AWS Direct Connect 連接和一個 Transit Gateway。將兩個帳戶的 VPC 與 Transit Gateway 關聯。更新 VPC 路由表以移除到 0.0.0.0/0 的路由。
- C. 在主要帳戶中，在 VPC 中預置一個 Redshift 集群和 Amazon SageMaker Studio。在帳戶之間創建一個 AWS Site-to-Site VPN 連接，並設置兩個加密的 IPsec 隧道。為 Amazon S3 設置接口 VPC 端點。
- **D. 在主要帳戶中，在 VPC 中預置一個 Redshift 集群和 Amazon SageMaker Studio。創建一個 S3 網關端點。更新 S3 存儲桶策略以允許來自主要帳戶的 IAM 主體。為 SageMaker 和 Amazon Redshift 設置接口 VPC 端點。**

▼ 解答

D

選項 D：最優解 (Correct Answer)

這是最符合 AWS 最佳實踐且成本效益最高的方案。

S3 網關端點 (S3 Gateway Endpoint)：允許 VPC 內的服務（如 Redshift）通過 AWS 內部網路訪問 S3，無需經過公網或 NAT 網關，直接解決了「不需要公共 IPv4」的要求。

跨帳戶權限設置：通過更新次要帳戶的 S3 Bucket Policy，明確授權主要帳戶的 IAM Role（Redshift 或 SageMaker 使用的角色）訪問權限，這是跨帳戶資源共享的標準做法。

接口 VPC 端點 (Interface VPC Endpoints)：讓 SageMaker Studio 和 Redshift 的控制台/API 請求能留在私有網路內處理，確保了整條路徑的私密性。

選項 A：VPC Peering (錯誤原因：架構過度複雜且方向錯誤)

解析：VPC Peering (對等連接) 通常用於兩個 VPC 之間的內部 IP 通訊。

錯誤點：S3 是一個全域服務 (Public Service)，並不在 VPC 內部。雖然可以使用 Peering 配合某些路由，但這不是訪問 S3 的標準做法。此外，單純移除 0.0.0.0/0 路由而不設置 S3 Endpoint，會導致所有 AWS 服務調用中斷。

選項 B：Direct Connect 與 Transit Gateway (錯誤原因：成本極高且不適用)

解析：Direct Connect (DX) 是用於連接「本地數據中心」與 AWS 的物理專線；Transit Gateway 用於多 VPC 的大規模聯網。

錯誤點：本題的情境是「兩個 AWS 帳戶之間」的雲端通訊，完全不需要用到物理專線 (DX)。這屬於「殺雞用牛刀」，且 DX 並不直接解決 S3 訪問的私密性問題。

選項 C：Site-to-Site VPN (錯誤原因：通訊路徑冗餘且不必要)

解析：VPN 用於建立加密的隧道，通常也是用於連接本地辦公室與雲端。

錯誤點：在兩個 AWS 帳戶之間建立 VPN 隧道來訪問 S3 是非常低效且維護成本高昂的做法。雖然它提到了接口端點，但建立 IPsec 隧道的基礎架構要求完全偏離了「雲原生跨帳戶訪問」的簡便性。

▼ 65

▼ 中文

一家公司正在使用 AWS Lambda 函數來監控來自機器學習模型的指標。機器學習工程師需要實現一個解決方案，當指標超出閾值時發送電子郵件消息。哪種解決方案可以滿足此需求？

- A. 將指標從 Lambda 函數記錄到 AWS CloudTrail。配置一個 CloudTrail 路徑以發送電子郵件消息。
- B. 將指標從 Lambda 函數記錄到 Amazon CloudFront。配置一個 Amazon CloudWatch 警報以發送電子郵件消息。
- **C. 將指標從 Lambda 函數記錄到 Amazon CloudWatch。配置一個 CloudWatch 警報以發送電子郵件消息。**
- D. 將指標從 Lambda 函數記錄到 Amazon CloudWatch。配置一個 Amazon CloudFront 規則以發送電子郵件消息。

▼ 解答

C

• 考察的知識點

- 如何使用AWS服務監控和記錄指標。
- 如何配置AWS服務（如CloudWatch）以觸發警報和發送通知。
- 熟悉AWS Lambda其他服務的集成。

• 選項分析

- **A. Log the metrics from the Lambda function to AWS CloudTrail. Configure a CloudTrail trail to send the email message.**

錯誤原因：CloudTrail主要用於記錄API調用和帳戶活動，而不是監控指標。它無法直接用於觸發警報或發送電子郵件。

- **B. Log the metrics from the Lambda function to Amazon CloudFront. Configure an Amazon CloudWatch alarm to send the email message.**

錯誤原因：CloudFront是一個內容分發網絡服務，主要用於分發內容和優化性能，而不是記錄或監控指標。此選項與題目要求不符。

- **C. Log the metrics from the Lambda function to Amazon CloudWatch. Configure a CloudWatch alarm to send the email message.**

正確原因：CloudWatch是AWS的監控服務，可以記錄指標並設置警報。當指標超過閾值時，可以通過SNS發送電子郵件通知。

- **D. Log the metrics from the Lambda function to Amazon CloudWatch. Configure an Amazon CloudFront rule to send the email message.**

錯誤原因：CloudFront規則與監控指標無關，無法用於發送電子郵件通知。此選項與題目要求不符。

▼ 66

▼ 中文

一家公司使用 Amazon SageMaker 在生產環境中部署了一個預測機器學習模型。該公司在模型上使用了 SageMaker Model Monitor。模型更新後，一位

機器學習工程師注意到 Model Monitor 檢查中存在數據質量問題。
機器學習工程師應該如何緩解 Model Monitor 識別出的數據質量問題？

- A. 調整模型的參數和超參數。
- B. 啟動一個使用最新生產數據的手動 Model Monitor 作業。
- **C. 從最新的數據集創建一個新的基線。更新 Model Monitor 以使用新的基線進行評估。**
- D. 在模型的現有訓練集裡包含額外的數據。重新訓練並重新部署模型。

▼ 解答

C

- **考察的知識點**

- Amazon SageMaker Model Monitor的功能與使用，包括基線數據的創建和更新。
- 如何處理生產環境中模型的質量問題。

- **選項分析**

- **A. 調整模型的參數和超參數。**
錯誤原因：數據質量問題通常與輸入數據的分佈或特徵有關，而不是模型的參數或超參數。調整模型參數無法直接解決數據質量問題。
- **B. 啟動一個使用最新生產數據的手動 Model Monitor 作業。**
錯誤原因：手動運行 Model Monitor作業可以幫助檢查數據質量問題，但無法解決問題。需要更新基線數據以適應新的數據分佈。
- **C. 從最新的數據集創建一個新的基線。更新 Model Monitor 以使用新的基線進行評估。**
正確原因：Model Monitor使用基線數據來評估生產數據的質量。如果數據分佈發生變化，創建新的基線並更新Model Monitor是解決數據質量問題的正確方法。
- **D. 在模型的現有訓練集裡包含額外的數據。重新訓練並重新部署模型。**
錯誤原因：重新訓練模型可能是解決模型性能問題的步驟，但題目明確指出的是數據質量問題，而不是模型性能問題。重新訓練模型並不能直接解決數據質量問題。

▼ 67

▼ 中文

一家公司擁有一個機器學習模型，該模型根據客戶上傳到公司網站的圖像生成文本描述。圖像總大小可達 50 MB。

一名機器學習工程師決定將圖像存儲在一個 Amazon S3 bucket 中。該工程師必須實施一個能夠根據需求變化進行擴展的處理解決方案。

哪種解決方案能夠以最低的運營開銷滿足這些需求？

- A. 創建一個 Amazon SageMaker 批量轉換作業來處理 S3 bucket 中的所有圖像。
- B. 創建一個 Amazon SageMaker 異步推理端點和一個擴展策略。運行一個腳本為每張圖像發起推理請求。
- C. 創建一個使用 Karpenter 進行自動擴展的 Amazon Elastic Kubernetes Service (Amazon EKS) 集群。在 EKS 集群上託管模型。運行一個腳本為每張圖像發起推理請求。
- D. 創建一個使用 Amazon Elastic Container Service (Amazon ECS) 集群的 AWS Batch 作業。為每個 AWS Batch 作業指定一個要處理的圖像列表。

▼ 解答

B

- **考察的知識點**
 - Amazon SageMaker 的異步推理功能及其擴展能力。
 - 如何選擇合適的 AWS 服務以滿足動態需求和最小化操作開銷。
 - 對比 AWS 服務的特性，例如 SageMaker、EKS、Batch 等。
- **選項分析**
 - **A. Create an Amazon SageMaker batch transform job to process all the images in the S3 bucket.**
錯誤原因：Batch Transform 適用於批量處理靜態數據集，但不適合動態需求的場景。它無法根據需求變化自動擴展，且需要手動管理作業提交，操作開銷較高。
 - **B. Create an Amazon SageMaker Asynchronous Inference endpoint and a scaling policy. Run a script to make an inference request for each image.**

正確原因：異步推理端點支持處理大規模、動態的推理請求，並且可以通過自動擴展策略輕鬆適應需求變化。操作開銷低，且直接支持S3作為輸入源。

- **C. Create an Amazon Elastic Kubernetes Service (Amazon EKS) cluster that uses Karpenter for auto scaling. Host the model on the EKS cluster. Run a script to make an inference request for each image.**

錯誤原因：雖然EKS和Karpenter可以實現自動擴展，但設置和維護EKS集群的操作開銷較高。對比SageMaker，EKS需要更多的管理工作，不符合“最小操作開銷”的要求。

- **D. Create an AWS Batch job that uses an Amazon Elastic Container Service (Amazon ECS) cluster. Specify a list of images to process for each AWS Batch job.**

錯誤原因：AWS Batch適用於批量任務處理，但不適合實時或動態需求的場景。需要手動管理任務隊列和作業提交，操作開銷較高。

▼ 68

▼ 中文

一位機器學習工程師需要使用 AWS 服務來識別並提取文檔中的有意義的唯一關鍵詞。哪種解決方案能夠以最少的運營開銷滿足這些需求？

- A. 在 Amazon EC2 實例上使用 Natural Language Toolkit (NLTK) 庫進行文本預處理。使用 Latent Dirichlet Allocation (LDA) 算法識別並提取相關關鍵詞。
- B. 使用 Amazon SageMaker 和 BlazingText 算法。應用自定義預處理步驟進行詞幹提取和停用詞移除。計算詞頻-逆文檔頻率 (TF-IDF) 分數以識別並提取相關關鍵詞。
- C. 將文檔存儲在 Amazon S3 桶中。創建 AWS Lambda 函數來處理文檔並運行用於詞幹提取和停用詞移除的 Python 腳本。使用二元組和三元組技術識別並提取相關關鍵詞。
- **D. 使用 Amazon Comprehend 的自定義實體識別和關鍵短語提取功能來識別並提取相關關鍵詞。**

▼ 解答

D

- **考察的知識點**

本題考察的是AWS服務在自然語言處理（NLP）中的應用，特別是如何使用AWS服務以最低的操作開銷完成關鍵詞提取任務。

涉及的服務包括Amazon Comprehend、Amazon SageMaker、Amazon EC2、AWS Lambda等。

- **選項分析**

- **A. 使用Natural Language Toolkit (NLTK)庫和Latent Dirichlet Allocation (LDA)算法：**

正確性分析：NLTK和LDA是強大的工具，但需要在Amazon EC2實例上運行，這會增加操作開銷（例如實例管理、擴展、維護等）。

錯誤原因：雖然可以實現關鍵詞提取，但操作開銷較高，不符合題目要求的“LEAST operational overhead”。

- **B. 使用Amazon SageMaker和BlazingText算法：**

正確性分析：Amazon SageMaker是一個託管的機器學習服務，BlazingText算法可以用於文本處理。然而，題目要求關鍵詞提取，而BlazingText主要用於文本分類和嵌入。

錯誤原因：需要自定義預處理步驟（例如詞幹提取和停用詞移除），增加了操作複雜性。此外，BlazingText並非專門設計用於關鍵詞提取。

- **C. 使用Amazon S3和AWS Lambda：**

正確性分析：AWS Lambda可以實現無服務器計算，結合Python腳本可以完成關鍵詞提取任務。然而，這種方法需要手動編寫和維護代碼，增加了開發和維護的複雜性。

錯誤原因：雖然操作開銷較低，但仍需要手動實現關鍵詞提取邏輯，不如使用專門的服務（如Amazon Comprehend）直接完成任務。

- **D. 使用Amazon Comprehend：**

正確性分析：Amazon Comprehend是一個託管的自然語言處理服務，提供內置的關鍵短語提取功能，可以直接用於關鍵詞提取任務。

正確原因：無需額外的預處理或算法開發，操作開銷最低，完全符合題目要求。

▼ 69

▼ 中文

一家公司需要為其機器學習工程師提供適當的訓練數據訪問權限。機器學習工程師只能訪問屬於自己業務組的訓練數據。機器學習工程師不得訪問其他業務

組的訓練數據。

該公司使用單一的 AWS 帳戶，並將所有訓練數據存儲在 Amazon S3 存儲桶中。所有機器學習模型訓練均在 Amazon SageMaker 中進行。哪種解決方案可以為機器學習工程師提供適當的訪問權限？

- A. 啟用 S3 存儲桶版本控制。
- B. 為每個用戶配置 S3 Object Lock 設置。
- C. 向 S3 存儲桶添加跨域資源共享 (CORS) 策略。
- D. 創建 IAM 策略。將策略附加到 IAM 用戶或 IAM 角色。

▼ 解答

D

- **考察的知識點**

本題考察的是AWS Identity and Access Management (IAM)的使用，以及如何通過IAM策略控制對Amazon S3存儲桶的訪問權限。

重點在於如何為不同的用戶或角色設置訪問權限，以確保數據隔離和安全性。

- **選項分析**

- **A. Enable S3 bucket versioning. 啟用 S3 存儲桶版本控制。**
錯誤。S3存儲桶版本控制用於跟蹤對象的歷史版本，防止意外刪除或覆蓋數據，與訪問控制無關，無法解決不同業務組之間的數據隔離問題。
- **B. Configure S3 Object Lock settings for each user. 為每個用戶配置 S3 Object Lock 設置。**
錯誤。S3 Object Lock用於防止對象被刪除或覆蓋，主要用於數據保護和合規性，與用戶訪問權限管理無關。
- **C. Add cross-origin resource sharing (CORS) policies to the S3 buckets. 向 S3 存儲桶添加跨域資源共享 (CORS) 策略。**
錯誤。CORS策略用於控制跨域訪問，通常用於Web應用程序的前端與S3的交互，與用戶權限管理無關。
- **D. Create IAM policies. Attach the policies to IAM users or IAM roles. 創建 IAM 策略。將策略附加到 IAM 用戶或 IAM 角色。**
正確。通過創建IAM策略，可以精確控制用戶或角色對S3存儲桶的訪問權限。可以根據業務組的需求設置策略，確保每個組只能訪問自己的數據。

▼ 70

▼ 中文

一家公司需要託管一個自定義的機器學習模型以執行預測分析。預測分析將在每天相同的 2 小時期間內以可預測且持續的負載進行。在分析期間的多次調用將需要快速響應。公司需要 **AWS 來管理底層基礎設施以及任何自動擴展活動**。哪種解決方案可以滿足這些需求？

- A. 使用 AWS Lambda 調度一個 Amazon SageMaker 批量轉換作業。
- B. 配置一個 Amazon EC2 實例的 Auto Scaling 組以使用計劃擴展。
- **C. 使用 Amazon SageMaker Serverless Inference 並配置預置並發。**
- D. 在 Amazon EC2 上的 Amazon Elastic Kubernetes Service (Amazon EKS) 集群上運行模型，並使用 pod 自動擴展。

▼ 解答

C

- **考察的知識點**
 - Amazon SageMaker 的功能，包括 Serverless Inference 和批量轉換。
 - 自動擴展 (Auto Scaling) 的概念和應用。
 - 如何選擇適合的 AWS 服務來滿足特定的機器學習工作負載需求。
- **選項分析**
 - **A. Schedule an Amazon SageMaker batch transform job by using AWS Lambda.**
錯誤原因：Amazon SageMaker 的批量轉換作業適用於離線處理大規模數據集，而不是實時響應的場景。題目要求“快速響應”，批量轉換不適合。
 - **B. Configure an Auto Scaling group of Amazon EC2 instances to use scheduled scaling.**
錯誤原因：雖然 EC2 實例可以通過 Auto Scaling 實現計劃擴展，但這需要公司自行管理基礎設施，違背了題目中“需要 AWS 管理基礎設施”的要求。

- **C. Use Amazon SageMaker Serverless Inference with provisioned concurrency.**

正確原因：Amazon SageMaker Serverless Inference支持無服務器部署，AWS會管理基礎設施。通過配置預置並發，可以確保在高負載期間快速響應請求，完全符合題目要求。

- **D. Run the model on an Amazon Elastic Kubernetes Service (Amazon EKS) cluster on Amazon EC2 with pod auto scaling.**

錯誤原因：使用Amazon EKS需要公司自行管理集群和基礎設施，違背了題目中“需要AWS管理基礎設施”的要求。

▼ 71

▼ 中文

一家公司的機器學習工程師已將一個用於情感分析的機器學習模型部署到一個 Amazon SageMaker 端點。該機器學習工程師需要向公司利益相關者解釋模型如何進行預測。哪種解決方案可以為模型的預測提供解釋？

- A. 在已部署的模型上使用 SageMaker Model Monitor。
- **B. 在已部署的模型上使用 SageMaker Clarify。**
- C. 在 Amazon CloudWatch 中顯示來自 A/B 測試的推斷分佈。
- D. 添加一個影子端點。分析樣本上的預測差異。

▼ 解答

B

- **考察的知識點**

本題考察的是如何使用 AWS 服務解釋機器學習模型的預測結果，特別是與 Amazon SageMaker Clarify 的功能相關。

- **選項分析**

- **A. Use SageMaker Model Monitor on the deployed model.**

錯誤：SageMaker Model Monitor 的主要功能是監控模型的性能和數據漂移，而不是解釋模型的預測結果。

- **B. Use SageMaker Clarify on the deployed model.**

正確：SageMaker Clarify 是專門設計用於解釋機器學習模型的預測

結果和檢測模型偏差的工具。它可以提供關於模型如何做出預測的詳細解釋。

- **C. Show the distribution of inferences from A/B testing in Amazon CloudWatch.**

錯誤：A/B 測試和 CloudWatch 的分佈分析主要用於比較不同模型或版本的性能，而不是解釋單個模型的預測結果。

- **D. Add a shadow endpoint. Analyze prediction differences on samples.**

錯誤：影子端點用於測試新模型的性能或行為，但它並不提供關於模型預測的解釋。

▼ 72

▼ 中文

一位機器學習工程師正在使用 Amazon SageMaker 訓練一個需要分佈式訓練的深度學習模型。在幾次訓練嘗試之後，機器學習工程師發現實例的性能未達到預期。機器學習工程師確認了訓練實例之間的通信開銷問題。

機器學習工程師應該怎麼做才能最大限度地減少實例之間的通信開銷？

- A. 將實例放在在同一個 VPC 子網中。將數據存儲在與實例部署位置不同的 AWS Region 中。
- B. 將實例放在在同一個 VPC 子網中，但在不同的可用區中。將數據存儲在與實例部署位置不同的 AWS Region 中。
- **C. 將實例放在在同一個 VPC 子網中。將數據存儲在與實例部署位置相同的 AWS Region 和可用區中。**
- D. 將實例放在在同一個 VPC 子網中。將數據存儲在與實例部署位置相同的 AWS Region，但在不同的可用區中。

▼ 解答

C

• 考察的知識點

- Amazon SageMaker 分佈式訓練的優化。
- 如何減少實例間的通信開銷。
- 理解 AWS 網絡架構，包括 VPC 子網、可用區 (Availability Zone)、以及跨區域數據存儲的影響。

- 選項分析

- **A. Place the instances in the same VPC subnet. Store the data in a different AWS Region from where the instances are deployed.**

錯誤：將數據存儲在不同的AWS Region會導致跨區域通信，這會顯著增加通信延遲和開銷。雖然實例在同一個VPC子網中可以減少網絡延遲，但跨區域數據存儲完全抵消了這一優勢。

- **B. Place the instances in the same VPC subnet but in different Availability Zones. Store the data in a different AWS Region from where the instances are deployed.**

錯誤：雖然實例在同一個VPC子網中可以減少網絡延遲，但跨可用區通信仍然會增加一些開銷。此外，將數據存儲在不同的AWS Region會導致跨區域通信，進一步增加延遲和開銷。

- **C. Place the instances in the same VPC subnet. Store the data in the same AWS Region and Availability Zone where the instances are deployed.**

正確：將實例放置在同一個VPC子網中可以減少網絡延遲。將數據存儲在與實例相同的AWS Region和可用區可以最大限度地減少通信開銷，因為數據和實例之間的通信不需要跨區域或跨可用區。

- **D. Place the instances in the same VPC subnet. Store the data in the same AWS Region but in a different Availability Zone from where the instances are deployed.**

錯誤：雖然實例和數據在同一個AWS Region中可以減少跨區域通信開銷，但跨可用區通信仍然會增加一些延遲和開銷。

▼ 73

▼ 中文

一家公司正在使用定制的 Python 腳本和專有數據集在本地運行機器學習模型。該公司正在使用 PyTorch。模型構建需要獨特的領域知識。該公司需要將模型遷移到 AWS。

哪種解決方案能夠以最少的努力滿足這些需求？

Options:

- A. 使用 SageMaker 內置算法訓練專有數據集。
- B. 使用 SageMaker 腳本模式和機器學習框架的預制鏡像。

- C. 在 AWS 上構建一個包含自定義包和機器學習框架選擇的容器。
- D. 通過 AWS Marketplace 購買類似的生產模型。

▼ 解答

B

• 考察的知識點

- Amazon SageMaker的功能和使用場景，包括內置算法、腳本模式和容器支持。
- 如何遷移現有的機器學習工作流到AWS。
- PyTorch框架的支持和集成方式。

• 選項分析

- **A. 使用 SageMaker 內置算法訓練專有數據集。**
錯誤：SageMaker內置算法是預定義的算法，適用於通用場景，但無法直接支持自定義的Python腳本和特定的PyTorch模型。該選項不適合需要遷移現有自定義模型的場景。
- **B. 使用 SageMaker 腳本模式和機器學習框架的預制鏡像。**
正確：SageMaker腳本模式允許用戶使用現有的Python腳本，並支持PyTorch等主流框架的預制鏡像。這種方式可以直接遷移現有的代碼和模型，減少開發工作量。
- **C. 在 AWS 上構建一個包含自定義包和機器學習框架選擇的容器。**
錯誤：雖然構建自定義容器可以滿足需求，但需要額外的開發工作來構建和維護容器。相比腳本模式，這種方式的工作量更大，不符合“最少努力”的要求。
- **D. 通過 AWS Marketplace 購買類似的生產模型。**
錯誤：AWS Marketplace提供的是現成的模型，而題目明確要求遷移現有的自定義模型。購買類似模型無法滿足遷移現有模型的需求。

▼ 74

▼ 中文

一家公司正在使用 Amazon SageMaker 和數百萬個文件來訓練一個機器學習模型。每個文件的大小為幾兆字節。這些文件存儲在一個 Amazon S3 存儲桶中。該公司需要提高訓練性能。哪種解決方案能在最短時間內滿足這些要求？

- A.將數據轉移到一個提供 S3 Express One Zone 存儲的新 S3 存儲桶。調整訓練任務以使用新的 S3 存儲桶。
- B.創建一個 Amazon FSx for Lustre 文件系統。將文件系統連接到現有的 S3 存儲桶。調整訓練任務以從文件系統讀取數據。
- C.創建一個 Amazon Elastic File System (Amazon EFS) 文件系統。將現有數據轉移到文件系統。調整訓練任務以從文件系統讀取數據。
- D.創建一個 Amazon ElastiCache (Redis OSS) 集群。將 Redis OSS 集群連接到現有的 S3 存儲桶。直接從 Redis OSS 集群向訓練任務流式傳輸數據。

▼ 解答

B

• 考察的知識點

- Amazon SageMaker的訓練性能優化。
- 如何高效地從Amazon S3讀取數據以支持機器學習訓練。
- Amazon FSx for Lustre的特性及其與S3的集成能力。

• 選項分析

- A.
錯誤：S3 Express One Zone存儲僅影響數據的冗餘和成本，但不會顯著提高數據讀取性能。此解決方案無法解決訓練性能問題。
- B.
正確：Amazon FSx for Lustre是專為高性能計算設計的文件系統，能夠加速從S3讀取數據的過程。FSx for Lustre可以將S3數據映射為文件系統，減少I/O瓶頸，從而顯著提高訓練性能。
- C.
錯誤：Amazon EFS是一個通用的文件存儲服務，適合共享文件存儲，但其性能不如FSx for Lustre，尤其是在高性能計算場景中。將數據從S3轉移到EFS還需要額外的時間和成本。
- D.
錯誤：ElastiCache（Redis OSS）是一個內存緩存服務，適合低延遲數據訪問，但不適合處理大規模文件數據。將S3數據流式傳輸到Redis OSS並用於訓練會增加複雜性，且不符合場景要求。

▼ 75

▼ 中文

一家公司希望使用來自其客戶的表格數據開發一個機器學習模型。這些數據包含有意義的有序特徵，並且包含不應丟棄的敏感信息。一名機器學習工程師必須確保敏感數據在另一個團隊開始構建模型之前被屏蔽。

哪種解決方案可以滿足這些要求？

- A. Use Amazon Macie to categorize the sensitive data.
使用 Amazon Macie 來分類敏感數據。
- **B. Prepare the data by using AWS Glue DataBrew.**
使用 AWS Glue DataBrew 準備數據。
- C. Run an AWS Batch job to change the sensitive data to random values.
運行一個 AWS Batch 作業，將敏感數據更改為隨機值。
- D. Run an Amazon EMR job to change the sensitive data to random values.
運行一個 Amazon EMR 作業，將敏感數據更改為隨機值。

▼ 解答

B

- **考察的知識點**
 - 數據預處理與敏感信息保護：如何在機器學習項目中處理敏感數據，確保數據隱私和安全。
 - AWS服務的功能與適用場景：了解AWS Glue DataBrew、AWS Batch、Amazon EMR等服務的用途和特點。
- **選項分析**
 - **A. Use Amazon Macie to categorize the sensitive data.**
錯誤：題目中沒有提到需要對數據進行分類，而是要求對敏感數據進行掩碼處理。Amazon Macie（題目中可能誤寫為“Made”）是用於識別和保護敏感數據的服務，但它不直接提供數據掩碼功能。
 - **B. Prepare the data by using AWS Glue DataBrew.**
正確：AWS Glue DataBrew是一種數據準備工具，支持數據清理、轉換和掩碼操作。它可以輕鬆地對敏感數據進行掩碼處理，符合題目要求。

- **C. Run an AWS Batch job to change the sensitive data to random values.**

錯誤：AWS Batch主要用於運行批處理作業，而不是專門設計用於數據預處理或掩碼操作。雖然可以通過自定義代碼實現數據掩碼，但這不是最佳選擇。

- **D. Run an Amazon EMR job to change the sensitive data to random values.**

錯誤：Amazon EMR主要用於大規模數據處理和分析，而不是專門設計用於數據掩碼操作。雖然可以通過自定義代碼實現數據掩碼，但這不是最佳選擇。

▼ 76

▼ 中文

一名機器學習工程師需要將機器學習模型部署，以異步方式從大型數據集中獲取推斷結果。該工程師還需要實施定期監控模型的數據質量。當數據質量發生變化時，工程師必須接收到警報。

哪種解決方案可以滿足這些要求？

- A. 使用計劃的 AWS Glue 作業部署模型。使用 Amazon CloudWatch 警報監控數據質量並發送警報。
- B. 使用計劃的 AWS Batch 作業部署模型。使用 AWS CloudTrail 監控數據質量並發送警報。
- C. 使用 Amazon Elastic Container Service (Amazon ECS) 在 AWS Fargate 上部署模型。使用 Amazon EventBridge 監控數據質量並發送警報。
- **D. 使用 Amazon SageMaker batch transform 部署模型。使用 SageMaker Model Monitor 監控數據質量並發送警報。**

▼ 解答

D

- **考察的知識點**
 - 如何選擇適合的服務來部署機器學習模型以進行異步推理。
 - 如何實現數據質量監控和警報機制。

- 對AWS服務的功能和適用場景的理解，包括AWS Glue、AWS Batch、Amazon ECS、Amazon SageMaker等。

- 選項分析

- **A. Deploy the models by using scheduled AWS Glue jobs. Use Amazon CloudWatch alarms to monitor the data quality and to send alerts.**

錯誤原因：雖然AWS Glue可以用於數據處理和ETL任務，但它並不是專門設計用於部署機器學習模型進行推理的服務。此外，CloudWatch可以監控指標，但它無法直接監控機器學習模型的數據質量。

- **B. Deploy the models by using scheduled AWS Batch jobs. Use AWS CloudTrail to monitor the data quality and to send alerts.**

錯誤原因：AWS Batch適合運行批量計算任務，但它不是專門設計用於機器學習模型推理的服務。AWS CloudTrail主要用於記錄API調用和用戶活動日誌，而不是監控數據質量。

- **C. Deploy the models by using Amazon Elastic Container Service (Amazon ECS) on AWS Fargate. Use Amazon EventBridge to monitor the data quality and to send alerts.**

錯誤原因：Amazon ECS和AWS Fargate可以用於容器化部署，但它們需要額外的定制來實現機器學習模型推理和數據質量監控。EventBridge可以處理事件，但它不是專門設計用於監控機器學習模型的數據質量。

- **D. Deploy the models by using Amazon SageMaker batch transform. Use SageMaker Model Monitor to monitor the data quality and to send alerts.**

正確原因：Amazon SageMaker batch transform專門用於異步批量推理任務，非常適合處理大數據集。SageMaker Model Monitor是專門設計用於監控機器學習模型的數據質量的工具，並可以設置警報以通知數據質量的變化。

▼ 77

▼ 中文

一位機器學習工程師使用 AWS Glue DataBrew 對訓練數據進行了最小-最大歸一化處理。該工程師必須在將生產推理數據傳遞給模型進行預測之前，以

與訓練數據相同的方式對生產推理數據進行歸一化處理。

哪種解決方案可以滿足此要求？

- A. 使用來自一個知名數據集的統計數據來歸一化生產樣本。
- **B. 保留訓練集中的最小-最大歸一化統計數據。使用這些值來歸一化生產樣本。**
- C. 從一批生產樣本中計算一組新的最小-最大歸一化統計數據。使用這些值來歸一化所有生產樣本。
- D. 從每個生產樣本中計算一組新的最小-最大歸一化統計數據。使用這些值來歸一化所有生產樣本。

▼ 解答

B

題目分析與解答：

1. 考察的知識點

- 數據預處理：特別是歸一化（Normalization）技術。
- 生產環境數據處理與一致性：確保訓練數據和生產數據的處理方式一致。
- AWS Glue DataBrew的使用場景。

2. 選項分析

- **A.**
錯誤：使用一個與訓練數據無關的“知名數據集”的統計數據來歸一化生產樣本會導致數據分佈不一致，模型預測可能不準確。歸一化必須基於訓練數據的統計信息，以確保訓練和生產數據的處理方式一致。
- **B.**
正確：這是標準的做法。生產數據的歸一化需要使用訓練數據的統計信息（如最小值和最大值），以確保數據分佈一致性。這樣可以避免數據分佈差異導致模型性能下降。
- **C.**
錯誤：生產數據的統計信息可能與訓練數據不同，使用生產數據的統計信息會導致數據分佈不一致，影響模型預測效果。歸一化必須基於訓練數據的統計信息，而不是生產數據。
- **D.**
錯誤：逐個樣本計算歸一化統計信息會導致數據分佈完全失去一致

性，模型無法正確預測。歸一化必須基於訓練數據的統計信息，而不是每個生產樣本的統計信息。

▼ 78

▼ 中文

一家公司計劃使用 Amazon SageMaker 基於圖像進行分類評級。公司擁有 6 TB 的訓練數據，存儲在一個 Amazon FSx for NetApp ONTAP 系統虛擬機 (SVM) 中。該 SVM 與 SageMaker 位於同一個 VPC 中。

一名機器學習工程師必須使訓練數據在 SageMaker 環境中的機器學習模型可訪問。

哪種解決方案可以滿足這些需求？

- A. 將 FSx for ONTAP 文件系統作為卷掛載到 SageMaker 實例。
- B. 創建一個 Amazon S3 存儲桶。使用 Mountpoint for Amazon S3 將 S3 存儲桶鏈接到 FSx for ONTAP 文件系統。
- C. 從 SageMaker Data Wrangler 創建到 FSx for ONTAP 文件系統的目錄連接。
- D. 從 SageMaker Data Wrangler 創建到 FSx for ONTAP 文件系統的直接連接。

▼ 解答

A

• 考察的知識點

- Amazon SageMaker與存儲服務的集成。
- 如何在SageMaker中訪問和使用外部存儲數據。
- Amazon FSx for NetApp ONTAP的功能和掛載方式。

• 選項分析

- **A. Mount the FSx for ONTAP file system as a volume to the SageMaker Instance.**

正確：Amazon FSx for NetApp ONTAP支持通過掛載文件系統的方式直接訪問數據。在同一個VPC內，SageMaker實例可以直接掛載 FSx文件系統作為卷，從而訪問存儲的數據。這是最直接和高效的解決方案，符合題目要求。

- **B. Create an Amazon S3 bucket. Use Mountpoint for Amazon S3 to link the S3 bucket to the FSx for ONTAP file system.**

錯誤：雖然可以將數據從FSx遷移到S3，但這增加了額外的步驟和複雜性。題目並未要求將數據遷移到S3，而是直接訪問FSx數據。

Mountpoint for Amazon S3是用於掛載S3存儲桶的工具，與FSx無直接關聯。

- **C. Create a catalog connection from SageMaker Data Wrangler to the FSx for ONTAP file system.**

錯誤：SageMaker Data Wrangler主要用於數據預處理和分析，而不是直接掛載文件系統。題目要求的是如何讓訓練數據可訪問，而不是數據預處理。

- **D. Create a direct connection from SageMaker Data Wrangler to the FSx for ONTAP file system.**

錯誤：SageMaker Data Wrangler並不支持直接連接到FSx文件系統。此選項與題目要求不符，且技術上不可行。

▼ 79

▼ 中文

一家公司定期從一個機器學習模型的供應商處接收新的訓練數據。供應商每隔 3-4 天將清理和準備好的數據傳遞到公司的 Amazon S3 存儲桶。

公司有一個 Amazon SageMaker 管道用於重新訓練模型。一位機器學習工程師需要實現一個解決方案，以便在新數據上傳到 S3 存儲桶時運行管道。

哪種解決方案能夠以最少的運營工作量滿足這些要求？

- **A. Create an S3 Lifecycle rule to transfer the data to the SageMaker training instance and to initiate training.**

創建一個 S3 生命周期規則，將數據傳輸到 SageMaker 訓練實例並啟動訓練。

- **B. Create an AWS Lambda function that scans the S3 bucket. Program the Lambda function to initiate the pipeline when new data is uploaded.**

創建一個 AWS Lambda 函數掃描 S3 存儲桶。編程該 Lambda 函數以在新數據上傳時啟動管道。

- **C. Create an Amazon EventBridge rule that has an event pattern that matches the S3 upload. Configure the pipeline as the target of the rule.**

創建一個 Amazon EventBridge 規則，該規則具有與 S3 上傳匹配的事件模式。將管道配置為該規則的目標。

- D. Use Amazon Managed Workflows for Apache Airflow (Amazon MWAA) to orchestrate the pipeline when new data is uploaded.
使用 Amazon Managed Workflows for Apache Airflow (Amazon MWAA) 在新數據上傳時編排管道。

▼ 解答

C

- 考察的知識點

- Amazon S3事件通知機制
- Amazon SageMaker管道自動化
- AWS服務集成（EventBridge、Lambda等）
- 選擇最少的操作工作量（Least Operational Effort）

- 選項分析

- **A. Create an S3 Lifecycle rule to transfer the data to the SageMaker training instance and to initiate training.**

分析：S3 Lifecycle規則用於管理對象的生命周期（如過期或轉移到其他存儲層），而不是觸發事件或啟動管道。此解決方案無法實現自動化觸發訓練任務的需求。

錯誤原因：S3 Lifecycle規則不支持直接觸發SageMaker管道。

- **B. Create an AWS Lambda function that scans the S3 bucket. Program the Lambda function to initiate the pipeline when new data is uploaded.**

分析：Lambda可以通過編程實現掃描S3存儲桶並觸發SageMaker管道，但需要手動編寫代碼和管理Lambda函數。雖然可行，但操作工作量較高（需要定期掃描或編寫複雜邏輯）。

錯誤原因：不符合“最少操作工作量”的要求。

- **C. Create an Amazon EventBridge rule that has an event pattern that matches the S3 upload. Configure the pipeline as the target of the rule.**

分析：EventBridge可以直接監聽S3事件（如對象上傳），並觸發目標（如SageMaker管道）。無需額外編寫代碼，配置簡單，完全符合“最少操作工作量”的要求。

正確原因：EventBridge是AWS推薦的事件驅動架構解決方案，適合此場景。

- **D. Use Amazon Managed Workflows for Apache Airflow (Amazon MWAA) to orchestrate the pipeline when new data is uploaded.**

分析：Amazon MWAA適用於複雜的工作流編排，但設置和管理工作流需要額外的操作工作量。對於簡單的觸發需求，使用MWAA顯得過於複雜且不必要。

錯誤原因：不符合“最少操作工作量”的要求。

▼ 80

▼ 中文

一位機器學習工程師正在使用 Amazon SageMaker XGBoost 算法開發一個欺詐檢測模型。該模型將交易分類為欺詐或合法。

在測試過程中，該模型在識別訓練數據集中的欺詐行為方面表現出色。然而，該模型在識別新的和未見過的交易中的欺詐行為方面效率較低。

機器學習工程師應該怎麼做以改進新交易的欺詐檢測？

- A. Increase the learning rate.
增加學習率。
- B. Remove some irrelevant features from the training dataset.
從訓練數據集中移除一些不相關的特徵。
- C. Increase the value of the max_depth hyperparameter.
增加 max_depth 超參數的值。
- **D. Decrease the value of the max_depth hyperparameter.**
減少 max_depth 超參數的值。

▼ 解答

D

1. 考察的知識點

- 模型過擬合問題：如何解決模型在訓練數據上表現良好，但在新數據上表現不佳的問題。
- 超參數調優：理解 XGBoost 算法中的 max_depth 參數對模型複雜度和泛化能力的影響。

2. 選項分析

- **A. Increase the learning rate. 增加學習率。**
增加學習率可能會導致模型收斂過快，從而無法充分學習數據特徵。這與解決過擬合問題無關，因此此選項錯誤。
- **B. Remove some irrelevant features from the training dataset. 從訓練數據集中移除一些不相關的特徵。**
雖然移除不相關的特徵可以提高模型性能，但題目中並未提到特徵相關性問題，而是明確指出模型在新數據上的表現不佳（過擬合）。此選項與問題無關，因此錯誤。
- **C. Increase the value of the max_depth hyperparameter. 增加 max_depth 超參數的值。**
增加 max_depth 會使模型更複雜，可能進一步加劇過擬合問題。因此此選項錯誤。
- **D. Decrease the value of the max_depth hyperparameter. 減少 max_depth 超參數的值。**
減少 max_depth 可以降低模型複雜度，從而減少過擬合，提高模型在新數據上的泛化能力。這是解決問題的正確方法。

▼ 81

▼ 中文

一家公司在生產環境中擁有一個二元分類模型。一位機器學習工程師需要開發該模型的新版本。

新模型版本必須最大化對正標籤和負標籤的正確預測。機器學習工程師必須使用一個指標來重新校准模型以滿足這些要求。

機器學習工程師應該使用哪個指標來重新校准模型？

- **A. Accuracy**
- B. Precision
- C. Recall
- D. Specificity

▼ 解答

A

- **考察的知識點**

本題考察的是機器學習模型評估指標的選擇，特別是如何根據業務需求選擇合適的指標來優化模型性能。

需要了解常見的評估指標：Accuracy（準確率）、Precision（精確率）、Recall（召回率）、Specificity（特異性）。

- **選項分析**

- **A. Accuracy:**

準確率是正確預測的樣本占總樣本的比例。

題目要求最大化正負標籤的正確預測，準確率是一個綜合性指標，能夠同時衡量正負樣本的預測效果。

因此，Accuracy是符合題目要求的正確選項。

- **B. Precision:**

精確率是正確預測的正樣本占有所有預測為正樣本的比例。

Precision主要關注正樣本的預測質量，但題目要求同時最大化正負標籤的正確預測，因此Precision不符合要求。

- **C. Recall:**

召回率是正確預測的正樣本占有所有實際正樣本的比例。

Recall主要關注正樣本的覆蓋率，但題目要求同時最大化正負標籤的正確預測，因此Recall不符合要求。

- **D. Specificity:**

特異性是正確預測的負樣本占有所有實際負樣本的比例。

Specificity主要關注負樣本的預測質量，但題目要求同時最大化正負標籤的正確預測，因此Specificity不符合要求。

▼ 82

▼ 中文

一家公司正在使用 Amazon SageMaker 創建機器學習模型。該公司的數據科學家需要對他們編排的機器學習工作流進行細粒度控制。數據科學家還需要能夠將 SageMaker 作業和工作流可視化為有向無環圖 (DAG)。數據科學家必須保持模型發現實驗的運行歷史，並且必須建立模型治理以進行審計和合規性驗證。

哪種解決方案可以滿足這些需求？

- A. 使用 AWS CodePipeline 及其與 SageMaker Studio 的集成來管理整個機器學習工作流。使用 SageMaker ML Lineage Tracking 來記錄實

驗的運行歷史，並進行審計和合規性驗證。

- B. 使用 AWS CodePipeline 及其與 SageMaker Experiments 的集成來管理整個機器學習工作流。使用 SageMaker Experiments 來記錄實驗的運行歷史，並進行審計和合規性驗證。
- C. 使用 SageMaker Pipelines 及其與 SageMaker Studio 的集成來管理整個機器學習工作流。使用 SageMaker ML Lineage Tracking 來記錄實驗的運行歷史，並進行審計和合規性驗證。
- D. 使用 SageMaker Pipelines 及其與 SageMaker Experiments 的集成來管理整個機器學習工作流。使用 SageMaker Experiments 來記錄實驗的運行歷史，並進行審計和合規性驗證。

▼ 解答

C

• 考察的知識點

- Amazon SageMaker Pipelines的功能和用途。
- SageMaker Studio的集成能力。
- SageMaker ML Lineage Tracking的作用。
- 如何滿足模型治理、審計和合規性要求。

• 選項分析

- **A. 使用 AWS CodePipeline 和 SageMaker Studio：**
CodePipeline主要用於CI/CD工作流，而不是專門設計用於ML工作流的可視化和管理。
SageMaker ML Lineage Tracking確實可以記錄實驗歷史並支持審計和合規性，但CodePipeline無法滿足數據科學家對DAG可視化的需求。
此選項不完全滿足題目要求，因此錯誤。
- **B. 使用 AWS CodePipeline 和 SageMaker Experiments：**
CodePipeline仍然不適合用於ML工作流的可視化和管理。
SageMaker Experiments可以記錄實驗歷史，但它不是專門設計用於審計和合規性驗證的工具。
此選項不完全滿足題目要求，因此錯誤。
- **C. 使用 SageMaker Pipelines 和 SageMaker Studio：**
SageMaker Pipelines專門設計用於ML工作流的管理和可視化，支持DAG結構，非常適合數據科學家的需求。

SageMaker Studio提供了集成環境，可以與Pipelines協同工作。
SageMaker ML Lineage Tracking可以記錄實驗歷史並支持審計和合規性驗證。

此選項完全滿足題目要求，因此正確。

- **D. 使用 SageMaker Pipelines 和 SageMaker Experiments：**
SageMaker Pipelines確實適合ML工作流的管理和可視化。
SageMaker Experiments主要用於實驗管理，但它不完全滿足審計和合規性驗證的需求。
此選項不完全滿足題目要求，因此錯誤。

▼ 83

▼ 中文

一家公司希望降低其容器化機器學習應用程序的成本。這些應用程序使用運行在 Amazon EC2 實例、AWS Lambda 函數和 Amazon Elastic Container Service (Amazon ECS) 集群上的機器學習模型。EC2 工作負載和 ECS 工作負載使用 Amazon Elastic Block Store (Amazon EBS) 卷來保存預測和工件。一名機器學習工程師必須識別被低效使用的資源。該工程師還必須生成減少這些資源成本的建議。哪種解決方案能夠以最少的開發工作量滿足這些需求？

- A. 編寫代碼來評估每個實例的內存和計算使用情況。
- B. 向資源添加成本分配標籤。在 AWS Billing and Cost Management 中激活標籤。
- C. 檢查 AWS CloudTrail 事件歷史以了解資源的創建情況。
- D. 運行 AWS Compute Optimizer。

▼ 解答

D

- **考察的知識點**
 - 本題主要考察對AWS成本優化工具的理解與使用，尤其是AWS Compute Optimizer的功能。
 - 還涉及資源監控、成本分配標籤以及事件歷史的使用場景。
- **選項分析**

- **A. Create code to evaluate each instance's memory and compute usage.**

錯誤：雖然編寫代碼可以實現資源使用情況的評估，但這需要較高的開發工作量，違背了題目要求的“最少開發工作量”。

此外，AWS已經提供了現成的工具（如AWS Compute Optimizer）來完成類似的任務，無需手動編寫代碼。

- **B. Add cost allocation tags to the resources. Activate the tags in AWS Billing and Cost Management.**

錯誤：成本分配標籤可以幫助跟蹤資源的成本，但它無法直接評估資源的使用效率或生成優化建議。

此選項無法滿足題目中“識別資源使用效率低下並生成優化建議”的要求。

- **C. Check AWS CloudTrail event history for the creation of the resources.**

錯誤：CloudTrail主要用於記錄API調用和資源創建的歷史記錄，無法直接評估資源的使用效率或生成優化建議。

此選項與題目要求不符。

- **D. Run AWS Compute Optimizer.**

正確：AWS Compute Optimizer可以分析EC2實例、EBS卷、Lambda函數和ECS服務的使用情況，並生成優化建議。

它是一個現成的工具，使用起來非常簡單，符合題目中“最少開發工作量”的要求。

▼ 84

▼ 中文

一家公司需要為所有公司的機器學習模型創建一個中央目錄。模型位於公司最初開發模型的AWS帳戶中。模型託管在Amazon Elastic Container Registry (Amazon ECR) 存儲庫中。

哪種解決方案可以滿足這些需求？

- A. Configure ECR cross-account replication for each existing ECR repository. Ensure that each model is visible in each AWS account. 為每個現有的ECR存儲庫配置ECR跨帳戶複製。確保每個模型在每個AWS帳戶中都可見。

- B. Create a new AWS account with a new ECR repository as the central catalog. Configure ECR cross-account replication between the initial ECR repositories and the central catalog.

創建一個新的AWS帳戶，並在其中創建一個新的ECR存儲庫作為中央目錄。在初始ECR存儲庫和中央目錄之間配置ECR跨帳戶複製。

- **C. Use the Amazon SageMaker Model Registry to create a model group for models hosted in Amazon ECR. Create a new AWS account. In the new account, use the SageMaker Model Registry as the central catalog. Attach a cross-account resource policy to each model group in the initial AWS accounts.**

使用Amazon SageMaker Model Registry為託管在Amazon ECR中的模型創建一個模型組。創建一個新的AWS帳戶。在新帳戶中，將SageMaker Model Registry用作中央目錄。在初始AWS帳戶中的每個模型組上附加跨帳戶資源策略。

- D. Use an AWS Glue Data Catalog to store the models. Run an AWS Glue crawler to migrate the models from the ECR repositories to the Data Catalog. Configure cross-account access to the Data Catalog.
- 使用AWS Glue Data Catalog存儲模型。運行AWS Glue爬網程序將模型從ECR存儲庫遷移到Data Catalog。配置對Data Catalog的跨帳戶訪問。

▼ 解答

C

1. 考察的知識點

- 跨帳戶資源共享與訪問控制
- Amazon SageMaker Model Registry的功能與使用
- Amazon ECR跨帳戶複製的配置
- AWS Glue Data Catalog的用途與限制

2. 選項分析

- **A. 配置ECR跨帳戶複製，確保每個模型在每個帳戶中都可見。**
分析：雖然ECR支持跨帳戶複製，但這種方法會導致每個帳戶都擁有一份模型的副本，無法實現“中央目錄”的需求。每個帳戶仍需單獨管理模型，增加複雜性。
結論：錯誤。
- **B. 創建一個新的AWS帳戶和ECR存儲庫作為中央目錄，並配置跨帳戶複製。**

分析：此方法確實可以集中存儲模型，但ECR本身並不是專門設計用於管理和版本控制機器學習模型的工具。它缺乏模型註冊、分組和版本管理功能，因此不符合最佳實踐。

結論：錯誤。

- **C. 使用Amazon SageMaker Model Registry創建模型組，並配置跨帳戶資源策略。**

分析：Amazon SageMaker Model Registry是專門設計用於管理機器學習模型的工具，支持模型分組、版本控制和跨帳戶訪問。通過創建一個新的AWS帳戶並使用Model Registry作為中央目錄，可以實現集中管理，同時滿足跨帳戶訪問的需求。

結論：正確。

- **D. 使用AWS Glue Data Catalog存儲模型，並配置跨帳戶訪問。**

分析：AWS Glue Data Catalog主要用於存儲和管理數據元數據，而不是機器學習模型。將模型遷移到Data Catalog並不符合其設計用途，且無法提供模型版本控制和分組功能。

結論：錯誤。

▼ 85

▼ 中文

一家公司開發了一個新的機器學習模型。該公司要求在正式將模型投入生產之前，對10%的流量進行在線模型驗證。該公司使用一個Amazon SageMaker端點，並通過一個Application Load Balancer (ALB)來提供模型服務。

哪種解決方案可以以最少的運營開銷設置所需的在線驗證？

- **A. 使用生產變體將新模型添加到現有的SageMaker端點。將新模型的變體權重設置為0.1。通過Amazon CloudWatch監控調用次數。**
- B. 使用生產變體將新模型添加到現有的SageMaker端點。將新模型的變體權重設置為1。通過Amazon CloudWatch監控調用次數。
- C. 創建一個新的SageMaker端點。使用生產變體將新模型添加到新的端點。通過Amazon CloudWatch監控調用次數。
- D. 配置ALB將10%的流量路由到現有SageMaker端點上的新模型。通過AWS CloudTrail監控調用次數。

▼ 解答

A

- **考察的知識點**

- Amazon SageMaker生產變體（Production Variants）的使用。
- 流量分配和權重設置的概念。
- 如何使用Amazon CloudWatch監控模型調用。
- 最小化操作開銷的解決方案設計。

- **選項分析**

- **A. 使用生產變體將新模型添加到現有的SageMaker端點。將新模型的變體權重設置為0.1。通過Amazon CloudWatch監控調用次數。**
正確：生產變體允許在同一個SageMaker端點中部署多個模型，並通過權重分配流量。設置權重為0.1意味著10%的流量會被路由到新模型，符合題目要求。
正確：使用Amazon CloudWatch可以輕鬆監控模型的調用次數，操作開銷較低。
- **B. 使用生產變體將新模型添加到現有的SageMaker端點。將新模型的變體權重設置為1。通過Amazon CloudWatch監控調用次數。**
錯誤：權重設置為1意味著100%的流量會被路由到新模型，而不是題目要求的10%。
雖然生產變體和CloudWatch是正確的工具，但權重設置不符合題目要求。
- **C. 創建一個新的SageMaker端點。使用生產變體將新模型添加到新的端點。通過Amazon CloudWatch監控調用次數。**
錯誤：創建一個新的SageMaker端點增加了操作開銷，不符合題目要求的“最小化操作開銷”。
雖然生產變體和CloudWatch是正確的工具，但創建新端點不是必要的。
- **D. 配置ALB將10%的流量路由到現有SageMaker端點上的新模型。通過AWS CloudTrail監控調用次數。**
錯誤：雖然ALB可以實現流量分配，但使用AWS CloudTrail監控調用次數並不是最佳選擇。CloudTrail主要用於記錄API調用，而不是實時監控。
相比生產變體的解決方案，使用ALB增加了操作複雜性。

一家公司需要開發一個ML模型。該模型必須識別圖像中的某個物品，並且必須提供該物品的位置。

哪個Amazon SageMaker算法能夠滿足這些要求？

- A. Image classification 圖像分類
- B. XGBoost
- **C. Object detection 物體檢測**
- D. K-nearest neighbors (k-NN)

▼ 解答

C

- **考察的知識點**

本題考察的是Amazon SageMaker中機器學習算法的應用場景，特別是圖像處理相關的算法。

需要理解不同算法的功能，例如圖像分類、物體檢測等。

- **選項分析**

- **A. Image classification 圖像分類**

圖像分類算法用於對整個圖像進行分類，但無法提供物體的具體位置。因此此選項錯誤。

- **B. XGBoost XGBoost**

XGBoost是一種梯度提升算法，主要用於結構化數據的分類和回歸任務，不適用於圖像處理任務。因此此選項錯誤。

- **C. Object detection 物體檢測**

物體檢測算法不僅可以識別圖像中的物體，還可以提供物體的具體位置（例如邊界框）。此選項正確。

- **D. K-nearest neighbors (k-NN) K-最近鄰 (k-NN)**

k-NN是一種簡單的分類算法，通常用於結構化數據的分類任務，不適用於圖像處理任務。因此此選項錯誤。

▼ 87

▼ 中文

一家公司有一個 Amazon S3 存儲桶，其中包含來自不同來源的 1 TB 文件。該 S3 存儲桶在同一個 S3 文件夾中包含以下文件類型：CSV、JSON、XLSX 和 Apache Parquet。一名 ML 工程師必須實施一個解決方案，使用 AWS

Glue DataBrew 來處理數據。該 ML 工程師還必須將最終輸出存儲在 Amazon S3 中，以便 AWS Glue 將來可以使用該輸出。哪種解決方案可以滿足這些要求？

- A. 使用 DataBrew 處理現有的 S3 文件夾。將輸出存儲為 Apache Parquet 格式。
- B. 使用 DataBrew 處理現有的 S3 文件夾。將輸出存儲為 AWS Glue Parquet 格式。
- **C. 將數據按文件類型分到不同的文件夾中。使用 DataBrew 分別處理每個文件夾。將輸出存儲為 Apache Parquet 格式。**
- D. 將數據按文件類型分到不同的文件夾中。使用 DataBrew 分別處理每個文件夾。將輸出存儲為 AWS Glue Parquet 格式。

▼ 解答

C

• 考察的知識點

- 了解AWS Glue DataBrew的功能和使用場景。
- 熟悉數據格式轉換（如Apache Parquet格式）。
- 理解如何組織和處理不同類型的數據文件。

• 選項分析

- **A. Use DataBrew to process the existing S3 folder. Store the output in Apache Parquet format.**

錯誤：雖然Apache Parquet格式是正確的選擇，但直接處理整個S3文件夾可能會導致問題，因為文件類型不同（CSV、JSON、XLSX、Parquet），DataBrew可能無法正確處理所有文件類型。

- **B. Use DataBrew to process the existing S3 folder. Store the output in AWS Glue Parquet format.**

錯誤：AWS Glue並沒有特定的“Glue Parquet格式”，這可能是一個誤導性的選項。此外，直接處理整個S3文件夾的問題與選項A相同。

- **C. Separate the data into a different folder for each file type. Use DataBrew to process each folder individually. Store the output in Apache Parquet format.**

正確：將數據按文件類型分到不同的文件夾可以確保DataBrew能夠正確處理每種文件類型。Apache Parquet格式是一個高效的存儲格式，適合後續的AWS Glue處理。

- **D. Separate the data into a different folder for each file type. Use DataBrew to process each folder individually. Store the output in AWS Glue Parquet format.**

錯誤：同選項B，AWS Glue並沒有特定的“Glue Parquet格式”，這可能是一個誤導性的選項。

▼ 88

▼ 中文

一家製造公司使用一個機器學習模型來判斷產品是否符合質量標準。該模型輸出“通過”或“未通過”。機器人使用該模型分析生產線上的照片，將產品分為這兩類。公司應該使用哪些指標來評估模型的性能？（選擇兩個）

- A. Precision and recall
- B. Root mean square error (RMSE) and mean absolute percentage error (MAPE)
- C. Accuracy and F1 score
- D. Bilingual Evaluation Understudy (BLEU) score
- E. Perplexity

▼ 解答

AC

- **考察的知識點**

本題考察的是機器學習模型性能評估的相關指標，特別是分類模型的評估指標。

需要理解分類模型的常用指標，如Precision、Recall、Accuracy、F1 Score，以及它們的適用場景。

- **選項分析**

- **A. Precision and recall**

Precision和Recall是分類模型的重要指標，分別衡量模型預測的準確性和召回率。

在質量檢測場景中，Precision可以衡量“通過”的預測是否準確，Recall可以衡量“通過”的產品是否被正確識別。

此選項是正確的。

- **B. Root mean square error (RMSE) and mean absolute percentage error (MAPE)**
RMSE和MAPE是回歸模型的評估指標，用於衡量預測值與真實值之間的誤差。
本題是分類問題，而非回歸問題，因此此選項不適用。
此選項是錯誤的。
- **C. Accuracy and F1 score**
Accuracy是分類模型的整體預測準確率，適用於衡量模型的總體性能。
F1 Score是Precision和Recall的調和平均值，適用於不平衡數據集的分類問題。
在質量檢測場景中，Accuracy和F1 Score是合理的選擇。
此選項是正確的。
- **D. Bilingual Evaluation Understudy (BLEU) score**
BLEU是用於評估機器翻譯模型的指標，與本題的分類問題無關。
此選項是錯誤的。
- **E. Perplexity**
Perplexity是用於評估語言模型的指標，與本題的分類問題無關。
此選項是錯誤的。

▼ 89

▼ 中文

一位機器學習工程師需要在機器學習訓練任務運行時加密所有傳輸中的數據。該機器學習工程師必須確保在訓練任務期間，Amazon SageMaker 使用的流程應用了傳輸中的加密。

哪種解決方案可以滿足這些要求？

- A. 為批處理加密節點之間的通信。
- **B. 為訓練集群中的節點之間加密通信。**
- C. 在創建訓練任務請求時指定一個 AWS Key Management Service (AWS KMS) 密鑰。
- D. 在創建 SageMaker 域時指定一個 AWS Key Management Service (AWS KMS) 密鑰。

▼ 解答

B

- **考察的知識點**

Amazon SageMaker的加密機制，包括數據在傳輸中的加密。

如何確保訓練任務中節點之間的通信安全。

AWS Key Management Service (KMS)的使用場景。

- **選項分析**

- **A. Encrypt communication between nodes for batch processing.**

錯誤：此選項提到的是“批處理”，而題目明確要求的是“ML訓練任務”。批處理與訓練任務的加密需求不同，因此此選項不符合題目要求。

- **B. Encrypt communication between nodes in a training cluster.**

正確：此選項直接提到“訓練集群中的節點之間加密通信”，完全符合題目要求。Amazon SageMaker支持在訓練集群中對節點之間的通信進行加密，以確保數據在傳輸中的安全性。

- **C. Specify an AWS Key Management Service (AWS KMS) key during creation of the training job request.**

錯誤：AWS KMS密鑰主要用於加密存儲中的數據（如S3上的訓練數據），而不是用於加密節點之間的通信。此選項與題目要求的“數據在傳輸中的加密”不匹配。

- **D. Specify an AWS Key Management Service (AWS KMS) key during creation of the SageMaker domain.**

錯誤：SageMaker域的創建與訓練任務的加密無直接關係。此選項與題目要求的“訓練任務中節點之間的通信加密”不相關。

▼ 90

▼ 中文

一位機器學習工程師需要使用指標來評估時間序列預測模型的質量。

哪些指標適用於此模型？（選擇兩個。）

- A. Recall
- B. LogLoss
- C. Root mean square error (RMSE)
- D. InferenceLatency

- E. Average weighted quantile loss (wQL)

▼ 解答

CE

- **考察的知識點**

本題考察的是時間序列預測模型的評估指標，包括如何選擇合適的評估指標來衡量模型的質量。

- **選項分析**

- **A. Recall:** Recall（召回率）通常用於分類問題，衡量模型正確識別正類的能力。時間序列預測模型不涉及分類問題，因此此選項錯誤。
- **B. LogLoss:** LogLoss（對數損失）是分類問題中常用的評估指標，用於衡量模型預測概率的準確性。時間序列預測模型不使用 LogLoss，因此此選項錯誤。
- **C. Root mean square error (RMSE):** RMSE是回歸問題中常用的評估指標，用於衡量預測值與真實值之間的平均誤差。時間序列預測模型屬於回歸問題的一種，因此此選項正確。
- **D. InferenceLatency:** InferenceLatency（推理延遲）是衡量模型運行效率的指標，而不是衡量模型預測質量的指標。因此此選項錯誤。
- **E. Average weighted quantile loss (wQL):** wQL是時間序列預測中特定的評估指標，特別適用於分位數預測模型。此選項正確。

▼ 91

▼ 中文

一家公司運行使用加速實例的 Amazon SageMaker 機器學習模型。這些模型需要實時響應。每個模型有不同的擴展需求。公司必須避免模型的冷啟動。哪種解決方案可以滿足這些需求？

- A. 為每個模型創建一個 SageMaker Serverless Inference 端點。為端點使用預置並發。
- B. 為每個模型創建一個 SageMaker Asynchronous Inference 端點。為每個端點創建一個自動擴展策略。

- **C.** 創建一個 SageMaker 端點。為每個模型創建一個推理組件。在推理組件設置中，指定新創建的端點。為每個推理組件創建一個自動擴展策略。將最小副本數量參數設置為至少 1。
- **D.** 創建一個 Amazon S3 存儲桶。將所有模型工件存儲在 S3 存儲桶中。創建一個 SageMaker 多模型端點。將端點指向 S3 存儲桶。為端點創建一個自動擴展策略。將最小副本數量參數設置為至少 1。

▼ 解答

C

• 考察的知識點

- Amazon SageMaker 的不同推理端點類型及其適用場景。
- 如何滿足實時響應需求並避免冷啟動。
- 如何為不同模型設置自動擴展策略。

• 選項分析

- **A.** 錯誤原因：雖然 Serverless Inference 支持預置並發以減少冷啟動，但它主要適用於間歇性負載的場景，而不是實時響應的高性能需求。此外，Serverless Inference 不支持加速實例。
- **B.** 錯誤原因：Asynchronous Inference 適用於批量處理或長時間運行的推理任務，而不是實時響應場景。它無法滿足實時響應的需求。
- **C.** 正確原因：使用 SageMaker 端點可以支持加速實例，並且通過設置最小副本數量為至少 1，可以避免冷啟動。每個模型可以單獨配置推理組件和自動擴展策略，滿足不同的擴展需求。
- **D.** 錯誤原因：雖然多模型端點可以減少資源使用，但它需要從 S3 加載模型，這可能導致冷啟動問題。此外，多模型端點不適合需要實時響應的場景。

▼ 92

▼ 中文

一家公司使用 Amazon SageMaker 進行其機器學習流程。合規性審計發現用於訓練數據的 Amazon S3 存儲桶使用服務器端加密，並採用 S3 管理密鑰 (SSE-S3)。該公司要求使用客戶管理密鑰。一名機器學習工程師將 S3 存儲桶更改為使用服務器端加密，並採用 AWS KMS 密鑰 (SSE-KMS)。該機器學習工程師未進行其他配置更改。在加密設置更改後，SageMaker 訓練任務開

始因 AccessDenied 錯誤而失敗。機器學習工程師應該怎麼做來解決這個問題？

- A. 更新附加到訓練任務執行角色的 IAM 策略。包括 s3:ListBucket 和 s3:GetObject 權限。
- B. 更新附加到 S3 存儲桶的 S3 存儲桶策略。將 aws:SecureTransport 條件鍵的值設置為 True。
- **C. 更新附加到訓練任務執行角色的 IAM 策略。包括 kms:Encrypt 和 kms:Decrypt 權限。**
- D. 更新附加到創建訓練任務的用戶的 IAM 策略。包括 kms:CreateGrant 權限。

▼ 解答

C

• 考察的知識點

- Amazon SageMaker與Amazon S3的集成。
- 使用AWS KMS進行加密的權限配置。
- IAM角色和策略的權限管理。

• 選項分析

- **A. 錯誤：**雖然s3:ListBucket和s3:GetObject權限是訪問S3數據所需的權限，但問題的核心是與KMS加密相關的權限，而不是S3訪問權限。
- **B. 錯誤：**aws:SecureTransport條件鍵用於確保通過HTTPS訪問S3，而不是解決KMS加密相關的權限問題。
- **C. 正確：**當S3使用SSE-KMS加密時，SageMaker需要執行角色具有 kms:Encrypt和kms:Decrypt權限，以便能夠解密訓練數據。
- **D. 錯誤：**kms:CreateGrant權限允許用戶創建KMS授權，但問題的核心是執行角色缺少kms:Encrypt和kms:Decrypt權限，而不是用戶權限。

▼ 93

▼ 中文

一家公司通過使用計算優化型實例在 Amazon SageMaker 上運行訓練任務。未來 55 周內，訓練任務的需求將保持不變。實例每周需要運行 35 小時。公司需要降低其模型訓練成本。哪種解決方案可以滿足這些要求？

- A. 使用具有每周 35 小時預置並發的無服務器端點。在端點上運行訓練任務。
- B. 使用 SageMaker Edge Manager 進行訓練。在邊緣設備配置中指定實例需求。運行訓練任務。
- C. 使用 SageMaker Training 的異構集群功能。配置 `instance_type`、`instance_count` 和 `instance_groups` 參數以運行訓練任務。
- D. 選擇 SageMaker Savings Plan，選擇 1 年期並采用全額預付方式。在實例上運行 SageMaker Training 任務。

▼ 解答

D

- **考察的知識點**

- Amazon SageMaker 的成本優化策略。
- 理解 SageMaker Savings Plan 的使用場景和優勢。
- 對比不同 SageMaker 功能（如 Edge Manager、異構集群）的適用性。

- **選項分析**

- **A. 使用具有每周 35 小時預置並發的無服務器端點。在端點上運行訓練任務。**
錯誤。無服務器端點主要用於模型部署和推理，而不是訓練任務。訓練任務需要專門的計算資源，且無服務器端點無法滿足長期穩定的訓練需求。
- **B. 使用 SageMaker Edge Manager 進行訓練。在邊緣設備配置中指定實例需求。運行訓練任務。**
錯誤。SageMaker Edge Manager 主要用於管理和部署機器學習模型到邊緣設備，而不是用於訓練任務。此選項與題目需求不符。
- **C. 使用 SageMaker Training 的異構集群功能。配置 `instance_type`、`instance_count` 和 `instance_groups` 參數以運行訓練任務。**
錯誤。異構集群功能適用於需要多種實例類型協同工作的複雜訓練任

務，但題目中並未提到需要異構集群，且此選項未提到成本優化策略。

- **D. 選擇 SageMaker Savings Plan，選擇 1 年期並採用全額預付方式。在實例上運行 SageMaker Training 任務。**

正確。SageMaker Savings Plan 允許用戶通過承諾使用特定的計算資源來獲得顯著的成本節約。題目中提到需求穩定且持續 55 周，選擇 1 年期的 Savings Plan 是最優的成本優化方案。

▼ 94

▼ 中文

一家公司需要訓練一個機器學習模型，該模型將使用歷史交易數據來預測客戶行為。


從以下列表中選擇正確的 AWS 服務來執行數據上的每項任務。每個服務應被選擇一次或不選擇。（選擇三個。）

- Amazon Athena
- AWS Glue
- Amazon Kinesis Data Streams
- Amazon S3

Query the data for exploration and analysis.

Store the data.

Transform the data.



▼ 解答

Correct Answer:

Query the data for exploration and analysis.

Store the data.

Transform the data.

• 考察的知識點

本題考察的是AWS服務在機器學習數據處理流程中的應用，包括數據存儲、數據查詢分析以及數據轉換。

需要理解每個服務的功能和適用場景，例如Amazon Athena用於查詢分析，AWS Glue用於數據轉換，Amazon S3用於數據存儲。

• 獨立分析每個選項

◦ Query the data for exploration and analysis

- Amazon Athena: 正確。Amazon Athena是一種交互式查詢服務，允許用戶使用標準SQL直接查詢存儲在Amazon S3中的數據，非常適合數據探索和分析。
- AWS Glue: 錯誤。AWS Glue主要用於ETL（提取、轉換、加載）任務，而不是直接用於數據查詢分析。
- Amazon Kinesis Data Streams: 錯誤。Kinesis主要用於實時數據流處理，不適合靜態數據的查詢分析。
- Amazon S3: 錯誤。S3是存儲服務，不具備數據查詢分析功能。

◦ Store the data

- Amazon Athena: 錯誤。Athena是查詢服務，不用於數據存儲。
- AWS Glue: 錯誤。Glue是ETL服務，不用於數據存儲。
- Amazon Kinesis Data Streams: 錯誤。Kinesis用於實時數據流處理，不適合長期數據存儲。
- Amazon S3: 正確。Amazon S3是對象存儲服務，適合存儲歷史交易數據等靜態數據。

◦ Transform the data

- Amazon Athena: 錯誤。Athena用於查詢分析，不具備數據轉換功能。
- AWS Glue: 正確。AWS Glue是一種完全託管的ETL服務，專門用於數據轉換和準備工作。
- Amazon Kinesis Data Streams: 錯誤。Kinesis主要用於實時數據流處理，不適合靜態數據轉換。
- Amazon S3: 錯誤。S3是存儲服務，不具備數據轉換功能。

▼ 95

▼ 中文

一家公司部署了一個使用 XGBoost 算法的機器學習模型，用於預測產品故障。該模型託管在 Amazon SageMaker 端點上，並基於正常運行數據進行訓練。一個 AWS Lambda 函數將預測結果提供給公司的應用程序。一名機器學習工程師必須實現一個解決方案，使用實時數據來檢測模型準確性隨時間的下降。哪種解決方案可以滿足這些要求？

- A. 使用 Amazon CloudWatch 創建一個儀表板，監控實時推理數據和模型預測。使用該儀表板檢測漂移。
- B. 修改 Lambda 函數，通過使用實時推理數據和模型預測來計算模型漂移。編程 Lambda 函數以發送警報。
- C. 在 SageMaker Model Monitor 中安排一個監控作業。使用該作業通過分析實時數據與訓練數據統計和約束的基線進行比較來檢測漂移。
- D. 在 SageMaker Debugger 中安排一個監控作業。使用該作業通過分析實時數據與訓練數據統計和約束的基線進行比較來檢測漂移。

▼ 解答

C

- **考察的知識點**
 - Amazon SageMaker Model Monitor的功能與使用場景。
 - 如何檢測模型漂移（Model Drift）並監控模型性能。
 - 實時數據與訓練數據基線的比較方法。
- **選項分析**

- **A. 使用Amazon CloudWatch創建一個儀表板，監控實時推理數據和模型預測。使用該儀表板檢測漂移。**
分析：CloudWatch可以監控指標，但它並不具備直接檢測模型漂移的功能。需要額外的邏輯來比較實時數據與訓練數據基線，單靠儀表板無法實現自動化的漂移檢測。此選項不符合要求。
- **B. 修改Lambda函數，通過使用實時推理數據和模型預測來計算模型漂移。編程Lambda函數以發送警報。**
分析：Lambda函數可以處理實時數據，但實現模型漂移檢測需要複雜的邏輯和額外的開發工作。此選項增加了開發複雜性，並且沒有利用AWS提供的現成工具（如SageMaker Model Monitor）。此選項不符合最佳實踐。
- **C. 在SageMaker Model Monitor中安排一個監控作業。使用該作業通過分析實時數據與訓練數據統計和約束的基線進行比較來檢測漂移。**
分析：SageMaker Model Monitor是專門設計用於監控模型性能和檢測數據漂移的工具。它可以自動比較實時數據與訓練數據基線，並生成報告或警報。此選項符合要求，是最佳解決方案。
- **D. 在SageMaker Debugger中安排一個監控作業。使用該作業通過分析實時數據與訓練數據統計和約束的基線進行比較來檢測漂移。**
分析：SageMaker Debugger主要用於調試和分析模型訓練過程，而不是用於實時監控模型性能或檢測漂移。此選項不符合要求。

▼ 96

▼ 中文

一家公司有一個機器學習模型，該模型使用歷史交易數據來預測客戶行為。一位機器學習工程師正在 Amazon SageMaker 中優化該模型，以提高模型的預測準確性。機器學習工程師必須檢查輸入數據和結果預測，以識別可能導致模型在不同人口統計數據之間表現偏差的趨勢。哪種解決方案可以提供這種類別的分析？

- A. 使用 Amazon CloudWatch 監控網絡指標和 CPU 指標，以便在模型訓練期間進行資源優化。
- B. 創建 AWS Glue DataBrew 配方，根據模型輸出的統計數據來糾正數據。

- **C. 使用 SageMaker Clarify 評估模型和訓練數據，以發現可能影響準確性的潛在模式。**
- D. 創建 AWS Lambda 函數以自動化數據預處理，並確保模型輸入數據的一致質量。

▼ 解答

C

• 考察的知識點

- 本題考察的是如何使用AWS工具進行模型優化和數據分析，特別是針對潛在數據偏差和模型性能的影響。
- 關鍵知識點包括Amazon SageMaker Clarify、AWS Glue DataBrew、Amazon CloudWatch和AWS Lambda的功能及適用場景。

• 選項分析

- **A. 使用 Amazon CloudWatch 監控網絡指標和 CPU 指標，以便在模型訓練期間進行資源優化。**
錯誤。CloudWatch主要用於監控資源使用情況（如CPU、內存、網絡等），並不涉及數據分析或模型性能評估。該選項與題目要求的“分析數據和預測結果以識別趨勢”無關。
- **B. 創建 AWS Glue DataBrew 配方，根據模型輸出的統計數據來糾正數據。**
錯誤。AWS Glue DataBrew是一個數據準備工具，用於清理和轉換數據，但它不直接提供模型性能評估或數據偏差分析功能。該選項未能滿足題目要求的“識別趨勢以優化模型性能”的需求。
- **C. 使用 SageMaker Clarify 評估模型和訓練數據，以發現可能影響準確性的潛在模式。**
正確。SageMaker Clarify專門用於檢查數據和模型中的偏差，並提供解釋性分析，幫助識別可能影響模型性能的潛在模式。這完全符合題目要求。
- **D. 創建 AWS Lambda 函數以自動化數據預處理，並確保模型輸入數據的一致質量。**
錯誤。AWS Lambda可以用於自動化數據預處理，但它不具備分析數據偏差或模型性能的功能。該選項未能滿足題目要求的“分析數據和預測結果以識別趨勢”的需求。

▼ 中文

一家公司使用 10 個加速實例類型的 Reserved Instances 來支持當前版本的 ML 模型。一名 ML 工程師需要將模型的新版本部署到 Amazon SageMaker 實時推理端點。解決方案必須使用原來的 10 個實例來支持模型的兩個版本。解決方案還必須包括一個額外的 Reserved Instance，可用於部署過程。版本之間的過渡必須無停機或服務中斷。哪種解決方案可以滿足這些要求？

- A. Configure a blue/green deployment with all-at-once traffic shifting.
配置一個藍/綠部署，並採用全量流量切換。
- B. Configure a blue/green deployment with canary traffic shifting and a size of 10%.
配置一個藍/綠部署，並採用金絲雀流量切換，比例為 10%。
- C. Configure a shadow test with a traffic sampling percentage of 10%.
配置一個影子測試，並採用 10% 的流量採樣比例。
- **D. Configure a rolling deployment with a rolling batch size of 1.**
配置一個滾動部署，並設置滾動批量大小為 1。

▼ 解答

D

• 考察的知識點

- Amazon SageMaker 實時推理端點的部署策略。
- 藍/綠部署、金絲雀部署、影子測試和滾動部署的概念與應用。
- 如何在無停機時間的情況下進行模型版本切換。
- 如何有效利用 Reserved Instances。

• 選項分析

- **A. 配置一個藍/綠部署，並採用全量流量切換。**
錯誤：全量流量切換會導致服務中斷，因為流量會直接從舊版本切換到新版本，沒有逐步過渡。不符合題目要求的“無停機時間或服務中斷”。
- **B. 配置一個藍/綠部署，並採用金絲雀流量切換，比例為 10%。**
錯誤：金絲雀流量切換通常用於測試新版本的模型，但題目要求使用

原來的 10 個實例同時服務兩個版本，這與金絲雀流量切換的設計不符。金絲雀流量切換無法滿足“使用原來的 10 個實例同時服務兩個版本”的要求。

- **C. 配置一個影子測試，並採用 10% 的流量採樣比例。**

錯誤：影子測試是將部分流量複製到新版本進行測試，但不會影響主流量的處理。影子測試無法滿足“使用原來的 10 個實例同時服務兩個版本”的要求。

- **D. 配置一個滾動部署，並設置滾動批量大小為 1。**

正確：滾動部署允許逐步替換實例上的模型版本，確保無停機時間。通過設置滾動批量大小為 1，可以逐個替換實例，確保服務不中斷，同時滿足題目要求的“使用原來的 10 個實例”和“無停機時間”。

▼ 98

▼ 中文

一家物聯網公司使用 Amazon SageMaker 來訓練和測試用於對象檢測的 XGBoost 模型。機器學習工程師需要在使用不同超參數訓練模型時監控性能指標。機器學習工程師還需要在訓練完成後發送短消息服務 (SMS) 文本消息。哪種解決方案可以滿足這些要求？

- A. 使用 Amazon CloudWatch 監控性能指標。使用 Amazon Simple Queue Service (Amazon SQS) 進行消息傳遞。
- **B. 使用 Amazon CloudWatch 監控性能指標。使用 Amazon Simple Notification Service (Amazon SNS) 進行消息傳遞。**
- C. 使用 AWS CloudTrail 監控性能指標。使用 Amazon Simple Queue Service (Amazon SQS) 進行消息傳遞。
- D. 使用 AWS CloudTrail 監控性能指標。使用 Amazon Simple Notification Service (Amazon SNS) 進行消息傳遞。

▼ 解答

B

• 考察的知識點

- Amazon SageMaker 的性能監控工具選擇 (CloudWatch vs CloudTrail)。
- 消息傳遞服務的選擇 (Amazon SQS vs Amazon SNS)。

- 選項分析

- **A. Use Amazon CloudWatch to monitor performance metrics. Use Amazon Simple Queue Service (Amazon SQS) for message delivery.**

正確性分析：Amazon CloudWatch是正確的工具，用於監控性能指標，因為它可以收集和顯示SageMaker的訓練指標。Amazon SQS是一個消息隊列服務，適合異步消息傳遞，但不直接支持發送SMS文本消息。

結論：此選項部分正確，但不滿足發送SMS的需求。

- **B. Use Amazon CloudWatch to monitor performance metrics. Use Amazon Simple Notification Service (Amazon SNS) for message delivery.**

正確性分析：Amazon CloudWatch是正確的工具，用於監控性能指標。Amazon SNS支持多種消息傳遞方式，包括發送SMS文本消息，完全滿足需求。

結論：此選項完全正確。

- **C. Use AWS CloudTrail to monitor performance metrics. Use Amazon Simple Queue Service (Amazon SQS) for message delivery.**

正確性分析：AWS CloudTrail主要用於記錄API調用和用戶活動日誌，不適合監控SageMaker的性能指標。Amazon SQS不支持直接發送SMS文本消息。

結論：此選項完全錯誤。

- **D. Use AWS CloudTrail to monitor performance metrics. Use Amazon Simple Notification Service (Amazon SNS) for message delivery.**

正確性分析：AWS CloudTrail不適合監控SageMaker的性能指標。Amazon SNS支持發送SMS文本消息，但由於監控工具選擇錯誤，此選項不正確。

結論：此選項部分正確，但整體錯誤。

-

▼ 99

▼ 中文

一家公司正在進行一個機器學習項目，該項目將包括 Amazon SageMaker notebook 實例。一名機器學習工程師必須確保 SageMaker notebook 實例不允許 root 訪問。

哪種解決方案可以防止部署允許 root 訪問的 notebook 實例？

- **A.** 使用 IAM 條件鍵來阻止部署允許 root 訪問的 SageMaker notebook 實例。
- **B.** 使用 AWS Key Management Service (AWS KMS) 密鑰來阻止部署允許 root 訪問的 SageMaker notebook 實例。
- **C.** 通過使用 Amazon EventBridge 事件監控資源創建。創建一個 AWS Lambda 函數來刪除所有已部署的允許 root 訪問的 SageMaker notebook 實例。
- **D.** 通過使用 AWS CloudFormation 事件監控資源創建。創建一個 AWS Lambda 函數來刪除所有已部署的允許 root 訪問的 SageMaker notebook 實例。

▼ 解答

A

• 考察的知識點

- 本題考察的是如何通過權限管理和策略控制來限制 Amazon SageMaker notebook 實例的行為，特別是禁止 root 訪問。
- 涉及 AWS IAM 條件鍵的使用，以及如何通過事件監控和自動化響應來管理資源。

• 選項分析

- **A. 正確：** IAM 條件鍵可以用於定義策略，限制特定操作或資源的行為。通過使用 IAM 條件鍵，可以在創建 SageMaker notebook 實例時直接阻止允許 root 訪問的實例部署。這是最直接和有效的解決方案，符合題目要求。
- **B. 錯誤：** AWS KMS 主要用於加密和密鑰管理，與限制 root 訪問無關。使用 KMS 無法直接阻止 SageMaker notebook 實例的部署。
- **C. 錯誤：** 雖然可以通過 EventBridge 監控資源創建並觸發 Lambda 函數刪除不符合要求的實例，但這種方法是事後處理，無法在部署階段直接阻止實例創建。這種方法效率較低，且不符合題目要求的“防止部署”目標。

- **D.錯誤：**與選項C類似，使用CloudFormation事件監控並觸發Lambda函數刪除實例是事後處理，無法在部署階段直接阻止實例創建。這種方法也不符合題目要求的“防止部署”目標。

▼ 100

▼ 中文

一家公司正在使用 Amazon SageMaker 開發機器學習模型。該公司將敏感的訓練數據存儲在一個 Amazon S3 bucket 中。模型訓練必須與互聯網進行網絡隔離。哪種解決方案可以滿足此要求？

- A. 在私有子網中運行 SageMaker 訓練作業。創建一個 NAT gateway。通過 NAT gateway 路由訓練流量。
- **B. 在私有子網中運行 SageMaker 訓練作業。創建一個 S3 gateway VPC endpoint。通過 S3 gateway VPC endpoint 路由訓練流量。**
- C. 在附加了安全組的公共子網中運行 SageMaker 訓練作業。在安全組中，使用入站規則限制來自互聯網的流量。使用 AWS KMS 密鑰 (SSE-KMS) 的服務器端加密對 SageMaker 實例存儲進行加密。
- D.通過包含 aws:SecureTransport 條件鍵值為 True 的 bucket policy 加密到 Amazon S3 的流量。使用 Amazon S3 的默認靜態加密。使用 AWS KMS 密鑰 (SSE-KMS) 的服務器端加密對 SageMaker 實例存儲進行加密。

▼ 解答

B

- **考察的知識點**
 - Amazon SageMaker的網絡隔離配置。
 - 如何通過VPC配置實現與互聯網隔離。
 - 使用S3 Gateway VPC Endpoint進行安全的數據訪問。
- **選項分析**
 - **A. 錯誤：**NAT網關允許私有子網中的資源訪問互聯網，這與題目要求的“網絡隔離”相違背。
 - **B. 正確：**S3 Gateway VPC Endpoint允許私有子網中的資源直接訪問S3，而無需通過互聯網。這完全符合題目要求的網絡隔離。

- **C. 錯誤：**公共子網本質上是與互聯網連接的，即使使用安全組限制流量，也無法實現完全的網絡隔離。
- **D. 錯誤：**雖然加密是安全的最佳實踐，但題目要求的是網絡隔離，而不是單純的加密措施。