



101~200

▼ 1

▼ 中文

一家公司需要一個AWS解決方案，該解決方案能夠在創建模型時自動創建模型的版本。哪個解決方案可以滿足此需求？

- A. Amazon Elastic Container Registry (Amazon ECR)
- B. 來自Amazon SageMaker Marketplace的模型包
- C. Amazon SageMaker ML Lineage Tracking
- **D. Amazon SageMaker Model Registry**

▼ 解答

D

• 考察的知識點

本題考察的是AWS SageMaker中與模型版本管理相關的功能，特別是如何自動創建和管理模型版本。

• 選項分析

◦ **A. Amazon Elastic Container Registry (Amazon ECR)**

錯誤。Amazon ECR 是一個容器鏡像存儲服務，用於存儲和管理 Docker 容器鏡像。它不直接支持 ML 模型的版本管理功能，因此不符合題目要求。

◦ **B. Model packages from Amazon SageMaker Marketplace**

錯誤。SageMaker Marketplace 提供預訓練模型和算法的市場，但它主要用於模型的分發和購買，而不是用於自動創建模型版本。

◦ **C. Amazon SageMaker ML Lineage Tracking**

錯誤。SageMaker ML Lineage Tracking 用於跟蹤機器學習工作流程中的數據、模型和訓練過程的關係，但它不負責自動創建模型版本。

- **D. Amazon SageMaker Model Registry**正確。Amazon SageMaker Model Registry 是專門設計用於管理和版本控制 ML 模型的服務。它支持自動創建模型版本並記錄模型的元數據，完全符合題目要求。

▼ 2

▼ 中文

一家公司需要使用檢索增強生成（Retrieval Augmented Generation，RAG）來補充運行在 Amazon Bedrock 上的開源大型語言模型（LLM）。該公司的 RAG 數據是一組存儲在 Amazon S3 存儲桶中的文檔。這些文檔包括 .csv 文件和 .docx 文件。哪種解決方案能夠以最少的運營開銷滿足這些需求？

- A. 在 Amazon SageMaker Pipelines 中創建一個管道以生成一個新模型。從 Amazon Bedrock 調用新模型以執行 RAG 查詢。
- B. 將數據轉換為向量。將數據存儲在 Amazon Neptune 數據庫中。將數據庫連接到 Amazon Bedrock。調用 Amazon Bedrock API 來執行 RAG 查詢。
- C. 使用 Amazon SageMaker 中的 AutoML 作業對現有 LLM 進行微調。將 S3 存儲桶配置為 AutoML 作業的數據源。將 LLM 部署到 SageMaker 端點。使用該端點執行 RAG 查詢。
- **D. 為 Amazon Bedrock 創建一個知識庫。配置一個引用 S3 存儲桶的數據源。使用 Amazon Bedrock API 執行 RAG 查詢。**

▼ 解答

D

- **考察的知識點**
 - Amazon Bedrock的功能與使用場景
 - Retrieval Augmented Generation (RAG)的實現方法
 - 如何處理和集成Amazon S3中的數據
 - 選擇最少的操作開銷解決方案
- **選項分析**
 - **A.** 建議創建一個新模型並使用SageMaker Pipelines生成模型。這增加了操作複雜性，並且不直接利用Amazon Bedrock的內置功能來處理RAG查詢。操作開銷較高，因為需要額外的模型訓練和部署步驟。

- **B.** 中是一個可行的解決方案，但它需要額外的步驟來處理數據轉換和數據庫管理。操作開銷較高，因為需要設置和維護Amazon Neptune數據庫，並且不直接利用Amazon Bedrock的知識庫功能。
- **C.** 有的LLM需要大量的計算資源和時間，並且增加了操作複雜性。此選項沒有直接利用Amazon Bedrock的內置功能，而是依賴SageMaker進行模型微調和部署。
- **D.** 確原因：此選項直接利用Amazon Bedrock的知識庫功能，允許配置S3作為數據源並執行RAG查詢。操作開銷最低，因為不需要額外的模型訓練、數據轉換或數據庫管理。

▼ 3

▼ 中文

家公司計劃在 Amazon SageMaker 端點上部署一個機器學習模型用於生產推理。平均推理負載大小將從 100 MB 到 300 MB 不等。推理請求必須在 60 分鐘或更短時間內處理完成。

哪種 SageMaker 推理選項可以滿足這些要求？

- A. Serverless inference無服務器推理
- **B. Asynchronous inference**異步推理
- C. Real-time inference實時推理
- D. Batch transform批量轉換

▼ 解答

B

• 考察的知識點

- Amazon SageMaker的不同推理選項及其適用場景。
- 異步推理的特點和適用場景。
- 實時推理與批量轉換的區別。

• 選項分析

◦ **A. Serverless inference 無服務器推理**

錯誤。無服務器推理適用於低延遲和小型推理請求場景，通常用於實時推理場景。由於推理請求的大小在100 MB到300 MB之間，且需要在60分鐘內完成，這種場景不適合無服務器推理。

- **B. Asynchronous inference 異步推理**
正確。異步推理適用於處理較大的推理請求（如100 MB到300 MB），並且允許較長的處理時間（如60分鐘）。它能夠處理高負載和長時間的推理任務，因此是最佳選擇。
- **C. Real-time inference 實時推理**錯誤。實時推理適用於低延遲場景，通常要求推理請求在毫秒或秒級完成。由於推理請求的大小較大且處理時間較長，實時推理不適合此場景。
- **D. Batch transform 批量轉換**錯誤。批量轉換適用於離線批量處理場景，而不是在線推理場景。題目要求的是生產推理，因此批量轉換不符合要求。

▼ 4

▼ 中文

一位機器學習工程師注意到圖像分類訓練任務中存在類別不平衡。機器學習工程師應該怎麼做來解決這個問題？

- A. Reduce the size of the dataset.減少數據集的大小。
- B. Transform some of the images in the dataset.對數據集中的一些圖像進行轉換。
- **C. Apply random oversampling on the dataset.**對數據集應用隨機過採樣。
- D. Apply random data splitting on the dataset.對數據集應用隨機數據拆分。

▼ 解答

C

• 考察的知識點

本題考察的是如何處理機器學習中的類別不平衡問題，特別是在圖像分類任務中。

類別不平衡問題可能導致模型對某些類別的預測性能較差，需要通過數據增強或採樣技術來解決。

• 選項分析

- **A. Reduce the size of the dataset. 減少數據集的大小。**錯誤：減少數據集的大小可能會進一步減少少數類別的樣本數量，從而加劇類別

不平衡問題。此外，減少數據集的大小可能會導致模型性能下降，因為訓練數據不足。

- **B. Transform some of the images in the dataset. 對數據集中的一些圖像進行轉換。**部分正確：數據增強（如圖像轉換）可以增加少數類別的樣本數量，但題目沒有明確說明是針對少數類別進行增強，因此不完全解決類別不平衡問題。數據增強通常是輔助方法，而不是直接解決類別不平衡的主要手段。
- **C. Apply random oversampling on the dataset. 對數據集應用隨機過採樣。**正確：隨機過採樣是解決類別不平衡問題的常用方法，通過增加少數類別的樣本數量，使類別分佈更加均衡。這種方法可以有效提高模型對少數類別的預測性能。
- **D. Apply random data splitting on the dataset. 對數據集應用隨機數據拆分。**錯誤：隨機數據拆分是**用於劃分訓練集、驗證集和測試集的方法**，與解決類別不平衡問題無關。隨機拆分可能會導致少數類別樣本在訓練集中進一步減少，加劇類別不平衡問題。

▼ 5

▼ 中文

一家公司每天接收關於客戶與其機器學習模型交互的 .csv 文件。該公司將這些文件存儲在 Amazon S3 中，並使用這些文件重新訓練模型。一名機器學習工程師需要實施一個解決方案，在模型重新訓練之前**對文件中的信用卡號碼進行屏蔽**。哪種解決方案能夠以最少的開發工作量滿足此需求？

- A. 在 Amazon Macie 中創建一個發現任務。配置該任務以查找並屏蔽敏感數據。
- **B. 編寫在 AWS Glue 作業上運行的 Apache Spark 代碼。使用 AWS Glue 中的敏感數據檢測功能來查找並屏蔽敏感數據。**
- C. 編寫在 AWS Glue 作業上運行的 Apache Spark 代碼。編程代碼以執行正則表達式操作來查找並屏蔽敏感數據。
- D. 編寫在 Amazon EC2 實例上運行的 Apache Spark 代碼。編程代碼以執行操作來查找並屏蔽敏感數據。

▼ 解答

B

- **考察的知識點**

- 數據預處理：如何在機器學習管道中處理敏感數據。
- AWS服務：Amazon Macie、AWS Glue、Amazon EC2的功能和適用場景。
- 敏感數據檢測：如何高效地發現和屏蔽敏感數據。

• 選項分析

- **A. 正確性分析：**Amazon Macie是專門用於發現和保護敏感數據的服務，但它主要用於數據分類和發現，而不是直接用於數據處理或修改（如屏蔽敏感數據）。
錯誤原因：Macie無法直接對數據進行屏蔽或修改，因此需要額外的開發工作來實現屏蔽功能。
- **B. 正確性分析：**AWS Glue提供了內置的敏感數據檢測功能，可以直接用於發現和屏蔽敏感數據。這種方法利用了Glue的託管服務，減少了開發和管理的複雜性。
正確原因：此選項直接使用AWS Glue的功能，開發工作量最少，符合題目要求。
- **C. 正確性分析：**使用正則表達式可以實現敏感數據的查找和屏蔽，但需要手動編寫代碼，增加了開發工作量。
錯誤原因：雖然可以實現功能，但與AWS Glue的內置敏感數據檢測功能相比，開發工作量更大，不符合“最少開發工作量”的要求。
- **D. 正確性分析：**在EC2實例上運行Apache Spark代碼可以實現敏感數據的查找和屏蔽，但需要手動管理EC2實例和編寫代碼，開發工作量和運維成本較高。
錯誤原因：與AWS Glue相比，此方法需要更多的開發和管理工作，不符合題目要求。

▼ 6

▼ 中文

一家醫療公司正在使用AWS構建一個工具，用於為患者推薦治療方案。該公司已從患者處獲得健康記錄和自我報告的英文文本信息。公司需要利用這些信息來獲得關於患者的洞察。

哪種解決方案能夠以最少的開發工作量滿足此需求？

- A. 使用Amazon SageMaker構建一個循環神經網絡（RNN）來總結數據。
- B. 使用Amazon Comprehend Medical總結數據。

- C. 使用Amazon Kendra創建一個快速搜索工具以查詢數據。
- D. 使用Amazon SageMaker Sequence-to-Sequence (seq2seq) 算法從數據中創建文本摘要。

▼ 解答

B

• 考察的知識點

本題考察的是AWS服務在醫療數據處理中的應用，特別是如何使用現有的服務來處理和分析醫療文本數據。

重點關注Amazon Comprehend Medical、Amazon SageMaker、Amazon Kendra等服務的功能和適用場景。

• 選項分析

- **A. 錯誤原因：**雖然Amazon SageMaker可以用來構建自定義機器學習模型，但使用RNN需要大量的開發工作，包括數據預處理、模型訓練和優化。這與題目要求的“最少開發工作”不符。
- **B. 正確原因：**Amazon Comprehend Medical是一個專門用於處理醫療文本的託管服務，可以快速提取醫療信息（如藥物、診斷、治療等），無需額外開發工作。這是最符合題目要求的解決方案。
- **C. 錯誤原因：**Amazon Kendra是一個智能搜索服務，適用於構建搜索工具，但它並不適合直接處理和總結醫療文本數據。題目要求的是“總結數據”，而不是“查詢數據”。
- **D. 錯誤原因：**雖然seq2seq算法可以用於文本摘要，但使用Amazon SageMaker進行模型訓練和部署仍然需要較多的開發工作。這與題目要求的“最少開發工作”不符。

▼ 7

▼ 中文

一家公司需要從 PDF 文檔中提取實體以構建分類器模型。哪種解決方案能在最短時間內提取並存儲實體？

- **A. 使用 Amazon Comprehend 提取實體。將輸出存儲在 Amazon S3。**
- B. 在 Amazon SageMaker 上使用開源 AI 光學字符識別 (OCR) 工具提取實體。將輸出存儲在 Amazon S3。

- C. 使用 Amazon Textract 提取實體。使用 Amazon Comprehend 將實體轉換為文本。將輸出存儲在 Amazon S3。
- D. 使用集成了 Amazon Augmented AI (Amazon A2I) 的 Amazon Textract 提取實體。將輸出存儲在 Amazon S3。

▼ 解答

A

- **考察的知識點**

本題考察的是AWS服務的選擇與組合，特別是與文檔處理相關的服務，包括Amazon Comprehend、Amazon Textract、Amazon SageMaker以及Amazon Augmented AI (A2I)。

重點在於理解如何高效地提取實體並存儲數據，同時選擇最合適的服務以節省時間。

- **選項分析**

- **A.** Amazon Comprehend是一種自然語言處理服務，能夠直接從文本中提取實體。
如果PDF文檔已經是可解析的文本格式，Comprehend可以快速提取實體並存儲到S3。此選項是直接使用Comprehend提取實體，省去了OCR或其他額外步驟，因此時間最短。
正確。
- **B.** 使用開源OCR工具需要額外的開發和部署時間，且可能需要額外的調試和優化。
雖然可以提取實體，但相比AWS原生服務，時間成本較高。
錯誤。
- **C.** Amazon Textract用於從文檔中提取結構化數據，但它並不直接提取實體。
需要額外使用Amazon Comprehend將數據轉換為實體，這增加了處理時間。
錯誤。
- **D.** Amazon Textract與Amazon A2I集成可以實現人工審查，但這會增加處理時間。
此選項適合需要高精度和人工干預的場景，但不適合追求最快時間的場景。
錯誤。

▼ 8

▼ 中文

一家公司通過VPN共享Amazon SageMaker Studio筆記本。公司必須實施訪問控制，以防止惡意行為者利用預簽名URL訪問筆記本。

哪種解決方案能夠滿足這些要求？

- **A.** 使用aws:sourcelp IAM策略條件設置Studio客戶端IP驗證。
- **B.** 使用aws:sourceVpc IAM策略條件設置Studio客戶端VPC驗證。
- **C.** 使用aws:PrimaryTag IAM策略條件設置Studio客戶端角色端點驗證。
- **D.** 使用aws:PrincipalTag IAM策略條件設置Studio客戶端用戶端點驗證。

▼ 解答

A

• 考察的知識點

- Amazon SageMaker Studio的安全性配置。
- 如何使用IAM策略條件（如aws:sourcelp）來控制訪問權限。
- 防止惡意用戶通過預簽名URL訪問資源。

• 選項分析

- **A.** 正確：使用aws:sourcelp IAM策略條件可以限制訪問者的IP地址，從而確保只有通過VPN的合法IP地址可以訪問SageMaker Studio筆記本。
這是解決問題的正確方法，因為它直接限制了惡意用戶通過預簽名URL訪問資源的可能性。
- **B.** 錯誤：aws:sourceVpc IAM策略條件用於限制來自特定VPC的訪問，但題目中並未提到需要基於VPC的限制。
雖然VPC驗證可以提供一定的安全性，但它並不能直接解決預簽名URL的安全問題。
- **C.** 錯誤：aws:PrimaryTag IAM策略條件用於基於資源的標籤進行訪問控制，與題目中提到的預簽名URL和IP地址限制無關。
此選項與題目要求不匹配。
- **D.** 錯誤：aws:PrincipalTag IAM策略條件用於基於用戶標籤進行訪問控制，與題目中提到的預簽名URL和IP地址限制無關。
此選項與題目要求不匹配。

▼ 9

▼ 中文

一位機器學習工程師需要合併並轉換來自兩個數據源的數據，以重新訓練現有的機器學習模型。一個數據源由存儲在 Amazon S3 存儲桶中的 .csv 文件組成。每個 .csv 文件包含數百萬條記錄。另一個數據源是一個 Amazon Aurora 數據庫集群。

合併過程的結果必須寫入第二個 S3 存儲桶。機器學習工程師需要每周執行一次此合併和轉換任務。

哪種解決方案可以以最少的運營開銷滿足這些需求？

- A. 每周創建一個臨時 Amazon EMR 集群。使用該集群運行一個 Apache Spark 作業來合併和轉換數據。
- **B. 創建一個每周運行的 AWS Glue 作業，使用 Apache Spark 引擎。使用 DynamicFrame 原生操作來合併和轉換數據。**
- C. 創建一個 AWS Lambda 函數，每周運行 Apache Spark 代碼來合併和轉換數據。配置 Lambda 函數以連接到初始 S3 存儲桶和數據庫集群。
- D. 創建一個 AWS Batch 作業，每周在 Amazon EC2 實例上運行 Apache Spark 代碼。配置 Spark 代碼將數據從 EC2 實例保存到第二個 S3 存儲桶。

▼ 解答

B

• 考察的知識點

- 數據處理與轉換：如何高效地合併和轉換來自不同數據源的數據。
- AWS服務選擇：選擇適合的AWS服務以實現低運營開銷的定期任務。
- Apache Spark與AWS Glue的使用：了解兩者的功能和適用場景。

• 選項分析

- **A. 正確性分析：**Amazon EMR可以運行Apache Spark作業並處理大規模數據，但需要手動管理集群的創建和銷毀，增加了運營開銷。
結論：雖然可以實現需求，但運營開銷較高，不是最佳選擇。
- **B. 正確性分析：**AWS Glue是一個託管的ETL服務，支持Apache Spark引擎，並且可以通過DynamicFrame高效處理和轉換數據。Glue作業可以定期運行，且無需管理底層基礎設施，運營開銷最低。
結論：滿足需求且運營開銷最低，是最佳選擇。

- **C. 正確性分析：**AWS Lambda不支持直接運行Apache Spark代碼。Lambda適合處理小規模任務，但不適合處理數百萬條記錄的大規模數據處理。
結論：技術上不可行，錯誤選項。
- **D. 正確性分析：**AWS Batch可以運行大規模計算任務，但需要管理EC2實例的配置和資源分配，增加了運營開銷。
結論：雖然可以實現需求，但運營開銷較高，不是最佳選擇。

▼ 10

▼ 中文

一位機器學習工程師已將一個 Amazon SageMaker 模型部署到生產環境中的無服務器端點。該模型通過 InvokeEndpoint API 操作調用。該模型在生產環境中的延遲比測試環境中的基線延遲更高。機器學習工程師認為延遲增加是由於模型啟動時間導致的。機器學習工程師應該怎麼做來確認或否定這個假設？

- A. 安排一個 SageMaker Model Monitor 任務。觀察有關模型質量的指標。
- B. 安排一個啟用 Amazon CloudWatch 指標的 SageMaker Model Monitor 任務。
- **C. 啟用 Amazon CloudWatch 指標。觀察 SageMaker 命名空間中的 ModelSetupTime 指標。**
- D. 啟用 Amazon CloudWatch 指標。觀察 SageMaker 命名空間中的 ModelLoadingWaitTime 指標。

▼ 解答

C

• 考察的知識點

- Amazon SageMaker的性能監控與診斷。
- 使用Amazon CloudWatch監控SageMaker模型的相關指標。
- 理解SageMaker模型啟動時間（ModelSetupTime）和加載時間（ModelLoadingWaitTime）的區別。

• 選項分析

- **A. 錯誤：**SageMaker Model Monitor主要用於監控模型質量（如數據漂移、預測偏差），而不是用於診斷模型啟動時間或性能問題。

- **B. 錯誤：**雖然啟用CloudWatch可以提供一些性能指標，但Model Monitor的主要功能仍然是監控模型質量，而不是直接診斷模型啟動時間問題。
- **C. 正確：**ModelSetupTime是SageMaker提供的一個專門指標，用於衡量模型啟動時間。通過觀察該指標，可以確認或否定模型啟動時間是否是導致延遲的原因。
- **D. 錯誤：**ModelLoadingWaitTime是另一個相關指標，但它主要用於衡量模型加載到內存的等待時間，而不是模型啟動時間。題目明確提到需要診斷“模型啟動時間”，因此該選項不符合要求。

▼ 11

▼ 中文

一位機器學習工程師需要確保數據集符合有關個人身份信息 (PII) 的法規要求。該機器學習工程師將使用這些數據在 Amazon SageMaker 實例上訓練機器學習模型。SageMaker 必須不能使用任何 PII。哪種解決方案能夠以最具操作效率的方式滿足這些要求？

- **A. 使用 Amazon Comprehend DetectPiiEntities API 調用從數據中刪除 PII。將數據存儲在 Amazon S3 存儲桶中。從 SageMaker 實例訪問 S3 存儲桶以進行模型訓練。**
- B. 使用 Amazon Comprehend DetectPiiEntities API 調用從數據中刪除 PII。將數據存儲在 Amazon Elastic File System (Amazon EFS) 文件系統中。將 EFS 文件系統掛載到 SageMaker 實例以進行模型訓練。
- C. 使用 AWS Glue DataBrew 清理數據集中的 PII。將數據存儲在 Amazon Elastic File System (Amazon EFS) 文件系統中。將 EFS 文件系統掛載到 SageMaker 實例以進行模型訓練。
- D. 使用 Amazon Macie 自動發現數據中的 PII。移除 PII。將數據存儲在 Amazon S3 存儲桶中。將 S3 存儲桶掛載到 SageMaker 實例以進行模型訓練。

▼ 解答

A

- **考察的知識點**

- 數據隱私與合規性：如何處理包含個人身份信息（PII）的數據以確保合規性。
- AWS服務選擇：了解Amazon Comprehend、Amazon S3、Amazon EFS、AWS Glue DataBrew和Amazon Macie的功能及適用場景。
- Amazon SageMaker數據處理：如何準備數據以供機器學習模型訓練。

• 選項分析

- **A. 使用Amazon Comprehend DetectPiiEntities API調用從數據中刪除PII，將數據存儲在Amazon S3存儲桶中，從SageMaker實例訪問S3存儲桶以進行模型訓練。**

正確性分析：Amazon Comprehend的DetectPiiEntities API可以有效識別和刪除PII，確保數據合規性。將數據存儲在Amazon S3中是高效且常見的做法，S3與SageMaker集成良好，支持直接訪問。

操作效率：此方法直接使用S3存儲，避免了額外的掛載操作，最為高效。

結論：正確。

- **B. 使用Amazon Comprehend DetectPiiEntities API調用從數據中刪除PII，將數據存儲在Amazon EFS文件系統中，將EFS文件系統掛載到SageMaker實例以進行模型訓練。**

正確性分析：Amazon Comprehend可以識別和刪除PII，但使用EFS存儲數據並掛載到SageMaker實例增加了複雜性。EFS通常用於共享文件系統，而不是存儲訓練數據的最佳選擇。

操作效率：相比S3，EFS的操作效率較低，且需要額外的掛載步驟。

結論：錯誤。

- **C. 使用AWS Glue DataBrew清理數據集中的PII，將數據存儲在Amazon EFS文件系統中，將EFS文件系統掛載到SageMaker實例以進行模型訓練。**

正確性分析：AWS Glue DataBrew可以清理數據，但其主要用於數據預處理和轉換，而非專門處理PII。使用EFS存儲數據並掛載到SageMaker實例增加了複雜性。

操作效率：此方法涉及多個步驟，操作效率較低。

結論：錯誤。

- **D. 使用Amazon Macie自動發現數據中的PII，移除PII，將數據存儲在Amazon S3存儲桶中，將S3存儲桶掛載到SageMaker實例以進行模型訓練。**

正確性分析：Amazon Macie可以發現PII，但其主要用於數據分類和

安全性評估，而非直接刪除PII。此方法需要額外的步驟來移除PII。
操作效率：相比直接使用Amazon Comprehend，Amazon Macie的流程較為複雜，效率較低。
結論：錯誤。

▼ 12

▼ 中文

一家公司必須在任何新創建的 Amazon SageMaker notebook 實例上安裝自定義腳本。

哪種解決方案能夠以最少的運營開銷滿足此要求？

- **A.** 創建一個生命周期配置腳本，在創建新的 SageMaker notebook 時安裝自定義腳本。在創建步驟中，將生命周期配置附加到每個新的 SageMaker notebook。
- **B.** 創建一個包含自定義腳本的 Amazon Elastic Container Registry (Amazon ECR) 自定義鏡像。將 ECR 鏡像推送到 Docker 註冊表。將 Docker 鏡像附加到 SageMaker Studio 域。選擇內核作為 SageMaker notebook 的一部分運行。
- **C.** 創建一個自定義包索引存儲庫。使用 AWS CodeArtifact 管理自定義腳本的安裝。設置 AWS PrivateLink 端點以連接 CodeArtifact 到 SageMaker 實例。安裝腳本。
- **D.** 將自定義腳本存儲在 Amazon S3 中。創建一個 AWS Lambda 函數，在新的 SageMaker notebook 上安裝自定義腳本。配置 Amazon EventBridge 在初始化新的 SageMaker notebook 時調用 Lambda 函數。

▼ 解答

A

1. 考察的知識點

- Amazon SageMaker生命周期配置的使用。
- 如何在創建新的SageMaker notebook實例時自動執行腳本。
- 選擇最少的操作開銷解決方案。

2. 選項分析

- **A.**
正確：Amazon SageMaker支持生命周期配置腳本，可以在創建或啟動notebook實例時自動執行腳本。這種方法直接集成到SageMaker的功能中，操作開銷最小。
- **B.**
錯誤：雖然使用自定義ECR鏡像可以實現類似功能，但需要額外的步驟來創建和管理鏡像，並且需要用戶手動選擇內核。這增加了操作開銷。
- **C.**
錯誤：使用CodeArtifact和PrivateLink的解決方案複雜度較高，涉及多個服務的配置，操作開銷顯著增加。
- **D.**
錯誤：此方法需要額外的服務（Lambda和EventBridge）的配置和管理，增加了操作開銷。

▼ 13

▼ 中文

一家公司正在為一個電子商務應用程序構建即時數據處理管道。該應用程序生成大量點擊流數據，必須以接近即時的方式進行攝取、處理和可視化。公司需要一個支持使用 SQL 進行數據處理以及支持使用 Jupyter notebooks 進行交互式分析的解決方案。

哪種解決方案可以滿足這些需求？

- **A.** 使用 Amazon Data Firehose 攝取數據。創建一個 AWS Lambda 函數來處理數據。將處理後的數據存儲在 Amazon S3 中。使用 Amazon QuickSight 對數據進行可視化。
- **B.** 使用 Amazon Kinesis Data Streams 攝取數據。使用 Amazon Data Firehose 轉換數據。使用 Amazon Athena 處理數據。使用 Amazon QuickSight 對數據進行可視化。
- **C.** 使用 Amazon Managed Streaming for Apache Kafka (Amazon MSK) 攝取數據。使用 AWS Glue 和 PySpark 處理數據。將處理後的數據存儲在 Amazon S3 中。使用 Amazon QuickSight 對數據進行可視化。
- **D.** 使用 Amazon Managed Streaming for Apache Kafka (Amazon MSK) 攝取數據。使用 Amazon Managed Service for Apache Flink 處理數據。使用內置的 Flink 儀表板對數據進行可視化。

▼ 解答

D

• 考察的知識點

- 即時數據處理與分析的架構設計。
- AWS服務的功能與適用場景，包括Amazon MSK、Amazon Flink、Amazon QuickSight等。
- 支持SQL數據處理和交互式分析工具（如Jupyter notebooks）的服務選擇。

• 選項分析

- **A. 使用Amazon Data Firehose攝取數據，AWS Lambda處理數據，Amazon S3存儲數據，Amazon QuickSight可視化。**

錯誤：Amazon Data Firehose主要用於數據流的傳輸和存儲，而不是即時數據處理。

錯誤：AWS Lambda適合事件驅動的處理，但不適合高吞吐量的即時數據流處理。

正確：Amazon QuickSight可以用於數據可視化，但不支持即時交互式分析。

- **B. 使用Amazon Kinesis Data Streams攝取數據，Amazon Data Firehose轉換數據，Amazon Athena處理數據，Amazon QuickSight可視化。**

正確：Amazon Kinesis Data Streams適合即時數據攝取。

錯誤：Amazon Data Firehose主要用於數據傳輸，而不是複雜的即時數據轉換。

錯誤：Amazon Athena是交互式查詢服務，但不適合即時數據處理。

正確：Amazon QuickSight可以用於數據可視化，但不支持即時交互式分析。

- **C. 使用Amazon MSK攝取數據，AWS Glue和PySpark處理數據，Amazon S3存儲數據，Amazon QuickSight可視化。**

正確：Amazon MSK適合高吞吐量的即時數據攝取。

錯誤：AWS Glue和PySpark適合批處理，而不是即時數據處理。

正確：Amazon S3可以存儲處理後的數據。

正確：Amazon QuickSight可以用於數據可視化，但不支持即時交互式分析。

- **D. 使用Amazon MSK攝取數據，Amazon Managed Service for Apache Flink處理數據，內置Flink儀表板可視化。**

正確：Amazon MSK適合高吞吐量的即時數據攝取。

正確：Amazon Managed Service for Apache Flink支持即時數據處理，並且支持SQL查詢和Jupyter notebooks進行交互式分析。

正確：內置的Flink儀表板可以用於即時數據可視化。

▼ 14

▼ 中文

一家醫療公司需要存儲臨床數據。該數據包括個人身份信息 (PII) 和受保護的健康信息 (PHI)。

一位機器學習工程師需要實施一個解決方案，以確保 PII 和 PHI 不會用於訓練機器學習模型。哪種解決方案可以滿足這些要求？

- A. 將臨床數據存儲在 Amazon S3 存儲桶中。在數據用於模型訓練之前，使用 AWS Glue DataBrew 對 PII 和 PHI 進行屏蔽。
- B. 將臨床數據上傳到 Amazon Redshift 數據庫。在數據用於模型訓練之前，使用內置的 SQL 存儲過程自動分類和屏蔽 PII 和 PHI。
- **C. 使用 Amazon Comprehend 在數據用於模型訓練之前檢測並屏蔽 PII。使用 Amazon Comprehend Medical 在數據用於模型訓練之前檢測並屏蔽 PHI。**
- D. 創建一個 AWS Lambda 函數來加密 PII 和 PHI。編程該 Lambda 函數，將加密的數據保存到一個 Amazon S3 存儲桶中用於模型訓練。

▼ 解答

C

• 考察的知識點

- 數據隱私與合規性：如何處理包含敏感信息（PII和PHI）的數據。
- AWS服務的使用：包括Amazon Comprehend、Amazon Comprehend Medical、AWS Glue DataBrew、Amazon Redshift 等。
- 機器學習數據預處理：確保敏感數據不會用於模型訓練。

• 選項分析

- **A. Store the clinical data in Amazon S3 buckets. Use AWS Glue DataBrew to mask the PII and PHI before the data is used for model training.**

正確性分析：AWS Glue DataBrew確實可以用於數據清理和屏蔽敏感信息，但它並不專門針對PII和PHI的檢測和屏蔽。需要額外的配置和規則來實現這一功能。

結論：此選項不夠全面，無法直接滿足要求。

- **B. Upload the clinical data to an Amazon Redshift database. Use built-in SQL stored procedures to automatically classify and mask the PII and PHI before the data is used for model training.**

正確性分析：Amazon Redshift的SQL存儲過程可以處理數據，但它並沒有內置功能專門用於檢測和屏蔽PII和PHI。需要額外的開發工作。

結論：此選項不夠直接，無法滿足要求。

- **C. Use Amazon Comprehend to detect and mask the PII before the data is used for model training. Use Amazon Comprehend Medical to detect and mask the PHI before the data is used for model training.**

正確性分析：Amazon Comprehend可以檢測和屏蔽PII，而Amazon Comprehend Medical專門用於處理醫療數據中的PHI。這兩個服務結合使用可以直接滿足要求。

結論：此選項是正確答案。

- **D. Create an AWS Lambda function to encrypt the PII and PHI. Program the Lambda function to save the encrypted data to an Amazon S3 bucket for model training.**

正確性分析：加密數據並保存到S3並不能屏蔽PII和PHI，且加密後的數據仍然無法直接用於模型訓練。

結論：此選項不符合要求。

▼ 15

▼ 中文

一名機器學習工程師正在開發一個分類模型。該工程師需要在 Amazon SageMaker 的處理任務、訓練任務和管道中使用自定義庫。

哪種解決方案能夠以**最少的實施工作量**提供此功能？

- A. 手動在 SageMaker 容器中安裝這些庫。
- **B. 構建一個包含所需庫的自定義 Docker 容器。將容器托管在 Amazon Elastic Container Registry (Amazon ECR) 中。在 SageMaker 任務和管道中使用 ECR 鏡像。**

- C. 創建一個 SageMaker notebook 實例來托管任務。創建一個 AWS Lambda 函數，在 notebook 實例啟動時安裝這些庫。配置 SageMaker 任務和管道在 notebook 實例上運行。
- D. 在 Amazon EC2 實例上外部運行這些庫的代碼。將結果存儲在 Amazon S3 中。在 SageMaker 任務和管道中導入這些結果。

▼ 解答

B

• 考察的知識點

- Amazon SageMaker的容器化能力及其與Amazon Elastic Container Registry (ECR)的集成。
- 如何在SageMaker中使用自定義庫以支持處理任務、訓練任務和管道。
- 對比不同方法的實現複雜度和效率。

• 獨立分析與答案選擇

逐個分析選項：

- **A. 手動在 SageMaker 容器中安裝這些庫。**
優點：直接在SageMaker容器中安裝庫，操作簡單。
缺點：需要每次手動安裝，無法自動化，且不適合大規模任務或管道的重複使用。實現效率低，容易出錯。
結論：錯誤。此方法不符合“最少實現努力”的要求。
- **B. 構建一個包含所需庫的自定義 Docker 容器。將容器托管在 Amazon ECR 中。在 SageMaker 任務和管道中使用 ECR 鏡像。**
優點：通過構建自定義Docker容器，可以一次性打包所有所需的庫，托管在ECR中後可重複使用，適合處理任務、訓練任務和管道。實現自動化，減少重複工作。
缺點：需要初次構建容器，但後續使用非常高效。
結論：正確。此方法符合“最少實現努力”的要求。
- **C. 創建一個 SageMaker notebook 實例來托管任務。創建一個 AWS Lambda 函數，在 notebook 實例啟動時安裝這些庫。配置 SageMaker 任務和管道在 notebook 實例上運行。**
優點：可以動態安裝庫，適合小規模任務。
缺點：需要額外創建Lambda函數和notebook實例，增加複雜性。Notebook實例並不適合大規模管道任務，且動態安裝庫可能導致啟動

時間延長。

結論：錯誤。此方法複雜度較高，不符合“最少實現努力”的要求。

- **D. 在 Amazon EC2 實例上外部運行這些庫的代碼。將結果存儲在 Amazon S3 中。在 SageMaker 任務和管道中導入這些結果。**

優點：可以利用EC2實例運行代碼並存儲結果。

缺點：需要額外管理EC2實例和S3存儲，無法直接在SageMaker中運行自定義庫，增加了操作複雜性。此方法效率低且不適合直接集成到 SageMaker 管道中。

結論：錯誤。此方法複雜度較高，不符合“最少實現努力”的要求。

▼ 16

▼ 中文

一位機器學習工程師正在將一個訓練好的模型部署到一個 Amazon SageMaker endpoint。該工程師需要在生產環境中發生數據質量問題時接收警報。

哪種解決方案可以滿足此需求？

- A. 配置一個 Amazon CloudWatch metric alarm 和一個對應的操作，以發送 Amazon Simple Notification Service (Amazon SNS) 通知。
- B. 將 SageMaker endpoint 與 SageMaker Clarify 處理作業集成。配置一個 Amazon CloudWatch alarm 以提供警報。
- **C. 在 SageMaker Model Monitor 中配置一個監控作業。將 Model Monitor 與 Amazon CloudWatch 集成以提供警報。**
- D. 在 SageMaker Data Wrangler 中配置一個數據流。將 Data Wrangler 與 Amazon CloudWatch 集成以提供警報。

▼ 解答

C

- **這題考察的知識點是什麼**

本題考察的是 Amazon SageMaker 的模型監控功能，特別是如何在生產環境中監控數據質量問題並設置警報。

涉及的服務包括 SageMaker Model Monitor、Amazon CloudWatch 和 Amazon SNS。

- **獨立分析每個選項**

- **A.**
 正確性分析：此選項提到使用 CloudWatch 和 SNS 來發送通知，但沒有提到如何具體監控數據質量問題。CloudWatch 本身無法直接監控數據質量，必須結合其他工具（如 SageMaker Model Monitor）才能實現數據質量監控。
 結論：此選項不正確。
- **B.**
 正確性分析：SageMaker Clarify 是用於檢測模型偏差和解釋性分析的工具，而不是專門用於監控數據質量問題。雖然可以通過 CloudWatch 設置警報，但 Clarify 並不適合直接用於生產環境中的數據質量監控。
 結論：此選項不正確。
- **C.**
 正確性分析：SageMaker Model Monitor 是專門設計用於監控生產環境中數據質量的工具。它可以檢測數據漂移、缺失值等問題，並通過與 CloudWatch 集成發送警報。這是解決問題的最佳方案。
 結論：此選項正確。
- **D.**
 正確性分析：SageMaker Data Wrangler 是用於數據預處理和特徵工程的工具，而不是用於生產環境中的數據質量監控。此選項與題目要求不符。
 結論：此選項不正確。

▼ 17

▼ 中文

一家公司需要使用 Amazon SageMaker 在超過 300 GB 的數據上訓練模型。訓練數據由大小為 200 MB 的文件組成。這些數據存儲在 Amazon S3 Standard 存儲中，並為一個儀表板工具提供支持。對於此場景，哪種 SageMaker 訓練數據攝取機制是最具成本效益的解決方案？

- A. Amazon Elastic File System (Amazon EFS) file system
 Amazon Elastic File System (Amazon EFS) 文件系統
- B. Amazon FSx for Lustre file system
 Amazon FSx for Lustre 文件系統

- C. Amazon S3 in fast file mode while using S3 Express One Zone
Amazon S3 快速文件模式，同時使用 S3 Express One Zone
- **D. Amazon S3 in fast file mode without using S3 Express One Zone**
Amazon S3 快速文件模式，不使用 S3 Express One Zone

▼ 解答

D

- **考察的知識點**
 - Amazon SageMaker的訓練數據攝取機制。
 - Amazon S3與其他存儲服務（如Amazon EFS和Amazon FSx for Lustre）的成本和性能比較。
 - 如何選擇最具成本效益的解決方案來處理大規模數據訓練任務。
- **獨立分析每個選項**
 - **A. Amazon Elastic File System (Amazon EFS) 文件系統**
Amazon EFS是一種可擴展的文件存儲服務，適合需要共享文件系統的應用程序。然而，EFS的成本較高，且不適合處理大規模的機器學習訓練數據。對於這種場景，使用EFS並不是最具成本效益的選擇，因此此選項錯誤。
 - **B. Amazon FSx for Lustre 文件系統**
Amazon FSx for Lustre是一種高性能文件系統，專為處理高吞吐量和低延遲的工作負載而設計。雖然它在性能上非常適合機器學習訓練，但其成本較高，且對於本題中提到的“最具成本效益”的要求來說並不合適。因此此選項錯誤。
 - **C. Amazon S3 快速文件模式，同時使用 S3 Express One Zone**
S3 Express One Zone是一種存儲選項，數據僅存儲在單個可用區中，成本較低，但可靠性較低。對於機器學習訓練任務，數據的可靠性和可用性非常重要，因此使用S3 Express One Zone可能會帶來數據丟失的風險，不是最佳選擇。因此此選項錯誤。
 - **D. Amazon S3 快速文件模式，不使用 S3 Express One Zone**
Amazon S3的快速文件模式允許高效地攝取數據，同時保持S3的高可靠性和可用性。相比其他選項，它既滿足性能需求，又具有較低的成本，是最適合本場景的解決方案。因此此選項正確。

▼ 中文

家公司有一個機器學習模型部署在 Amazon SageMaker 端點上用於實時推理。該公司需要部署一個新模型。公司必須在將所有流量切換到新模型之前，比較新模型的性能與當前部署模型的性能。

哪種解決方案能夠以最少的操作工作量滿足這些需求？

- A. 將新模型部署到一個單獨的端點。手動在兩個端點之間分流流量。
- B. 將新模型部署到一個單獨的端點。使用 Amazon CloudFront 在兩個端點之間分配流量。
- **C. 將新模型作為一個 shadow variant 部署在與當前模型相同的端點上。將部分實時流量路由到 shadow 模型進行評估。**
- D. 使用帶有自定義邏輯的 AWS Lambda 函數在當前模型和新模型之間路由流量。

▼ 解答

C

- **考察的知識點**
 - Amazon SageMaker的模型部署與流量管理。
 - 如何在生產環境中進行模型性能比較（A/B測試或Shadow Testing）。
 - 選擇最少的操作複雜度來實現流量分配和模型評估。
- **獨立分析與答案選擇選項分析**
 - **A. 將新模型部署到一個單獨的端點。手動在兩個端點之間分流流量。**
正確性分析：手動分流流量需要額外的操作步驟，增加了操作複雜度，不符合“最少操作複雜度”的要求。
結論：錯誤。
 - **B. 將新模型部署到一個單獨的端點。使用 Amazon CloudFront 在兩個端點之間分配流量。**
正確性分析：雖然使用Amazon CloudFront可以實現流量分配，但這需要額外配置CloudFront分配規則，增加了操作複雜度。
結論：錯誤。
 - **C. 將新模型作為一個 shadow variant 部署在與當前模型相同的端點上。將部分實時流量路由到 shadow 模型進行評估。**
正確性分析：Amazon SageMaker支持在同一端點上部署多個模型變體（variant），並可以通過流量分配策略將部分流量路由到shadow模

型。這種方法操作簡單，符合“最少操作複雜度”的要求。

結論：正確。

- **D. 使用帶有自定義邏輯的 AWS Lambda 函數在當前模型和新模型之間路由流量。**

正確性分析：使用AWS Lambda函數需要編寫和維護額外的代碼邏輯，增加了操作複雜度，不符合“最少操作複雜度”的要求。

結論：錯誤。

▼ 19

▼ 中文

一家公司在 Amazon SageMaker 上運行一個機器學習模型。該公司使用一個自動化流程，通過 API 調用來創建模型的訓練任務。公司有新的合規規則，禁止收集來自訓練任務的聚合元數據。

哪種解決方案可以防止 SageMaker 收集訓練任務的元數據？

- **A. 為提交的任何訓練任務選擇退出元數據跟蹤。**
- B. 確保訓練任務在自定義 VPC 的私有子網中運行。
- C. 使用 AWS Key Management Service (AWS KMS) 客戶管理密鑰加密訓練數據。
- D. 重新配置訓練任務以僅使用 AWS Nitro 實例。

▼ 解答

A

- **這題考察的知識點是什麼**

本題考察的是Amazon SageMaker的元數據收集機制，以及如何通過配置來禁用元數據收集以滿足合規性要求。

涉及的知識點包括SageMaker的API調用、元數據跟蹤機制、VPC配置、數據加密和AWS Nitro實例的特性。

- **獨立分析每個選項**

- **A. 此選項直接提到可以選擇退出元數據跟蹤，這是SageMaker提供的功能之一。**

根據AWS文檔，SageMaker允許用戶通過API或控制台禁用元數據收集，從而滿足合規性要求。

此選項是正確的，因為它直接解決了題目中關於禁止元數據收集的要求。

- **B.** 此選項提到在自定義VPC的私有子網中運行訓練任務，但這與元數據收集無關。
VPC配置主要用於網絡隔離和安全性，而不是控制SageMaker的元數據收集行為。
此選項是錯誤的，因為它無法解決題目中關於禁止元數據收集的要求。
- **C.** 此選項提到使用KMS加密訓練數據，但加密數據與元數據收集無直接關係。
加密數據可以提高數據安全性，但無法阻止SageMaker收集訓練任務的元數據。
此選項是錯誤的，因為它無法解決題目中關於禁止元數據收集的要求。
- **D.** 此選項提到使用AWS Nitro實例，但Nitro實例的主要優勢是提供更高的性能和安全性，與元數據收集無關。
使用Nitro實例不會影響SageMaker的元數據收集行為。
此選項是錯誤的，因為它無法解決題目中關於禁止元數據收集的要求。

▼ 20

▼ 中文

一家公司正在探索生成式 AI，並希望添加一個新的產品功能。一名 ML 工程師正在從現有的 Amazon EC2 實例向 Amazon Bedrock 發起 API 調用。這些 EC2 實例位於一個私有子網中，並且在實施過程中必須保持私有狀態。這些 EC2 實例分配了一個安全組，該安全組允許訪問私有子網中的所有 IP 地址。ML 工程師應該**怎麼做才能在 EC2 實例和 Amazon Bedrock 之間建立連接？**

- A. 修改安全組以允許與 Amazon Bedrock 的入站和出站流量。
- **B. 使用 AWS PrivateLink 通過接口 VPC 端點訪問 Amazon Bedrock。**
- C. 配置 Amazon Bedrock 使用部署 EC2 實例的私有子網。
- D. 通過使用 AWS Direct Connect 連接將現有 VPC 鏈接到 Amazon Bedrock。

▼ 解答

B

- **這題考察的知識點是什麼**

本題主要考察AWS網絡架構相關知識，特別是如何在私有子網中通過安全

的方式訪問AWS服務（如Amazon Bedrock）。

涉及的技術包括AWS PrivateLink、VPC端點、安全組配置、Direct Connect等。

- **獨立分析每個選項**

- **A. 修改安全組以允許與 Amazon Bedrock 的入站和出站流量。**

錯誤：安全組的修改僅能控制流量的允許或拒絕，但無法解決私有子網與Amazon Bedrock之間的連接問題。Amazon Bedrock是一個託管服務，通常需要通過公共網絡或專用網絡（如PrivateLink）訪問。此外，EC2實例位於私有子網，無法直接訪問互聯網，因此即使修改安全組也無法建立連接。

- **B. 使用 AWS PrivateLink 通過接口 VPC 端點訪問 Amazon Bedrock。**

正確：AWS PrivateLink允許通過接口VPC端點安全地訪問AWS服務（如Amazon Bedrock），而無需暴露流量到公共互聯網。

PrivateLink是專門為解決私有子網訪問AWS服務而設計的，符合題目中“EC2實例必須保持私有”的要求。

- **C. 配置 Amazon Bedrock 使用部署 EC2 實例的私有子網。**

錯誤：Amazon Bedrock是一個託管服務，無法直接配置為使用特定的私有子網。AWS服務通常通過VPC端點或公共網絡訪問，而不是直接部署到用戶的子網中。

- **D. 通過使用 AWS Direct Connect 連接將現有 VPC 鏈接到 Amazon Bedrock。**

錯誤：AWS Direct Connect主要用於建立本地數據中心與AWS之間的專線連接，而不是用於在VPC內訪問AWS服務。

Direct Connect不適用於解決私有子網與Amazon Bedrock之間的連接問題。

▼ 21

▼ 中文

一家電子商務公司正在使用 Amazon SageMaker Clarify Foundation Model Evaluations (FMEval) 來評估機器學習模型。從以下列表中為每個電子商務用例選擇正確的模型評估任務。每個模型評估任務應僅選擇一次。

- Classification evaluation

- Open-ended generation
- Question answering
- Text summarization

Categorize customer reviews as positive, neutral, or negative sentiment.

Create concise product descriptions from complete manufacturer details.

Recommend products based on a user's browsing history.

Respond to specific customer queries about product features.

▼ 解答

Correct Answer:

Categorize customer reviews as positive, neutral, or negative sentiment.

Create concise product descriptions from complete manufacturer details.

Recommend products based on a user's browsing history.

Respond to specific customer queries about product features.

- **考察的知識點**

本題考察的是Amazon SageMaker Clarify Foundation Model Evaluations (FMEval)的不同任務類型及其適用場景。

需要了解每種任務類型的定義和適用場景，包括分類評估（Classification evaluation）、開放式生成（Open-ended generation）、問答（Question answering）和文本摘要（Text summarization）。

- **獨立分析每個選項**

- **第一項：**

- → **將顧客評論分為正面、中性或負面情緒。**

- Classification evaluation：正確。情感分析任務屬於分類問題，需要將客戶評論歸類為正面、中性或負面情感。

- **第二項：**

- 根據完整的製造商資訊建立簡潔的產品描述

- Text summarization：正確。文本摘要任務適用於從詳細信息中提取簡短的產品描述。

- **第三項：**

- 根據使用者的瀏覽記錄推薦產品

- Open-ended generation：正確。開放式生成適用於生成推薦內容，例如基於用戶瀏覽歷史生成的個性化推薦。

- **第四項：**

- 回覆客戶關於產品功能的具體諮詢

- Question answering：正確。問答任務專門用於根據問題從文本中提取答案，適用於回答客戶查詢。

▼ 22

▼ 中文

一家公司希望推出一個新的內部生成式 AI 界面來回答用戶問題。該界面將基於一個流行的開源大型語言模型（LLM）。

以下哪些步驟組合可以以**最少的運營開銷**部署該界面？（選擇兩項）

- **A.** 使用 Amazon SageMaker JumpStart 部署 LLM。

- B. 下載 LLM 為 .zip 文件。將 LLM 部署在基於 GPU 的 Amazon EC2 實例上。
- C. 創建一個前端 HTML 界面，該界面使用 Amazon API Gateway WebSocket API 和 AWS Lambda 函數來處理用戶交互。
- D. 使用 Amazon QuickSight 創建一個 UI 來處理用戶交互。
- E. 使用 Amazon Lex 創建一個 UI 來處理用戶交互。

▼ 解答

AC

• 這題考察的知識點是什麼

本題考察如何使用AWS服務以最小的操作開銷部署一個基於開源大型語言模型（LLM）的生成式AI接口。

涉及的知識點包括：Amazon SageMaker JumpStart的功能、Amazon EC2的部署方式、API Gateway與Lambda的集成、Amazon QuickSight的用途以及Amazon Lex的交互能力。

• 獨立分析每個選項

◦ A. 使用 Amazon SageMaker JumpStart 部署 LLM。

Amazon SageMaker JumpStart提供了預訓練模型的快速部署功能，支持開源LLM的託管服務，減少了手動配置和管理的複雜性。

此選項正確，因為它顯著降低了操作開銷，且專門設計用於機器學習模型的部署。

◦ B. 下載 LLM 為 .zip 文件。將 LLM 部署在基於 GPU 的 Amazon EC2 實例上。

此選項需要手動下載模型、配置環境、管理實例和監控性能，操作開銷較高。

雖然可以實現目標，但與題目要求的“最小操作開銷”不符，因此此選項錯誤。

◦ C. 創建一個前端 HTML 界面，該界面使用 Amazon API Gateway WebSocket API 和 AWS Lambda 函數來處理用戶交互。

API Gateway和Lambda的結合可以實現無服務器架構，簡化了用戶交互的處理流程，降低了運維複雜性。

此選項正確，因為它符合“最小操作開銷”的要求。

◦ D. 使用 Amazon QuickSight 創建一個 UI 來處理用戶交互。

Amazon QuickSight主要用於數據可視化和商業智能分析，不適合用

於創建交互式UI來處理用戶問題。
此選項錯誤，因為它與題目要求的功能不符。

◦ **E. 使用 Amazon Lex 創建一個 UI 來處理用戶交互。**

Amazon Lex是一個構建對話式接口的服務，適合處理用戶交互，但它通常用於基於語音或文本的聊天機器人，而不是直接與LLM集成。
此選項雖然可以實現部分功能，但與題目要求的“最小操作開銷”不完全匹配，因此此選項錯誤。

▼ 23

▼ 中文

一家公司希望構建一個使用社交媒體流數據的實時分析應用程序。一名機器學習工程師必須實施一個解決方案，該解決方案**每分鐘攝取和轉換 5 GB 的數據**。該解決方案還必須將數據加載到支持**實時分析快速查詢**的數據存儲中。哪個解決方案可以滿足這些要求？

- A. 使用 Amazon EventBridge 攝取社交媒體數據。使用 AWS Glue 轉換數據。將轉換後的數據存儲在 Amazon ElastiCache (Memcached) 中。
- B. 使用 Amazon Simple Queue Service (Amazon SQS) 攝取社交媒體數據。使用 AWS Lambda 轉換數據。將轉換後的數據存儲在 Amazon S3 中。
- C. 使用 Amazon Simple Notification Service (Amazon SNS) 攝取社交媒體數據。使用 Amazon EMR 轉換數據。將轉換後的數據存儲在 Amazon RDS 中。
- **D. 使用 Amazon Kinesis Data Streams 攝取社交媒體數據。使用 Amazon Managed Service for Apache Flink 轉換數據。將轉換後的數據存儲在 Amazon DynamoDB 中。**

▼ 解答

D

• **考察的知識點**

- 實時數據流處理：如何高效地攝取、轉換和存儲大規模實時數據。
- AWS服務的選擇與組合：包括數據流攝取、數據轉換和存儲服務的最佳實踐。
- 性能與可擴展性：處理高吞吐量數據（每分鐘5GB）的能力。

- 查詢效率：支持實時分析的存儲解決方案。

- **獨立分析每個選項**

- **A. 使用 Amazon EventBridge 攝取社交媒體數據，使用 AWS Glue 轉換數據，將轉換後的數據存儲在 Amazon ElastiCache (Memcached) 中。**

攝取數據：Amazon EventBridge 主要用於事件驅動架構，適合處理事件通知，但不適合高吞吐量的實時數據流（如每分鐘 5GB）。

數據轉換：AWS Glue 是批處理 ETL 工具，適合處理大規模數據，但不適合實時流數據轉換。

數據存儲：Amazon ElastiCache (Memcached) 是一個內存緩存服務，適合快速查詢，但不適合存儲大規模數據或支持複雜查詢。

結論：此選項無法滿足實時數據流處理和存儲需求。

- **B. 使用 Amazon Simple Queue Service (Amazon SQS) 攝取社交媒體數據，使用 AWS Lambda 轉換數據，將轉換後的數據存儲在 Amazon S3 中。**

攝取數據：Amazon SQS 是消息隊列服務，適合異步任務處理，但不適合高吞吐量實時數據流。

數據轉換：AWS Lambda 適合處理小規模事件驅動任務，但不適合處理每分鐘 5GB 的高吞吐量數據轉換。

數據存儲：Amazon S3 是物件存儲服務，適合存儲大規模數據，但不支持實時查詢。

結論：此選項無法滿足實時數據流處理和實時查詢需求。

- **C. 使用 Amazon Simple Notification Service (Amazon SNS) 攝取社交媒體數據，使用 Amazon EMR 轉換數據，將轉換後的數據存儲在 Amazon RDS 中。**

攝取數據：Amazon SNS 是消息發布/訂閱服務，適合通知和分發消息，但不適合高吞吐量實時數據流。

數據轉換：Amazon EMR 適合處理大規模數據分析，但主要用於批處理，不適合實時流數據轉換。

數據存儲：Amazon RDS 是關係型數據庫服務，支持複雜查詢，但不適合高吞吐量實時數據存儲。

結論：此選項無法滿足實時數據流處理需求。

- **D. 使用 Amazon Kinesis Data Streams 攝取社交媒體數據，使用 Amazon Managed Service for Apache Flink 轉換數據，將轉換後的數據存儲在 Amazon DynamoDB 中。**

攝取數據：Amazon Kinesis Data Streams 專為高吞吐量實時數據流設計，能夠處理每分鐘 5GB 的數據。

數據轉換：Amazon Managed Service for Apache Flink支持實時流數據處理和轉換，適合實時分析場景。

數據存儲：Amazon DynamoDB是高性能NoSQL數據庫，支持快速查詢，適合實時分析需求。

結論：此選項完全滿足實時數據流處理和存儲需求。

▼ 24

▼ 中文

一家公司將訓練數據以 .csv 文件的形式存儲在 Amazon S3 bucket 中。該公司必須加密數據，並且必須控制哪些應用程序可以訪問加密密鑰。

哪種解決方案可以滿足這些要求？

- A. 創建一個新的 SSH 訪問密鑰。使用 AWS Encryption CLI 並引用新的訪問密鑰來加密文件。
- B. 通過使用 Amazon API Gateway 的 CreateApiKey API 操作創建一個新的 API 密鑰。使用 AWS CLI 並引用新的 API 密鑰來加密文件。
- C. 創建一個新的 IAM 角色。附加一個允許 AWS Key Management Service (AWS KMS) 的 GenerateDataKey 操作的策略。使用該角色來加密文件。
- D. 創建一個新的 AWS Key Management Service (AWS KMS) 密鑰。使用 AWS Encryption CLI 並引用新的 KMS 密鑰來加密文件。

▼ 解答

D

• 考察的知識點

本題主要考察AWS Key Management Service (KMS) 的使用，以及如何通過加密工具（如AWS Encryption CLI）對數據進行加密。同時涉及IAM權限管理和加密密鑰的控制與分配。

• 獨立分析每個選項

- A. 創建一個新的 SSH 訪問密鑰。使用 AWS Encryption CLI 並引用新的訪問密鑰來加密文件。
錯誤：SSH訪問密鑰用於遠程登錄和訪問服務器，而不是用於加密數據。AWS Encryption CLI無法使用SSH密鑰進行加密操作。
- B. 創建一個新的 API 密鑰。使用 AWS CLI 並引用新的 API 密鑰來加密文件。

錯誤：API密鑰用於授權API調用，而不是用於加密數據。AWS CLI無法使用API密鑰進行加密操作。

- **C. 創建一個新的 IAM 角色。附加一個允許 AWS Key Management Service (AWS KMS) 的 GenerateDataKey 操作的策略。使用該角色來加密文件。**

部分正確：IAM角色可以授予權限以使用AWS KMS生成數據密鑰，但本題要求的是直接加密文件，而不是生成數據密鑰後再進行加密。此外，IAM角色本身並不是加密工具，無法直接用於加密文件。

- **D. 創建一個新的 AWS Key Management Service (AWS KMS) 密鑰。使用 AWS Encryption CLI 並引用新的 KMS 密鑰來加密文件。**

正確：AWS KMS是專門用於管理加密密鑰的服務，可以創建新的KMS密鑰來加密數據。

AWS Encryption CLI支持與KMS集成，可以使用KMS密鑰對文件進行加密。

此選項完全符合題目要求：加密數據並控制應用對加密密鑰的訪問。

▼ 25

▼ 中文

一家公司需要進行特徵工程、聚合和數據準備。在生成特徵後，公司必須在AWS上實施一個解決方案來處理和存儲這些特徵。

哪種解決方案可以滿足這些需求？

- **A. 使用 Amazon SageMaker Feature Processing 處理和攝取數據。使用 SageMaker Feature Store 管理和存儲特徵。**
- B. 使用 Amazon SageMaker Model Monitor 自動攝取和轉換數據。創建一個 Amazon S3 bucket 以 JSON 格式存儲特徵。
- C. 使用 Amazon Managed Service for Apache Flink 轉換數據並將數據直接攝取到 Amazon SageMaker Feature Store。使用 Feature Store 管理和存儲特徵。
- D. 使用 Amazon SageMaker batch transform job 分析、轉換和攝取數據。創建一個 Amazon DynamoDB 表來存儲特徵。

▼ 解答

A

- **這題考察的知識點是什麼**

本題主要考察對AWS服務的理解，尤其是與機器學習相關的服務，包括

Amazon SageMaker Feature Store、Amazon SageMaker Model Monitor、Amazon Managed Service for Apache Flink、Amazon S3、Amazon DynamoDB等。

重點在於數據的特徵工程、聚合、準備，以及如何在AWS中實現特徵的處理和存儲。

- **獨立分析每個選項**

- **A. 使用Amazon SageMaker Feature Processing處理和攝取數據。使用SageMaker Feature Store管理和存儲特徵。**

Amazon SageMaker Feature Store是專門設計用於存儲和管理機器學習特徵的服務，支持特徵的版本控制和共享。

Amazon SageMaker Feature Processing可以處理和攝取數據，直接與Feature Store集成。

此選項完全符合題目要求，能夠完成特徵工程、數據處理和存儲。正確。

- **B. 使用Amazon SageMaker Model Monitor自動攝取和轉換數據。創建一個Amazon S3 bucket以JSON格式存儲特徵。**

Amazon SageMaker Model Monitor的主要功能是監控模型的性能和數據漂移，而不是用於特徵工程或數據攝取。

雖然Amazon S3可以存儲數據，但它不是專門設計用於存儲機器學習特徵的服務，缺乏特徵管理功能。

錯誤。

- **C. 使用Amazon Managed Service for Apache Flink轉換數據並將數據直接攝取到Amazon SageMaker Feature Store。使用Feature Store管理和存儲特徵。**

Amazon Managed Service for Apache Flink是一個流處理服務，可以用於實時數據轉換和攝取。

雖然它可以與Amazon SageMaker Feature Store集成，但題目並未提到需要實時處理數據，且使用Flink可能過於複雜，不符合題目中“實施解決方案”的簡單性要求。

錯誤。

- **D. 使用Amazon SageMaker batch transform job分析、轉換和攝取數據。創建一個Amazon DynamoDB表來存儲特徵。**

Amazon SageMaker batch transform job主要用於批量預測，而不是特徵工程或數據攝取。

Amazon DynamoDB是一個NoSQL數據庫，雖然可以存儲數據，但它不是專門設計用於存儲機器學習特徵的服務，缺乏特徵管理功能。

錯誤。

▼ 26

▼ 中文

一家公司正在開發一個新的在線應用程序，用於收集客戶信息。一位機器學習工程師開發了一個新的機器學習模型，該模型將為每位客戶確定一個評分。該模型將使用評分來決定向客戶展示哪個產品。機器學習工程師需要盡量減少模型的響應時間延遲。

機器學習工程師應該如何在 Amazon SageMaker 中部署該應用程序以滿足這些要求？

- A. Configure batch transform.
配置批量轉換。
- **B. Configure a real-time inference endpoint.**
配置實時推理端點。
- C. Configure a serverless inference endpoint.
配置無服務器推理端點。
- D. Configure an asynchronous inference endpoint.
配置異步推理端點。

▼ 解答

B

• 這題考察的知識點是什麼

本題考察的是 Amazon SageMaker 中不同推理端點的使用場景，包括實時推理、批量轉換、無服務器推理和異步推理。

重點在於理解如何選擇合適的推理方式以滿足低延遲需求。

• 獨立分析每個選項

◦ **A. Configure batch transform. 配置批量轉換。**

批量轉換適用於離線處理大批量數據的場景，通常用於非實時任務。由於批量轉換需要先收集數據並進行處理，無法滿足低延遲的實時響應需求，因此此選項錯誤。

◦ **B. Configure a real-time inference endpoint. 配置實時推理端點。**

實時推理端點專為低延遲場景設計，能夠在接收到請求後立即返回推理結果。對於需要快速響應的在線應用，這是最合適的選擇。因此此選項正確。

- **C. Configure a serverless inference endpoint. 配置無服務器推理端點。**
無服務器推理端點適用於間歇性或低流量的推理場景，雖然可以提供實時響應，但在高流量或需要極低延遲的場景下可能不如專用的實時推理端點表現穩定。因此此選項不如B合適。
- **D. Configure an asynchronous inference endpoint. 配置異步推理端點。**
異步推理端點適用於處理需要較長時間的推理任務，通常用於非實時場景。客戶提交請求後，系統會異步處理並返回結果，無法滿足低延遲的實時響應需求，因此此選項錯誤。

▼ 27

▼ 中文

一家公司正在使用 Amazon EMR。該公司在 Amazon S3 中有一個大型數據集，需要將其導入到 Amazon SageMaker Feature Store。該數據集包含歷史數據和實時流數據。

該公司必須確保 Feature Store 在線存儲在數據可用時立即更新為最新數據。公司還必須維護一個完整的 Feature Store 離線存儲以進行批處理。哪種解決方案可以滿足這些要求？

- A. 使用 Feature Store Runtime 中的 PutRecord API 將所有數據導入在線存儲。
- B. 使用 Feature Store Runtime 中的 PutRecord API 將所有數據導入離線存儲。
- **C. 使用 Feature Store Spark connector 將數據作為 Spark DataFrames 導入，同時啟用在線存儲和離線存儲。**
- D. 使用 Feature Store Spark connector 將數據作為 Spark DataFrames 導入，僅啟用在線存儲。

▼ 解答

C

• 考察的知識點

- Amazon SageMaker Feature Store的功能和使用場景，包括在線存儲和離線存儲的區別。

- 如何使用Feature Store Runtime API和Spark Connector來處理數據。
- 數據流處理和批處理的結合應用。

- **獨立分析每個選項**

- **A. 使用 Feature Store Runtime 中的 PutRecord API 將所有數據導入在線存儲。**

PutRecord API主要用於實時數據的單條記錄寫入在線存儲，適合實時流數據的處理。

此選項僅更新在線存儲，無法滿足題目要求的離線存儲維護需求。因此此選項錯誤。

- **B. 使用 Feature Store Runtime 中的 PutRecord API 將所有數據導入離線存儲。**

PutRecord API不支持直接寫入離線存儲，離線存儲通常通過批處理方式更新。

此選項不符合Feature Store的設計邏輯，因此錯誤。

- **C. 使用 Feature Store Spark connector 將數據作為 Spark DataFrames 導入，同時啟用在線存儲和離線存儲。**

Feature Store Spark Connector支持批量數據處理，可以同時更新在線存儲和離線存儲。

此選項滿足題目要求：實時數據更新在線存儲，同時維護完整的離線存儲。

此選項正確。

- **D. 使用 Feature Store Spark connector 將數據作為 Spark DataFrames 導入，僅啟用在線存儲。**

此選項僅更新在線存儲，無法滿足題目要求的離線存儲維護需求。因此此選項錯誤。

▼ 28

▼ 中文

一位機器學習工程師需要在 Amazon SageMaker 推理管道中部署四個機器學習模型。[這些模型是使用不同的框架构建的](#)。該機器學習工程師還需要為客戶提供使用 `invoke_endpoint` 調用來對每個模型執行推理的能力。

哪種解決方案將最具成本效益地滿足這些需求？

- A. 創建一個 SageMaker 多模型端點。

- B. 創建一個 SageMaker 多容器端點。
- C. 創建多個 SageMaker 單模型端點。
- D. 運行一個 SparkML 作業以生成多個端點。

▼ 解答

B

• 考察的知識點

- Amazon SageMaker的端點類型，包括單模型端點、多模型端點和多容器端點。
- 如何選擇最具成本效益的解決方案來部署多個模型。
- 如何滿足客戶調用端點進行推理的需求。

• 獨立分析每個選項

- **A. 創建一個 SageMaker 多模型端點**
多模型端點適用於多個模型共享一個容器的情况，通常用於模型文件存儲在Amazon S3中，並且使用相同的框架。
題目中明確指出模型是使用不同框架構建的，因此多模型端點不適用。
此選項錯誤。
- **B. 創建一個 SageMaker 多容器端點**
多容器端點允許在一個端點中部署多個容器，每個容器可以運行不同的框架和模型。
這種方法可以滿足題目中“不同框架”和“單一端點調用”的需求。
此選項正確。
- **C. 創建多個 SageMaker 單模型端點**
單模型端點適用於每個端點只運行一個模型的情况。
雖然可以滿足不同框架的需求，但需要創建多個端點，增加了成本和管理複雜性。
此選項不夠成本效益，因此錯誤。
- **D. 運行一個 SparkML 作業以生成多個端點**
SparkML通常用於分佈式機器學習任務，而不是直接用於部署端點。
此選項與題目要求不符，因為題目要求使用SageMaker端點進行推理。
此選項錯誤。

▼ 29

▼ 中文

一位機器學習工程師希望 Amazon SageMaker notebook 在閒置 1 小時後自動停止運行。

機器學習工程師如何實現這一目標？

- A. 在 SageMaker 中創建一個生命周期配置。從 GitHub 複製 auto-stop-idle 腳本到 Start Notebook 部分。
- B. 在 SageMaker 中創建一個生命周期配置。從 GitHub 複製 auto-stop-idle 腳本到 Create Notebook 部分。
- C. 通過使用 Amazon CloudWatch Logs 跟蹤 notebook 的 CPU 指標。如果 CPU 利用率變為零，從 CloudWatch Logs 調用 AWS Lambda 函數以關閉 notebook 實例。
- D. 通過使用 Amazon CloudWatch Logs 跟蹤 notebook 的內存指標。如果內存利用率變為零，從 CloudWatch Logs 調用 AWS Lambda 函數以關閉 notebook 實例。

▼ 解答

A

• 考察的知識點

- Amazon SageMaker 生命周期配置的使用。
- 如何通過腳本實現自動化任務（例如自動停止閒置的 Notebook 實例）。
- 對 AWS 服務（如 CloudWatch、Lambda）的集成和使用。

• 獨立分析每個選項

- **A. Create a lifecycle configuration in SageMaker. Copy the auto-stop-idle script from GitHub to the Start Notebook section.**

正確性分析：生命周期配置允許在 Notebook 實例啟動時執行腳本。將 auto-stop-idle 腳本放在 “Start Notebook” 部分，可以監控 Notebook 的閒置時間並在超過設定時間後自動停止實例。

優點：直接在 Notebook 啟動時加載腳本，邏輯清晰且易於實現。

結論：此選項正確。

- **B. Create a lifecycle configuration in SageMaker. Copy the auto-stop-idle script from GitHub to the Create Notebook**

section.

正確性分析：生命周期配置的“Create Notebook”部分用於在 Notebook 實例創建時執行腳本，而不是在實例啟動時執行。

問題：Notebook 實例可能會在創建後閒置一段時間才啟動，因此將腳本放在“Create Notebook”部分無法有效監控閒置時間。

結論：此選項錯誤。

- **C. Track the notebook's CPU metric by using Amazon CloudWatch Logs. Invoke an AWS Lambda function from CloudWatch Logs to shut down the notebook instance if CPU utilization becomes zero.**

正確性分析：通過 CloudWatch 監控 CPU 利用率並觸發 Lambda 函數關閉實例是可行的，但 CPU 利用率為零並不一定意味著 Notebook 處於閒置狀態（例如，某些後台任務可能仍在運行）。

問題：這種方法可能會誤判閒置狀態，導致不必要的實例關閉。

結論：此選項錯誤。

- **D. Track the notebook's memory metric by using Amazon CloudWatch Logs. Invoke an AWS Lambda function from CloudWatch Logs to shut down the notebook instance if memory utilization becomes zero.**

正確性分析：類似於選項 C，通過 CloudWatch 監控內存利用率並觸發 Lambda 函數關閉實例是可行的，但內存利用率為零也不一定意味著 Notebook 處於閒置狀態。

問題：這種方法同樣可能會誤判閒置狀態，導致不必要的實例關閉。

結論：此選項錯誤。

▼ 30

▼ 中文

一家公司希望提供服務來幫助其他企業標註圖像。該公司希望其標註專家在 AWS 上完成人工標註任務。

公司應該如何註冊標註專家以接收 AWS 上的任務？

- A. 使用 AWS Data Exchange。
- **B. 在 Amazon SageMaker Ground Truth 中創建並使用內部勞動力。**
- C. 在 Amazon SageMaker human loop 中創建並使用 Amazon Mechanical Turk 實體。
- D. 使用 Amazon Mechanical Turk 網站。

▼ 解答

B

- **這題考察的知識點是什麼**

本題考察的是 Amazon SageMaker Ground Truth 的功能和如何設置人工標註工作流。

重點在於理解如何在 AWS 上註冊人工標註人員以完成標註任務。

- **獨立分析每個選項**

- **A. Use AWS Data Exchange. 使用 AWS Data Exchange。**

錯誤。AWS Data Exchange 是一個數據共享服務，用於訂閱和分發第三方數據集，與人工標註任務無關。

- **B. Create and use an internal workforce in Amazon SageMaker Ground Truth. 在 Amazon SageMaker Ground Truth 中創建並使用內部勞動力。**

正確。Amazon SageMaker Ground Truth 提供了創建內部勞動力的功能，允許公司註冊自己的標註人員並分配任務。這是最適合題目需求的選項，因為公司希望使用自己的標註專家完成任務。

- **C. Create and use Amazon Mechanical Turk entities in an Amazon SageMaker human loop. 在 Amazon SageMaker human loop 中創建並使用 Amazon Mechanical Turk 實體。**

錯誤。Amazon Mechanical Turk 是一個眾包平台，適合公開招募標註人員，而題目要求的是公司自己的標註專家。此外，Amazon SageMaker human loop 是用於處理模型預測結果的人工審查工作流，與題目需求不完全匹配。

- **D. Use the Amazon Mechanical Turk website. 使用 Amazon Mechanical Turk 網站。**

錯誤。Amazon Mechanical Turk 網站是一個公開平台，適合招募外部標註人員，而題目明確要求公司自己的標註專家。

▼ 31

▼ 中文

一家公司希望使用 Amazon SageMaker 來託管一個運行在 CPU 上用於實時預測的機器學習模型。該模型在工作時間內會有間歇性流量，而在工作時間之

外則沒有流量。公司需要一個解決方案，以最具成本效益的方式處理推理請求。哪種託管選項可以滿足這些需求？

- A. 將模型部署到 SageMaker 實時端點。添加基於計劃的自動擴展策略以處理工作時間內的流量激增。
- **B. 將模型部署到 SageMaker Serverless Inference 端點。配置在工作時間內增加的預置並發量。**
- C. 將模型部署到 SageMaker Asynchronous Inference 端點。配置一個自動擴展策略，在工作時間之外縮減到零。
- D. 將模型部署到 SageMaker 實時端點。創建一個計劃的 AWS Lambda 函數，僅在工作時間內激活端點。

▼ 解答

B

• 考察的知識點

- Amazon SageMaker 的不同推理端點類型及其適用場景，包括實時端點、無服務器推理端點和異步推理端點。
- 如何根據流量模式選擇最具成本效益的推理解決方案。
- 自動擴展策略的使用及其配置方法。

• 獨立分析與答案選擇

- **A. 實時端點**適用於需要低延遲的持續流量場景，但在流量間歇性或無流量時，實時端點仍會產生固定的實例成本。
雖然可以通過計劃自動擴展策略來優化流量高峰時的性能，但無法完全避免非工作時間的成本浪費。
此選項不符合“最具成本效益”的要求。
錯誤。
- **B. 無服務器推理端點**適用於間歇性流量場景，因為它按請求計費，無流量時不會產生成本。
通過配置預置並發量，可以在工作時間內滿足流量需求，同時在非工作時間避免額外成本。
此選項符合“最具成本效益”的要求。
正確。
- **C. 異步推理端點**適用於需要處理大批量請求且對延遲要求較低的場景。
雖然可以通過自動擴展策略在非工作時間縮減到零，但異步推理端點

的設計並不適合實時預測場景。
此選項不符合題目中“實時預測”的要求。
錯誤。

- **D. 實時端點無法通過Lambda函數完全關閉或激活，實時端點的實例會持續運行並產生成本，即使沒有流量。**
此選項無法實現“最具成本效益”的目標。
錯誤。

▼ 32

▼ 中文

一位機器學習工程師需要訓練一個監督式深度學習模型。可用的數據集是大量未標籤的圖像，僅限員工訪問。機器學習工程師需要實施一個解決方案，以盡可能高的準確性標籤數據集。

機器學習工程師應採取哪些步驟來滿足這些要求？（選擇兩個。）

- A. 使用 Amazon Rekognition 自動標籤數據集。
- B. 直接在原始數據上訓練深度學習模型，讓模型自行推斷標籤。
- **C. 使用 Amazon SageMaker Ground Truth 創建一個註釋任務，指定標籤任務和要求。**
- **D. 設置工作團隊以訪問一個私有工作團隊，運行並審核由 Amazon SageMaker Ground Truth 創建的註釋任務。**
- E. 使用 Amazon Mechanical Turk 完成由 Amazon SageMaker Ground Truth 創建的註釋任務。

▼ 解答

C D

- **考察的知識點**
 - 監督學習的基本概念：監督學習需要標籤數據集。
 - 數據標籤工具的使用：Amazon SageMaker Ground Truth 和其他 AWS 服務的功能和適用場景。
 - 數據隱私與安全：確保數據僅供員工訪問。
- **獨立分析每個選項**
 - **A. 使用 Amazon Rekognition 自動標註數據集。**
錯誤：Amazon Rekognition 是一種預訓練的計算機視覺服務，主要

用於圖像分析（如物體識別、對象檢測等），但它並不適合用於高精度的自定義數據集標籤任務。

此外，題目要求最高的標籤準確性，而 Rekognition 的自動標籤可能無法滿足這一要求。

- **B. 直接在原始數據上訓練深度學習模型，讓模型自行推斷標籤。**

錯誤：監督學習需要標籤數據集作為輸入，直接在未標籤數據上訓練模型無法滿足監督學習的要求。

此外，模型自行推斷標籤屬於無監督學習或半監督學習的範疇，與題目要求不符。

- **C. 使用 Amazon SageMaker Ground Truth 創建一個註釋任務，指定標註任務和要求。**

正確：Amazon SageMaker Ground Truth 是一種專門用於數據標籤的服務，可以創建高質量的標籤任務。

它允許用戶定義標籤任務的具體要求，並支持多種標籤工作流。

- **D. 設置工作團隊以訪問一個私有工作團隊，運行並審核由 Amazon SageMaker Ground Truth 創建的註釋任務。**

正確：設置私有工作團隊可以確保數據僅供員工訪問，符合題目中關於數據隱私的要求。

私有工作團隊可以提高標籤質量，因為團隊成員可以根據具體要求進行審核和標籤。

- **E. 使用 Amazon Mechanical Turk 完成由 Amazon SageMaker Ground Truth 創建的註釋任務。**

錯誤：Amazon Mechanical Turk 是一種眾包平台，適合公開數據集的標籤任務。

題目要求數據僅供員工訪問，而 Mechanical Turk 的工作團隊是公開的，無法滿足數據隱私要求。

▼ 33

▼ 中文

一家公司正在使用 Amazon S3 bucket 來收集數據，這些數據將用於機器學習工作流。該公司需要使用 AWS Glue DataBrew 來清理和規範化數據。哪種解決方案可以滿足這些需求？

Options:

- A. 通過使用 S3 路徑創建一個 DataBrew 數據集。使用 DataBrew profile job 清理和規範化數據。

- **B.** 通過使用 S3 路徑創建一個 DataBrew 數據集。使用 DataBrew recipe job 清理和規範化數據。
- **C.** 通過使用 Java Database Connectivity (JDBC) 驅動程序連接到 S3 bucket 創建一個 DataBrew 數據集。使用 DataBrew profile job 清理和規範化數據。
- **D.** 通過使用 Java Database Connectivity (JDBC) 驅動程序連接到 S3 bucket 創建一個 DataBrew 數據集。使用 DataBrew recipe job 清理和規範化數據。

▼ 解答

B

• 考察的知識點

本題考察的是AWS Glue DataBrew的使用，包括如何創建數據集以及如何清理和規範化數據。

需要理解DataBrew的兩個主要作業類型：Profile Job和Recipe Job。

還涉及到如何通過S3路徑或JDBC連接來創建數據集。

• 獨立分析每個選項

- **A.** 正確性分析：DataBrew的Profile Job主要用於生成數據的統計信息和質量報告，而不是用於清理和規範化數據。因此，使用Profile Job來清理和規範化數據是錯誤的。
結論：錯誤。
- **B.** 正確性分析：DataBrew支持通過S3路徑創建數據集，這是正確的。Recipe Job是專門用於清理和規範化數據的作業類型，因此這個選項完全符合要求。
結論：正確。
- **C.** 正確性分析：S3並不支持通過JDBC連接來訪問數據，因此這個選項在創建數據集的方式上是錯誤的。此外，Profile Job也不適合用於清理和規範化數據。
結論：錯誤。
- **D.** 正確性分析：同樣，S3並不支持通過JDBC連接來訪問數據，因此這個選項在創建數據集的方式上是錯誤的。雖然Recipe Job適合清理和規範化數據，但由於數據集創建方式錯誤，整體選項仍然是錯誤的。
結論：錯誤。

▼ 34

▼ 中文

一家公司正在開發一個使用 XGBoost 算法的新機器學習模型。該公司將在存儲於 Amazon S3 bucket 中的數據上訓練該模型。這些數據是嵌套的 JSON 格式。

一名機器學習工程師需要將 JSON 文件轉換為表格格式。

哪種解決方案能夠以最少的運營開銷滿足此需求？

- A. 創建一個 AWS Glue PySpark 作業，使用 Relationalize 轉換來轉換文件。
- B. 編寫自定義 Scala 代碼來轉換文件。使用 Amazon EMR Serverless 運行 Scala 代碼。
- C. 創建一個使用 Python runtime 的 AWS Lambda 函數，並調用 reduce() 函數來轉換文件。調用該 Lambda 函數。
- D. 創建一個基於 JSON 文件的 Amazon Athena 數據庫。使用 Athena flatten 函數來轉換數據。

▼ 解答

A

• 考察的知識點

本題考察的是如何高效地處理和轉換數據格式，特別是從嵌套的JSON格式轉換為表格格式。

涉及AWS服務的選擇，包括AWS Glue、Amazon EMR Serverless、AWS Lambda和Amazon Athena。

重點在於選擇最少的操作開銷（Least operational overhead）的解決方案。

• 獨立分析每個選項

- A. 正確性分析：AWS Glue是專門設計用於ETL（Extract, Transform, Load）任務的服務，支持PySpark作業，並且提供了Relationalize方法，可以直接將嵌套JSON轉換為表格格式。
操作開銷：AWS Glue是託管服務，自動管理資源，減少了手動配置和管理的複雜性。
結論：此選項正確，符合題目要求。
- B. 正確性分析：雖然Scala代碼可以實現JSON到表格的轉換，但需要編寫和維護自定義代碼，增加了開發複雜性。

操作開銷：Amazon EMR Serverless雖然簡化了資源管理，但編寫和調試Scala代碼仍然需要較高的技術投入。

結論：此選項不符合“最少操作開銷”的要求。

- **C. 正確性分析：**AWS Lambda可以運行Python代碼，但使用reduce()函數處理嵌套JSON可能會非常複雜且效率低下。

操作開銷：需要編寫和維護自定義代碼，並且Lambda函數可能不適合處理大規模數據轉換任務。

結論：此選項不符合“最少操作開銷”的要求。

- **D. 正確性分析：**Amazon Athena可以查詢JSON數據，但Athena的flatten函數並不直接支持複雜的嵌套JSON轉換為表格格式。

操作開銷：需要手動創建數據庫和表，並且查詢複雜嵌套JSON可能需要額外的SQL邏輯。

結論：此選項不符合“最少操作開銷”的要求。

▼ 35

▼ 中文

一家醫療公司從監測患者生命體徵的設備中攝取數據流。該公司使用 Amazon SageMaker，並計劃準備機器學習模型以預測患者的不良事件。數據集非常大，包含數千個特徵。

一名機器學習工程師需要運行數百次訓練迭代，使用不同的特徵集、不同的算法以及許多潛在參數。機器學習工程師必須實施一個解決方案來記錄每次訓練迭代的特性和結果。

哪種解決方案能夠以最少的實施工作量滿足這些要求？

- A. 使用 Amazon CloudWatch 為每次迭代的特性創建自定義指標。
- B. 將每次迭代的特性寫入 Amazon S3 的日誌中。使用 AWS Glue 和 Amazon Athena 搜索日誌。
- C. 使用 SageMaker Model Registry 跟踪每次迭代的特性和結果。
- **D. 使用 SageMaker Experiments 跟踪每次迭代的特性和結果。**

▼ 解答

D

• 考察的知識點

本題主要考察的是如何在Amazon SageMaker中高效地管理和記錄機器學習實驗的特性和結果。

涉及的知識點包括：SageMaker Experiments、SageMaker Model

Registry、Amazon CloudWatch、Amazon S3、AWS Glue和Amazon Athena的功能和適用場景。

- **獨立分析每個選項**

- **A. 使用 Amazon CloudWatch 為每次迭代的特性創建自定義指標。**
CloudWatch主要用於監控和記錄系統性能指標，而不是專門設計用於記錄機器學習實驗的特性和結果。
雖然可以通過創建自定義指標來記錄實驗數據，但實現起來複雜且不適合大規模機器學習實驗的管理。
此選項不符合“最少實現努力”的要求。
錯誤。
- **B. 將每次迭代的特性寫入 Amazon S3 的日誌中。使用 AWS Glue 和 Amazon Athena 搜索日誌。**
將數據寫入S3並使用Glue和Athena進行查詢是一個通用的數據管理解決方案，但它並不是專門為機器學習實驗設計的。
這種方法需要額外的開發工作來實現數據記錄、查詢和分析，複雜度較高。
此選項不符合“最少實現努力”的要求。
錯誤。
- **C. 使用 SageMaker Model Registry 跟踪每次迭代的特性和結果。**
SageMaker Model Registry主要用於[管理和部署機器學習模型](#)，而不是記錄實驗的特性和結果。
雖然可以間接使用Model Registry存儲模型相關信息，但它並不適合記錄實驗的詳細特性和結果。
此選項不符合題目要求。
錯誤。
- **D. 使用 SageMaker Experiments 跟踪每次迭代的特性和結果。**
SageMaker Experiments是專門設計用於記錄和管理機器學習實驗的工具，可以輕鬆記錄每次迭代的特性和結果。
它支持自動化記錄、可視化和分析實驗數據，完全符合題目要求。
此選項實現起來最簡單，符合“最少實現努力”的要求。
正確。

一家公司計劃創建一個僅供內部使用的聊天界面，以幫助員工處理客戶查詢。目前，員工需要參考大量內部文檔知識庫來解決客戶問題。新的解決方案必須是無服務器的。

哪些步驟組合可以滿足這些要求？

- **A. 設置 Amazon Bedrock 並使用 Anthropic Claude 基礎模型。**
- B. 設置 Amazon SageMaker JumpStart 並使用 Llama 基礎模型。
- C. 使用 Amazon EC2 實例和 Amazon API Gateway 調用模型 API。
- D. 使用 AWS Lambda 函數和 Amazon API Gateway 調用模型 API。
- E. 使用 Amazon S3 存儲桶存儲向量數據庫轉儲和嵌入。
- F. 使用 Amazon RDS for MySQL 存儲向量數據庫轉儲和嵌入。

▼ 解答

ADE

- **考察的知識點**

本題主要考察對AWS服務的理解，包括Amazon Bedrock、Amazon SageMaker JumpStart、AWS Lambda、Amazon API Gateway、Amazon S3、Amazon RDS等服務的用途和適用場景。

同時考察對構建無服務器（Serverless）架構的能力，以及如何選擇合適的服務來滿足特定業務需求。

- **獨立分析每個選項**

- **A. 設置 Amazon Bedrock 並使用 Anthropic Claude 基礎模型。**

Amazon Bedrock 是一種無服務器服務，支持使用預訓練的基礎模型（如Anthropic Claude）來構建生成式AI應用。

它非常適合構建無服務器的解決方案，且可以直接用於處理自然語言任務。

此選項正確。

- **B. 設置 Amazon SageMaker JumpStart 並使用 Llama 基礎模型。**

Amazon SageMaker JumpStart是一個機器學習服務，支持使用預訓練模型（如Llama）。

然而，SageMaker並非完全無服務器，它需要配置和管理底層計算資源（如實例），不符合題目要求的“無服務器”架構。

此選項錯誤。

- **C. 使用 Amazon EC2 實例和 Amazon API Gateway 調用模型 API。**

Amazon EC2 是一種虛擬服務器服務，需要手動管理實例，顯然不符

合“無服務器”架構的要求。

此選項錯誤。

- **D. 使用 AWS Lambda 函數和 Amazon API Gateway 調用模型 API。**

AWS Lambda 是一種無服務器計算服務，能夠自動擴展並按使用量計費，非常適合無服務器架構。

Amazon API Gateway 可以用來創建和管理API，結合Lambda可以實現無服務器的API調用。

此選項正確。

- **E. 使用 Amazon S3 存儲桶存儲向量數據庫轉儲和嵌入。**

Amazon S3 是一種無服務器的對象存儲服務，適合存儲靜態文件和數據，包括向量數據庫轉儲和嵌入。

此選項正確。

- **F. 使用 Amazon RDS for MySQL 存儲向量數據庫轉儲和嵌入。**

Amazon RDS 是一種託管數據庫服務，但它並非無服務器架構，因為需要管理數據庫實例。

此選項錯誤。

▼ 37

▼ 中文

一位機器學習工程師需要部署一個基於遺傳算法的訓練模型。該算法解決了一個複雜問題，並且生成預測**可能需要幾分鐘時間**。

當模型被部署時，模型需要訪問大量數據來處理請求。這些請求可能涉及多達 100 MB 的數據。

哪種部署解決方案能夠以**最少的運營開銷**滿足這些需求？

- A. 將模型部署到一個位於 Application Load Balancer 後的 Auto Scaling 組中的 Amazon EC2 實例。
- B. 將模型部署到一個 Amazon SageMaker 實時端點。
- **C. 將模型部署到一個 Amazon SageMaker 異步推理端點。**
- D. 將模型打包為一個容器。將模型部署到 Amazon Elastic Container Service (Amazon ECS) 上的 Amazon EC2 實例。

▼ 解答

C

題目分析與解答：

1. 考察的知識點

本題考察的是機器學習模型的部署方式，特別是如何選擇適合的 AWS 服務來滿足特定的性能需求和操作簡化需求。

重點包括：模型推理時間長、需要處理大數據量（100 MB）、以及如何降低操作複雜性。

2. 獨立分析每個選項

- **A. 正確性分析：**EC2實例可以提供靈活的計算資源，並且可以通過 Auto Scaling組動態擴展。但這種方法需要手動管理EC2實例的配置、負載均衡器的設置以及模型的部署，操作複雜性較高。
錯誤原因：雖然可以滿足性能需求，但操作複雜性高，不符合題目要求的“LEAST operational overhead”。
- **B. 正確性分析：**SageMaker實時端點適合低延遲的實時推理場景，但本題中模型推理時間較長（幾分鐘），實時端點不適合處理這種高延遲任務。
錯誤原因：實時端點無法有效處理長時間推理任務，可能會導致超時問題。
- **C. 正確性分析：**SageMaker異步推理端點專為長時間推理任務設計，支持處理大數據量請求（如100 MB），並且可以通過異步隊列機制降低操作複雜性。
正確原因：完全符合題目要求，既支持長時間推理，又降低了操作複雜性。
- **D. 正確性分析：**將模型打包為容器並部署到ECS可以提供靈活性，但需要手動管理容器的配置、任務調度和EC2實例，操作複雜性較高。
錯誤原因：雖然可以滿足性能需求，但操作複雜性高，不符合題目要求的“LEAST operational overhead”。

▼ 38

▼ 中文

一位機器學習工程師希望使用一組調查問卷的回覆作為機器學習分類器的訓練數據。所有的調查問卷回覆都是“yes”或“no”。

機器學習工程師需要將這些回覆轉換為一個特徵，以便產生更好的模型訓練結果。機器學習工程師不能增加數據集的維度。

哪些方法可以滿足這些要求？（選擇兩個。）

- **A. Binary encoding**
- **B. Label encoding**
- C. One-hot encoding
- D. Statistical imputation
- E. Tokenization

▼ 解答

AB

- **考察的知識點**

本題考察的是數據預處理中的編碼方法，特別是將分類數據（如“yes”和“no”）轉換為數值特徵以供機器學習模型使用。

同時要求不增加數據集的維度，這意味著需要選擇不會擴展特徵空間的編碼方法。

- **獨立分析每個選項**

- **A. Binary encoding:** 二進制編碼將分類數據轉換為二進制數值表示。例如，“yes”和“no”可以分別編碼為0和1。這種方法不會增加數據集的維度，符合題目要求。
- **B. Label encoding:** 標籤編碼將分類數據直接映射為整數值。例如，“yes”和“no”可以分別編碼為0和1。這種方法也不會增加數據集的維度，符合題目要求。
- **C. One-hot encoding:** 獨熱編碼會為每個類別創建一個單獨的特徵列。例如，“yes”和“no”會分別變成兩個特徵列（[1,0]和[0,1]）。這種方法會增加數據集的維度，不符合題目要求。
- **D. Statistical imputation:** 統計插補通常用於處理缺失值，而不是將分類數據轉換為數值特徵。因此，這種方法與題目要求無關。
- **E. Tokenization:** 分詞通常用於處理文本數據，將文本分割為單詞或子詞。這種方法不適用於將“yes”和“no”轉換為數值特徵，因此不符合題目要求。

▼ 39 下拉題

▼ 中文

一名機器學習工程師必須選擇適當的 Amazon SageMaker 算法來解決特定的 AI 問題。從以下列表中為每個使用案例選擇正確的 SageMaker 內置算法。每

個算法應僅選擇一次。

- Random Cut Forest (RCF) algorithm
- Semantic segmentation algorithm
- Sequence-to-Sequence (seq2seq) algorithm

Summarize the text of a research paper.

Scan every pixel of an image to help self-driving cars identify objects in their path.

Identify abnormal data points in a dataset.

▼ 解答

Correct Answer:

Summarize the text of a research paper.

Scan every pixel of an image to help self-driving cars identify objects in their path.

Identify abnormal data points in a dataset.

- 考察的知識點
Amazon SageMaker內置算法的用途和適用場景。
理解每種算法的功能，例如Random Cut Forest (RCF)、Semantic Segmentation、Sequence-to-Sequence (seq2seq)。
- 獨立分析每個選項
 - Summarize the text of a research paper

- 概括一篇研究論文的内容
Sequence-to-Sequence (seq2seq) algorithm: 正確。Seq2Seq算法擅長處理自然語言任務，例如文本摘要、翻譯等。
- **Scan every pixel of an image to help self-driving cars identify objects in their path**
- 掃描影像的每個像素，以幫助自動駕駛汽車識別路徑上的物體
Semantic segmentation algorithm: 正確。語義分割算法專門用於圖像處理，能夠逐像素掃描圖像並識別物體，是自動駕駛場景的理想選擇。
- **Identify abnormal data points in a dataset**
- 識別資料集中的異常資料點
Random Cut Forest (RCF) algorithm: 正確。RCF算法專門用於檢測數據中的異常點，適用於此場景。

▼ 40

▼ 中文

家公司計劃使用 Amazon SageMaker 預構建算法來創建一個推薦模型。該算法必須能夠對高維稀疏數據進行預測。

公司應該選擇哪個 SageMaker 算法用於推薦模型？

- A. K-nearest neighbors (k-NN)
- **B. Factorization Machines**
- C. Principal component analysis (PCA)
- D. Sequence-to-Sequence (seq2seq)

▼ 解答

B

題目分析與解答：

1. 考察的知識點

本題考察的是Amazon SageMaker中預構建算法的選擇，特別是針對高維稀疏數據的推薦模型。

需要了解每種算法的適用場景和特點。

2. 獨立分析每個選項

- **A. K-nearest neighbors (k-NN)**

k-NN是一種基於距離的分類或回歸算法，適用於低維數據或數據量較小的場景。

它不擅長處理高維稀疏數據，因為計算距離時會受到“維度災難”的影響。

因此，k-NN不適合用於推薦系統中的高維稀疏數據。

錯誤

- **B. Factorization Machines**

Factorization Machines是一種專門設計用於處理高維稀疏數據的算法，特別適合推薦系統。

它通過矩陣分解的方式捕捉特徵之間的交互關係，能夠有效處理稀疏數據並生成準確的預測。

這是推薦系統中處理高維稀疏數據的最佳選擇。

正確

- **C. Principal component analysis (PCA)**

PCA是一種降維算法，主要用於數據預處理和特徵提取。

雖然它可以處理高維數據，但它的目標是降低維度，而不是直接用於推薦系統的預測任務。

因此，PCA不適合用於推薦系統中的高維稀疏數據預測。

錯誤

- **D. Sequence-to-Sequence (seq2seq)**

Seq2Seq是一種用於處理序列數據的深度學習模型，通常用於機器翻譯、文本生成等任務。

它不適合處理推薦系統中的高維稀疏數據。

因此，Seq2Seq不是正確的選擇。

錯誤

▼ 41

▼ 中文

一家公司有多個團隊，他們在自己的筆記本電腦上開發了獨立的預測模型。這些團隊使用 Python 結合 scikit-learn 和 TensorFlow 框架開發了這些模型。該公司必須重新構建這些模型，並將這些模型集成到公司使用 Amazon SageMaker 管理的機器學習基礎設施中。公司還必須將這些模型納入模型註冊表中。

哪種解決方案能夠以最少的運營開銷滿足這些要求？

- A. 將模型從筆記本電腦導出到 Amazon S3 存儲桶。使用 Amazon API Gateway REST API 和 AWS Lambda 函數結合 SageMaker 端點訪問這些模型。將模型註冊到 SageMaker Model Registry 中。
- B. 將模型導入到 SageMaker Model Registry 中。使用 SageMaker 運行導入的模型。
- C. Register the models in the SageMaker Model Registry.
使用筆記本電腦上的代碼為模型創建容器。使用 SageMaker 的自帶容器 (BYOC) 功能導入並使用這些模型。將模型註冊到 SageMaker Model Registry 中。
- D. 將基於 Python 的模型導入到 SageMaker 中。在 SageMaker 中重新構建 scikit-learn 和 TensorFlow 模型。將所有模型註冊到 SageMaker Model Registry 中。

▼ 解答

D

- **這題考察的知識點是什麼**
 - Amazon SageMaker的功能，包括模型註冊（Model Registry）、模型部署和管理。
 - 如何將現有的機器學習模型遷移到AWS環境中，並使用SageMaker進行管理和部署。
 - 理解SageMaker支持的框架（如scikit-learn和TensorFlow）以及如何重建和集成模型。
- **獨立分析每個選項**
 - **A. 將模型從筆記本電腦導出到 Amazon S3 存儲桶。使用 Amazon API Gateway REST API 和 AWS Lambda 函數結合 SageMaker 端點訪問這些模型。將模型註冊到 SageMaker Model Registry 中。**
 - **正確性分析：** 此選項提到使用S3存儲模型，並通過API Gateway 和Lambda函數訪問模型。這種方法增加了額外的複雜性，因為需要額外的API和Lambda配置，而不是直接使用SageMaker的內置功能。
 - **錯誤原因：** 雖然可以實現，但操作複雜度較高，不符合題目要求的“LEAST operational overhead”。
 - **B. 將模型導入到 SageMaker Model Registry 中。使用 SageMaker 運行導入的模型。**

- **正確性分析：** 此選項直接提到將模型導入到SageMaker Model Registry中並運行，但沒有提到如何處理模型的重建或遷移過程。現有的模型可能需要重新構建以適配SageMaker環境。
- **錯誤原因：** 此選項忽略了模型遷移和重建的必要步驟，無法滿足題目要求。
- **C. 使用筆記本電腦上的代碼為模型創建容器。使用 SageMaker 的自帶容器 (BYOC) 功能導入並使用這些模型。將模型註冊到 SageMaker Model Registry 中。**
 - **正確性分析：** 此選項提到使用BYOC（Bring Your Own Container）功能，這是一種靈活的方式，可以將自定義模型遷移到SageMaker中。但創建和管理容器需要額外的開發和維護工作。
 - **錯誤原因：** 雖然可以實現，但操作複雜度較高，不符合題目要求的“LEAST operational overhead”。
- **D. 將基於 Python 的模型導入到 SageMaker 中。在 SageMaker 中重新構建 scikit-learn 和 TensorFlow 模型。將所有模型註冊到 SageMaker Model Registry 中。**
 - **正確性分析：** 此選項提到直接將Python模型導入到SageMaker，並在SageMaker中重建模型。這是最直接、最符合題目要求的方式，能夠充分利用SageMaker的內置功能，包括模型註冊和管理。
 - **正確原因：** 此選項操作簡單，符合“LEAST operational overhead”的要求，同時滿足題目中提到的所有需求。

▼ 42

▼ 中文

一家公司正在使用本地基礎設施訓練一個大型語言模型（LLM）。一個實時對話引擎使用該LLM來幫助客戶在信用卡數據中找到實時洞察。

一名機器學習工程師必須實施一個解決方案，以在Amazon SageMaker上訓練和部署LLM。

哪種解決方案可以滿足這些需求？

- **A. 使用SageMaker Training Compiler訓練LLM。使用SageMaker實時推理部署LLM。**

- B. 使用SageMaker帶有深度學習容器進行大型模型推理來訓練LLM。使用SageMaker實時推理部署LLM。
- C. 使用SageMaker Notebook Jobs訓練LLM。使用SageMaker異步推理部署LLM。
- D. 使用SageMaker Studio訓練LLM。使用SageMaker批量轉換部署LLM。

▼ 解答

A

- **考察的知識點**
 - Amazon SageMaker的功能與服務，包括訓練和部署機器學習模型的不同方法。
 - 實時推理（Real-time Inference）與異步推理（Asynchronous Inference）的區別和適用場景。
 - 如何優化大型語言模型（LLM）的訓練效率，例如使用SageMaker Training Compiler。
- **獨立分析每個選項**
 - **A. 使用SageMaker Training Compiler訓練LLM。使用SageMaker實時推理部署LLM。**
 - **正確性分析：** SageMaker Training Compiler可以優化大型語言模型的訓練效率，特別是對於需要大量計算資源的模型。實時推理適用於需要快速響應的場景，例如實時客戶交互。
 - **優點：** 此選項符合題目要求，既優化了訓練過程，又滿足了實時推理的需求。
 - **結論：** 正確。
 - **B. 使用SageMaker帶有深度學習容器進行大型模型推理來訓練LLM。使用SageMaker實時推理部署LLM。**
 - **正確性分析：** 深度學習容器主要用於推理，而不是訓練。此選項在訓練階段的描述不準確。
 - **缺點：** 深度學習容器不適合直接用於訓練大型語言模型。
 - **結論：** 錯誤。
 - **C. 使用SageMaker Notebook Jobs訓練LLM。使用SageMaker異步推理部署LLM。**

- **正確性分析：** SageMaker Notebook Jobs適合小規模實驗性訓練，但不適合大規模模型的訓練。異步推理適用於非實時場景，與題目要求不符。
 - **缺點：** 訓練方法不適合大型語言模型，推理方式不符合實時交互的需求。
 - **結論：** 錯誤。
- **D. 使用SageMaker Studio訓練LLM。使用SageMaker批量轉換部署LLM。**
- **正確性分析：** SageMaker Studio是一個集成開發環境，適合模型開發和調試，但不適合直接用於大規模訓練。批量轉換適用於離線處理，而非實時交互。
 - **缺點：** 訓練和推理方法均不符合題目要求。
 - **結論：** 錯誤。

▼ 43

▼ 中文

一家公司在生產端點上擁有一個現有的 Amazon SageMaker 模型 (v1)。該公司開發了一個新的模型版本 (v2)，並需要在生產環境中測試 v2，然後再將 v2 替換 v1。

該公司需要實施一個解決方案，以盡量減少 v2 在生產環境中生成錯誤輸出的風險。該解決方案必須在切換到 v2 時防止生產流量的任何中斷。

哪種解決方案可以滿足這些要求？

- A. 為 v2 創建第二個生產變體。將 1% 的流量分配給 v2，將 99% 的流量分配給 v1。將 v2 的所有輸出收集到 Amazon S3 bucket 中。如果 v2 表現符合預期，則將所有流量切換到 v2。
- B. 為 v2 創建第二個生產變體。將 10% 的流量分配給 v2，將 90% 的流量分配給 v1。將 v2 的所有輸出收集到 Amazon S3 bucket 中。如果 v2 表現符合預期，則將所有流量切換到 v2。
- C. 將 v2 部署到一個新的端點。開啟生產端點的數據捕獲功能。編寫一個腳本，將 100% 的輸入數據傳遞給 v2。如果 v2 表現符合預期，則停用 v1 端點並將流量定向到 v2。
- D. 將 v2 部署到一個影子變體中，該變體會對 100% 的推理請求進行採樣。將所有輸出收集到 Amazon S3 bucket 中。如果 v2 表現符合預期，

則將 v2 提升為生產版本。

▼ 解答

D

• 這題考察的知識點是什麼：

- Amazon SageMaker的生產端點管理，包括模型版本的切換和流量分配。
- 如何在生產環境中測試新模型以最小化風險。
- 數據捕獲與流量分配的最佳實踐。

• 獨立分析每個選項：

◦ A.

- **正確性分析：** 此選項採用流量分配的方式測試新模型（v2），並將1%的流量分配給v2，99%的流量分配給v1。這種方案可以減少對生產流量的影響，但仍然會將實際用戶流量暴露給可能存在問題的v2模型。
- **缺點：** 即使只分配1%的流量給v2，仍然可能導致用戶體驗問題，因為v2的輸出直接影響了生產環境。
- **結論：** 此選項不符合“防止生產流量中斷”的要求，因此不正確。

◦ B.

- **正確性分析：** 此選項與A類似，只是將10%的流量分配給v2。這種方案增加了測試流量，但也增加了生產環境受到影響的風險。
- **缺點：** 同樣會將實際用戶流量暴露給可能存在問題的v2模型，無法完全避免生產流量中斷。
- **結論：** 此選項不符合“防止生產流量中斷”的要求，因此不正確。

◦ C.

- **正確性分析：** 此選項採用創建一個新的端點來運行v2，並使用腳本將所有輸入數據傳遞給v2進行測試。這種方案可以完全避免對生產流量的影響。
- **優點：** 生產流量不會直接暴露給v2，測試過程完全獨立於生產環境。
- **缺點：** 需要額外的資源來運行新端點，並且需要編寫腳本來實現數據傳遞，增加了複雜性。

- **結論：** 此選項是一個可行的解決方案，但相比D選項，操作複雜度更高。
- **D.**
 - **正確性分析：** 此選項採用影子變體（Shadow Variant）進行測試，影子變體會對生產流量進行採樣，但不會影響生產環境的實際輸出。v2的輸出被收集到Amazon S3中進行分析。
 - **優點：** 完全避免了生產流量中斷，測試過程對用戶透明，且可以全面評估v2的性能。
 - **缺點：** 需要額外的資源來運行影子變體，但這是一個合理的成本，能夠確保生產環境的安全性。
 - **結論：** 此選項符合題目要求，是最佳方案。

▼ 44

▼ 中文

一家公司正在使用 Amazon SageMaker、AWS 自有庫和開源庫構建一個機器學習模型。該公司必須確保 SageMaker 在訓練期間不會收集關於使用情況和錯誤的元數據。

哪種解決方案可以滿足這些要求？

- A. 將 SageMaker 域與一個自定義 IAM 角色關聯。將該角色附加到一個拒絕 Amazon CloudWatch 服務使用日誌的策略。
- B. 向 SageMaker 域添加一個 IAM 角色以拒絕 Amazon CloudWatch 報告元數據的權限。
- **C. 關閉 SageMaker 域中的設置以共享控制台作業的元數據。通過 AWS CLI 或 AWS SDK 提交的每個訓練作業選擇退出元數據收集。**
- D. 為通過 AWS CLI、Boto3 或 SageMaker Python SDK 提交的每個訓練作業設置一個參數以選擇退出元數據收集。

▼ 解答

C

- **考察的知識點**
 - Amazon SageMaker的元數據收集機制。
 - 如何通過配置或權限管理來控制AWS服務的行為。

- IAM角色和策略的使用。
- 如何通過AWS CLI、SDK等工具進行配置。
- **獨立分析每個選項**
 - **A. 將 SageMaker 域與一個自定義 IAM 角色關聯。將該角色附加到一個拒絕 Amazon CloudWatch 服務使用日誌的策略。**
 - **錯誤：** 雖然可以通過IAM策略限制CloudWatch的日誌記錄，但這並不能完全阻止SageMaker收集元數據。元數據收集是SageMaker的內部行為，與CloudWatch日誌記錄無直接關係。
 - **B. 向 SageMaker 域添加一個 IAM 角色以拒絕 Amazon CloudWatch 報告元數據的權限。**
 - **錯誤：** 與選項A類似，限制CloudWatch權限並不能阻止SageMaker收集元數據。元數據收集是SageMaker的默認行為，必須通過特定的設置來禁用。
 - **C. 關閉 SageMaker 域中的設置以共享控制台作業的元數據。通過 AWS CLI 或 AWS SDK 提交的每個訓練作業選擇退出元數據收集。**
 - **正確：** 此選項明確提到關閉SageMaker域中的設置以禁用元數據收集，並且通過CLI或SDK提交的訓練作業也可以選擇退出元數據收集。這是符合要求的解決方案。
 - **D. 為通過 AWS CLI、Boto3 或 SageMaker Python SDK 提交的每個訓練作業設置一個參數以選擇退出元數據收集。**
 - **部分正確：** 此選項提到通過CLI、Boto3或SDK設置參數來選擇退出元數據收集，但沒有提到如何處理SageMaker域的元數據共享設置，因此不夠全面。

▼ 45

▼ 中文

一位機器學習工程師正在訓練一個機器學習模型，以基於20個特徵和1個目標來識別人們的健康風險。目標類別有兩個值：

- 可能有健康風險（正類）
- 不太可能有健康風險（負類）

數據集中人群的年齡範圍是30歲到60歲。年齡是其中一個特徵。

機器學習工程師分析了這些特徵。對於正類，年齡範圍在40到45歲之間的標

籤比例差異（DPL）值為(+0.9)，與其他年齡範圍相比。

機器學習工程師應該如何糾正這種數據不平衡？

- A. 對年齡範圍在40到45歲的正類進行過採樣。
- **B. 對年齡範圍在40到45歲的正類進行欠採樣。**
- C. 對除40到45歲年齡範圍外的所有年齡範圍的正類進行欠採樣。
- D. 對除40到45歲年齡範圍外的所有年齡範圍的負類進行過採樣。

▼ 解答

B

• 考察的知識點

- 數據不平衡問題的處理方法，包括過採樣和欠採樣。
- 如何根據特定特徵的分佈調整數據以提高模型的公平性和性能。
- 理解DPL（Difference in Proportions of Labels）值的含義及其對數據分佈的影響。

• 獨立分析與答案選擇

逐個分析選項

- **A. Oversample the positive class for the age range of 40 to 45.**
過採樣正類（40到45歲年齡範圍）會進一步增加該年齡段的正類比例，從而加劇數據不平衡問題。由於DPL值已經是+0.9，說明該年齡段的正類比例遠高於其他年齡段，過採樣會導致模型對該年齡段的正類過度偏向，因此此選項錯誤。
- **B. Undersample the positive class for the age range of 40 to 45.**
欠採樣正類（40到45歲年齡範圍）可以減少該年齡段的正類樣本數量，從而降低數據不平衡問題。DPL值為+0.9，表明該年齡段的正類比例遠高於其他年齡段，欠採樣可以使數據分佈更加均勻，減少模型偏差。因此此選項正確。
- **C. Undersample the positive class for all age ranges except 40 to 45.**
對除40到45歲年齡範圍外的所有年齡範圍的正類進行欠採樣會進一步減少其他年齡段的正類樣本數量，從而加劇數據不平衡問題。這與解決數據不平衡的目標相悖，因此此選項錯誤。
- **D. Oversample the negative class for all age ranges except 40 to 45.**

對除40到45歲年齡範圍外的所有年齡範圍的負類進行過採樣雖然可以增加負類樣本數量，但無法直接解決40到45歲年齡段的正類比例過高的問題。因此此選項錯誤。

▼ 46

一家公司正在建造一個用於機器學習模型的 Amazon SageMaker AI 管線。此流水線使用分散式處理和訓練。

一位機器學習工程師需要加密執行分散式作業的實例之間的網路通訊。此工程師將分散式作業配置為在私有 VPC 中執行。

為了滿足加密要求，該工程師該怎麼做？

- A. 啟用網路隔離。
- B. 使用安全群組設定流量加密。
- C. 啟用容器間流量加密。
- D. 啟用 VPC 流日誌。

▼ 解答

C

1. 核心知識點：SageMaker 數據傳輸加密 (Data in Transit Encryption)

- **分散式作業安全性**：當使用多個實例進行訓練時，預設情況下，節點之間的通訊不一定會加密。
- **Inter-container Traffic Encryption**：這是 SageMaker 提供的一個專門選項，用於確保在分散式訓練作業中，集群內各個容器 (Container) 之間交換的數據通過 **TLS (Transport Layer Security)** 進行加密。
- **效能權衡**：啟用此功能會增加 CPU 負載（因為需要加解密），可能會稍微增加訓練時間，但在處理敏感數據或符合法規要求（如 HIPAA, PCI DSS）時是必要的。

2. 選項獨立分析

A. 啟用網路隔離 (Enable network isolation) - 錯誤

- **分析：**網路隔離（Network Isolation）是指防止容器與外界（包括網際網路或其他 AWS 服務）進行通訊，以確保模型訓練的程式碼不會將數據外流。
- **為什麼不選：**雖然它提升了安全性，但它的作用是「阻斷通訊」而非「加密通訊」。它無法解決實例與實例之間傳輸數據的加密問題。

B. 使用安全群組設定流量加密 (Configure traffic encryption using security groups) - 錯誤

- **分析：**安全群組（Security Groups）的作用是**防火牆（Firewall）**，用來控制哪些連接埠（Port）和 IP 地址可以進出流量。
- **為什麼不選：**安全群組僅能「允許」或「拒絕」流量，它**本身不具備加密流量**的功能。

C. 啟用容器間流量加密 (Enable inter-container traffic encryption) - 正確

- **分析：**這是 AWS SageMaker 的原生功能。在 API 調用（如 `CreateTrainingJob`）或 SageMaker Python SDK 中，可以將 `encrypt_inter_container_traffic` 參數設定為 `True`。
- **為什麼正確：**這正是專為滿足「分散式作業中實例間通訊加密」需求而設計的功能。它會自動在集群節點之間建立安全的 TLS 通道。

D. 啟用 VPC 流日誌 (Enable VPC Flow Logs) - 錯誤

- **分析：**VPC Flow Logs 是用來**監控與記錄** VPC 網路介面（Network Interface）進出的 IP 流量資訊。
- **為什麼不選：**流日誌是用於「審計」和「疑難排解」的工具，它無法加密正在傳輸中的數據。

3. 解題關鍵與總結

- **關鍵字對應：**當題目提到 **"Encrypt network communication between instances"** 搭配 **"Distributed jobs"** 時，標準答案幾乎總是 **"Inter-container traffic encryption"**。
- **注意陷阱：**題目提到的「私有 VPC」是為了干擾考生，讓考生誤以為要從 VPC 層級（如 Security Group 或 VPN）來解決，但實際上 SageMaker 已經在應用層提供了專門的開關。

一個機器學習模型已部署到生產環境。此模型運作良好，數月以來一直達到各項指標閾值。

一位負責監控此模型的機器學習工程師發現其效能突然下降，各項效能指標均低於閾值。

造成效能下降的原因可能是什麼？

- A. 缺乏訓練數據
- B. 生產數據分佈的漂移
- C. 計算資源約束
- D. 模型過擬合

▼ 答案

B

1. 核心知識點：模型漂移 (Model Drift)

- **概念漂移 (Concept Drift) 與 數據漂移 (Data Drift)**：這是模型部署後最常見的失效原因。機器學習模型是基於「歷史數據」訓練的，假設未來的預測數據會與歷史數據具有相似的分佈。
- **環境變化**：當現實世界的環境、使用者行為或數據來源發生變化時，原本的模型參數就不再適用，導致預測準確度下降。
- **SageMaker Model Monitor**：在 AWS 中，這是一個專門用來檢測此類問題的服務，它會自動對比生產環境的實時流量與訓練時的基準數據 (Baseline)。

2. 選項獨立分析

A. 缺乏訓練數據 (Lack of training data) - 錯誤

- **分析**：缺乏訓練數據通常發生在**模型開發階段**。如果數據不足，模型從一開始就無法達到指標閾值，或者無法良好收斂。
- **為什麼不選**：題目明確提到模型「運作良好」且「數月以來一直達到閾值」，這說明訓練數據在當時是充足且有效的。

B. 生產數據分佈的漂移 (Drift in production data distribution) - 正確

- **分析**：這是模型在生產環境中效能**突然或逐漸下降**的最典型原因。例如：電商推薦模型因為季節更換、或是金融風控模型因為市場環境劇變，導致

輸入數據的統計特性改變。

- **為什麼正確**：只有外部環境或數據分佈的改變，會讓一個原本表現優異的模型在「不更動程式碼」的情況下效能衰退。

C. 計算資源約束 (Computational resource constraints) - 錯誤

- **分析**：資源約束（如 CPU/Memory 不足、網路延遲）通常會導致**延遲（Latency）**增加、**吞吐量（Throughput）**下降或**系統崩潰（5xx 錯誤）**。
- **為什麼不選**：題目強調的是「效能指標（Performance metrics）」（如 Accuracy, F1-score, RMSE）下降，這通常指預測的「質量」問題，而非系統的「響應速度」問題。

D. 模型過擬合 (Model overfitting) - 錯誤

- **分析**：過擬合是指模型在訓練集上表現極佳，但在測試集或未見過的數據上表現很差。
- **為什麼不選**：過擬合是一個**部署前**就該發現的問題。如果模型過擬合，它在剛部署到生產環境時就會表現不佳，而不會「穩定運行數月」後才出問題。

3. 解題關鍵與延伸建議

- **時間線是關鍵**：題目中提到「運作良好數月」後才「突然下降」，這是判斷 **Drift** 的最強烈信號。
- **解決方案**：面對這種情況，機器學習工程師通常需要：
 1. 收集最新的生產數據。
 2. 重新標記數據（Labeling）。
 3. *重新訓練模型（Retraining）**並更新 Baseline。

▼ 48

一位機器學習工程師正在使用 AWS Glue 將第三方供應商提供的專有資料轉換為 Amazon SageMaker DeepAR 預測演算法所需的格式。資料包含多個類似的時間序列資料文件，該工程師必須將它們轉換為合適的格式。此外，該工程師還必須壓縮檔案以優化儲存成本。

哪種解決方案能夠滿足這些要求？

- A.使用 Snappy 將檔案轉換為 RecordIO-Protobuf 格式並壓縮檔案。
- B.使用 XZ 將檔案轉換為 RecordIO-Protobuf 格式並壓縮檔案。
- C.使用 XZ 將檔案轉換為 Apache Parquet 格式並壓縮檔案。
- D.使用 gzip 將檔案轉換為 Apache Parquet 格式並壓縮檔案。

▼ 答案

D

這題考查的是 **Amazon SageMaker DeepAR 演算法的輸入數據格式要求**，以及如何利用 **AWS Glue** 進行大數據處理與儲存成本優化。

以下是針對該題目的詳細分析：

1. 核心知識點

- **DeepAR 演算法的輸入格式：**
 - SageMaker 的 DeepAR 是一款用於時間序列預測的監督式學習演算法。
 - 它**僅支援**兩種資料格式：**JSON Lines**（每行是一個 JSON 物件）和 **Apache Parquet**。
 - 它**不支援**常見於其他 SageMaker 演算法（如 Linear Learner 或 Image Classification）的 RecordIO-Protobuf 格式。
- **儲存優化與壓縮 (Storage Optimization)：**
 - 在處理大規模資料時，使用列式存儲格式（Columnar Format，如 Parquet）配合壓縮演算法可以顯著減少 S3 儲存成本並提高讀取效能。
 - **Gzip** 是 Parquet 格式常用的壓縮方式，能提供極高的壓縮比（適合優化成本），且在 AWS 服務（如 Glue, Athena, SageMaker）中有很好的原生支援。
 - **XZ** 雖然壓縮率極高，但計算開銷極大，且在標準大數據流程中的支援度不如 Gzip。

2. 選項獨立分析

A. 使用 Snappy 將檔案轉換為 RecordIO-Protobuf 格式並壓縮檔案 - 錯誤

- 分析：雖然 Snappy 壓縮速度很快，但 **RecordIO-Protobuf 並非 DeepAR 支援的輸入格式**。DeepAR 無法讀取這種格式的資料。

B. 使用 XZ 將檔案轉換為 RecordIO-Protobuf 格式並壓縮檔案 - 錯誤

- 分析：同樣的錯誤，**RecordIO-Protobuf 不適用於 DeepAR**。此外，XZ 雖然壓縮率高，但在分散式訓練中解壓縮速度較慢，不常用於此情境。

C. 使用 XZ 將檔案轉換為 Apache Parquet 格式並壓縮檔案 - 錯誤

- 分析：格式（Parquet）雖然正確，但 **XZ 並非 Parquet 常見或推薦的壓縮編碼**。在 AWS Glue 的轉換任務中，Parquet 通常與 Snappy 或 Gzip 搭配。XZ 會消耗過多的 CPU 資源來進行壓縮與解壓縮，反而可能增加 Glue 運算成本。

D. 使用 gzip 將檔案轉換為 Apache Parquet 格式並壓縮檔案 - 正確

- 分析：
 - **格式正確**：DeepAR 官方支援 `application/x-parquet` 格式。
 - **壓縮正確**：Gzip 在 Parquet 中被廣泛支援，且能提供優異的壓縮比例，直接符合題目要求的「優化儲存成本」。
 - **Glue 相容性**：AWS Glue 轉換為 Parquet 並指定 Gzip 壓縮是標準的最佳實踐（Best Practice）。

3. 解題關鍵與總結

- 關鍵記憶點：
 - **DeepAR = JSON Lines 或 Parquet**。（考題常考這兩者的區別，RecordIO 是這題的最大陷阱）。
 - 如果要「優化儲存成本 (Optimize cost)」，通常傾向選擇 **Gzip**；如果要「優化讀寫效能 (Optimize performance)」，通常傾向選擇 **Snappy**。
- **實務延伸**：在 SageMaker 訓練時，如果使用 Parquet 格式，DeepAR 可以利用「管道模式 (Pipe Mode)」或是更高效的數據流，這對於處理大規模時間序列數據非常重要。

一家公司大幅增加了儲存在 Amazon S3 儲存桶中的 .csv 檔案資料量。現在，資料轉換腳本和查詢的運行時間比以前長得多。

一位機器學習工程師必須實施一個解決方案來優化數據，從而提高查詢效能。

哪種解決方案能夠在滿足此要求的同時，將維運開銷降至最低？

- A.配置 AWS Lambda 函數，將 .csv 檔案拆分為 S3 儲存桶中的較小物件。
- B.設定 AWS Glue 作業，刪除具有字串類型值的資料列，並將結果儲存到 S3 儲存桶。
- C.配置 AWS Glue 提取、轉換和載入 (ETL) 作業，將 .csv 檔案轉換為 Apache Parquet 格式。
- D.配置 Amazon EMR 叢集來處理 S3 儲存桶中的資料。

▼ 答案

C

1. 核心知識點：數據格式優化 (Data Format Optimization)

- **行式存儲 (Row-based) vs. 列式存儲 (Columnar)：**
 - **.csv** 是**行式存儲**。即使你只需要查詢「金額」這一欄，機器也必須掃描每一行的所有欄位，導致大量無謂的 I/O 消耗。
 - **Apache Parquet** 是**列式存儲**。它允許查詢引擎只讀取所需的欄位 (Column Projection)，並支持「謂詞下推 (Predicate Pushdown)」，大幅減少數據掃描量。
- **維運開銷 (Operational Overhead)：**
 - AWS Glue 是**無伺服器 (Serverless)** 服務，自動擴展，使用者不需要管理底層伺服器。
 - Amazon EMR 需要管理叢集、節點規格與軟體配置，維運成本較高。

2. 選項獨立分析

A. 使用 AWS Lambda 拆分 .csv 檔案 - 錯誤

- **分析：**雖然拆分小檔案可以增加並行處理能力，但它無法改變 **.csv** 檔案掃描效率低下的本質。
- **為什麼不選：**Lambda 有執行的超時限制 (15分鐘) 且需要撰寫與維護大量自定義程式碼 (維運開銷高)。此外，過多的小檔案會導致「小文件問題」。

(Small File Problem)」，反而可能降低某些查詢引擎（如 Athena）的效能。

B. 使用 AWS Glue 刪除具有字串類型值的資料列 - 錯誤

- **分析：**這是在做「數據清理 (Data Cleaning)」，而非「效能優化」。
- **為什麼不選：**直接刪除數據會導致資訊丟失，且這完全無法解決因資料量龐大導致的查詢緩慢問題。

C. 使用 AWS Glue ETL 將 .csv 轉換為 Apache Parquet 格式 - 正確

- **分析：**
 - **效能優化：**Parquet 是列式存儲，且內建壓縮，是 AWS 數據湖的最佳實踐，能顯著提升查詢（如 Athena, Glue, SageMaker）的速度。
 - **低維運開銷：**AWS Glue ETL 是一個託管服務，你只需要定義來源與目的地，AWS 會負責所有的運算資源管理。
- **為什麼正確：**這同時滿足了「提高效能」與「最低維運開銷」這兩個核心要求。

D. 配置 Amazon EMR 叢集來處理資料 - 錯誤

- **分析：**EMR 雖然可以非常高效地處理 PB 級數據。
- **為什麼不選：**與 AWS Glue 相比，EMR 要求工程師負責叢集的大小調整、版本管理、任務排程等工作。題目要求**將維運開銷降至最低**，在這種情況下，Serverless 的 Glue 通常優於 EMR。

3. 解題關鍵與總結

- **看到「S3 + CSV + 查詢慢」：**反射動作應尋找 **Parquet** 或 **ORC** 等列式格式。
- **看到「最低維運開銷 (Minimum Operational Overhead)」：**優先考慮 **Serverless (無伺服器)** 服務，如 Glue 或 Athena，而非 EMR。

▼ 50

一位機器學習工程師正在分析一個分類資料集，準備在 Amazon SageMaker AI 中訓練模型。該工程師懷疑資料集的類別標籤存在顯著不平衡，這可能導致模型預測偏差。為了確認類別不平衡問題，此工程師需要選擇適當的預訓練偏誤指標。

哪個指標能夠滿足此要求？

- A.均方誤差 (MSE)
- B.標籤比例差異 (DPL)
- C.輪廓分數
- D.結構相似性指數 (SSIM)

▼ 答案

B

1. 核心知識點：SageMaker Clarify 與數據偏誤 (Bias Detection)

- **SageMaker Clarify**：這是 AWS 專門用於檢測機器學習偏誤 (Bias) 與模型可解釋性 (Explainability) 的工具。
- **預訓練偏誤 (Pre-training Bias)**：指在模型訓練之前，存在於原始數據集中的偏誤。
- **標籤比例差異 (DPL, Difference in Proportions of Labels)**：這是檢測「類別不平衡」最直接的指標。它衡量的是不同分組（例如：男性 vs 女性）中，正向標籤（例如：核准貸款）出現比例的差異。

2. 選項獨立分析

A. 均方誤差 (MSE) - 錯誤

- **分析**：MSE ($MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$) 是**回歸模型 (Regression)** 的損失函數或評估指標。
- **為什麼不選**：它用於衡量預測值與真實值之間的差距，而不是用來衡量原始數據集中類別的分佈情況。

B. 標籤比例差異 (DPL) - 正確

- **分析**：DPL 衡量的是某個敏感特徵（如性別或種族）的不同子集中，標籤分佈的差異。
◦ 公式簡化表達： $DPL = \frac{n_a^{(1)}}{n_a} - \frac{n_d^{(1)}}{n_d}$ （其中 a 是受惠組， d 是受損組）。
- **為什麼正確**：在 SageMaker AI 中，DPL 正是專門用來確認數據集中是否存在類別標籤不平衡或分佈偏差的標準預訓練指標。

C. 輪廓分數 (Silhouette Score) - 錯誤

- **分析**：輪廓分數是用於評估**分群 (Clustering)** 演算法（如 K-Means）效果的指標。
- **為什麼不選**：它衡量的是群內相似度與群間差異度，與分類標籤的比例平衡無關。

D. 結構相似性指數 (SSIM) - 錯誤

- **分析：**SSIM 是一種衡量兩張圖像相似度的指標。
- **為什麼不選：**這通常用於電腦視覺領域（如影像壓縮、重建），完全無法用於分析分類資料集的標籤平衡問題。

3. 解題關鍵與總結

- **關鍵字對應：**看到 "Pre-training bias metric" 或 "Class imbalance"，應優先尋找 SageMaker Clarify 的相關指標，如 **DPL**、**CI (Class Imbalance)** 或 **JS (Jensen-Shannon Divergence)**。
- **區分階段：**
 - **訓練前 (Pre-training)：**分析數據集本身（如 DPL）。
 - **訓練後 (Post-training)：**分析模型預測結果（如 DPPL - Difference in Positive Proportions in Predicted Labels）。

▼ 51

一位機器學習工程師使用一個機器學習框架來訓練多個機器學習模型。該工程師需要優化推理成本，並將模型託管在 Amazon SageMaker AI 上。

哪一種解決方案能夠以最具成本效益的方式滿足這些要求？

- A. 建立一個用於直接呼叫的多容器推理端點。
- B. 為所有模型建立多模型推理端點。
- C. 為順序呼叫建立多容器推理端點。
- D. 為每個模型建立多個單模型推理端點。

▼ 答案

B

1. 核心知識點：SageMaker 多模型端點 (Multi-Model Endpoints, MME)

- **多模型端點 (MME)：**專門為託管大量模型而設計。這些模型共享相同的服務容器與計算實例資源。SageMaker 會根據需求自動從 S3 加載模型到記憶體，並在空間不足時卸載閒置模型。這對於有大量模型且並非所有模型都需要 24/7 高頻率調用的場景，能節省高達 90% 的成本。
- **多容器端點 (Multi-Container Endpoints)：**在同一個實例上運行多個不同的容器。這通常用於「推理管道 (Inference Pipelines)」或需要在同一

個端點調用完全不同框架（如一個容器跑 PyTorch，另一個跑 Scikit-learn）的模型。

- **成本效益 (Cost-effectiveness)**：共享資源（CPU/GPU/Memory）是降低推理成本的關鍵。

2. 選項獨立分析

A. 建立一個用於直接呼叫的多容器推理端點 - 錯誤

- **分析**：多容器端點（直接呼叫）允許你在一個端點中放置最多 15 個容器，並指定要呼叫哪一個。
- **為什麼不選**：雖然比單模型端點省錢，但它有 **15 個容器的上限**。如果模型數量很多（例如幾百個），這無法擴展。此外，維護多個容器的開銷高於多模型端點。

B. 為所有模型建立多模型推理端點 (MME) - 正確

- **分析**：MME 允許你在單個端點後方託管數千個模型。
- **為什麼正確**：它提供了最高的整合度。所有模型共享一組實例資源，且只有在被呼叫時才會佔用記憶體，這是託管多個模型時**最具成本效益**的標準解決方案。

C. 為順序呼叫建立多容器推理端點 - 錯誤

- **分析**：這被稱為 **Inference Pipeline（推理管道）**。它的運作方式是將數據傳給 Container A，處理完傳給 Container B。
- **為什麼不選**：這是為了完成「單個」預測流程的步驟（如：預處理 + 預測），而不是為了「分開託管多個獨立模型」。這不符合題目優化多個模型推理成本的需求。

D. 為每個模型建立多個單模型推理端點 - 錯誤

- **分析**：這是最傳統的做法，每個模型都有自己專屬的實例（Instances）。
- **為什麼不選**：這是最昂貴的方案。如果每個模型都配備一個實例，即使模型沒人在用，你還是得支付全額的實例費用，完全不符合成本優化。

3. 解題關鍵與總結

- **關鍵字對應**：當題目出現 "**Multiple models**" 且要求 "**Cost-effective**" 時，答案首選 **Multi-Model Endpoints (MME)**。

- **補充考點：**

- **MME 的限制：**所有模型必須使用相同的 ML 框架（相同的 Serving Container），或者使用支援多模型的自定義容器。
- **Serverless Inference：**如果模型調用頻率極低且對延遲不敏感，SageMaker Serverless Inference 也是一個成本優化的選項，但它通常針對單個模型。

▼ 52

一家公司使用機器學習模型對影片中的運動進行分類。資料以 MP4 格式儲存在 Amazon S3 中。該公司在創建該模型時，花了 4 個月的時間標註所有視訊幀。現在，

該公司需要使用 Amazon SageMaker AI 中現有的訓練工作流程重新訓練該模型。機器學習工程師必須實現一個能夠縮短標註時間的解決方案。

哪個解決方案能夠滿足這些要求？

- A.使用 SageMaker Ground Truth 對視訊畫面進行標註。
- B.使用 SageMaker JumpStart 利用預先訓練的電腦視覺模型發展標註模型。
- C.使用 SageMaker Data Wrangler 建立資料工作流程。使用此工作流程優化標註流程。
- D.使用 Amazon A2I 的 Amazon Rekognition 標註介面來標註視訊影格。

▼ 答案

答案是A

1. 核心知識點：Amazon SageMaker Ground Truth

- **標註效率優化：**對於視訊資料，手動標註每一影格（Frame）極其耗時。SageMaker Ground Truth 提供了多種加速功能：
 - **自動化資料標註（Automated Data Labeling）：**利用機器學習模型先進行預標註，只有在信心值低時才交給人工。
 - **輔助標註工具（Assisted Labeling）：**例如在視訊標註中，它支援物件追蹤（Object Tracking）。標註員只需在第一幀畫出框，系統會自動預測該物件在後續影格的位置，標註員只需微調。
- **視訊工作流程：**Ground Truth 內建了專門針對視訊物件偵測、視訊物件追蹤和視訊分類的介面。

2. 選項獨立分析

A. 使用 SageMaker Ground Truth 對視訊畫面進行標註 - 正確

- **分析**：Ground Truth 正是為了縮短標註時間而設計。
- **為什麼正確**：它提供了專門的視訊標註工作流。透過「輔助標註」和「自動化資料標註」功能，可以大幅減少工程師在視訊影格上花費的重複性體力勞動，直接解決了題目中「需要 4 個月」的痛點。

B. 使用 SageMaker JumpStart 發展標註模型 - 錯誤

- **分析**：JumpStart 提供了預訓練模型和一鍵式方案，方便快速部署模型。
- **為什麼不選**：JumpStart 是一個模型庫，雖然你可以用裡面的模型來做預測，但它**本身不是一個標註平台**。要建立一個完整的標註工作流（包含人工審核介面、任務分配等），JumpStart 並不具備這些功能。

C. 使用 SageMaker Data Wrangler 建立資料工作流程 - 錯誤

- **分析**：Data Wrangler 主要用於資料清理、轉換與特徵工程（例如處理缺失值、編碼、特徵縮放）。
- **為什麼不選**：Data Wrangler 的強項在於處理結構化（Tabular）資料或影像資料的「處理」，而非人工與機器協作的「標註」。它無法提供視訊標註所需的互動式 UI。

D. 使用 Amazon A2I 的 Amazon Rekognition 標註介面 - 錯誤

- **分析**：Amazon A2I (Augmented AI) 用於**人工審核（Human Review）**模型低信心的預測結果；Amazon Rekognition 是預先訓練好的影像/視訊分析服務。
- **為什麼不選**：Rekognition 是封裝好的 API，雖然可以用於偵測，但不適合用來標註「自定義」運動分類的專用訓練資料集。A2I 主要是「審核」而非從零開始的大規模「標註」流程。

3. 解題關鍵與總結

- **關鍵字對應**：看到 "Labeling" + "Reduce time" + "Video"，首選答案一定是 **SageMaker Ground Truth**。
- **視訊標註的特殊性**：考試常考 Ground Truth 的「物件追蹤」如何透過插值（Interpolation）和機器學習追蹤來減少人工工作量。

一家電商公司訓練了一個機器學習模型，根據歷史客戶活動資料預測近即時庫存管理的需求。該公司已成功將訓練好的模式部署到生產環境的 Amazon SageMaker AI 端點。然而，該公司發現模型的預測性能會隨著時間的推移而下降。該公司需要一個長期且自動化的解決方案來緩解效能下降的問題。

哪個解決方案能夠滿足這些要求？

- A.使用 Amazon SageMaker Debugger 在偵測到模型效能異常時自動發送警報。
- B.使用 AWS X-Ray 監控 SageMaker AI 端點的效能和傳入的請求，以引導模型重新訓練。
- C.使用 Amazon SageMaker Ground Truth 整理高品質資料集。使用該資料集重新訓練模型。
- D.使用 Amazon SageMaker Clarify 監控模型和特徵歸因偏差，以指導模型重新訓練。

▼ 答案

D

這道題目考查的是 **Amazon SageMaker 的生產環境監控與模型漂移 (Model Drift) 處理**。

當模型部署到生產環境後，隨著時間推移，由於外部環境變化或數據分佈改變（例如電商公司的客戶行為因季節或流行趨勢而改變），預測準確度會下降。這在 AWS 中通常透過 **Amazon SageMaker Model Monitor** 及其整合工具來解決。

1. 核心知識點：模型監控與漂移檢測 (Model Monitoring & Drift)

- **模型漂移 (Model Drift)**：指模型在生產環境中的預測能力下降。常見原因包括數據質量下降、數據分佈漂移 (**Data Drift**) 或特徵重要性改變 (**Feature Attribution Drift**)。
- **SageMaker Model Monitor**：這是一個託管服務，可自動監控部署在端點上的模型，並在檢測到異常時發送警報。它包含四個主要監控面向：
 1. **數據質量 (Data Quality)**：檢測輸入數據統計特性的變化。
 2. **模型質量 (Model Quality)**：檢測預測結果與實際結果之間的差距。
 3. **模型偏差 (Model Bias)**：檢測模型對特定群組的偏見是否增加（使用 **SageMaker Clarify**）。

4. **模型可解釋性 (Model Explainability)**：檢測特徵對預測結果的貢獻度是否發生顯著變化（使用 **SageMaker Clarify**）。

- **自動化重訓流程**：透過監控指標觸發 CloudWatch 警報，進而觸發 AWS Lambda 或 SageMaker Pipelines 進行數據重新抓取與模型重訓，實現「閉環」自動化。

2. 選項獨立分析

A. 使用 Amazon SageMaker Debugger 自動發送警報 - 錯誤

- **分析**：SageMaker Debugger 主要用於**訓練階段 (Training)**。它能捕捉張量 (Tensors)，監控消失梯度 (Vanishing Gradients)、權重過大等訓練異常。
- **為什麼不選**：雖然 Debugger 現在也具備部分推理監控能力，但它主要針對底層系統資源或訓練狀態，而非專門設計來處理生產環境中模型準確度隨時間下降（漂移）的長期監控方案。

B. 使用 AWS X-Ray 監控 SageMaker AI 端點的效能 - 錯誤

- **分析**：AWS X-Ray 是一個應用程式追蹤 (Tracing) 工具，用於分析 API 請求的延遲、路徑與錯誤率。
- **為什麼不選**：X-Ray 監控的是**系統效能**（如 HTTP 200/500 錯誤、響應時間），它完全無法得知模型預測的「邏輯正確性」或「數據分佈」是否發生偏移。

C. 使用 Amazon SageMaker Ground Truth 整理高品質資料集 - 錯誤

- **分析**：Ground Truth 是一個**資料標註 (Labeling)** 服務。
- **為什麼不選**：雖然重訓模型確實需要新標註的數據，但題目要求的是一個「長期且自動化的解決方案」來「緩解」效能下降。Ground Truth 本身不會主動「監控」模型效能，它只是數據準備階段的一個環節，無法滿足自動化監控與觸發的要求。

D. 使用 Amazon SageMaker Clarify 監控模型和特徵歸因偏差 - 正確

- **分析**：SageMaker Clarify 與 Model Monitor 深度整合。當模型表現下降時，往往是因為某些特徵 (Features) 的權重發生了偏移（例如某個原本不重要的特徵突然變得極具影響力）。

- **為什麼正確：**監控「特徵歸因偏差 (Feature Attribution Drift)」是識別模型預測邏輯失效的關鍵。透過 Clarify 的持續監控，可以自動檢測到模型何時「不再以正確的邏輯」做預測，並藉此「指導模型重新訓練」，這是最精準的自動化緩解方案。

3. 解題關鍵與總結

- **關鍵詞對應：**
 - "Performance degrades over time" (效能隨時間下降) = **Drift** (漂移)。
 - "Automated solution" (自動化方案) = **SageMaker Model Monitor / Clarify**。
- **解題心法：**在 AWS 考試中，處理生產環境模型「準確度」問題，首選 **Model Monitor** 家族。若選項中沒有直接列出 Model Monitor，則選擇其核心元件 **Clarify**。

▼ 54

一家物流公司安裝了車載攝像頭，用於對司機進行基本監控。該公司希望透過識別可能導致事故的分心駕駛行為來提高司機安全。

哪一種解決方案能夠以最小的營運成本滿足這項要求？

- A. 使用亞馬遜 Rekognition 眼動追蹤方向偵測來監控駕駛行為並識別分心行為。
- B. 使用 Amazon SageMaker AI 自訂 AI 模型來監控駕駛行為並識別分心行為。
- C. 將第三方駕駛員監控系統與 Amazon Rekognition 集成，以監控駕駛員行為並識別分心駕駛行為。
- D. 使用 Amazon Comprehend 分析基於文字的駕駛員回饋並識別分心因素。

▼ 答案

A

1. 核心知識點：Amazon Rekognition 臉部分析

- **Amazon Rekognition：**這是一個 **完全託管 (Fully Managed)** 的 AI 服務。開發者無需具備深度學習背景，只需透過 API 調用即可實現影像和影片分析。

- **臉部分析 (Face Analysis)**：Rekognition 的 `DetectFaces` API 可以偵測人臉並回傳多個屬性，包括：
 - **頭部姿勢 (Head Pose)**：偏航角 (Yaw)、俯仰角 (Pitch)、翻滾角 (Roll)。這對於判斷司機是否在「左顧右盼」非常有用。
 - **眼神偵測 (Eyes Open/Closed)**：判斷司機是否疲勞。
 - **臉部特徵點 (Facial Landmarks)**：可以追蹤眼睛和嘴巴的位置。
 - **最小維運開銷**：使用託管 API 不需要標註數據、訓練模型或管理伺服器，是最符合此要求的方案。
-

2. 選項獨立分析

A. 使用 Amazon Rekognition 方向偵測來監控駕駛行為 - 正確

- **分析**：Amazon Rekognition 提供了臉部辨識與分析功能，能夠精確偵測人臉的朝向 (Head Pose) 以及眼睛是否睜開。
- **為什麼正確**：這是一個 **Serverless** 方案，開發者只需將攝像頭的影像傳送到 API，即可獲得司機是否分心的特徵數據（例如：頭部長時間偏離前方）。這完全符合題目要求的「最小營運成本」。

B. 使用 Amazon SageMaker 自訂 AI 模型 - 錯誤

- **分析**：雖然 SageMaker 可以訓練出極其精準的自定義模型。
- **為什麼不選**：建立自定義模型需要經歷：蒐集分心駕駛影像 → 數據標註 -> 選擇算法 → 模型訓練 → 部署端點。這個過程涉及大量的**人工成本與維運開銷**。既然 Rekognition 已有內建功能，就不應選擇更複雜的 SageMaker。

C. 將第三方系統與 Amazon Rekognition 集成 - 錯誤

- **分析**：引入第三方系統會增加架構的複雜性。
- **為什麼不選**：這會增加整合難度，且通常需要支付額外的第三方軟體授權費，這與「最小營運成本」背道而馳。直接使用 AWS 原生服務更簡潔。

D. 使用 Amazon Comprehend 分析文字回饋 - 錯誤

- **分析**：Amazon Comprehend 是一個 **自然語言處理 (NLP)** 服務，用於分析文字（如：評論、郵件、文檔）。

- **為什麼不選：**題目明確指出資料來源是「車載攝像頭（影像/影片）」，而 Comprehend 只能處理文字。它無法從影像中識別分心行為。

3. 解題關鍵與總結

- **看到「影像/影片識別」且要求「最低開銷/成本」：**第一反應應是 **Amazon Rekognition**。
- **關鍵屬性：**對於駕駛安全，Rekognition 的 **Head Pose (頭部姿勢)** 偵測是判斷分心（看向側面或下方）的最常用指標。

▼ 55

一家公司訓練了一個機器學習模型，並將其打包在一個容器中。該公司需要將該模型整合到現有的 Python Web 應用程式中。該公司需要使用 Kubernetes 在 AWS 上託管該模型。

該公司不希望管理控制平面，並且必須以可重複的方式配置資源。基礎架構必須使用 Python 進行配置。

哪種解決方案能夠滿足這些要求？

- A.使用 AWS CloudFormation 在多個可用區中預置 Amazon EC2 執行個體。設定 Kubernetes 叢集。將模型容器託管在 Kubernetes 叢集上。
- B.使用 AWS CLI 設定 Amazon Elastic Kubernetes Service (Amazon EKS) 叢集。將鏡像儲存在 Amazon Elastic Container Registry (Amazon ECR) 儲存庫中。將模型容器託管在 EKS 叢集上。
- C.使用 AWS 雲端開發工具包 (AWS CDK) 來設定 Amazon Elastic Kubernetes Service (Amazon EKS) 叢集。將鏡像儲存在 Amazon Elastic Container Registry (Amazon ECR) 儲存庫中。將模型容器託管在 EKS 叢集上。
- D.使用 AWS CloudFormation 設定 Amazon Elastic Kubernetes Service (Amazon EKS) 叢集。將鏡像儲存在 Amazon Elastic Container Registry (Amazon ECR) 儲存庫中。將模型容器託管在 EKS 叢集上。

▼ 答案

C

1. 核心知識點

- **Amazon EKS (Elastic Kubernetes Service)：**
 - 這是一個託管型的 Kubernetes 服務。

- **不需管理控制平面 (Control Plane)**：符合題目的第一個核心要求，AWS 會負責維護 K8s 的 API Server 和 etcd 數據庫。
 - **AWS CDK (Cloud Development Kit)**：
 - 這是一種進階的 IaC 工具，允許開發者使用**熟悉的程式語言（如 Python、TypeScript、Java）**來定義雲端資源。
 - 它會將程式碼轉換（Synthesize）成 AWS CloudFormation 範本來執行佈署。
 - **Amazon ECR (Elastic Container Registry)**：
 - 這是 AWS 託管的 Docker 鏡像倉庫，用於存放模型容器鏡像，與 EKS 完美整合。
-

2. 選項獨立分析

A. 使用 CloudFormation 預置 EC2 並設定 K8s 叢集 - 錯誤

- **分析**：這屬於「自建 Kubernetes (Self-managed K8s on EC2)」。
- **為什麼不選**：題目明確要求「不希望管理控制平面」。在 EC2 上自建叢集意味著工程師必須親自負責控制平面的安裝、升級和高可用性管理。此外，手動設定 K8s 也很難僅透過 Python 簡單配置資源。

B. 使用 AWS CLI 設定 Amazon EKS 叢集 - 錯誤

- **分析**：AWS CLI 是命令列工具，適合執行單次操作。
- **為什麼不選**：
 1. **重複性差**：雖然可以寫 Shell Script，但與 IaC 工具（如 CDK 或 CloudFormation）相比，它缺乏狀態管理和宣告式配置。
 2. **非 Python 配置**：CLI 是命令列指令，不符合題目要求「使用 Python 進行配置」的標準開發流程。

C. 使用 AWS CDK 來設定 Amazon EKS 叢集 - 正確

- **分析**：
 1. **滿足管理要求**：使用 EKS 解決了「不管理控制平面」的問題。
 2. **滿足語言要求**：**AWS CDK 支援 Python**。這意味著機器學習工程師可以用 Python 編寫類別（Classes）和物件來定義 EKS 叢集、Node Groups 以及 ECR 儲存庫。

3. **滿足重複性要求**：CDK 是標準的 IaC，版本控制友好且可重複佈署。

- **為什麼正確**：這是唯一一個同時滿足「託管 K8s」、「可重複性」以及「使用 Python 配置」所有條件的選項。

D. 使用 AWS CloudFormation 設定 Amazon EKS 叢集 - 錯誤

- **分析**：CloudFormation 確實是可重複的 IaC 工具，也使用了託管的 EKS。
- **為什麼不選**：CloudFormation 使用的是 **YAML 或 JSON** 格式來撰寫範本。題目明確要求基礎架構必須使用 **Python** 進行配置，雖然可以使用一些轉換工具，但原生支援 Python 定義的 IaC 首選是 AWS CDK。

3. 解題關鍵與總結

- **關鍵字對應**：
 - "Do not want to manage control plane" = Amazon EKS。
 - "Configured using Python" = AWS CDK (Python)。
- **考試陷阱**：很多人會看到 CloudFormation (D) 就選，因為它是 AWS 最權威的 IaC。但 CDK 的出現就是為了讓開發者能用程式語言（如 Python）代替繁瑣的 YAML，這正是本題的「陷阱」所在。

▼ 56

一位機器學習工程師正在開發一個線性迴歸機器學習模型。該模型在訓練資料集上表現出很高的準確率，但在未見過的新資料上表現很差。

這位機器學習工程師應該採取什麼措施來解決這個問題？

- A. 增加模型的複雜度，以捕捉訓練資料中的更多模式。使用 Amazon SageMaker Debugger 監控收斂問題。
- B. 應用機器學習技術，例如交叉驗證和正規化。使用 Amazon SageMaker Experiments 追蹤和比較不同模型版本及其效能指標。
- C. 直接將模型部署到生產環境。使用 Amazon SageMaker Clarify 分析新資料的模型輸出結果。根據這些分析結果調整模型。
- D. 在不調整模型規模的情況下，增加訓練資料集的規模。使用新資料重新訓練模型。產生混淆矩陣以分析結果。

▼ 答案

B

1. 核心知識點：過擬合 (Overfitting) 與 模型一般化 (Generalization)

- **過擬合的徵兆**：模型在訓練集 (Training Set) 準確率極高，但在測試集或驗證集 (Unseen Data) 表現很差。這代表模型「死記硬背」了訓練數據中的雜訊，而沒有學會通用的規律 (高方差 High Variance)。

- **解決過擬合的標準手段**：

- **正規化 (Regularization)**：如 L1 (Lasso) 或 L2 (Ridge)，透過懲罰過大的權重來降低模型複雜度。

- **交叉驗證 (Cross-validation)**：確保模型在多個不同的數據子集上都能穩定運行，提升穩定性。

- **簡化模型**：減少特徵數量或降低多項式階數。

- **Amazon SageMaker Experiments**：這是 AWS 用於管理機器學習實驗的工具。當工程師嘗試不同的超參數 (如不同的正規化強度) 時，可以使用它來追蹤、比較不同版本的表現，從而選出最優模型。

2. 選項獨立分析

A. 增加模型複雜度，使用 SageMaker Debugger - 錯誤

- **分析**：題目描述的情況正是因為模型對於現有數據「太過複雜」導致的。增加複雜度會使過擬合更加嚴重。

- **為什麼不選**：SageMaker Debugger 主要用於監控訓練過程 (如梯度消失、權重爆炸)，雖然有助於調優，但本題的大方向 (增加複雜度) 是錯誤的。

B. 應用交叉驗證和正規化，使用 SageMaker Experiments - 正確

- **分析**：

- **手段正確**：正規化與交叉驗證是處理過擬合 (訓練好、預測差) 的教科書式解決方案。

- **工具正確**：SageMaker Experiments 讓工程師能有條理地對比「有正規化」與「沒正規化」的模型指標，選出一般化能力最強的版本。

- **為什麼正確**：它從理論 (解決過擬合) 與工具 (AWS 管理實踐) 兩方面都給出了最優解。

C. 直接部署到生產環境，使用 SageMaker Clarify - 錯誤

- **分析**：將一個已知在測試集表現很差的模型部署到生產環境是非常危險的行為。

- **為什麼不選**：SageMaker Clarify 用於偵測偏誤 (Bias) 與模型可解釋性 (Explainability)，它無法修復模型的一般化 (Generalization) 問題。

D. 增加訓練資料規模，產生混淆矩陣 - 錯誤

- **分析**：

- **手段部分正確**：增加數據確實有助於緩解過擬合。
- **邏輯錯誤**：題目明確指出這是一個**「線性迴歸 (Linear Regression)」**模型。
- **為什麼不選：混淆矩陣 (Confusion Matrix) 用於「分類模型」**（如判斷是不是貓），而迴歸模型應該使用 MSE、RMSE 或 R^2 等指標。因此，這個選項在技術細節上是錯誤的。

3. 解題關鍵與延伸建議

- **關鍵陷阱**：選項 D 的「混淆矩陣」是專門設計來坑沒注意到「線性迴歸」這四個字的考生的。
- **解題心法**：看到「訓練集好、測試集差」 $\rightarrow$ 反射動作找 **Regularization (正規化)** 或 **Drop out (針對神經網路)**。

▼ 57

一家公司正在訓練一個新的機器學習模型，以取代部署在 Amazon SageMaker AI 即時端點上的現有模型。機器學習工程師需要確定新模型的延遲和準確率。該工程師必須在生產環境中評估新模型，且不能影響現有模型的使用者。

哪種解決方案能夠滿足這些要求？

- A. 執行藍綠部署，實現線性流量切換。
- B. 執行藍綠部署，並進行金絲雀流量切換。
- C. 以目前車隊規模的 50% 進行滾動部署。
- D. 進行影子測試，流量抽樣百分比為 100%。

▼ 答案

D

1. 核心知識點：影子測試 (Shadow Testing)

- **影子測試 (Shadow Testing/Shadow Variants)**：這是一種特殊的部署模式。在這種模式下，生產環境的流量會同時發送到「目前的模型 (Production Variant)」和「新模型 (Shadow Variant)」。
- **關鍵特性**：系統僅將目前模型的預測結果回傳給使用者，而新模型的預測結果會被記錄下來供分析。
- **目的**：這讓工程師能在真實流量下觀察新模型的延遲、準確率和錯誤率，而**完全不會影響到現有的使用者體驗**。如果新模型發生錯誤或超時，使用者也不會察覺。

2. 選項獨立分析

A. 執行藍綠部署，實現線性流量切換 (Linear Traffic Shifting) - 錯誤

- **分析：**線性切換是指分階段（例如每 10 分鐘增加 10%）將真實使用者導向新模型。
- **為什麼不選：**雖然這種方法比一次性切換安全，但在切換過程中，仍有部分使用者會收到新模型的結果。如果新模型準確率不佳，**會直接影響到這部分使用者**，不符合題目要求。

B. 執行藍綠部署，並進行金絲雀流量切換 (Canary Traffic Shifting) - 錯誤

- **分析：**金絲雀部署是先將一小部分流量（例如 5%）導向新模型。
- **為什麼不選：**與選項 A 類似，雖然受影響的人數較少，但它依然是讓真實使用者去測試未經驗證的模型。這違背了「不能影響現有模型使用者」的條件。

C. 以目前車隊規模的 50% 進行滾動部署 (Rolling Deployment) - 錯誤

- **分析：**滾動部署會逐一替換實例。
- **為什麼不選：**在部署期間，負載均衡器會將 50% 的使用者請求導向新實例（新模型）。這是風險最高的做法之一，因為一半的使用者會立即與新模型互動。

D. 進行影子測試，流量抽樣百分比為 100% - 正確

- **分析：**影子測試會複製（Mirror）所有進入端點的請求。
- **為什麼正確：**
 1. **安全性：**使用者的回應僅來自舊模型，新模型在「後台」默默運行。
 2. **全面性：**100% 的流量抽樣意味著工程師可以獲得最完整的測試數據，精確比較兩者在延遲和準確率上的差異。
 3. **合規性：**完全符合「不影響使用者」且「在生產環境評估」的雙重需求。

3. 解題關鍵與總結

- **關鍵字對應：**看到 "No impact on existing users" + "Evaluate in production" $\rightarrow$ 唯一答案就是 **Shadow Testing**。
- **考點延伸：**
 - **A/B Testing：**用於比較兩個模型的效果（如轉化率），使用者會看到不同的結果。
 - **Blue/Green：**用於安全更換版本，通常配合切換策略減少停機時間。

▼ 58

一位機器學習工程師想要使用、準備和載入來自 Amazon S3 的資料進行分析。該工程師必須執行一個提取、轉換和載入 (ETL) 作業來發現資料模式並儲存元資料。

哪一種解決方案能夠以最少的人工干預滿足這些要求？

- A.使用 AWS Glue 執行 ETL 作業。使用此作業發現架構並將關聯的元資料儲存在 AWS Glue 資料目錄中。
- B.建立一個 Amazon SageMaker Data Wrangler 流來執行 ETL 作業。使用此作業發現架構並將關聯的元資料儲存在 S3 儲存桶中。
- C.使用整合了 Amazon Athena 和 AWS Step Functions 的 ETL 管道建立 ETL 管道。使用該管道執行 ETL 作業，以發現模式並將關聯的元資料儲存在 S3 儲存桶中。
- D.啟動一個包含 scikit-learn 函式庫的 Amazon EC2 執行個體來執行 ETL 作業。使用該作業來發現模式並將相關的元資料儲存在 Amazon Redshift 中。

▼ 答案

A

1. 核心知識點：AWS Glue 生態系統

- **AWS Glue Crawler (爬蟲)**：這是實現「最少人工干預」的關鍵。它可以自動掃描 S3 中的檔案（如 CSV, JSON, Parquet），識別檔案格式，並推斷其架構（Schema/模式）。
- **AWS Glue Data Catalog (資料目錄)**：這是一個集中式的元資料儲存庫。它存儲了數據的表定義、位置和模式資訊。這讓 Athena, Redshift Spectrum 和 SageMaker 等服務能直接讀取 S3 數據而不需要手動定義結構。
- **Serverless ETL**：AWS Glue 是一個無伺服器環境，自動處理底層資源的擴展，工程師只需專注於轉換邏輯。

2. 選項獨立分析

A. 使用 AWS Glue 執行 ETL 並將元資料儲存在資料目錄中 - 正確

- **分析**：AWS Glue 是專門為此場景設計的。
- **為什麼正確**：
 1. **自動化**：Glue Crawler 可以自動發現數據模式。
 2. **整合性**：Glue Data Catalog 是儲存元資料的標準 AWS 服務。
 3. **低維運**：它是 Serverless 服務，符合「最少人工干預」的要求。

B. 建立 Amazon SageMaker Data Wrangler 流 - 錯誤

- **分析**：Data Wrangler 是一個視覺化工具，旨在幫助工程師「手動」進行數據準備、特徵工程和視覺化。
- **為什麼不選**：雖然 Data Wrangler 很好用，但它主要用於**互動式探索**，而非大規模自動化 ETL 與全局元資料目錄管理。此外，它的元資料通常是流程的一部分，而不是像 Glue Data Catalog 那樣供全公司服務調用的全局目錄。

C. 使用 Athena 和 Step Functions 建立 ETL 管道 - 錯誤

- **分析：**這是一個「自建」方案。你需要寫 Step Functions 的狀態機邏輯，還要在 Athena 中編寫 DDL SQL 來定義表結構。
- **為什麼不選：**這涉及大量的程式碼撰寫與元件整合，**人工干預程度高**，不符合題目「最少人工干預」的優先級。

D. 啟動 EC2 執行個體來執行 ETL 並儲存至 Redshift - 錯誤

- **分析：**這是最傳統、維運負擔最大的做法。
- **為什麼不選：**
 1. **高維運：**需要管理 EC2 補丁、擴展與儲存。
 2. **不匹配：**scikit-learn 用於建模而非 ETL。
 3. **成本高：**為了存儲元資料而啟動 Redshift（數據倉庫）是大材小用且成本極高。

3. 解題關鍵與總結

- **關鍵詞對應：**
 - **"Discover data patterns" (發現數據模式)** $\rightarrow$ **AWS Glue Crawler**。
 - **"Store metadata" (儲存元資料)** $\rightarrow$ **AWS Glue Data Catalog**。
 - **"Minimal manual intervention" (最少人工干預)** $\rightarrow$ **Serverless / Fully Managed services (如 Glue)**。

▼ 59

一位機器學習工程師正在建造一個機器學習管線。此管線必須使用 Amazon Athena 以兩種方式處理資料集。管線必須使用批次來執行大規模資料轉換和模型訓練。管線還必須使用近即時處理來執行低延遲查詢，以進行推理和分析。

哪一種文件格式能夠為這兩種類型的處理提供最低的延遲？

- A.CSV
- B.阿帕契拼花地板
- C.巢狀 JSON
- D.反序列化 JSON

▼ 答案

B

這題考查的是 **Amazon Athena 的查詢效能優化** 以及 **大數據儲存格式 (Storage Formats)** 的選擇。在 AWS 數據湖架構中，選擇正確的文件格式對於減少數據掃描量、降低延遲和節省成本至關重要。

1. 核心知識點：列式存儲 (Columnar Storage) 的優勢

- **Amazon Athena 運作原理**：Athena 是一個基於 Presto 的無伺服器查詢服務。它的計費與效能直接取決於「掃描的數據量」。
 - **Apache Parquet**：這是一種高性能的**列式存儲**格式。
 - **列投影 (Column Projection)**：查詢時只讀取所需的欄位，而不必掃描整行數據。
 - **謂詞下推 (Predicate Pushdown)**：利用文件內的統計資訊（如最大/最小值）跳過不相關的數據塊。
 - **壓縮比**：列式存儲能提供更好的壓縮效果，進一步減少 I/O 負擔。
 - **近即時與批次處理**：對於大規模轉換（批次）和低延遲查詢（近即時），減少硬碟 I/O 是提升速度的最有效手段。
-

2. 選項獨立分析

A. CSV - 錯誤

- **分析**：CSV 是一種**行式存儲 (Row-based)** 的純文字格式。
- **為什麼不選**：Athena 在查詢 CSV 時，即使你只需要其中一欄，它也必須掃描每一行的所有內容。對於大規模資料集，這會導致極高的延遲和昂貴的查詢成本。它也不支持壓縮後的隨機讀取。

B. 阿帕契拼花地板 (Apache Parquet) - 正確

- **分析**：這裡題目中的「拼花地板」是 **Parquet** 的直譯（這在某些自動翻譯的考題中很常見）。
- **為什麼正確**：Apache Parquet 是 Athena 和大數據處理（如 Spark, Presto）的**黃金標準**。它具備卓越的列式存儲特性，能極大地減少數據掃描量，從而為批次轉換提供高吞吐量，並為推理分析提供最低的查詢延遲。

C. 巢狀 JSON (Nested JSON) - 錯誤

- **分析**：JSON 是半結構化的行式格式。

- **為什麼不選：**雖然 JSON 支持複雜結構，但解析 JSON 需要消耗大量的 CPU 資源，且 Athena 必須讀取整個文件才能找到需要的欄位，延遲遠高於 Parquet。

D. 反序列化 JSON (Deserialized JSON) - 錯誤

- **分析：**這通常指將 JSON 轉換為平面結構或記憶體對象。
- **為什麼不選：**在 S3 儲存層面，這依然不具備列式存儲的物理優勢。處理邏輯依然是行式的，無法滿足「大規模數據轉換」和「低延遲查詢」的高效能需求。

3. 解題關鍵與總結

- **關鍵字對應：**看到 "Amazon Athena" + "Low latency" + "Large-scale"，幾乎可以直覺選擇 Parquet 或 ORC。
- **翻譯小貼士：**在 AWS 考試中，如果你看到「拼花地板」或「木條地板」，請自動將其聯想為 Parquet 格式。
- **實務建議：**如果數據是從 Kinesis 傳入的，通常會建議透過 Kinesis Data Firehose 在寫入 S3 前就直接轉換為 Parquet 格式，以優化後續的 Athena 查詢效能。

▼ 60

一家公司使用 Amazon SageMaker AI 機器學習模型進行即時推理。該公司已為 SageMaker AI 用於推理的 Amazon EC2 執行個體配置了自動擴展。

在高峰使用期間，新實例會在現有實例完全就緒之前啟動。因此，模型會出現效率低下和延遲。

哪種解決方案可以在不影響回應時間的情況下優化擴展過程？

- A. 在 SageMaker AI 中變更為多模型端點配置。
- B. 整合 Amazon API Gateway 和 AWS Lambda 來管理 SageMaker AI 推理端點的呼叫。
- C. 縮短縮容活動的冷卻時間。增加最大實例數。
- D. 增加規模化活動後的冷卻時間。

▼ 答案

D

這題考查的是 **Amazon SageMaker 端點的自動擴展 (Auto Scaling) 機制**，特別是當流量變動劇烈時，如何透過調整**冷卻時間 (Cooldown

Period) **來穩定擴展行為並確保效能。

1. 核心知識點：SageMaker 自動擴展與冷卻時間

- **自動擴展 (Auto Scaling)**：SageMaker 透過監控指標（如 `SageMakerVariantInvocationsPerInstance`）來動態調整實例數量。
- **擴展冷卻時間 (Scale-out Cooldown)**：當擴展活動（增加實例）觸發後，系統會等待一段時間，確保新實例有足夠的時間完成啟動、載入模型並開始處理流量。
- **問題診斷**：題目提到「新實例在現有實例完全就緒前就啟動」，這意味著原本的擴展請求還在處理中，但因為監控指標尚未因新實例加入而下降，導致系統「誤判」還需要更多資源，進而連續觸發多個擴展活動。這會導致資源浪費（效率低下）以及在實例頻繁變動時可能產生的抖動或延遲。

2. 選項獨立分析

A. 變更為多模型端點 (Multi-model endpoint, MME) 配置 - 錯誤

- **分析**：MME 是為了在單個端點上託管數百個模型以節省成本。
- **為什麼不選**：MME 反而可能增加延遲，因為它在需要時才從 S3 載入模型（冷啟動）。它與解決自動擴展觸發時機過快的問題無關。

B. 整合 Amazon API Gateway 和 AWS Lambda - 錯誤

- **分析**：這是在 SageMaker 前端增加代理層。
- **為什麼不選**：Lambda 和 API Gateway 會引入額外的架構複雜性與延遲（如 Lambda 的冷啟動）。這無法解決底層 SageMaker 實例擴展邏輯不穩定（太快觸發新實例）的問題。

C. 縮短縮容冷卻時間，增加最大實例數 - 錯誤

- **分析**：縮短「縮容 (Scale-in)」冷卻時間會讓實例在流量下降時更快被刪除。
- **為什麼不選**：這會讓系統變得更敏感、更不穩定，容易造成在流量波動時頻繁刪除又重新建立實例，加劇延遲問題。增加最大實例數只能提供更高上限，無法解決「過早觸發下一次擴展」的時序問題。

D. 增加規模化活動後的冷卻時間 (Scale-out Cooldown) - 正確

- **分析：**增加**擴展冷卻時間 (Scale-out Cooldown)**可以強迫 Auto Scaling 在增加一個實例後「停看聽」。
- **為什麼正確：**這給予新啟動的 EC2 實例足夠的時間來完成容器初始化和模型加載。一旦新實例開始分擔流量，每秒調用數 (Invocations per Instance) 指標就會下降，系統就會發現不需要再額外啟動更多實例，從而使擴展過程變得平滑且高效，避免重複啟動過多未就緒的實例。

3. 解題關鍵與總結

- **關鍵現象：**"New instances start before existing instances are fully ready" (新實例在舊的還沒好之前就跑出來了)。
- **標準解法：**這是典型的 **Auto Scaling Thrashing (擴展抖動)**。在 AWS 考試中，當擴展太過頻繁或在實例準備好前就重複觸發時，**增加冷卻時間 (Increase Cooldown)** 是最標準的優化手段。

▼ 61

一家公司透過呼叫 CreateModel API 操作，將 Amazon SageMaker AI ML 模型部署到了一個端點。透過 API 呼叫建立的網路包含兩個私有子網路和一個安全群組。

該模型需要從 Amazon S3 儲存桶下載數據，並向該 S3 儲存桶上傳資料。與 S3 儲存桶的流量不得經過網際網路。

哪種解決方案能夠滿足這些要求？

- A. 建立 NAT 閘道。配置安全群組以允許出站連線。設定路由表，將所有到 S3 儲存桶的流量重新導向到 NAT 閘道。
- B. 建立網關 VPC 端點。配置端點政策，限制對 S3 儲存桶的存取。設定路由表，將所有發送到 S3 儲存桶的流量重新導向到該端點。
- C. 建立一個介面 VPC 端點。確認安全群組僅允許入站連線。設定路由表，將所有發送到 S3 儲存桶的流量重新導向到該端點。
- D. 建立網關負載平衡器 VPC 端點。配置 IAM 政策以限制對 S3 儲存桶的存取。設定路由表，將所有發送到 S3 儲存桶的流量重新導向到該端點。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	NAT 閘道 (NAT Gateway) 雖然能讓私有子網路存取外部資源，但它是透過網際網路閘道 (Internet Gateway) 連向公網的。這違反了題目要求「流量不得經過網際網路」的限制。
B	✓ 正確	網關 VPC 端點 (Gateway VPC Endpoint) 是專為 S3 和 DynamoDB 設計的。它能在 VPC 路由表中建立路徑，讓流量直接透過 AWS 內部網路傳輸至 S3。不僅完全不經公網，且不需要額外支付處理費，是最標準的做法。
C	✗ 錯誤	雖然 S3 現在也支援介面 VPC 端點 (Interface Endpoint / PrivateLink)，但該選項的設定有誤：介面端點需要配置安全群組以允許**出站 (Outbound) **連向端點的流量，且通常不需要手動設定路由表 (它是透過 DNS 解析)。此外，Gateway 端點通常是 S3 的首選經濟方案。
D	✗ 錯誤	網關負載平衡器 (GWLB) 主要是用於將流量導向第三方虛擬設備 (如防火牆、入侵偵測系統) 進行檢查，並非用於 VPC 與 AWS 服務 (如 S3) 之間的私密連線。

▼ 62

一家公司正在開發一種新的機器學習模型，用於對客戶的還款潛力進行排名。該公司需要使用亞馬遜 SageMaker AI 的內建演算法。

為了滿足這些要求，該公司應該使用哪種演算法？

- A.XGBoost
- B.K均值聚類
- C.主成分分析 (PCA)
- D.神經主題模型 (NTM)

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	XGBoost (eXtreme Gradient Boosting) 是一種強大的梯度提升樹演算法，廣泛用於分類

		(Classification) 與迴歸 (Regression)。對「還款潛力進行排名」通常被視為一個迴歸問題 (預測信用分數) 或二進制分類問題 (預測是否違約)，XGBoost 是處理這類結構化表格數據的首選內建演算法。
B	✗ 錯誤	K-Means (K-Means Clustering) 是一種 非監督式學習 演算法，主要用於將數據「分群」。雖然它可以將客戶分成不同的組，但它無法根據標籤 (如歷史還款數據) 來預測或「排名」客戶的具體還款潛力。
C	✗ 錯誤	PCA (Principal Component Analysis) 主要用於 降維 (Dimensionality Reduction) 。它能將多個相關聯的特徵壓縮成較少的主成分，以簡化模型，但它本身不是一個用來進行預測或排名的預測模型。
D	✗ 錯誤	NTM (Neural Topic Model) 是專門用於**自然語言處理 (NLP) **的演算法。它的作用是從大量文本文件中自動發現隱藏的「主題」(Topics)，與數值型或表格型的信用風險評估完全不相關。

▼ 63

一位機器學習工程師正在為機器學習模型設定 Amazon SageMaker AI 管線。如果偵測到**任何資料漂移**，此管線必須自動啟動重新訓練作業。

這位機器學習工程師應該如何設定管線以滿足此要求？

- A.使用 AWS Glue 爬蟲和 AWS Glue 擷取、轉換和載入 (ETL) 作業來偵測資料漂移。使用 AWS Glue 觸發器來自動執行重新訓練作業。
- B.使用 Amazon Managed Service for Apache Flink 偵測資料漂移。使用 AWS Lambda 函數自動執行重新訓練任務。
- C.使用 SageMaker 模型監控器偵測資料漂移。使用 AWS Lambda 函數自動執行重新訓練作業。
- D.使用 Amazon QuickSight 異常檢測功能來偵測資料漂移。使用 AWS Step Functions 工作流程來自動執行重新訓練作業。

▼ 答案

C

選項	是否適合	解析
----	------	----

A	✗ 錯誤	AWS Glue 主要用於資料整合與 ETL。雖然它可以處理資料，但它並非專門設計來監控 ML 模型推理過程中的「資料漂移 (Data Drift)」，且設定觸發重新訓練的邏輯較為複雜且非原生。
B	✗ 錯誤	Managed Service for Apache Flink 用於串流資料的即時分析。雖然理論上可以開發自定義邏輯來偵測漂移，但這需要大量的開發成本，不如 SageMaker 原生工具高效。
C	✓ 正確	SageMaker Model Monitor 是 AWS 專門為此需求設計的工具。它可以自動監控生產環境中的輸入資料，並與基準資料 (Baseline) 對比以偵測漂移。一旦偵測到偏差，它可以發送 CloudWatch Alarm，進而觸發 AWS Lambda 啟動 SageMaker Pipeline 進行重新訓練。
D	✗ 錯誤	Amazon QuickSight 是一個商業智慧 (BI) 視覺化工具。雖然它有機器學習驅動的異常檢測功能，但它是針對業務指標 (如銷量下滑) 進行視覺化分析，不適合用來與 ML 管線整合以監測底層特徵數據的漂移。

▼ 64

一家公司開發了一個電腦視覺模型。該公司需要將該模型部署到 Amazon SageMaker AI 的生產環境中。該公司之前從未在 SageMaker AI 上託管過模型。一位機器學習工程師需要實作一個解決方案來追蹤模型版本。此解決方案還必須提供使用哪些 Amazon EC2 執行個體類型來託管模型的建議。

哪個解決方案能夠滿足這些要求？

- A. 在 Amazon Elastic Container Registry (Amazon ECR) 中註冊模型。使用 AWS Compute Optimizer 取得執行個體類型的建議。
- B. 在 SageMaker 模型註冊表中註冊模型。使用 SageMaker Autopilot 取得執行個體類型的建議。
- C. 在 SageMaker 模型註冊表中註冊模型。使用 SageMaker 推理推薦器取得執行個體類型推薦。
- D. 在 Amazon Elastic Container Registry (Amazon ECR) 中註冊模型。使用 SageMaker Experiments 取得執行個體類型的建議。

▼ 答案

C

選項	是否適合	解析
A	✗ 錯誤	Amazon ECR 是容器鏡像倉庫，雖然它能存儲模型鏡像，但它不具備 ML 專用的「模型版本管理」邏輯（如審核狀態、模型指標紀錄）。 AWS Compute Optimizer 則是用於分析已運行的實例負載並建議縮減或擴張規模，無法在部署前針對特定 ML 模型提供精準的硬體建議。
B	✗ 錯誤	SageMaker Model Registry 是正確的模型管理工具，但 SageMaker Autopilot 是自動化機器學習（AutoML）工具，用於自動進行特徵工程、演算法選擇和調優，並非專門用來針對現有模型提供部署實例建議的工具。
C	✓ 正確	SageMaker Model Registry 專門用於追蹤模型版本、元數據及審核流程。而 SageMaker Inference Recommender 會透過在不同實例上運行負載測試（Load Tests），自動建議最佳的 EC2 執行個體類型，以平衡成本與效能（延遲/吞吐量）。
D	✗ 錯誤	SageMaker Experiments 用於追蹤訓練過程中的超參數、指標和構件，而不是管理生產環境的模型版本。它無法提供關於託管實例類型的部署建議。

▼ 65

一家公司正在使用 Amazon SageMaker AI 開發信用風險評估模型。在模型驗證過程中，該公司發現模型在驗證集上的準確率僅為 82%，但在訓練集上的準確率卻高達 99%。該公司需要在部署前解決模型準確率問題。

哪種解決方案能夠滿足此要求？

- A. 增加更多密集層以增加模型複雜度。實現批量歸一化。在訓練過程中使用早停法。
- B. 實作 dropout 層。使用 L1 或 L2 正規化。執行 k 折交叉驗證。
- C. 使用主成分分析（PCA）降低特徵維度。減少模型層數。實現交叉熵損失函數。
- D. 擴充訓練資料集。從訓練資料集中刪除重複記錄。實施分層抽樣。


▼ 答案

B

選項	是否適合	解析
----	------	----

A	✗ 錯誤	增加模型複雜度 （如增加更多密集層）通常會讓過擬合 更嚴重 。雖然「早停法（Early Stopping）」有助於防止過擬合，但前半部分的建議方向錯誤。
B	✓ 正確	Dropout 會在訓練時隨機關閉神經元，迫使模型學習更具魯棒性的特徵。 L1/L2 正規化 透過懲罰過大的權重值來限制模型複雜度。 k 折交叉驗證 則能更穩定地評估模型效能。這些都是解決過擬合的核心技術。
C	✗ 錯誤	雖然降低維度（PCA）和減少層數可能減輕過擬合，但「實現交叉熵損失函數」與解決過擬合無關，它是分類問題中標準的損失函數，無法直接修復訓練與驗證集的差異。
D	✗ 錯誤	雖然擴充數據有幫助，但「刪除重複記錄」和「分層抽樣」主要是為了解決數據偏誤或類別不平衡問題，對於已經發生的嚴重過擬合（99% vs 82%）來說，效果不如 B 選項的正規化手段直接。

核心觀念：過擬合與正規化Shutterstock探索



- **過擬合的徵兆**：訓練誤差極低，但測試/驗證誤差很高（High Variance）。
- **解決方案（Regularization）**：
 - **Dropout**：防止神經元之間過度依賴（Co-adaptation）。
 - **L1/L2 Regularization**：在損失函數中加入權重懲罰項，讓模型傾向於更簡單的參數空間。
 - **Data Augmentation**：增加數據多樣性。

▼ 66

一家公司每天收集客戶資料。該公司將資料以壓縮檔案的形式儲存在按日期分割的 Amazon S3 儲存桶中。每月，分析師下載數據，進行數據處理以檢查數據質量，然後將數據上傳到 Amazon QuickSight 控制面板。

一位機器學習工程師需要實作一個解決方案，在資料傳送到 QuickSight 之前自動檢查資料品質。

哪一種解決方案能夠以**最小的運維開銷**滿足這些要求？

- A.每月執行一次 AWS Glue 爬蟲程序，以更新 AWS Glue 資料目錄。使用 AWS Glue 資料品質規則檢查資料品質。
- B.使用 AWS Glue 觸發器每月執行一次 AWS Glue 爬蟲程序，以更新 AWS Glue 資料目錄。建立一個 AWS Glue 作業，將資料載入到 PySpark DataFrame 中。配置該作業以應用自訂函數並評估資料品質。
- C.每月在 AWS Lambda 函數上執行 Python 腳本以評估資料品質。配置 S3 儲存桶，以便在向 S3 儲存桶新增物件時呼叫 Lambda 函數。
- D.配置 S3 儲存桶，使其在物件上傳時傳送事件通知至 Amazon Simple Queue Service (Amazon SQS) 佇列。每月使用 Amazon CloudWatch Insights 評估 SQS 佇列的資料品質。

▼ 答案

A

選項	是否適合	解析
A	✔ 正確	AWS Glue Data Quality 是 AWS 提供的無伺服器解決方案，專門用於自動化資料品質檢查。它能與 Glue Crawler 整合，自動掃描 S3 資料並根據定義好的規則（如：欄位不為空、數值範圍等）產生評分，無需撰寫複雜的程式碼，且維運成本極低。
B	✘ 錯誤	雖然這個方案可行，但「建立 PySpark 作業並編寫自訂函數」需要投入大量的開發與維護工作。相比 A 選項的原生規則檢查，這不符合「最小運維開銷」的原則。
C	✘ 錯誤	使用 AWS Lambda 處理每月一次的大量壓縮檔案可能會遇到 15 分鐘的執行時間限制 (Timeout)。此外，自行編寫 Python 腳本來

		評估品質也比使用 Glue 的內建功能需要更多的維護。
D	✗ 錯誤	CloudWatch Insights 是用於分析日誌 (Logs) 或指標 (Metrics) 的工具，無法用來評估儲存在 S3 中業務資料 (如客戶資料) 的內容品質。SQS 則是用於訊息傳遞，非資料分析工具。

▼ 67

一家公司在 Amazon SageMaker AI 中有一個機器學習模型。一位機器學習工程師需要實施一個**監控解決方案，以自動偵測模型特徵輸入資料分佈的變化**。

哪一種解決方案能夠以最小的運維開銷滿足此要求？

- A.設定 SageMaker 模型監控器。建立數據品質基準。確保在基準約束檔案中啟用 emit_metrics 選項。配置 Amazon CloudWatch 警報，以便在與資料品質相關的特定指標變更時通知本公司。
- B.設定 SageMaker 模型監控器。建立模型品質基準。確保基線約束檔案中 comparison_method 選項設定為 Robust。配置 Amazon CloudWatch 警報，以便在模型品質指標變更時通知本公司。
- C.使用 SageMaker Debugger 和自訂規則來追蹤功能分佈的變化。配置 Amazon CloudWatch 警報，以便在規則偵測到重大變更時通知本公司。
- D.使用 Amazon CloudWatch 直接觀察 SageMaker AI 端點的效能指標。手動分析 CloudWatch 日誌，尋找資料漂移或特徵分佈變化的跡象。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	SageMaker Model Monitor - 資料品質 (Data Quality) 專門用於偵測 輸入特徵分佈的變化 (即資料漂移)。它會與基準 (Baseline) 進行比較，並能自動將指標發送到 CloudWatch 以觸發警報，這是維運開銷最小且最標準的做法。
B	✗ 錯誤	模型品質 (Model Quality) 監控的是預測結果與實際標籤 (Ground Truth) 之間的差異 (如準確率、F1 分數)。題目要求的是監控「 特徵輸入資料分佈 」，這屬於資料品質範疇而非模型品質。

C	✗ 錯誤	SageMaker Debugger 主要用於監控訓練過程中的張量（Tensors）與硬體資源利用率，或偵測過擬合。雖然它有自定義規則，但用於生產環境端點的輸入資料分佈監控並非其主要設計目標，維運成本較高。
D	✗ 錯誤	CloudWatch 預設指標 （如 Latency, CPUUtil）只能看到系統效能，看不到資料內容的統計分佈。手動分析日誌完全不符合「自動偵測」與「最小維運開銷」的要求。

▼ 68

一家公司正在使用 Amazon SageMaker AI 為其電商網站部署新的推薦模型。此模型必須使用所有客戶網站互動的資料作為輸入。

網站流量全天波動。該公司需要為該模型建立一個推理端點。

哪種類型的推理端點能夠以**最具成本效益的方式**滿足這些要求？

- A. 批量轉換推理端點
- B. 非同步推理端點
- C. 即時推理端點
- D. 無伺服器推理端點

▼ 答案

D

選項	是否適合	解析
A	✗ 錯誤	批量轉換（Batch Transform） 用於對非即時的大量數據進行離線預測。電商推薦通常需要根據客戶當前的點擊行為即時給出建議，Batch 無法滿足這種低延遲的互動需求。
B	✗ 錯誤	非同步推理（Asynchronous Inference） 適用於請求封包大（可達 1GB）或推理時間長（可達 1 小時）的場景（如影片生成）。它雖可自動縮減至 0 以節省成本，但會增加處理延遲，不適合追求快速反應的購物推薦。
C	✗ 錯誤	即時推理（Real-time Inference） 適用於低延遲需求。雖然它可以配置自動擴展（Auto Scaling），但即使在沒有流量時，仍需維持至少一個實例運行（除非手動關閉），對於流量波動大的場景，閒置成本較高。

D	✓ 正確	無伺服器推理（Serverless Inference）專為「間歇性或波動大」的流量設計。它會根據請求自動擴展，且僅按推理時間（毫秒級）和處理的資料量計費。在沒人訪問網站時，不會產生任何執行個體費用，是波動流量下最具成本效益的選擇。
---	------	--

▼ 69

一家公司在新建的 VPC 的公有子網路中運行著一個 Amazon SageMaker AI 域。網路配置正確，機器學習工程師可以存取該 SageMaker AI 域。

最近，該公司發現來自特定 IP 位址的可疑流量會造訪該域。該公司需要封鎖來自該特定 IP 位址的流量。

下列哪項網路配置更新可以滿足此要求？

- A. 建立一條安全群組入站規則，拒絕來自特定 IP 位址的流量。將該安全群組指派給該域。
- B. 建立一條網路 ACL 入站規則，拒絕來自特定 IP 位址的流量。將該規則指派給域所在子網路的預設網路 ACL。
- C. 為此域建立一個影子變體。配置 SageMaker 推理推薦器，使其將來自特定 IP 位址的流量傳送到影子端點。
- D. 建立 VPC 路由表，拒絕來自特定 IP 位址的入站流量。將該路由表指派給該域。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	安全群組（Security Groups）是「具狀態（Stateful）」的防火牆，它僅支援**允許（Allow）**規則，**不支援拒絕（Deny）**規則。你無法在安全群組中手動新增一條「拒絕來自 1.2.3.4」的規則。
B	✓ 正確	網路 ACL（Network Access Control Lists）是「無狀態（Stateless）」的防火牆，運行於子網路層級。它支援明確的 Allow 與 Deny 規則，且規則按編號順序處理。在 NACL 中新增一條編號較小（優先權高）的規則來拒絕特定 IP，是封鎖惡意流量的最佳手段。

C	✗ 錯誤	影子變體 (Shadow Variants) 和 推理推薦器 (Inference Recommender) 是用於模型測試與效能評估的工具。它們無法根據來源 IP 過濾流量，更無法達成安全防護或封鎖的目的。
D	✗ 錯誤	路由表 (Route Tables) 的作用是引導流量的去向 (Next Hop)，例如指向網際網路閘道或 VPC 端點。路由表本身不具備過濾或封鎖特定 IP 的功能。

▼ 70

一家公司的機器學習工程師正在創建一個分類模型。該工程師在瀏覽資料集時注意到有一個名為 day_of_week 的欄位。該列的資料包含以下值：星期一、星期二、星期三、星期四、星期五、星期六和星期日。

該工程師應該使用哪種技術將該列的資料轉換為二進位值？

- A.二進位編碼
- B.標籤編碼
- C.獨熱編碼
- D.分詞

▼ 答案

C

選項	是否適合	解析
A	✗ 錯誤	二進位編碼 (Binary Encoding) 會先將類別轉換為數值 (如 1, 2, 3)，再轉換為二進位碼 (如 01, 10, 11)。雖然它產生的特徵維度比獨熱編碼少，但在處理「星期」這種只有 7 個類別的數據時，不如獨熱編碼直觀且常用。
B	✗ 錯誤	標籤編碼 (Label Encoding) 會將類別分配為整數 (0, 1, 2...)。這會導致模型錯誤地認為數據之間存在「大小順序」(例如星期日=6 比星期一=0 更重要)，這對於大多數分類模型 (如線性回歸、SVM) 會產生負面影響。
C	✓ 正確	獨熱編碼 (One-Hot Encoding) 會為每個類別創建一個新的「虛擬變數」(Dummy Variable)，值為 0 或 1。例如「星期一」會變成 [1, 0, 0, 0, 0, 0, 0]。這是處理無序類別數據最標準、最能防止模型誤解數值大小意義的技術。

D	✗ 錯誤	分詞 (Tokenization) 是自然語言處理 (NLP) 中的技術，用於將長句子拆分為單個單詞或標記。這是用於文本處理的初步步驟，並非將類別欄位轉換為二進位數值的編碼技術。
---	------	--

▼ 71

一位機器學習工程師想使用 Amazon SageMaker AI 來準備訓練資料。在探索性資料分析過程中，該工程師發現一些分類特徵存在缺失值。

該工程師如何使用 SageMaker AI 來解決這個問題？

- A.使用 SageMaker Clarify 以平均值為基準來填入分類特徵。
- B.使用 SageMaker Clarify 以眾數值推斷分類特徵。
- C.使用 SageMaker Data Wrangler 以平均值來填入分類特徵。
- D.使用 SageMaker Data Wrangler 以眾數值填入分類特徵。

▼ 答案

D

選項	是否適合	解析
A	✗ 錯誤	SageMaker Clarify 主要用於偵測資料偏誤 (Bias) 和提供模型解釋性 (Explainability)，而非通用的資料預處理工具。此外，「平均值」不適用於分類數據。
B	✗ 錯誤	如前所述，Clarify 並非用於執行資料填補 (Imputation) 的主要工具。雖然「眾數」適合分類數據，但工具選擇不當。
C	✗ 錯誤	SageMaker Data Wrangler 是正確的工具（專為資料準備和特徵工程設計），但「平均值 (Mean)」僅能用於數值型數據（例如身高、體重），無法計算類別（例如顏色、城市）的平均值。
D	✓ 正確	SageMaker Data Wrangler 提供了內建的轉換功能來處理缺失值 (Handle missing values)。對於分類特徵，最常見且合理的填補方式就是使用「眾數 (Mode)」，即該欄位中出現頻率最高的值。

▼ 72

一家公司將使用者點擊流資料儲存在 AWS 帳戶 A 的 Amazon S3 儲存桶中。該公司需要使用這些資料在 AWS 帳戶 B 的 Amazon SageMaker AI 中訓練一個機器學習模型。訓練需要 10 天。

該公司需要在訓練過程中僅使用私人 IP 位址。此外，該公司還必須確保不與 AWS 共享任何訓練元資料。

哪種解決方案能夠滿足這些要求？

- A.在帳戶 A 和帳戶 B 之間建立 VPC 對等連線。透過電子郵件聯絡 AWS 選擇退出元資料收集。
- B.為 S3 儲存桶設定 VPC 端點。在訓練作業中將 SageMaker AI `OPT_OUT_TRACKING` 環境變數設定為 1。
- C.配置指派給帳戶 A 中的 S3 儲存桶的安全群組原則，僅允許從帳戶 B 存取。建立 AI 服務選擇退出策略。
- D.為儲存在 S3 儲存桶中的物件產生具有過期時間的預簽名 URL。使用預簽名 URL 存取資料。在訓練作業中將 SageMaker AI `OPT_OUT_TRACKING` 環境變數設定為 1。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	VPC 對等連線 (VPC Peering) 用於兩個 VPC 之間的溝通。雖然可行，但存取 S3 的標準且更簡單的做法是使用 S3 VPC 端點。此外，「透過電子郵件聯絡」並非 AWS 關閉元資料追蹤的標準技術手段。
B	✓ 正確	VPC 端點 (VPC Endpoint) 允許 SageMaker 透過 AWS 內部網路使用私有 IP 存取 S3。而設定環境變數 <code>OPT_OUT_TRACKING=1</code> 是 SageMaker 官方提供的機制，用於確保訓練的元資料（如演算法名稱、指標等）不會被傳回 AWS 用於改善服務。
C	✗ 錯誤	S3 儲存桶本身不支援安全群組 (Security Groups) ，安全群組是作用於實例或端點介面上的。此外，「AI 服務選擇退出策略」主要針對的是如 Amazon Rekognition 或 Lex 等高級 AI 服務的內容分析，而非 SageMaker 訓練作業的元資料追蹤。

D	✗ 錯誤	預簽名 URL (Presigned URL) 雖然可以限制存取時間，但它通常透過公網傳輸流量，不符合「僅使用私人 IP」的要求。
---	------	--

▼ 73

一家音樂串流媒體公司持續地將歌曲評分從應用程式傳輸到 Amazon S3 儲存桶。該公司希望將這些評分作為 Amazon SageMaker AI 模型訓練和推理的輸入。

該公司已配置 AWS Glue 資料目錄，並將 S3 儲存桶作為資料來源。一位機器學習工程師需要實作一個解決方案來建立此資料的儲存庫。此解決方案必須確保資料在批量訓練和即時推理期間保持同步。

哪個解決方案能夠滿足這些要求？

- A.從 S3 儲存桶將資料匯入 SageMaker Feature Store。應用標籤和索引。
- B.使用 Amazon Athena。使用 CREATE TABLE AS SELECT (CTAS) 查詢建立表格以對資料進行分組。
- C.使用 AWS Lake Formation。對數據應用基於標籤的控制。
- D.使用 SageMaker Data Wrangler 中的「產生資料洞察」功能。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	Amazon SageMaker Feature Store 是專為此需求設計的。它包含**離線存儲 (Offline Store) 用於批量訓練，以及在線存儲 (Online Store) **用於即時推理。Feature Store 會自動同步兩者，確保模型在訓練與推理時看到的特徵定義與數據是一致的。
B	✗ 錯誤	Amazon Athena 是一個互動式查詢服務，適合用於分析儲存在 S3 中的大數據。雖然它可以建立表格，但它不具備「在線存儲」所需的極低延遲 (毫秒級) 讀取能力，無法支持即時推理。
C	✗ 錯誤	AWS Lake Formation 用於簡化資料湖的建立、管理與安全控制。雖然它能協助管理 S3 資料，但它不是一個專門處理「特徵同步」或支持「即時推理端點」的高效能儲存庫。
D	✗ 錯誤	SageMaker Data Wrangler 的「產生資料洞察 (Get Insights)」功能是用於資料分析報告，例如檢查缺失值、偏誤或異常點。它是一個探索

	性資料分析（EDA）工具，而非資料存儲或同步解決方案。
--	-----------------------------

▼ 74

一家醫院使用機器學習模型來驗證X光片結果。該醫院每晚執行一個批量推理任務。醫院需要產生一份關於模型資料品質和模型效能的每日報告。

哪種解決方案能夠滿足這些要求？

- A.在 Amazon SageMaker 模型監控器中排程監控作業。產生模型和數據的監控結果。
- B.建立一個 Amazon CloudWatch 控制面板，其中包含夜間批次推理作業中各個處理步驟的指標。比較基準資源指標。分享控制面板連結。
- C.使用 AWS Glue DataBrew 建立自訂配方作業，該作業使用數值統計資料品質檢查來檢查模型檔案。生成結果。
- D.建立一個包含品質檢查步驟的 SageMaker AI 管線，用於執行監控作業。產生模型和數據的監控結果。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	Amazon SageMaker Model Monitor 不僅支援即時端點，也支援 批量變換作業（Batch Transform Jobs） 。它可以排程監控作業，自動對比基準（Baseline）來檢查資料漂移（Data Quality）與預測準確性（Model Quality），並生成包含統計數據和報告的 S3 檔案，完美符合醫院的需求。
B	✗ 錯誤	CloudWatch 控制面板 顯示的是系統層級的指標（如 CPU 使用率、記憶體、作業成功/失敗率）。它無法直接分析 X 光片數據內容的品質或模型預測的科學準確性（如 F1 分數、精確率等業務指標）。
C	✗ 錯誤	AWS Glue DataBrew 是一個視覺化資料準備工具，主要用於清洗和規範化數據。雖然它可以檢查資料品質，但它不具備監控「模型效能」（即預測結果與實際標籤對比）的原生機制。
D	✗ 錯誤	SageMaker Pipelines 雖然可以建立工作流，但將監控作業作為管線的一個「步驟」來每天執行會使架構過於複雜。Model Monitor 本身就

	具備內建的排程功能，直接使用 Model Monitor 才是運維開銷最小的做法。
--	---

▼ 75

一家公司需要將多個資料來源的資料匯入 Amazon SageMaker Data Wrangler。這些資料來源包括 Amazon S3、Amazon Redshift 和 Snowflake。匯入的資料必須始終與來源系統中的最新變更保持同步。

哪種解決方案能夠滿足這些要求？

- A.使用直接連接將資料從資料來源匯入到 Data Wrangler 中。
- B.使用目錄連接將資料從資料來源匯入到 Data Wrangler 中。
- C.使用 AWS Glue 從資料來源擷取資料。同時使用 AWS Glue 將資料直接匯入 Data Wrangler。
- D.使用 AWS Lambda 從資料來源擷取資料。同時使用 Lambda 將資料直接導入 Data Wrangler。

▼ 答案

A 網站B

選項	是否適合	解析
A	✅ 正確	Data Wrangler 支援多種 直接連線 (Direct Connections) 。它可以直接整合 Amazon S3、Amazon Redshift 以及第三方資料庫 (如 Snowflake)。透過直接連線，Data Wrangler 會在您執行資料串流或匯入時直接從源頭查詢，確保您看到的資料是與來源系統同步的最新狀態。
B	❌ 錯誤	目錄連接 (Catalog Connection) 通常指透過 AWS Glue Data Catalog 進行的連線。雖然它支援 S3 和 Redshift，但它不直接支持對 Snowflake 的原生目錄整合，且這會增加一層元數據管理的複雜度，不如直接連線來得直觀。
C	❌ 錯誤	AWS Glue 雖然可以執行 ETL，但它並不是將資料「匯入」Data Wrangler 的必要媒介。Data Wrangler 具備內建的連接器。手動維護 Glue Job 會增加不必要的開發工作與運維成本。
D	❌ 錯誤	AWS Lambda 適合處理短時間、輕量級的任務。用它來從 Snowflake 或 Redshift 搬運大數

		據集到 Data Wrangler 不僅有執行時間限制（15 分鐘），且架構極其低效。
--	--	---

▼ 76

一位機器學習工程師正在使用 Amazon SageMaker Canvas 從匯入的資料集建立自訂機器學習模型。該工程師希望模型能夠基於 10 年的資料進行連續的數值預測。

該工程師應該使用哪個指標來評估模型的效能？

- A.準確性Accuracy
- B.推理延遲Inference Latency
- C.ROC曲線下面積（AUC）
- D.均方根誤差 (RMSE)

▼ 答案

D

選項	是否適合	解析
A	✗ 錯誤	準確性（Accuracy） 是用於 分類問題 （例如：是或否、貓或狗）的指標。在預測連續數值時，預測值幾乎不可能與實際值完全相等，因此準確性不適用。
B	✗ 錯誤	推理延遲（Inference Latency） 是衡量模型生成預測所需時間的 效能指標 ，而非衡量預測結果精準度的 模型品質指標 。
C	✗ 錯誤	AUC (Area Under the ROC Curve) 專門用於評估 二進位分類器 區分兩個類別的能力。它無法衡量數值預測中「預測值與實際值之間的距離」。
D	✓ 正確	RMSE (Root Mean Square Error) 是迴歸模型中最常用的指標。它計算預測值與實際值之間差異的平方平均值的平方根。RMSE 的單位與預測目標一致，能直觀反映模型預測的平均誤差大小。

▼ 77

一家公司建構、訓練並調優了兩個新的機器學習模型：

- 模型 A 基於 IP 位址、位置和使用者的憑證偵測交易是否有詐欺。每次發生交易時都會呼叫此模型。

- 模型 B 基於歷史銷售資料預測下個月的銷售總額。每月會呼叫此模型一次。

該公司必須使用 Amazon SageMaker AI 將這兩個車型部署到生產環境。

為了滿足這些要求，該公司應該使用哪種模型託管解決方案？

- A.將兩個模型託管在同一個容器中，並使用同一個即時端點。
- B.主機模型 A，具有非同步端點。主機模型 B，具有即時端點。
- C.主機模型 A 配備即時端點。模型 B 使用批次轉換。
- D.對模型 A 使用批次轉換。為模型 B 提供非同步端點。

▼ 答案

C

▼ 78

一家銀行需要使用 Amazon SageMaker AI 建立機器學習模型，以確定哪些客戶符合新產品的購買條件。該銀行必須使用 SageMaker AI 直接支援的演算法。此外，該模型必須能夠向銀行的監管機構解釋。

哪一種建模方法能夠滿足這些要求？

- A.使用 Object2Vec 演算法訓練模型。
- B.使用線性學習演算法訓練模型。
- C.訓練神經網路。
- D.使用 k-means 演算法訓練模型。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	Object2Vec 是一種將高維物件（如單詞、句子、客戶行為序列）轉換為低維向量（Embeddings）的演算法。它通常作為其他任務的預處理步驟，其內部向量表示對監管機構來說難以直觀理解，缺乏可解釋性。
B	✓ 正確	線性學習（Linear Learner） 是 SageMaker 內建的監督式學習演算法，支援分類與迴歸。線性模型（如邏輯迴歸）具有極高的 可解釋性 ，因為每個特徵的權重（Weights）直接代表了該因素對最終決定的貢獻程度（例如：收入每增加一

		萬元，符合資格的機率增加多少)，非常符合銀行監管要求。
C	✗ 錯誤	神經網路 (Neural Networks) 通常被視為「黑盒子」。雖然效能強大，但很難精確解釋內層神經元是如何組合特徵來做出決定的。雖然現在有 SHAP 或 LIME 等技術，但與線性模型相比，它在原生可解釋性上較弱，不適合優先滿足監管需求。
D	✗ 錯誤	k-means 是一種 非監督式學習 的聚類演算法。它用於將客戶分群，而不是用於預測「客戶是否符合特定條件（二進制分類）」。

▼ 79

一家公司正在準備數據，用於在 Amazon SageMaker AI 上訓練一個新的機器學習模型。這些資料之前從未用於機器學習訓練。資料中包含重複項，並且缺少一些值。

該公司需要提高數據品質並檢測數據中是否存在統計偏差。

哪種解決方案能夠滿足這些要求？

- A.使用 SageMaker Clarify 建立資料品質規則。使用 SageMaker Model Monitor 偵測偏差。
- B.使用 SageMaker Data Wrangler 建立資料品質規則。使用 SageMaker Clarify 檢測偏差。
- C.使用 SageMaker Debugger 建立資料品質規則。使用 SageMaker Model Monitor 偵測偏差。
- D.使用 SageMaker Model Monitor 建立資料品質規則。使用 SageMaker Clarify 檢測偏差。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	SageMaker Clarify 確實可以檢測偏差，但它不是用來「建立資料品質規則（如處理重複項、缺失值）」的工具。 Model Monitor 則是用於監控生產環境中的模型，而非訓練前的資料準備。
B	✓ 正確	SageMaker Data Wrangler 專為資料準備設計，能輕鬆處理重複項、缺失值，並內建資料品質見解。而 SageMaker Clarify 整合在 Data

		Wrangler 中，可以在訓練模型前偵測資料集是否存在 統計偏差 (Statistical Bias) ，確保訓練資料的公平性。
C	✗ 錯誤	SageMaker Debugger 主要用於監控訓練過程中的效能（如梯度消失或硬體瓶頸），不具備處理重複項或缺失值的功能。
D	✗ 錯誤	Model Monitor 必須在模型部署到端點後才能發揮作用，無法在「準備數據」階段建立品質規則。此選項混淆了離線準備與在線監控的工具。

▼ 80

一位機器學習工程師正在建立一個預測房屋和公寓價格的模型。模型使用三個特徵：面積（平方公尺）、價格和房齡。資料集包含 10,000 條資料。數據中包含一棟大型豪宅和一套極小公寓的數據點。

這位機器學習工程師必須對資料集進行預處理，以確保模型能夠準確預測典型房屋或公寓的價格。

哪種解決方案能夠滿足這些要求？

- A. 移除異常值，並對平方公尺變數進行對數轉換。
- B. 保留異常值並對平方米變數進行歸一化。
- C. 刪除異常值並對平方米變數執行獨熱編碼。
- D. 保留異常值，並對平方米變數進行獨熱編碼。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	移除異常值 ：豪宅和極小公寓在 10,000 條資料中屬於離群值，會拉偏模型的預測（尤其是線性模型）。 對數轉換 (Log Transformation) ：面積（平方公尺）通常呈現長尾分佈（偏態分佈），透過對數轉換可以使其更接近常態分佈，縮小極端數值的影響，讓模型更容易學習。
B	✗ 錯誤	保留異常值 會讓模型為了擬合那幾間極端的房子而犧牲對普通房屋的準確度。 歸一化 (Normalization) 雖有助於梯度下降，但它對異常值非常敏感（因為極值會改變縮放比例）。

C	✗ 錯誤	獨熱編碼 (One-Hot Encoding) 是用於「類別型數據」的。面積是「連續數值」，如果對其進行獨熱編碼，會產生過多特徵（維度災難），且模型會失去面積大小的順序關係。
D	✗ 錯誤	同時犯了保留異常值（導致偏差）與對數值特徵錯誤使用獨熱編碼（導致維度災難與資訊流失）的錯誤。

▼ 81

一家公司正在使用 Amazon SageMaker AI 開發機器學習模型。該公司必須監控模型中的偏差，並將結果顯示在儀表板上。一位機器學習工程師創建了一個偏差監控作業。

這位機器學習工程師應該如何取得偏差指標以顯示在儀表板上？

- A.從 SageMaker Clarify 擷取 AWS CloudTrail 指標。
- B.從 SageMaker Clarify 捕捉 Amazon CloudWatch 指標。
- C.從 Amazon EventBridge 捕捉 SageMaker 模型監視器指標。
- D.從 Amazon Simple Notification Service (Amazon SNS) 擷取 SageMaker 模型監視器指標。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	AWS CloudTrail 用於記錄帳戶內的 API 活動（例如：誰在什麼時候啟動了 Clarify 作業）。它記錄的是操作稽核紀錄，而不是 Clarify 作業計算出來的「偏差數值指標」。
B	✓ 正確	當 SageMaker Clarify 作為模型監控器的一部分運行時，它會自動將計算出的偏差指標（如端點的預測偏誤）發送到 Amazon CloudWatch 。CloudWatch 是建立儀表板（Dashboard）的原生工具，工程師可以直接從中提取指標進行視覺化。
C	✗ 錯誤	Amazon EventBridge 用於根據事件觸發動作（例如：監控作業失敗時觸發 Lambda）。它主要負責「事件路由」，而非儲存或提供用於繪製儀表板的連續性偏差指標。

D	✗ 錯誤	Amazon SNS 是一個通知服務。它可以用於在偏差超過閾值時發送簡訊或電子郵件給工程師，但它無法提供資料供儀表板顯示圖表。
---	------	--

▼ 82

一家公司正在使用 Amazon SageMaker AI 機器學習模型來預測路面坑洞引起的交通事故。一位機器學習工程師已將 SageMaker 模型監控器配置為 SageMaker AI 管線的一部分。在 MonitoringExecution 輸出中，該機器學習工程師觀察到多個 baseline_drift_check 違規，導致管線運作失敗。

該機器學習工程師應該如何解決此問題？

- A.使用新的 SageMaker AI 訓練作業重新訓練模型。使用 SageMaker 偵錯器檢查錯誤。
- B.使用新的訓練資料重新訓練模型。在模型監控器中重複使用原始基線。
- C.使用新的訓練資料重新訓練模型。在模型監控器中使用新的基線資料。
- D.在基準約束檔中啟用 emit_metrics 選項後，重新執行 SageMaker AI 管道。

▼ 答案

C

選項	是否適合	解析
A	✗ 錯誤	SageMaker Debugger 主要用於監控訓練過程中的參數（如梯度、張量）或硬體利用率，無法解決生產環境中已經發生的「資料分佈漂移」問題。
B	✗ 錯誤	既然資料已經發生了漂移（與原始基準不同），如果繼續 重複使用原始基線 ，新的模型即便訓練好了，監控作業仍會因為新資料與舊基線不符而持續觸發違規報警。
C	✓ 正確	當偵測到基準漂移時，代表現實世界的資料分佈已改變（例如路面狀況隨季節變化）。標準做法是收集包含最新特徵分佈的 新資料重新訓練模型 ，並根據這批新資料生成新的 基準（New Baseline） 。這樣監控作業才能在新分佈的基礎上正常運行。
D	✗ 錯誤	<code>emit_metrics</code> 只是控制是否將指標發送到 CloudWatch，並不能解決底層的資料漂移問題。

		題，重新執行管線若不更動資料或基準，依然會因為違規而失敗。
--	--	-------------------------------

▼ 83

一家公司使用機器學習模型來預測交易是否為詐欺交易。該公司需要盡可能識別詐欺交易。

為了滿足這項要求，該公司應該使用哪種評估指標來評估模型？

- A.F1 分數
- B. Area Under the ROC Curve
ROC曲線下面積 (AUC)
- C.Precision
精度
- D. Recall
回憶

▼ 答案

D

選項	是否適合	解析
A	✗ 錯誤	F1 分數 是精準度 (Precision) 與召回率 (Recall) 的調和平均值。它適合用於類別不平衡但需要兼顧「誤報」與「漏報」的平衡場景。本題明確要求「盡可能識別」，側重點在於 Recall 而非平衡。
B	✗ 錯誤	AUC (ROC 曲線下面積) 衡量的是模型在所有可能的分類閾值下，區分正負樣本的整體能力。雖然是一個重要的性能指標，但它無法直接針對「極力避免漏掉詐欺」這一特定目標進行優化。
C	✗ 錯誤	精準度 (Precision) 關注的是「預測為詐欺的交易中，有多少真的是詐欺」。追求高精準度會讓模型變得很保守，只抓最有把握的，這會導致許多真正的詐欺交易漏網，不符合題目要求。
D	✓ 正確	召回率 (Recall / 回憶率) 衡量的是「在所有真正的詐欺交易中，模型成功抓到了多少」。 高召回率代表漏網之魚 (偽陰性) 最少 。在詐欺偵測中，漏掉一筆大額詐欺的代價通常遠高於誤報一筆正常交易，因此 Recall 是首選指標。

▼ 84

建議模型使用機器學習 (ML) 技術，並呼叫 Amazon SageMaker AI 端點來取得建議結果。機器學習工程師必須確保模型在預期用戶流量激增期間保持可用。

哪種解決方案能夠滿足這些要求？

- A.在 SageMaker AI 端點上設定自動擴充。
- B.建立一個新的 SageMaker AI 端點。將模型部署到新端點。
- C.使用 SageMaker Neo 最佳化推理模型。
- D.將自動擴充組附加到 SageMaker AI 端點。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	SageMaker 自動擴充 (Auto Scaling) 專為處理波動流量設計。它會根據您定義的指標 (如 <code>SageMakerVariantInvocationsPerInstance</code>) 自動增加或減少執行個體 (Instances) 的數量。當預期流量激增時，它能確保有足夠的資源處理請求，保持模型可用。
B	✗ 錯誤	僅僅建立一個新的端點並部署模型，並不能解決「流量激增」的問題。如果新端點的資源仍是固定的，當流量超過其承載能力時，服務依然會崩潰或產生延遲。
C	✗ 錯誤	SageMaker Neo 用於優化模型以在特定硬體 (如邊緣設備) 上更快速地運行 (減少模型大小並提高推論速度)。雖然這能提高單次推論效率，但它不是直接處理「用戶流量激增」的彈性擴充機制。
D	✗ 錯誤	在 AWS 術語中，「自動擴充組 (Auto Scaling Group, ASG)」通常是指 EC2 服務的概念。雖然 SageMaker 底層也使用擴充技術，但正確的官方功能名稱與操作方式是直接在端點上 配置 Application Auto Scaling ，而非手動附加一個 ASG。

▼ 85

熱點題

一家醫院希望預測來年的病人預後。一位機器學習工程師需要改進幾個目前表現不佳的現有機器學習模型。

請從以下清單中選擇正確的正規化方法來改進每個模型。每種正則化方法可以選擇一次、多次或不使用。（選擇三種。）

- L1 正規化
- L2 正規化
- 提前停止

A linear regression model whose coefficients should shrink but not become zero:

▼

L1 regularization
L2 regularization
Early stopping

A polynomial regression model with irrelevant polynomial terms that should be eliminated:

▼

L1 regularization
L2 regularization
Early stopping

A logistic regression model that has highly correlated features to eliminate highly redundant predictors:

▼

L1 regularization
L2 regularization
Early stopping

▼ 答案

正確答案：

A linear regression model whose coefficients should shrink but not become zero:

▼

L1 regularization
L2 regularization
Early stopping

A polynomial regression model with irrelevant polynomial terms that should be eliminated:

▼

L1 regularization
L2 regularization
Early stopping

A logistic regression model that has highly correlated features to eliminate highly redundant predictors:

▼

L1 regularization
L2 regularization
Early stopping

1. 係數應縮小但「不變為零」的線性回歸模型

- 最佳答案：L2 regularization (Ridge Regression)
- 解析：
 - L2 正規化是在損失函數中加入權重平方和的懲罰項。

- 它的特點是會均勻地將所有係數向零縮減 (shrink)，但通常**不會將係數完全變為零**。
- 它適合用於保留所有特徵但限制其影響力的場景，能有效防止過擬合並處理多重共線性。

2. 具有應「被消除」的不相關多項式項的多項式回歸模型

- **最佳答案：L1 regularization (Lasso Regression)**
- **解析：**
 - **L1 正規化**是在損失函數中加入權重絕對值的懲罰項。
 - 它的數學特性（在零點不可微）會產生**稀疏解 (Sparsity)**，傾向於將不重要或不相關特徵的係數**直接壓縮至零**。
 - 因此，它具有**特徵選擇**的功能，能自動「消除」題目中提到的不相關項。

3. 具有高度相關特徵以「消除高度冗餘預測變量」的邏輯回歸模型

- **最佳答案：L1 regularization (Lasso Regression)**
- **解析：**
 - 當模型中存在高度冗餘（高度相關）的預測變量時，我們需要一種機制來從中選擇一個並剔除其他的。
 - 如前所述，**L1 正規化**能夠將冗餘特徵的係數變為零，從而達到「消除冗餘」的目的。
 - 雖然在某些極端共線性下 L2 也能穩定模型，但若明確要求「消除 (Eliminate)」，則非 L1 莫屬。

▼ 86

一位機器學習工程師使用 Amazon SageMaker AI 訓練了一個機器學習模型。該工程師發現模型過度擬合，並且訓練資料中包含不必要的特徵。該工程師必須減少過擬合和不必要的特徵的影響。

哪種解決方案能夠滿足這些要求？

- A. 增加訓練迭代次數。重新訓練模型。
- B. 對訓練資料應用 L1 正規化。重新訓練模型。
- C. 減少訓練迭代次數，重新訓練模型。

- D.使用 SageMaker Debugger 對運行中的模型套用 L1 正規化。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	增加迭代次數 (Epochs) 通常會讓模型有更多機會去「死記硬背」訓練數據中的噪聲，這往往會 加劇過擬合 ，而不是減少它。
B	✓ 正確	L1 正規化 (Lasso) 在損失函數中加入權重絕對值的懲罰項。它具有 **稀疏性 (Sparsity) ** 的特性，能將不重要或不必要特徵的權重直接壓縮至 0 。這不僅能簡化模型 (減少特徵影響)，還能有效抑制過擬合。
C	✗ 錯誤	雖然減少迭代次數 (類似早停法 Early Stopping) 可以減輕過擬合，但它 無法主動識別並消除不必要的特徵 。L1 正規化在處理特徵冗餘方面更為直接有效。
D	✗ 錯誤	SageMaker Debugger 用於監控、分析和警告訓練過程中的異常 (如梯度消失)，但它無法直接對「運行中的模型」動態套用正規化邏輯。正規化必須在模型定義與訓練程式碼中設定。

▼ 87

一位機器學習工程師希望使用 Amazon SageMaker Data Wrangler 對資料集進行預處理。該工程師希望使用預處理後的資料集來訓練分類模型。在預處理過程中，該工程師注意到一個文字特徵包含數千個值，**這些值之間的差異僅在於拼字錯誤**。該工程師需要應用一種編碼方法，以便在預處理完成後，可以使用該文字特徵來訓練模型。

哪種解決方案能夠滿足這些要求？

- A.對特徵進行序數編碼以表示其類別。
- B.對特徵進行相似性編碼以表示其類別。
- C.對特徵進行獨熱編碼以表示其類別。
- D.執行目標編碼以表示特徵的類別。

▼ 答案

B

選項	是否適合	解析
----	------	----

A	✗ 錯誤	序數編碼 (Ordinal Encoding) 會將每個字串分配一個整數。由於拼寫錯誤會產生「數千個」不同的類別，這會讓模型誤以為這些錯誤拼寫之間存在某種數值順序。此外，它無法捕捉拼寫相近單詞之間的語義聯繫。
B	✓ 正確	相似性編碼 (Similarity Encoding) 專門用於處理包含拼寫差異或高基數的文字類別。它透過計算字串之間的相似度（例如 3-gram 相似度）來將其轉換為向量。這樣即使單詞拼寫有微小錯誤（如 "Apple" 與 "Aple"），它們在編碼後的特徵空間也會非常接近，非常適合這種場景。
C	✗ 錯誤	獨熱編碼 (One-Hot Encoding) 會為每個唯一值創建一個新維度。對於「數千個值」且包含拼寫錯誤的資料，這會導致 維度爆炸 ，產生一個極其稀疏的矩陣，且模型完全無法學習到 "Aple" 其實就是 "Apple" 的資訊。
D	✗ 錯誤	目標編碼 (Target Encoding) 使用目標變數的平均值來取代類別。雖然它能處理高基數，但對於包含大量拼寫錯誤（即許多類別只有極少數樣本）的情況，會導致嚴重的 過擬合 ，且同樣無法處理拼寫相似性的問題。

▼ 88

一位機器學習工程師正在 Amazon SageMaker AI 上訓練一個文字生成模型。經過幾個 epoch 後，損失函數沒有收斂，模型在驗證資料集上的準確率開始出現波動。

這位機器學習工程師需要確保模型具有泛化能力。

哪種解決方案能夠滿足這項要求？

- A. 提高學習率並減少小批量大小。
- B. 隨著訓練輪數的增加，提高學習率。
- C. 降低學習率並增加小批量大小。
- D. 降低學習率並減少小批量大小。

▼ 答案

C

選項	是否適合	解析
A	✗ 錯誤	提高學習率 會使模型在損失函數的表面「跳躍」得更厲害，導致更嚴重的波動甚至發散。 **減少

		小批量 (Batch Size) **會增加梯度的噪聲，讓訓練變得更不穩定。
B	✗ 錯誤	這是非常少見的做法。通常隨著訓練進行，我們需要的是「衰減」學習率 (Learning Rate Decay)，以便讓模型在接近局部最小值時能穩定下來。提高學習率只會讓已經在波動的模型完全失控。
C	✓ 正確	降低學習率可以讓權重更新更精細，避免在最小值附近跳過，減少準確率的波動。**增加小批量大小 (Mini-batch Size) **能提供更穩定的梯度估計 (噪聲較小)，有助於模型平滑地收斂到更好的泛化解。
D	✗ 錯誤	雖然降低學習率是正確的，但減少小批量大小會引入更多隨機性。在模型已經出現波動的情況下，增加批量大小通常是比減少它更穩妥的穩定方法。

▼ 89

一家公司使用基於 NFS 的資料儲存來儲存機器學習訓練資料。Linux 系統會存取該資料儲存。

該公司需要一個混合系統，使本地伺服器和使用資料的 Amazon SageMaker AI 筆記本都能存取共享的資料儲存。數據生產者需要文件鎖定。

哪種 AWS 儲存解決方案能夠滿足這些要求？

- A.使用 Amazon S3 儲存桶儲存資料。使用 Mountpoint for Amazon S3 將 S3 儲存桶掛載到本機伺服器和 SageMaker AI 筆記本。
- B.使用 Amazon Elastic File System (Amazon EFS) 檔案系統儲存資料。將檔案系統掛載到本機伺服器和 SageMaker AI 筆記本。
- C.使用 Amazon FSx for Lustre 檔案系統儲存資料。將該檔案系統掛載到本機伺服器和 SageMaker AI 筆記本。
- D.使用 Amazon Elastic Block Store (Amazon EBS) 磁碟區來儲存資料。將該卷掛載到本機伺服器和 SageMaker AI 筆記本。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	Amazon S3 是物件儲存，而非檔案系統。雖然 Mountpoint for Amazon S3 可將儲存桶掛載為

		檔案系統，但它明確 不支援檔案鎖定 與 POSIX 權限。
B	✓ 正確	Amazon EFS 是一個完全受管且可彈性擴充的 NFS (NFSv4/v4.1) 檔案系統。它支援 POSIX 語義（包括檔案鎖定） ，且可透過 VPN 或 Direct Connect 讓本機伺服器掛載，同時能原生掛載到 VPC 中的 SageMaker 筆記本實例。
C	✗ 錯誤	Amazon FSx for Lustre 主要用於高效能運算 (HPC)。雖然它也支援檔案鎖定與 S3 整合，但對於一般基於 NFS 的混合雲共享需求，EFS 是更標準且簡單的解決方案，且 NFS 是本題資料儲存的基礎前提。
D	✗ 錯誤	Amazon EBS 是區塊儲存，其 Multi-Attach 功能僅限於「相同可用區域 (AZ)」內的特定執行個體，且 不支援透過 NFS 協定從遠端本機伺服器直接掛載 。

▼ 90

一家公司需要分析儲存在 Amazon S3 中的大型資料集，該資料集採用 Apache Parquet 格式。該公司希望對部分欄位使用獨熱編碼。

該公司需要一個無需編寫程式碼的解決方案來轉換資料。此解決方案必須將轉換後的資料儲存回同一個 S3 儲存桶，以便進行模型訓練。

哪個解決方案能夠滿足這些要求？

- A.配置一個連接到資料的 AWS Glue DataBrew 專案。使用 DataBrew 互動式介面建立執行獨熱編碼轉換的配方。建立一個作業來套用此轉換並將輸出寫回 S3 儲存桶。
- B.配置指向資料的 AWS Glue 資料目錄表。使用 Amazon Athena 編寫 SQL 指令來執行獨熱編碼轉換。配置 Athena 將查詢結果寫回 S3 儲存桶。
- C.配置指向資料的 AWS Glue 資料目錄表。建立 AWS Glue ETL 互動筆記本。使用該筆記本執行獨熱編碼轉換。運行已配置的儲存格並將結果寫回 S3 儲存桶。
- D.配置 Amazon Redshift 集群，以便使用 Redshift Spectrum 存取資料。使用 SQL 指令在 Amazon Redshift 中執行獨熱編碼轉換。配置 Amazon Redshift 將結果寫回 S3 儲存桶。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	AWS Glue DataBrew 是一個視覺化的資料準備工具，專為無需編寫程式碼的需求而設計。它提供超過 250 種內建轉換，包括「獨熱編碼」。您可以透過互動式 UI 建立「配方 (Recipe)」，並啟動作業 (Job) 將結果以 Parquet 格式寫回 S3，完全符合所有要求。
B	✗ 錯誤	Amazon Athena 需要編寫 SQL 指令 。雖然 SQL 廣為人知，但它不符合題目「無需編寫程式碼」的嚴格限制，且在 SQL 中手動實作獨熱編碼（通常需要大量的 CASE WHEN 語句）非常繁瑣。
C	✗ 錯誤	AWS Glue ETL 互動筆記本 要求工程師編寫 Python (PySpark) 或 Scala 程式碼。這是一個開發者導向的工具，不屬於無程式碼解決方案。
D	✗ 錯誤	Amazon Redshift Spectrum 同樣需要編寫 SQL 。此外，為了分析 S3 資料而配置整個 Redshift 集群對於這個特定任務來說過於複雜且成本較高，且依然不符合無程式碼的條件。

▼ 91

一家公司希望將基於 PyTorch 演算法的機器學習模型從本地環境遷移到 Amazon SageMaker AI。該公司需要在 AWS 上盡可能地重複使用其現有的自訂腳本。

為了滿足這些要求，該公司應該使用 SageMaker AI 的哪個功能？

- A.SageMaker AI 內建演算法
- B.SageMaker 畫布
- C.SageMaker JumpStart
- D.SageMaker AI 腳本模式

▼ 答案

D

選項	是否適合	解析
A	✗ 錯誤	內建演算法 (Built-in Algorithms) 是 AWS 預先打包好的優化演算法（如 XGBoost, Linear Learner）。雖然效能很好，但它們通常是「黑

		盒子」，使用者無法將自己的自訂 PyTorch 腳本直接注入其中，不符合「重複使用現有腳本」的要求。
B	✗ 錯誤	SageMaker Canvas 是一個無程式碼（No-code）介面，主要針對商業分析師。它不需要編寫或導入腳本，與工程師想要遷移並運行自訂 PyTorch 程式碼的需求背道而馳。
C	✗ 錯誤	SageMaker JumpStart 提供預訓練模型和解決方案範本（如 Llama 3, BERT）。雖然它支援自訂，但它的主要目的是快速部署現成模型，而不是為了遷移和運行使用者在本地開發的自訂 PyTorch 訓練流程。
D	✓ 正確	腳本模式（Script Mode） 專為此場景設計。它允許您使用 SageMaker 提供的 PyTorch 容器，並只需將您原本在本地運行的 <code>train.py</code> 腳本傳遞給容器即可。SageMaker 會負責建立基礎設施，並執行您的自訂邏輯，是遷移自訂演算法的最快且最靈活的方式。

▼ 92

一家公司使用亞馬遜 QuickSight 控制面板來追蹤運動鞋的銷售價格隨時間的變化。此控制面板匯總了從多個零售網站抓取的銷售價格。該公司希望確定哪些價格異常高，並以視覺化的方式顯示這些異常值。

哪種解決方案能夠滿足這些要求？

- A.使用垂直長條圖視覺化異常值。在 QuickSight 中使用計算字段，對異常值價格取平方根以產生圖表。配置自訂 AWS Lambda 函數來掃描資料中的異常。
- B.使用 AWS Glue DataBrew 預處理資料。設定 REMOVE_OUTLIERS 操作以刪除包含異常高價格的資料行。呼叫 AWS Lambda 函數將刪除的資料列儲存到 Amazon DynamoDB 中。
- C.使用垂直長條圖視覺化異常值。使用 QuickSight 中的計算欄位對異常價格進行平方運算以產生圖表。利用 QuickSight 的異常檢測功能來確定哪些價格異常高。
- D.使用 QuickSight 篩選器找出運動鞋價格最低的 10 個值。為這 10 個最低值指派特定的顏色。

▼ 答案

C

選項	是否適合	解析
A	✗ 錯誤	使用 Lambda 來掃描異常會增加系統複雜度與運維成本。此外，「取平方根」並非識別異常值的標準統計方法。QuickSight 已內建 ML 功能，不需要外接自訂函數。
B	✗ 錯誤	題目的需求是「視覺化顯示異常值」，而 REMOVE_OUTLIERS 會直接刪除這些資料，這與監控並識別異常的目標相悖。
C	✓ 正確	Amazon QuickSight 異常檢測 是一項內建的 ML 功能，能自動分析數百萬個指標並找出異常值。將異常價格進行數學轉換（如平方）有助於在圖表中拉大異常值與正常值的視覺差距，使其在垂直長條圖中更明顯。
D	✗ 錯誤	題目要求的是尋找「異常高」的價格，篩選「最低的 10 個值」顯然方向錯誤。此外，前 10 名並不等於統計意義上的「異常」。

▼ 93

一位機器學習工程師正在使用 Amazon QuickSight 異常檢測功能來偵測機器運作溫度是否過高或過低（與正常值相比）。該工程師將「嚴重性」參數設為「低及以上」，並將「方向」參數設為「全部」。

如果該工程師將「方向」參數更改為「低於預期」，則異常檢測結果會受到什麼影響？

- A. 異常識別頻率和召回率均提高
- B. 異常辨識頻率和回憶率下降
- C. 異常識別頻率增加，召回率降低
- D. 異常辨識頻率降低，回憶率提高

▼ 答案

B

為什麼選擇 B？

- **頻率（Frequency）下降**：原本系統會抓出「太熱」和「太冷」兩類異常，現在只抓「太冷」，因此識別出的異常數量（頻率）必然會減少。
- **召回率（Recall / 回憶率）下降**：召回率衡量的是模型抓到「所有真正異常」的能力。題目背景是工程師需要監控溫度過高或過低。當參數改為

「低於預期」時，系統會漏掉 (Miss) 所有溫度過高的真實異常點。在評估整體異常 (高 + 低) 的目標下，漏報增加導致召回率下降。

▼ 94

一家公司在本地 Kubernetes 叢集上運行其機器學習工作流程。這些工作流程包含用於訓練和推理機器學習模型的機器學習服務。每個機器學習服務都運行在各自獨立的 Docker 映像中。

該公司需要將工作流程從本地 Kubernetes 叢集遷移到 Amazon Elastic Kubernetes Service (Amazon EKS) 叢集。

哪一種解決方案能夠以最小的運維開銷滿足此要求？

- A.重新設計要在 Kubeflow 中設定的機器學習服務。將新的 Kubeflow 管理的機器學習服務部署到 EKS 叢集。
- B.將 Docker 映像上傳到 Amazon Elastic Container Registry (Amazon ECR) 儲存庫。配置部署管道，將鏡像部署到 EKS 叢集。
- C.將訓練資料移轉到 Amazon Redshift 叢集。使用 Amazon Redshift ML 從遷移後的訓練資料重新訓練模型。將重新訓練的模型部署到 EKS 叢集。
- D.配置 Amazon SageMaker AI 筆記本。使用相同的程式碼重新訓練模型。將重新訓練的模型部署到 EKS 叢集。

▼ 答案

B

選項	是否適合	解析
A	✗ 錯誤	Kubeflow 雖然是 Kubernetes 上強大的機器學習平台，但「重新設計 (Redesign)」現有的服務以適應 Kubeflow 的架構會帶來巨大的開發與運維成本。這不符合「最小開銷」的要求。
B	✓ 正確	因為該公司的服務已經封裝在 Docker 映像 中，遷移到 EKS 的最快路徑就是利用鏡像的移植性。只需將鏡像推送到 Amazon ECR (AWS 的受管容器註冊表)，然後更新 Kubernetes 的部署清單 (YAML) 將其部署到 EKS 即可。這幾乎不需要更改代碼，運維開銷最小。
C	✗ 錯誤	Amazon Redshift ML 是為了讓 SQL 開發人員能直接在資料庫內建置模型。將資料遷移到 Redshift 並重新訓練模型是一個完全不同的技術路徑，對於已經擁有成熟 Docker 工作流的公司來說，這增加了極大的複雜度。

D	 錯誤	SageMaker 筆記本 主要用於開發。重新訓練模型並手動部署到 EKS 會中斷原本自動化的容器化流程，且「重新訓練」在單純的基礎設施遷移場景中通常是不必要的額外負擔。
---	--	--

▼ 95

一位機器學習工程師每月需要執行耗時 48 至 72 小時的密集模型訓練任務。這些訓練任務可以中斷和恢復，不會有重大問題。該工程師的預算有限，需要優化計算資源。

哪一種解決方案能夠以最具成本效益的方式滿足這些要求？

- A.透過部分預付款購買預留實例。
- B.按需購買實例，無需任何承諾。
- C.購買亞馬遜 SageMaker AI 儲蓄計劃。
- D.購買使用自動檢查點的競價實例。

▼ 答案

D

選項	是否適合	解析
A	 錯誤	預留實例 (Reserved Instances) 適合一年或三年以上的長期穩定負載。雖然比按需實例便宜，但對於每月僅執行幾天的任務來說，大部分時間資源會閒置，這在預算有限的情況下並非最優選。
B	 錯誤	按需實例 (On-Demand Instances) 最靈活，但價格也最昂貴，完全不符合「優化預算」和「最具成本效益」的要求。
C	 錯誤	SageMaker 儲蓄計劃 (Savings Plans) 透過承諾每小時的最低消費來換取折扣（高達 64%）。雖然適合多樣化的模型訓練，但仍需要長期承諾，且折扣幅度通常不如競價實例。
D	 正確	競價實例 (Spot Instances) 提供高達 70% 到 90% 的折扣，是 AWS 中最便宜的計算資源。雖然競價實例可能會被 AWS 收回，但題目提到訓練任務「可以中斷和恢復」。透過結合 自動檢查點 (Checkpoints) ，模型可以在中斷時

保存進度，並在資源重新可用時從中斷點繼續，完美契合需求。

▼ 96

熱門問題

一位機器學習工程師需要使用 Amazon SageMaker 超參數調優來縮短機器學習模型的訓練時間。

請從以下清單中選擇並按順序執行正確的步驟以滿足此要求。每個步驟只能選擇一次或完全不選擇。(選擇並排序三個步驟。)

- 選擇貝葉斯最佳化並增加參數數量。
- 選擇超參數調優並減少參數數量。
- 選擇隨機搜尋並使用隨機種子 -1。
- 將模型部署到 SageMaker 端點。
- 評估訓練時間的變化。
- 重新訓練模型。

Step 1:	▼ Choose Bayesian optimization and increase the number of parameters. Choose Hyperband tuning and decrease the number of parameters. Choose random search and use a random seed of -1. Deploy the model to a SageMaker endpoint. Evaluate the change in training time. Retrain the model.
Step 2:	▼ Choose Bayesian optimization and increase the number of parameters. Choose Hyperband tuning and decrease the number of parameters. Choose random search and use a random seed of -1. Deploy the model to a SageMaker endpoint. Evaluate the change in training time. Retrain the model.
Step 3:	▼ Choose Bayesian optimization and increase the number of parameters. Choose Hyperband tuning and decrease the number of parameters. Choose random search and use a random seed of -1. Deploy the model to a SageMaker endpoint. Evaluate the change in training time. Retrain the model.

▼ 答案

正確答案：

Step 1:	▼ Choose Bayesian optimization and increase the number of parameters. Choose Hyperband tuning and decrease the number of parameters. Choose random search and use a random seed of -1. Deploy the model to a SageMaker endpoint. Evaluate the change in training time. Retrain the model.
Step 2:	▼ Choose Bayesian optimization and increase the number of parameters. Choose Hyperband tuning and decrease the number of parameters. Choose random search and use a random seed of -1. Deploy the model to a SageMaker endpoint. Evaluate the change in training time. Retrain the model.
Step 3:	▼ Choose Bayesian optimization and increase the number of parameters. Choose Hyperband tuning and decrease the number of parameters. Choose random search and use a random seed of -1. Deploy the model to a SageMaker endpoint. Evaluate the change in training time. Retrain the model.

Step 1：選擇 Hyperband 並減少參數數量

- **為什麼選擇 Hyperband？** Hyperband 是一種基於強化的多臂老虎機（Multi-Armed Bandit）策略。它透過對多個超參數組合進行短時間的預訓練，並**快速停止（Early Stopping）**表現不佳的組合，將資源集中在有潛力的組合上。這比傳統的貝葉斯優化或隨機搜尋能更顯著地減少總訓練時間。
- **為什麼減少參數數量？** 調優的超參數越多，搜尋空間就越大，找到最優解所需的時間就越長。減少不必要的參數數量可以讓調優作業更快完成。

Step 2：重新訓練模型

- 在配置好調優策略（Hyperband）與精簡後的參數範圍後，啟動 SageMaker 超參數調優作業。此步驟會執行多個訓練任務（Training Jobs）來尋找最佳組合。

Step 3：評估訓練時間的變化

- 完成調優後，比較使用 Hyperband 前後的平均訓練時間與模型效能。確保在滿足效能標準的前提下，確實達到了縮短時間的目標。

▼ 97

熱門問題

一家公司開發了一個機器學習模型來對產品進行分類。該模型使用文字資料和視覺資料將產品分類到一個層級分類體系中。機器學習工程師必須使用特定的策略來提高模型的準確率並處理類別不平衡問題。

請從以下清單中為每個用例選擇正確的策略。每種策略選擇一次。(選擇五個。)

- 分類交叉熵
- 回退指標
- 層級損失
- 通用過採樣
- 文本合成少數類過採樣技術 (SMOTE)

Evaluate predictions with tolerance for broader category matches.

▼

Categorical cross-entropy

Fallback metric

Hierarchical loss

General oversampling

Synthetic Minority Oversampling Technique (SMOTE) for text

Balance the training data by increasing the presence of minority categories.

▼

Categorical cross-entropy

Fallback metric

Hierarchical loss

General oversampling

Synthetic Minority Oversampling Technique (SMOTE) for text

Enhance the model's ability to recognize nested structures within product categories.

▼

Categorical cross-entropy

Fallback metric

Hierarchical loss

General oversampling

Synthetic Minority Oversampling Technique (SMOTE) for text

Enhance textual data representation for underrepresented categories.

▼

Categorical cross-entropy

Fallback metric

Hierarchical loss

General oversampling

Synthetic Minority Oversampling Technique (SMOTE) for text

▼ 答案

正確答案：

Evaluate predictions with tolerance for broader category matches.	▼ - Categorical cross-entropy Fallback metric - Hierarchical loss - General oversampling - Synthetic Minority Oversampling Technique (SMOTE) for text
Balance the training data by increasing the presence of minority categories.	▼ - Categorical cross-entropy - Fallback metric - Hierarchical loss General oversampling - Synthetic Minority Oversampling Technique (SMOTE) for text
Enhance the model's ability to recognize nested structures within product categories.	▼ - Categorical cross-entropy - Fallback metric Hierarchical loss - General oversampling - Synthetic Minority Oversampling Technique (SMOTE) for text
Enhance textual data representation for underrepresented categories.	▼ - Categorical cross-entropy - Fallback metric - Hierarchical loss - General oversampling Synthetic Minority Oversampling Technique (SMOTE) for text

需求場景	推薦策略	解析
評估預測結果時對更廣泛類別匹配的容忍度 (Evaluate predictions with tolerance for broader category matches)	回退指標 (Fallback metric)	當模型無法精準預測到最細層級（如「慢跑鞋」）時，如果能正確預測到上一層級（如「運動鞋」），則給予部分分數。這就是回退指標的作用。
透過增加少數類別的存在來平衡訓練資料 (Balance the training data by increasing the presence of minority categories)	通用過採樣 (General oversampling)	這是處理類別不平衡最基礎的方法。透過簡單複製少數類別的樣本，讓模型有更多機會學習這些稀有類別。
增強模型識別產品類別中「嵌套結構」的能力 (Enhance the model's ability to recognize nested structures)	層級損失 (Hierarchical loss)	層級損失函數會考慮類別之間的「父子關係」。例如，將「蘋果」誤分類為「梨子」（同屬水果）的懲罰，會比誤分類為「筆記本」輕，從而引導模型理解分類結構。
增強代表性不足類別的「文字數據」表示 (Enhance textual data representation for underrepresented categories)	文本合成少數類過採樣技術 (SMOTE for text)	SMOTE 原理是在特徵空間中插值產生新樣本。針對文字數據，這可以合成新的向量表示，增加模型對於少數文字類別的泛化能力。

▼ 98

一家零售公司正在開發一款人工智慧客服助理。該公司擁有大量文檔，客服助理需要利用這些文檔來處理一般性諮詢。該公司希望所有關於價格的回應都只使用一個月以內的文件。

哪種解決方案能夠滿足這些要求？

- A.使用 Amazon Q Business 產生回覆。配置文件屬性篩選器，使有關價格的回應僅使用上個月的文件。
- B.使用 Amazon Q Business 產生回應。配置來源歸屬引用，使有關價格的回應僅使用上個月的文件。
- C.依照文件建立月份將文件分門別類地放入不同的資料夾。配置 Amazon Q Developer，使其僅使用上個月的文件來產生有關價格的回應。
- D.依照文件建立月份將文件分門別類地放入不同的資料夾。僅允許助手存取上個月的文檔，以便提供價格相關的回應。使用 Amazon Q Developer 開發回覆功能。

▼ 答案

A

選項	是否適合	解析
A	✓ 正確	Amazon Q Business 專為企業文件查詢設計。透過 文件屬性篩選器 (Document Attribute Filters) ，你可以針對特定的元數據（如文件日期）設定過濾規則。這允許系統在處理價格諮詢時，自動篩選出最近一個月內的文件作為參考來源。
B	✗ 錯誤	來源歸屬引用 (Source Attributions) 是在生成回答後，告訴使用者資訊來自哪裡。它是一種「展示」機制，而不是「篩選」機制。它無法防止系統使用過期的文件來產生答案。
C	✗ 錯誤	Amazon Q Developer 是專門為開發者設計的 AI 助手（用於編寫程式碼、修復錯誤）。雖然它與 Q Business 系出同門，但它並非用於建立面向終端用戶的企業知識庫對話助理。
D	✗ 錯誤	將文件手動放入不同資料夾的運維成本極高。此外，僅允許助手存取上個月的文件會導致「一般性諮詢」無法使用更早的有用文檔（題目要求一般性諮詢使用大量文檔，只有價格需過濾），這不符合靈活運用的需求。

▼ 99

熱門問題

一位機器學習工程師需要自動化重建和重新部署機器學習模型。當模型程式碼庫發生變更時，模型也會隨之更新。此機器學習工程師必須使用 AWS 服務配置持續整合和持續交付 (CI/CD) 管道，以實現重建和重新部署。

請從以下清單中選擇並排序步驟以設定 CI/CD 管道。每個步驟只能選擇一次。
(選擇並排序三個步驟。)

- 呼叫 Amazon SageMaker Pipelines 運行模型訓練和部署所需的所有步驟。
- 在 AWS CodePipeline 中建立管道。在 AWS CodeBuild 中建置和測試容器。
- 建立 Git 原始碼儲存庫。

Step 1:	▼ Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment. Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild. Create a Git source code repository.
Step 2:	▼ Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment. Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild. Create a Git source code repository.
Step 3:	▼ Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment. Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild. Create a Git source code repository.

▼ 答案

正確答案：

Step 1:	▼ Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment. Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild. Create a Git source code repository.
Step 2:	▼ Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment. Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild. Create a Git source code repository.
Step 3:	▼ Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment. Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild. Create a Git source code repository.

- **Step 1：建立 Git 原始碼儲存庫 (Create a Git source code repository).**
 - **解析：**CI/CD 的起點永遠是原始碼。建立一個儲存庫（如 AWS CodeCommit 或 GitHub）來存放模型代碼。當工程師提交代碼變更時，這是觸發後續所有自動化流程的「事件源」。
- **Step 2：在 AWS CodePipeline 中建立管道。在 AWS CodeBuild 中建置和測試容器 (Create a pipeline in AWS CodePipeline. Build and test containers in AWS CodeBuild).**
 - **解析：**這是 CI（持續整合）的核心。**CodePipeline** 負責編排整個流程，而 **CodeBuild** 負責實際的「粗活」——將代碼打包成 Docker 映像檔並執行單元測試，確保新的代碼環境是可用的。
- **Step 3：呼叫 Amazon SageMaker Pipelines 運行模型訓練和部署所需的所有步驟 (Invoke Amazon SageMaker Pipelines to run all steps required for model training and deployment).**
 - **解析：**這是 CD（持續交付/部署）的具體實作。一旦容器構建完成，CodePipeline 會觸發 **SageMaker Pipelines**。這個專門為 ML 設計的工作流會自動執行數據處理、模型訓練、模型註冊，並最終將模型更新到生產端點。

熱門問題

一家航空公司將機器學習模型部署到十二個 Amazon SageMaker AI 推理端點。這些推理端點必須能夠以經濟高效的方式處理不同類型的工作負載。

請從以下清單中選擇正確的推理選項來處理每種類型的工作負載。每個推理選項只能選擇一次。（選擇四個。）

- 非同步推理
- 批量推理
- 即時推理
- 無伺服器推理

Provide flight departure, arrival, and delay information, and provide updates for low-latency workloads.

▼
Asynchronous inference
Batch inference
Real-time inference
Serverless inference

Advertise holiday travel promotional deals to millions of users in multiple markets before holiday seasons for spiky workloads.

▼
Asynchronous inference
Batch inference
Real-time inference
Serverless inference

Generate quarterly and annual flight reports and insights for trend analysis of large datasets.

▼
Asynchronous inference
Batch inference
Real-time inference
Serverless inference

Generate online image and audio stories for passengers to watch or listen to while waiting at an airport.

▼
Asynchronous inference
Batch inference
Real-time inference
Serverless inference

▼ 答案

正確答案：

Provide flight departure, arrival, and delay information, and provide updates for low-latency workloads.

▼

Asynchronous inference

Batch inference

Real-time inference

Serverless inference

Advertise holiday travel promotional deals to millions of users in multiple markets before holiday seasons for spiky workloads.

▼

Asynchronous inference

Batch inference

Real-time inference

Serverless inference

Generate quarterly and annual flight reports and insights for trend analysis of large datasets.

▼

Asynchronous inference

Batch inference

Real-time inference

Serverless inference

Generate online image and audio stories for passengers to watch or listen to while waiting at an airport.

▼

Asynchronous inference

Batch inference

Real-time inference

Serverless inference

1. 提供航班起飛、到達和延誤資訊，並為低延遲工作負載提供更新

- 正確選項：即時推理 (Real-time inference)
- 解析： 航班資訊需要極低延遲的即時更新，以便乘客隨時掌握最新動態。即時推理端點保持開啟狀態，隨時準備處理毫秒級的回應請求。

2. 在節假日前向多個市場的數百萬用戶宣傳假日旅行促銷活動，應對突發流量

- 正確選項：無伺服器推理 (Serverless inference)
- 解析： 促銷活動帶來的流量通常是突發性 (Spiky) 且不可預測的。無伺服器推理能根據需求自動擴縮，且在沒有流量時無需付費，是應對此類間歇性、高波動工作負載最經濟高效的方案。

3. 為大型數據集的趨勢分析生成季度和年度航班報告及洞察

- 正確選項：批量推理 (Batch inference / Batch Transform)

- **解析：** 季度或年度報告屬於**離線、非即時**的大型資料處理任務。批量推理可以一次處理整個資料集，處理完成後即關閉資源，非常適合大規模、週期性的數據分析。

4. 生成在機場候機時供乘客觀看或收聽的在線圖像和音訊故事

- **正確選項：**非同步推理 (Asynchronous inference)
- **解析：** 生成圖像或音訊通常需要較長的時間（可能超過 60 秒）且**資料有效負載（Payload）較大**。非同步推理支持高達 1GB 的請求大小，並會將請求排隊處理，非常適合這種推論時間長且檔案大的多媒體生成任務。